

Frankenstein Transformer: Biblioteca Unificada de Codificador-Decodificador, CLI y Notas de Diseño Basadas en Investigación

Erick F. Merino M.
Este trabajo no está afiliado
erickfmm@gmail.com

Febrero 2026

Resumen

Las arquitecturas de transformers se han convertido en el paradigma dominante para el modelado de secuencias en el procesamiento del lenguaje natural, la visión por computadora y la biología computacional. Los últimos años han sido testigos de una rápida diversificación de los mecanismos de atención y las estrategias de optimización, con innovaciones que abarcan variantes densas de softmax, alternativas recurrentes y retentivas, patrones de atención dispersa, mecanismos lineales con compuerta, proyecciones en espacio latente y bloques con aumento de memoria. Paralelamente, el panorama de optimizadores se ha expandido más allá del AdamW clásico para incluir métodos de reducción de varianza, variantes eficientes en memoria, enfoques sin programación de tasa de aprendizaje, preconditionadores de segundo orden y aproximaciones de bajo rango. A pesar de esta riqueza de avances arquitectónicos y algorítmicos, el ecosistema de investigación permanece fragmentado: comparar mezcladores de secuencia y optimizadores bajo condiciones de entrenamiento consistentes requiere un esfuerzo de ingeniería sustancial, lo que dificulta la reproducibilidad y ralentiza el progreso científico. En este trabajo proponemos Frankenstein Transformer, un conjunto de herramientas CLI basado en configuración (**frankenstein-transformer**) que unifica la definición, el entrenamiento y el despliegue de modelos transformer mediante un esquema YAML estricto. El conjunto de herramientas soporta cuarenta y tres variantes de mezcladores de secuencia en ocho familias (densa, recurrente, dispersa, con compuerta, latente, con aumento de memoria, de peso rápido y de campo geométrico) y veintitrés familias de optimizadores con control de hiperparámetros por grupo de parámetros mediante prefijos. El conjunto de herramientas además soporta una clase de modelo Vision Transformer (**frankenstein_vit**) para tareas de comprensión de imágenes incluyendo predicción autosupervisada de parches enmascarados, clasificación y segmentación, reutilizando la misma infraestructura de mezcladores de atención y optimizadores. Proporciona subcomandos para entrenamiento (**train**, incluyendo objetivos estilo SBERT para incrustaciones de oraciones), despliegue y exportación (**deploy** con formatos cuantizado, estándar, HuggingFace Transformers y GGUF BitNet), inferencia (**infer**) y un constructor de configuración basado en web (**web-server**). El sistema impone la reproducibilidad mediante un contrato de esquema estricto con restricciones **additionalProperties: false**, ofrece una interfaz web basada en Streamlit para la construcción de configuraciones guiada por esquema e incluye tuberías de despliegue de extremo a extremo con cuantización ternaria de pesos y flujos de trabajo de incrustación de oraciones inspirados en SBERT. Las pruebas automatizadas integrales con suites de pruebas unitarias, validación de presets YAML y ejecución de CI en múltiples versiones de Python garantizan la confiabilidad.

Índice

1. Introducción

9

1.1. Motivación y Planteamiento del Problema	9
1.2. Contribuciones	10
1.3. Guía de Lectura	11
1.4. Constructor de Configuración Basado en Web	11
2. Trabajo Relacionado	12
2.1. Frameworks de Aprendizaje Profundo Base	12
2.2. Frameworks de Entrenamiento Listos para Usar	12
2.3. Herramientas de Bajo Código y Eficiencia	13
2.4. Experimentación Basada en Configuración	13
3. Diseño y Arquitectura del Sistema	14
3.1. Arquitectura Centrada en Configuración	14
3.2. Alcance del Esquema y Reglas de Validación	15
3.3. Esquema de Configuración	15
3.4. Tipos de Tarea de Entrenamiento	16
3.5. Configuración del Optimizador	17
3.6. Seguridad de Entrenamiento y Semántica de Ejecución	17
3.7. Variantes de Normalización	17
3.8. Arquitecturas de Flujo Residual	17
4. Taxonomía de Arquitectura e Implementación	18
4.1. Familias de Atención y Mezcladores de Secuencias	18
4.2. Familias Densas y Recurrentes	19
4.3. Familia de Atención Latente y de Rango Bajo	19
4.4. Extensiones de Atención Dispersa	20
4.5. Extensiones de Atención con Compuerta	20
5. Familias de Optimizadores y Dinámicas de Entrenamiento	21
6. Cuantización y Despliegue	21
6.1. Cuantización Ternaria y Escalado de Activaciones	22
7. Tareas Posteriores de SBERT	22
8. Integración Sin Código: El Plugin dashai-frankenstein	23
8.1. Componentes Registrados	24
8.2. Esquema de Configuración de Passthrough	25
8.3. Trabajo en Proceso	25
9. Discusión	26
9.1. Compromisos de Diseño Basado en Esquemas	26
9.2. Cobertura Arquitectónica y Vacíos	26
9.3. Fragmentación del Panorama de Optimizadores	27
9.4. Consideraciones de Despliegue y Producción	27
9.5. Desafíos de Integración y Extensibilidad	27
10. Conclusión	27
10.1. Limitaciones y Direcciones Futuras	28
Bibliografía	29
Anexos	

1. Introducción Conceptual—Transformers y Atención para Principiantes	37
1.1. ¿Qué es un Transformer?	37
1.2. El Mecanismo de Atención: Una Analogía	38
1.3. Ejemplo Práctico Paso a Paso	38
1.3.1. Contexto 1: “El gato come pescado”	38
1.3.2. Contexto 2: “El restaurante come los márgenes de beneficio”	38
1.4. Cómo Funciona la Atención Matemáticamente (Versión Simple)	39
1.4.1. Paso 1: Consultas, Claves y Valores	39
1.4.2. Paso 2: Compatibilidad	39
1.4.3. Paso 3: Enfoque	39
1.4.4. Paso 4: Combinar	39
1.5. Múltiples Cabezas de Atención: Múltiples Perspectivas	39
1.6. Apilar Capas	40
1.7. ¿Por Qué es Importante?	40
1.8. Desafíos Prácticos	40
1.8.1. Complejidad Computacional	40
1.8.2. Requisitos de Memoria	40
1.8.3. Eficiencia del Dispositivo	40
1.9. Soluciones Modernas	41
1.10. Conclusiones Clave	41
2. Estructura del Esquema de Configuración	41
2.1. Estructura de Nivel Superior	41
2.2. Configuración del Modelo	42
2.2.1. Enumeración del Patrón de Capas	46
2.3. Configuración de Entrenamiento	48
2.4. Configuración del Tokenizador	50
2.5. Configuración del Optimizador	51
2.5.1. Sufijos Compartidos por Grupo	52
2.5.2. Sufijos Globales Específicos del Optimizador	52
2.6. Configuración SBERT	52
2.7. Reglas de Validación	53
3. Tablas de Resumen Completas	54
3.1. Resumen de Mezcladores de Secuencia	54
3.2. Resumen de Optimizadores	57
3.3. Variantes de Normalización	58
3.4. Conexiones Residuales	58
3.5. Funciones de Activación	59
3.6. Variantes de Embedding	60
4. Familias de Optimizadores	61
4.1. La Evolución de la Optimización en Redes Neuronales	61
4.2. Línea Base Estándar y Optimizadores Adaptativos	62
4.3. Momentum Avanzado y Reducción de Varianza (2024–2025)	64
4.4. Optimizadores de Lote Grande, Eficientes en Memoria y Sin Tasa de Aprendizaje	68
4.5. Optimizadores de Segundo Orden, Geométricos y de Ortogonalidad	74

5. Transformadores Densos, Recurrentes y Aumentados con Memoria	79
5.1. Atención Densa de Referencia: Estándar y Sigmoide	79
5.1.1. Atención Softmax Estándar	79
5.1.2. Atención Sigmoide	80
5.1.3. Atención por Consultas Agrupadas (GQA)	80
5.2. Arquitecturas Recurrentes y Retentivas	81
5.2.1. Redes Retentivas (RetNet)	81
5.2.2. Mamba: Modelos de Espacio de Estado Selectivos	81
5.3. Transformers de Profundidad Continua: Integración EDO	82
5.3.1. Transformer EDO	82
5.4. Memoria en Tiempo de Prueba: Titans	83
5.5. Despacho de Mezclador Guiado por Patrón	83
6. Familias de Atención Latente y de Rango Bajo	84
6.1. Atención Latente Multi-Cabeza (MLA)	84
6.1.1. Formulación Matemática	84
6.1.2. Pseudocódigo Algorítmico	85
6.1.3. Características Clave	85
6.2. Atención Latente por Consultas Agrupadas (GQLA)	85
6.2.1. Formulación Matemática	85
6.2.2. Pseudocódigo Algorítmico	85
6.2.3. Características Clave	86
6.3. Atención Multi-Cabeza de Rango Bajo (MLRA)	86
6.3.1. Formulación Matemática	86
6.3.2. Pseudocódigo Algorítmico	86
6.3.3. Características Clave	87
6.4. Atención Tucker	87
6.4.1. Formulación Matemática	87
6.4.2. Pseudocódigo Algorítmico	87
6.4.3. Características Clave	87
6.5. Atención de Cabezas Entrelazadas (IHA)	88
6.5.1. Formulación Matemática	88
6.5.2. Pseudocódigo Algorítmico	88
6.5.3. Características Clave	88
6.6. Atención laTenT por Cabezas Agrupadas (GTA)	88
6.6.1. Formulación Matemática	89
6.6.2. Pseudocódigo Algorítmico	89
6.6.3. Características Clave	89
6.7. Atención Latente Temporal Multi-Cabeza (MTLA)	89
6.7.1. Formulación Matemática	89
6.7.2. Pseudocódigo Algorítmico	90
6.7.3. Características Clave	90
6.8. Comparación y Síntesis Arquitectónica	90
6.9. Atención Convolutiva Comprimida (CCA)	90
6.9.1. Formulación Matemática	91
6.9.2. Características Clave	91
6.10. Atención Convolutiva Comprimida por Consultas Agrupadas (CCGQA)	91
6.10.1. Características Clave	91
6.11. Atención de Mezcla Gaussiana (GMA)	92
6.11.1. Formulación Matemática	92
6.11.2. Pseudocódigo Algorítmico	93

6.11.3. Características Clave	93
7. Mecanismos de Atención Dispersa Exhaustivos	93
7.1. Resumen Ejecutivo	93
7.2. Sparse Transformer: Patrones Estrideados y Fijos Factorizados	94
7.2.1. Formulación Matemática	94
7.2.2. Pseudocódigo Algorítmico	94
7.2.3. Características Clave	95
7.3. Longformer: Ventana Deslizante, Dilatación y Tokens Globales	95
7.3.1. Formulación Matemática	95
7.3.2. Pseudocódigo Algorítmico	96
7.3.3. Características Clave	96
7.4. BigBird: Grafo Disperso Aleatorio, Local y Global	96
7.4.1. Formulación Matemática	96
7.4.2. Garantía Teórica	97
7.4.3. Pseudocódigo Algorítmico	97
7.4.4. Características Clave	97
7.5. Atención SparseK: Selección Diferencial Top- k	98
7.5.1. Formulación Matemática	98
7.5.2. Pseudocódigo Algorítmico	98
7.5.3. Características Clave	98
7.6. NSA (Native Sparse Attention): Ramas Jerárquicas Alineadas con el Hardware	99
7.6.1. Formulación Matemática	99
7.6.2. Pseudocódigo Algorítmico	100
7.6.3. Características Clave	100
7.7. FASA: Atención Dispersa Consciente de la Frecuencia	100
7.7.1. Formulación Matemática	100
7.7.2. Pseudocódigo Algorítmico	101
7.7.3. Características Clave	101
7.8. SpargeAttn: Filtrado de Dos Etapas a Nivel de Bloques	102
7.8.1. Formulación Matemática	102
7.8.2. Pseudocódigo Algorítmico	103
7.8.3. Características Clave	103
7.9. MSA (MiniMax Sparse Attention): Atención Dispersa por Bloques con Rama de Índice Ligera	103
7.9.1. Formulación Matemática	103
7.9.2. Pseudocódigo Algorítmico	104
7.9.3. Características Clave	105
7.10. SparDA (Atención Dispersa Desacoplada): Selección de Bloques Anticipada Guiada por Pronóstico	105
7.10.1. Formulación Matemática	105
7.10.2. Pseudocódigo Algorítmico	106
7.10.3. Características Clave	106
7.11. Espacio de Diseño y Criterios de Selección	106
8. Familias de Atención con Compuerta—Análisis Exhaustivo de Literatura	107
8.1. Resumen Ejecutivo: Compuertas para el Control de Memoria	107
8.2. 1. Atención Lineal con Compuerta (GLA)	107
8.2.1. Fundamento Matemático	107
8.2.2. Entrenamiento Eficiente en Hardware	108
8.2.3. Fortalezas y Limitaciones	109
8.3. 2. DeltaNet: Atención Lineal con Corrección de Errores	109

8.3.1.	Fundamento Matemático	109
8.3.2.	Entrenamiento Paralelo Eficiente	109
8.3.3.	Fortalezas y Limitaciones	110
8.4.	3. Gated DeltaNet: Síntesis de Compuerta y Corrección de Errores	110
8.4.1.	Fundamento Matemático	110
8.4.2.	Rendimiento Empírico y Compensaciones	111
8.5.	4. HGRN2: Compuerta Jerárquica con Expansión de Producto Externo	112
8.5.1.	Fundamento Matemático	112
8.5.2.	Escalado y Resultados Empíricos	112
8.6.	5. Forgetting Transformer (FoX): Compuerta en el Espacio de Logits Softmax	112
8.6.1.	Fundamento Matemático	112
8.6.2.	Integración con FlashAttention	113
8.6.3.	Fortalezas y Limitaciones	114
8.7.	6. Atención con Compuerta (Post-SDPA Sigmoide)	114
8.7.1.	Fundamento Matemático	114
8.7.2.	Hallazgos Clave	115
8.8.	7. Gated DeltaNet-2: Borrado y Escritura Canalizados Decouplados	115
8.8.1.	Fundamento Matemático	115
8.8.2.	Rendimiento Empírico y Compromisos	116
8.9.	8. Kimi Delta Attention (KDA): Compuerta de Decaimiento Canalizada para la Regla Delta	116
8.9.1.	Fundamento Matemático	116
8.9.2.	Rendimiento Empírico y Compromisos	117
8.10.	Principio Unificado de Compuerta	118
8.11.	Implementación y Orientación Práctica	118
8.11.1.	Cuándo Usar Cada Arquitectura	118
8.11.2.	Consideraciones de Hardware	119
9.	Normalización, Cuantización, Enrutamiento de Profundidad y Algoritmos de Ejecución	119
9.1.	Variantes de Normalización: LayerNorm, RMSNorm, pRMSNorm, Tanh Dinámico, Erf Dinámico y FlashNorm	119
9.1.1.	LayerNorm (Línea Base)	120
9.1.2.	RMSNorm	120
9.1.3.	RMSNorm Parcial (pRMSNorm)	120
9.1.4.	Tanh Dinámico (DyT)	120
9.1.5.	Erf Dinámico (Derf)	120
9.1.6.	FlashNorm (RMSNorm sin pesos)	121
9.1.7.	Comparación	122
9.2.	Ruta de Cuantización Ternaria BitNet	123
9.3.	Enrutamiento de Tokens Mixture-of-Depths (MoD)	123
9.3.1.	Configuración	123
9.4.	Memoria Condicional Engram	124
9.4.1.	Configuración	124
9.5.	Embeddings Factorizados y Convolución de Embedding	124
9.5.1.	Embeddings Factorizados	124
9.5.2.	Convolución de Embedding	124
9.6.	Controles de Estabilidad del Paso de Entrenamiento	124
9.7.	Enrutador de Modo de Inferencia SBERT	125

10. Funciones de Activación	126
10.1. Familia Clásica / Sigmoid–Tanh (12 activaciones)	126
10.2. Familia Rectificada (12 activaciones)	127
10.3. Familia Exponencial / ELU (12 activaciones)	128
10.4. Swish y Activaciones Paramétricas	129
10.5. Funciones de Activación Racionales (RAF)	130
10.6. Variantes de FFN con Compuerta: SwiGLU, GEGLU, ReGLU	131
10.7. Esquema de Configuración	131
10.8. Guía de Selección	132
11. Hyper-Connexiones Restringidas por Variedad (mHC)	132
11.1. Motivación: la Propiedad de Mapeo de Identidad	132
11.2. Formulación	133
11.3. Propiedades de la Restricción de Variedad	133
11.4. Implementación en Frankenstein Transformer	134
11.5. Resultados Reportados	135
11.6. Hyperloop: Hiperconexiones a Nivel de Bucle en Transformers en Bucle	135
12. Residuales de Atención (AttnRes)	136
12.1. Motivación: De una Suma Fija a Atención sobre la Profundidad	137
12.2. Cuatro Estrategias	137
12.2.1. Residual Estándar ("standard")	137
12.2.2. Sin Residual ("none", experimental)	137
12.2.3. Residuales de Atención Completa ("full_attn", paper § 3.1)	138
12.2.4. Residuales de Atención por Bloques ("block_attn", paper § 3.2)	138
12.3. Implementación en Frankenstein Transformer	138
12.4. Integración con mHC y Mixture-of-Depths	139
12.5. Resultados Reportados	140
13. Vision Transformer: Predicción de Parches, Clasificación y Segmentación	140
13.1. Embedding de Parches y Codificación Posicional	140
13.2. Predicción de Parches Enmascarados (Autosupervisado)	141
13.3. Clasificación de Imágenes	141
13.4. Segmentación de Imágenes	141
13.4.1. Cabeza Por-Pixel (pixel)	141
13.4.2. Encoder-only Mask Transformer (eomt)	141
13.5. Reutilización de la Infraestructura Existente	142
13.6. Pseudocódigo en PyTorch	142
14. Codificaciones Posicionales de Todo el Modelo	142
14.1. Arquitectura: Un Módulo Compartido, Exclusión Por Mezclador	142
14.2. Estilos de Inyección	143
14.3. Formulaciones Matemáticas	143
14.3.1. RoPE — Codificación Posicional Rotatoria	143
14.3.2. HoPE — Codificación Posicional Rotatoria Hiperbólica	143
14.3.3. NoPE — Sin Codificación Posicional	144
14.3.4. ALiBi — Atención con Sesgos Lineales	144
14.3.5. BAM — Mecanismo de Atención Bayesiana	144
14.3.6. PaPE — Codificación Posicional Parabólica	144
14.3.7. Sinusoidal Absoluta	145
14.3.8. Sinusoidal Rotatoria	145
14.3.9. Absoluta Aprendida	145

14.4. Banderas <code>use_pe</code> Por Mezclador	145
14.5. Unificación del Transformer de Visión	146
14.6. Compatibilidad con Legado	146
14.7. Perfil Arquitectónico: Codificaciones Posicionales	146
15.SSOG: Atención Separable Sum of Gaussians	147
15.1. Formulación Matemática	147
15.2. Pseudocódigo Algorítmico	148
15.3. Características Clave	148
16.Atención de Peso Rápido para Aprendizaje Continuo	148
16.1. Preliminares: Alineación, Normalización, Renormalización	149
16.2. La Familia de Regresión (Falcon-1/2/3)	149
16.2.1. Falcon-1: Regresión NLMS Escalar	149
16.2.2. Falcon-2: Regresión NLMS por Columnas	150
16.2.3. Falcon-3: Regresión de Minilote con Ventana Deslizante	150
16.3. La Familia de Producto Interno (Falcon-1A/2A/3A)	150
16.3.1. Falcon-1A y Falcon-2A	150
16.3.2. Falcon-3A: Producto Interno con Ventana Deslizante	151
16.4. Interfaz de Configuración	151
16.5. Resultados Publicados	152
16.6. Relación con Trabajos Previos	152
16.6.1. Cuándo Usar Cada Variante	152

1. Introducción

1.1. Motivación y Planteamiento del Problema

Las arquitecturas de transformers han transformado fundamentalmente el panorama del modelado de secuencias en el procesamiento del lenguaje natural [92], la visión por computadora y la biología computacional. El éxito de modelos como BERT [21], GPT y sus variantes ha establecido al transformer como el estándar de facto para el aprendizaje de representaciones en el aprendizaje profundo. Sin embargo, la rápida proliferación de innovaciones arquitectónicas presenta desafíos prácticos significativos para investigadores y profesionales.

Los últimos años han sido testigos de una explosión de mecanismos alternativos de atención y mezcla de secuencias, cada uno abordando limitaciones específicas de la atención softmax estándar: complejidad computacional cuadrática [16], requisitos de inferencia eficiente en memoria [88, 33], gestión selectiva de estados basada en contenido [7] y optimizaciones conscientes del hardware [77]. Simultáneamente, la literatura sobre optimización se ha diversificado más allá del AdamW clásico, introduciendo técnicas de reducción de varianza [97, 68, 104], variantes eficientes en memoria [82, 111], enfoques sin programación de tasa de aprendizaje [19] y métodos de preconditionamiento de segundo orden [35, 93].

La consecuencia práctica es un ecosistema de investigación fragmentado donde la comparación experimental entre arquitecturas y optimizadores requiere un esfuerzo de ingeniería significativo. Los investigadores deben implementar y depurar múltiples variantes desde cero, garantizar tuberías de entrenamiento consistentes y gestionar espacios de hiperparámetros complejos. Esta fragmentación dificulta la reproducibilidad, ralentiza el progreso científico y aumenta la barrera de entrada para nuevos investigadores.

Este trabajo aborda estos desafíos mediante un conjunto de herramientas de experimentación unificado y basado en configuración, disponible en <https://github.com/erickfmm/frankenstein-transformer> que proporciona:

1. **Diseño Basado en Esquemas:** Un contrato de configuración estricto y validado que garantiza la reproducibilidad mientras admite cuarenta y tres variantes de mezcladores de secuencia en ocho familias y veintitrés familias de optimizadores.
2. **Entrenamiento Agnóstico a la Arquitectura:** Infraestructura de entrenamiento común que soporta líneas base de atención densa (estándar, sigmoide), alternativas recurrentes (RetNet, Mamba, bloques tipo EDO), enrutamiento adaptativo de profundidad (Mixture-of-Depths) [114], bloques de memoria condicional (Engram) [15], conexiones residuales restringidas por variedad (mHC) [98], patrones de atención dispersa (Sparse Transformer, Longformer, BigBird, SparseK, NSA, SpargeAttn, FASA) y mecanismos con compuerta (GLA, DeltaNet, Gated DeltaNet, Gated DeltaNet-2, HGRN2, FoX, Gated Softmax).
3. **Marco de Enrutamiento de Optimizadores:** Grupos de hiperparámetros con prefijos que permiten un control detallado sobre incrustaciones, capas de normalización, bloques recurrentes, bloques de atención y otros subconjuntos de parámetros a través de diversos optimizadores, incluyendo la familia APOLLO (Apollo, Apollo-Mini, Q-Apollo) [112].
4. **Flujos de Trabajo de Extremo a Extremo:** Despliegue integrado mediante cuantización (empaquetado ternario de pesos, activaciones INT8) y capacidades de incrustación de oraciones inspiradas en SBERT [78].
5. **Configuración Interactiva:** Interfaz basada en web que proporciona renderizado de formularios impulsado por esquemas, validación en tiempo real y generación de comandos CLI.
6. **Herramientas de Confiabilidad:** Pruebas automatizadas integrales con suites de pruebas unitarias, validación de presets YAML y automatización de CI en versiones de Python compatibles.

La superficie de comandos del proyecto es:

frankenstein-transformer

con subcomandos para flujos de trabajo de codificador y decodificador: **train** (incluyendo objetivos estilo SBERT para incrustaciones de oraciones vía **training.task: sbert**), **deploy** (artefactos cuantizado/estándar más formatos de exportación HuggingFace Transformers y GGUF BitNet), **infer** y **web-server**.

El comando **web-server** lanza un constructor de configuración basado en Streamlit que proporciona:

- Campos de formulario impulsados por esquemas con títulos de parámetros y descripciones detalladas
- Información sobre herramientas en tiempo real y texto de ayuda para cada opción de configuración
- Vista previa YAML en vivo y funcionalidad de descarga
- Comandos CLI generados para entrenamiento, despliegue, inferencia y flujos de trabajo SBERT

Esta interfaz interactiva sirve como alternativa a la edición manual de YAML, mejorando la usabilidad para usuarios que exploran las opciones de configuración disponibles y comprenden su impacto en el comportamiento del modelo y la dinámica de entrenamiento.

1.2. Contribuciones

Este trabajo realiza las siguientes contribuciones principales:

1. **Esquema de Configuración Unificado:** Un contrato de esquema basado en YAML con validación estricta que soporta cuarenta y tres variantes de mezcladores de secuencia en ocho familias (densa, recurrente, dispersa, con compuerta, latente, con aumento de memoria, de peso rápido y de campo geométrico), junto con controles de profundidad adaptativa y memoria condicional, mientras garantiza la reproducibilidad mediante restricciones **additionalProperties: false**.
2. **Soporte Integral de Arquitecturas:** Implementación de variantes modernas de transformers incluyendo atención softmax estándar [92], atención sigmoide [77], RetNet [88], Mamba [33], transformers continuos tipo EDO [108], atención con aumento de memoria Titans [7], capas de memoria condicional Engram [15], enrutamiento de tokens Mixture-of-Depths [114], mecanismos de atención dispersa [16, 8, 105, 59, 103, 109, 95] y arquitecturas de atención con compuerta [99, 100, 101, 36, 74, 54, 75]. El sistema soporta tanto entrenamiento en modo codificador con atención bidireccional para modelado de lenguaje enmascarado (MLM) como entrenamiento en modo decodificador con enmascaramiento causal para predicción autorregresiva del siguiente token.
3. **Marco de Enrutamiento de Optimizadores:** Sistema de hiperparámetros con prefijos que permite control por grupo de parámetros a través de veintitrés optimizadores, incluyendo Anon con adaptabilidad ajustable [3], métodos de reducción de varianza (MARS, Adan, AdE-MAMix, Cautious AdamW), variantes eficientes en memoria (Adafactor, GaLore, Lion), enfoques sin programación de tasa de aprendizaje (Schedule-Free AdamW), métodos conscientes de curvatura (Sophia), preconditionadores de segundo orden (Shampoo, SOAP), optimizadores orientados a ortogonalidad (Muon, Turbo-Muon), escalado de lotes grandes (LAMB) y la familia APOLLO (Apollo, Apollo-Mini, Q-Apollo) [112].

4. **Cuantización y Despliegue:** Tubería de despliegue integrada que soporta empaquetado ternario de pesos y cuantización de activaciones INT8 con estimaciones de tamaño siguiendo la aproximación de almacenamiento de 1,58 bits.
5. **Flujos de Trabajo de Incrustación de Oraciones:** Tuberías de entrenamiento e inferencia inspiradas en SBERT que soportan puntuación de similitud, recuperación, agrupamiento y exportación persistente de incrustaciones.
6. **Interfaz de Configuración Interactiva:** Servidor web basado en Streamlit que proporciona generación de formularios impulsada por esquemas, validación en tiempo real, documentación en línea y generación de comandos CLI.
7. **Tubería de Validación Automatizada:** Integración continua y pruebas unitarias ampliadas que verifican las rutas de entrenamiento del modelo, la integración optimizador/esquema y la compatibilidad de ejemplos YAML.

1.3. Guía de Lectura

Este documento está organizado como una referencia técnica que aborda cuatro preocupaciones operativas:

1. **Requisitos Previos:** El Apéndice 1 proporciona una introducción accesible a los transformers y mecanismos de atención para lectores nuevos en el campo.
2. **Contrato de Configuración:** La Sección 3.1 describe el esquema YAML que garantiza experimentos válidos y la Sección 3.2 explica las reglas de validación.
3. **Selección de Arquitectura:** La Sección 4.1 proporciona una comparación exhaustiva de las familias de mezcladores de secuencia; los Apéndices 5, 6, 7 y 8 sintetizan la literatura de respaldo; el Apéndice 9 detalla las variantes de normalización, la cuantización BitNet, el enrutamiento Mixture-of-Depths y la memoria condicional Engram; el Apéndice 11 detalla las conexiones residuales restringidas por variedad (mHC).
4. **Dinámica de Optimización:** La Sección 5 detalla el enrutamiento de optimizadores y la dinámica de entrenamiento; el Apéndice 4 proporciona un análisis exhaustivo de las familias de optimizadores.
5. **Despliegue e Inferencia:** Las Secciones 6 y 7 describen el despliegue cuantizado y los flujos de trabajo de incrustación de oraciones.

1.4. Constructor de Configuración Basado en Web

Además de la edición directa de YAML, este proyecto proporciona una interfaz web basada en Streamlit (accesible mediante el comando `web-server`) que mejora la accesibilidad y descubribilidad de la configuración. La interfaz genera dinámicamente formularios guiados por el esquema con documentación de parámetros en línea, vista previa YAML en tiempo real y generación automática de comandos CLI para entrenamiento, despliegue, inferencia y flujos de trabajo SBERT. Los metadatos del esquema (títulos y descripciones) se renderizan sistemáticamente en todas las secciones de configuración, incluyendo arquitectura del modelo, ejecución de entrenamiento, hiperparámetros del optimizador, despliegue y parámetros específicos de SBERT. Este enfoque reduce la necesidad de memorizar la estructura YAML, previene errores tipográficos mediante la validación del esquema y sirve tanto como herramienta de configuración como recurso de aprendizaje para usuarios que exploran arquitecturas novedosas.

2. Trabajo Relacionado

Este trabajo se sitúa en la intersección de frameworks de aprendizaje profundo, herramientas de entrenamiento y experimentación basada en configuración. Mientras que las Secciones 4.1 y 5 examinan en profundidad la literatura arquitectónica y de optimización, esta sección se centra en el ecosistema de software para construir, entrenar y configurar modelos transformer.

2.1. Frameworks de Aprendizaje Profundo Base

El ecosistema moderno de investigación en transformers se apoya en varios frameworks fundamentales que proporcionan diferenciación automática, aceleración GPU y APIs de alto nivel para construcción de modelos.

PyTorch [69] se ha convertido en el framework dominante para la investigación en transformers. Su modelo de programación imperativa y grafos de cómputo dinámicos permiten depuración flexible y prototipado rápido de arquitecturas novedosas. La abstracción `torch.nn.Module`, el entrenamiento automático con precisión mixta mediante `torch.cuda.amp` y el compilador JIT `torch.compile` forman la columna vertebral de la mayoría de las implementaciones contemporáneas de transformers. Frankenstein Transformer está construido completamente sobre PyTorch, aprovechando su sistema de módulos para definiciones de arquitectura componibles.

TensorFlow [1] fue pionero en aprendizaje profundo orientado a producción con su paradigma de grafo de cómputo estático y la API de alto nivel Keras. Aunque su influencia en la investigación de transformers ha disminuido en relación con PyTorch, la infraestructura de serving de TensorFlow (TF Serving, TF Lite) y la biblioteca `tensorflow-text` siguen siendo relevantes para escenarios de despliegue.

JAX [11] ofrece un modelo de programación funcional construido alrededor de transformaciones componibles (`jit`, `vmap`, `grad`) y compilación XLA. Su diseño permite implementaciones limpias de algoritmos complejos y ha sido adoptado por varias bibliotecas recientes de transformers (por ejemplo, Flax, Haiku). El diseño sin estado de JAX y su vectorización automática son particularmente adecuados para la investigación en mecanismos de atención novedosos y algoritmos de optimización.

scikit-learn [70] proporciona algoritmos clásicos de aprendizaje automático y utilidades (preprocesamiento, métricas, selección de modelos) que sirven como líneas base y herramientas complementarias en flujos de trabajo con transformers. Aunque no está diseñado para aprendizaje profundo, su API consistente y documentación extensa lo convierten en un punto de referencia estándar para comparar enfoques basados en transformers con métodos tradicionales.

2.2. Frameworks de Entrenamiento Listos para Usar

Varias bibliotecas proporcionan pipelines de entrenamiento completos que abstraen la complejidad del entrenamiento distribuido, la carga de datos y la gestión de hiperparámetros.

Hugging Face Transformers [96] es el estándar de facto para acceder, ajustar y compartir modelos transformer preentrenados. Su API `Trainer`, el hub de modelos con más de 500,000 modelos y su estrecha integración con las bibliotecas `datasets` y `tokenizers` lo han convertido en el punto de entrada principal para NLP basado en transformers. Sin embargo, su arquitectura está optimizada para el ajuste fino de modelos preentrenados existentes en lugar de experimentar con diseños novedosos de mezcladores de secuencia o entrenar desde cero con estrategias de optimización personalizadas.

Oumi (<https://github.com/oumi-ai/oumi>, 2025) es una plataforma de código abierto de extremo a extremo para entrenar, ajustar, evaluar y desplegar modelos fundacionales. Proporciona una interfaz unificada a través de múltiples proveedores de nube y soporta tanto ajuste fino supervisado como optimización de preferencias (DPO, RLHF). Oumi enfatiza la preparación para producción con monitoreo integrado, checkpointing y herramientas de despliegue.

LLaMA Factory (<https://github.com/hiyouga/LLaMA-Factory>, 2024) ofrece un framework unificado para el ajuste fino eficiente de más de 100 modelos de lenguaje grandes. Proporciona tanto una interfaz web como una CLI, soportando LoRA, QLoRA, ajuste fino de parámetros completos y diversas técnicas de alineación. Su enfoque está en adaptar LLMs preentrenados existentes a tareas posteriores en lugar de experimentación arquitectónica.

Axolotl (<https://github.com/axolotl-ai-cloud/axolotl>, 2024) es una herramienta simplificada de ajuste fino que soporta LoRA, QLoRA, DeepSpeed y FSDP. Enfatiza flujos de trabajo basados en configuración mediante archivos YAML y se ha vuelto popular en la comunidad de ajuste fino de LLMs de código abierto. Al igual que LLaMA Factory, se enfoca en el ajuste fino de modelos preentrenados en lugar de entrenar arquitecturas novedosas desde cero.

2.3. Herramientas de Bajo Código y Eficiencia

Una categoría creciente de herramientas prioriza la accesibilidad y la eficiencia computacional, reduciendo la barrera para el entrenamiento de transformers.

Unsloth (<https://github.com/unslothai/unsloth>, 2024) proporciona ajuste fino de bajo código con aceleración de 2–5× y requisitos de VRAM significativamente reducidos mediante kernels CUDA escritos a mano y operaciones Triton optimizadas. Soporta exportación GGUF para despliegue cuantizado y se integra con el ecosistema Hugging Face. El enfoque de Unsloth está en hacer el ajuste fino más rápido y eficiente en memoria, no en exploración arquitectónica.

dashAI (<https://github.com/DashAISoftware/dashAI>, v0.9.7.post2, 2026) es una aplicación de escritorio open-source y local-first para aprendizaje automático desarrollada por un consorcio académico chileno (Universidad de Chile/FCFM, CENIA, IMFD y financiamiento ANID). Su interfaz es completamente basada en esquemas: los formularios de configuración se generan directamente desde esquemas Pydantic de los componentes sin código frontend escrito a mano, y su catálogo abarca unos 76 modelos multitask—clasificadores tabulares, modelos de NLP, traducción, LLMs de pesos abiertos y generación de texto a imagen—unificados tras una docena de abstracciones base tipadas. La extensibilidad es central en su diseño: los plugins son paquetes PyPI ordinarios descubiertos mediante el grupo de entry-points `dashai.plugins` e instalables desde la UI, un mecanismo lo bastante central que incluso las capacidades generativas propias de dashAI (p. ej., Stable Diffusion, Flux) se distribuyen como plugins. Mientras que releases anteriores se enfocaban en ML clásico, la plataforma actual abarca modelado predictivo y generativo en múltiples dominios, lo que la convierte en un anfitrión natural para componentes transformer vía su sistema de plugins; la Sección 8 presenta el adaptador `dashai-frankenstein` construido sobre este mecanismo.

2.4. Experimentación Basada en Configuración

Un hilo común entre las herramientas examinadas anteriormente es su enfoque en el ajuste fino de modelos preentrenados existentes. Hugging Face Transformers, LLaMA Factory, Axolotl y Unsloth asumen un checkpoint preentrenado como punto de partida. Oumi soporta entrenamiento desde cero pero se enfoca en arquitecturas estándar. Ninguna de estas herramientas proporciona un marco sistemático para experimentar con arquitecturas novedosas de mezcladores de secuencia, comparar diversos algoritmos de optimización bajo condiciones controladas o explorar la interacción entre elecciones arquitectónicas y dinámicas de entrenamiento.

Frankenstein Transformer llena este vacío proporcionando un sistema de configuración basado en esquemas diseñado específicamente para la experimentación arquitectónica. Sus diferenciadores clave incluyen:

- **Más de 36 mezcladores de secuencia** que abarcan atención densa, bloques recurrentes/retentivos, patrones de atención dispersa, mecanismos con compuerta, enrutamiento adaptativo por profundidad y capas de memoria condicional, todos seleccionables mediante un único campo YAML.

- **23 familias de optimizadores** con un sistema de enrutamiento de hiperparámetros con prefijos que permite control por grupo de parámetros a través de embeddings, capas de normalización, bloques de atención y redes feed-forward.
- **Modos de entrenamiento duales** que soportan tanto modelado de lenguaje enmascarado (MLM) estilo encoder como predicción del siguiente token autorregresiva (AR) estilo decoder, con flujos de trabajo de ajuste fino especializados para cada uno.
- **Validación estricta de esquemas** mediante restricciones `additionalProperties: false` que previenen errores de configuración antes de que comience el entrenamiento, asegurando reproducibilidad entre experimentos.
- **Flujos de trabajo de extremo a extremo** que abarcan despliegue cuantizado (empaquetado de pesos ternarios, activaciones INT8) y entrenamiento de sentence embeddings inspirado en SBERT [78].
- **Interfaz de configuración web** que proporciona renderizado de formularios basado en esquemas con documentación en línea, validación en tiempo real y generación de comandos CLI.

Al desacoplar la definición de arquitectura de la infraestructura de entrenamiento mediante un contrato de configuración validado, Frankenstein Transformer permite la comparación sistemática de familias de mezcladores de secuencia y estrategias de optimización bajo condiciones de entrenamiento idénticas—una capacidad no proporcionada por ninguna herramienta existente en el ecosistema.

3. Diseño y Arquitectura del Sistema

3.1. Arquitectura Centrada en Configuración

La decisión de diseño principal en este repositorio es que la experimentación es *esquema primero*. En lugar de exponer una gran cantidad de indicadores laxamente verificados, el proyecto obliga a la topología del modelo, la familia de optimizadores, los límites de entrenamiento y las opciones de telemetría a través de un único documento de configuración validado. Esto reduce la ambigüedad al reproducir resultados y permite comparar muchas arquitecturas bajo una interfaz operativa consistente.

El contrato autoritativo es `configs/schema.yaml`. Este impone tres objetos de primer nivel:

- `model_class`
- `model`
- `training`

Selección de Clase de Modelo. El campo `model_class` determina la variante arquitectónica instanciada por el pipeline de entrenamiento. Se soportan dos opciones:

- **frankenstein:** Modelos encoder de arquitectura mixta que soportan diversos mecanismos de atención (estándar, sigmoide, retentiva, espacio de estados, dispersa y mezcladores con compuerta) con MoE (Mezcla de Expertos) y características avanzadas. Optimizado para entrenamiento bidireccional tipo encoder con objetivos de modelado de lenguaje enmascarado (MLM).
- **frankensteindecoder:** Decoder causal autorregresivo para generación de siguiente token estilo LLM. Permite el enmascaramiento de atención causal para tareas de generación secuencial de texto. Cuando se selecciona esta clase, en tiempo de ejecución se fuerza `mode='decoder'`.

Selección de Modo de Entrenamiento. El campo `model.mode` controla el comportamiento de enmascaramiento de atención en todo el modelo:

- **encoder:** Utiliza atención bidireccional donde todos los tokens atienden a todos los demás tokens en la secuencia. Adecuado para tareas de preentrenamiento de modelado de lenguaje enmascarado (MLM) donde el modelo aprende a predecir tokens enmascarados aleatoriamente basándose en el contexto completo.
- **decoder:** Utiliza enmascaramiento causal donde cada token solo puede atender a tokens anteriores en la secuencia. Requerido para tareas autorregresivas (AR) de predicción del siguiente token, como modelado de lenguaje y generación de texto. Cuando `model_class='frankensteindecoder'`, el sistema fuerza automáticamente `mode='decoder'` en tiempo de ejecución.

Este soporte de arquitectura dual permite al sistema manejar tanto preentrenamiento tipo encoder (MLM en contextos bidireccionales) como generación tipo decoder (predicción causal autorregresiva) a través de una interfaz de configuración unificada.

Selección de Patrones de Mezcladores de Secuencia: El campo `layer_pattern` acepta una lista ordenada de identificadores de mezcladores que abarcan ocho familias: líneas base densas (`standard_attn`, `sigmoid_attn`, `gqa`), recurrentes/retentivas (`retnet`, `retnet_attn`, `mamba`, `ode`, `titan_attn`), atención dispersa (`sparse_transformer_attn`, `longformer_attn`, `bigbird_attn`, `sparsek_attn`, `nsa_attn`, `sparge_attn`, `fasa_attn`, `msa_attn`, `sparda_attn`), mecanismos con compuerta (`gla_attn`, `deltanet_attn`, `gated_deltanet_attn`, `gated_deltanet2_attn`, `hgrn2_attn`, `fox_attn`, `gated_softmax_attn`, `kda_attn`), compresión latente (`mla_attn`, `gqla_attn`, `mlra_attn`, `tucker_attn`, `iha_attn`, `gta_attn`, `mtla_attn`, `cca_attn`, `csgqa_attn`, `gma_attn`) memoria condicional (`engram_attn`) atención de peso rápido (`falcon1_attn`, `falcon2_attn`, `falcon3_attn`, `falcon1a_attn`, `falcon2a_attn`, `falcon3a_attn`) y campo geométrico (`ssog_attn`). La taxonomía completa con referencias se proporciona en la Sección 4 y el Apéndice 3.

El `training.optimizer.optimizer_class` soporta una amplia familia de optimizadores: `sgd_momentum`, `adamw`, `adafactor`, `galore_adamw`, `prodigy`, `lion`, `sophia`, `muon`, `turbo_muon`, `radam`, `adan`, `adopt`, `ademamix`, `mars_adamw`, `cautious_adamw`, `lamb`, `schedulefree_adamw`, `shampoo`, `soap`, `anon`, `apollo`, `apollo_mini`, y `q_apollo`.

3.2. Alcance del Esquema y Reglas de Validación

El esquema es estricto: los objetos de primer nivel y anidados establecen `additionalProperties: false`. Esto garantiza que las claves desconocidas fallen rápidamente en lugar de ser ignoradas silenciosamente. El objeto `training.optimizer.parameters` está adicionalmente restringido por reglas de prefijo específicas del optimizador mediante verificaciones de patrón `allOf+if/then`.

Los valores de normalización actualmente aceptados por el esquema son:

$$\text{norm_type} \in \{\text{layer_norm}, \text{dynamic_tanh}, \text{derf}, \text{rms_norm}, \text{prms_norm}\}$$

3.3. Esquema de Configuración

El esquema completo de configuración del modelo y entrenamiento, incluyendo todos los campos, tipos, rangos y reglas de validación, se documenta en el Apéndice 2. El esquema impone `additionalProperties: false` en todos los niveles, garantizando que las claves desconocidas fallen rápidamente.

La profundidad en bucle inducida por el esquema es:

$$L_{\text{logical}} = \text{num_layers} \times \text{num_loops}$$

que es la definición a nivel de configuración de los bloques en bucle.




Figura 1: Arquitectura del sistema: la configuración fluye a través de la validación, se divide en modelo/entrenamiento/optimizador, ejecuta en tiempo real y produce artefactos de despliegue/SBERT/exportación.

3.4. Tipos de Tarea de Entrenamiento

El campo `training.task` determina el objetivo de entrenamiento, trabajando en conjunto con `model.mode` para definir cómo aprende el modelo:

Modelado de Lenguaje Enmascarado (MLM).

- **Modo:** Requiere `mode='encoder'` para atención bidireccional.
- **Objetivo:** Enmascarar aleatoriamente tokens en la secuencia de entrada (típicamente 15 %) y entrenar al modelo para predecir los tokens enmascarados basándose en el contexto bidireccional completo.
- **Caso de Uso:** Preentrenamiento de encoders para aprendizaje de representaciones, siguiendo la metodología BERT [21]. El modelo aprende representaciones bidireccionales que capturan contexto tanto de izquierda como de derecha.
- **Configuración:** Utiliza el parámetro `mlm_probability` para controlar la fracción de enmascaramiento.

Modelado de Lenguaje Causal (`causal_lm`).

- **Modo:** Requiere `mode='decoder'` para enmascaramiento causal.
- **Objetivo:** Predicción autorregresiva del siguiente token — cada posición i predice el token $i + 1$ dados solo los tokens precedentes. La cross-entropy se calcula sobre todas las posiciones desplazadas sin enmascarar (no hay enmascaramiento), a diferencia del MLM que supervisa solo posiciones enmascaradas aleatoriamente.
- **Caso de Uso:** Generación de lenguaje y tareas estilo LLM siguiendo la metodología GPT. El modelo aprende dependencias secuenciales con atención causal donde cada token solo puede atender a tokens precedentes.

- **Clase de Modelo:** Establecer `task='causal_lm'` y `model_class='frankensteindecoder'`; el esquema y el runtime requieren la clase `decoder` para esta tarea (el enmascaramiento causal solo lo proporciona el `decoder`).
- **Configuración:** Reutiliza `training.optimizer`; el dataset de streaming almacena las secuencias sin enmascarar (`labels == input_ids`) para que el trainer pueda calcular la pérdida de siguiente token desplazada.

Este soporte de tareas permite la experimentación unificada tanto en preentrenamiento tipo `encoder` (MLM para comprensión bidireccional), generación tipo `decoder` (`causal_lm` para predicción autorregresiva del siguiente token) como en `embedding` de oraciones (SBERT), dentro del mismo código base.

3.5. Configuración del Optimizador

El objeto `training.optimizer` selecciona entre 23 familias de optimizadores mediante `optimizer_class` y proporciona control de hiperparámetros por grupo de parámetros a través de una convención de nombres con prefijos. El contrato completo de prefijos del optimizador y las familias soportadas se documentan en el Apéndice 2.

3.6. Seguridad de Entrenamiento y Semántica de Ejecución

Las características de seguridad a nivel de esquema incluyen acumulación, recorte, verificación de explosión post-recorte y reintentos por NaN:

$$g_{\text{acc}} = \frac{1}{K} \sum_{i=1}^K g_i, \quad K = \text{gradient_accumulation_steps}$$

$$g_{\text{clip}} = g_{\text{acc}} \cdot \min\left(1, \frac{\tau}{\|g_{\text{acc}}\|_2 + \epsilon}\right), \quad \tau = \text{grad_clip_max_norm}$$

luego los guardas de desbordamiento usan `inf_post_clip_threshold` y lógica de reintentos limitada por `max_nan_retries`.

El pseudocódigo completo del paso de entrenamiento guiado por esquema—incluyendo acumulación de gradientes, recorte de norma global, guardas de explosión post-recorte, reintentos acotados de NaN/Inf, despacho del scheduler y rotación de checkpoints rodantes/mejores—se difiere al Apéndice 9.

3.7. Variantes de Normalización

La normalización controla la escala de activación a través de la profundidad y es también una cuestión de compatibilidad con el esquema, ya que los valores aceptados de `norm_type` son `layer_norm`, `dynamic_tanh`, `derf`, `rms_norm` y `prms_norm` (RMSNorm parcial). Las formulaciones matemáticas de LayerNorm, RMSNorm, pRMSNorm, Tanh Dinámico (DyT) [113] y Erf Dinámico (Derf) [13], junto con una tabla comparativa, se detallan en el Apéndice 9.

3.8. Arquitecturas de Flujo Residual

La conexión residual no es solo una elección de modelado, sino también una decisión de macro-diseño. El sistema expone cuatro estrategias de conexión residual mediante el sub-objeto `model.residuals` (clave plana `residual_type`, por defecto `standard`):

- **Residual estándar** (`residual_type="standard"`): el residual de identidad clásico [38], $x_{l+1} = x_l + F(x_l, W_l)$. Sin estado, sin parámetros extra.

- **Sin residual** (`residual_type="none"`, experimental): $x_{l+1} = F(x_l, W_l)$, eliminando la conexión skip por completo. Útil solo como sonda de ablación.
- **Residuales de Atención** (`residual_type="full_attn"` o `"block_attn"`) [89]: reemplazan la suma residual de coeficiente unitario fijo por atención softmax aprendida sobre la profundidad. Cada capa atiende sobre todas las salidas de capas anteriores (Full AttnRes) o sobre un pequeño conjunto de representaciones acumuladas por bloque (Block AttnRes). Añade $L \cdot C$ parámetros (un vector de query aprendido w_l por capa). Los queries inicializados a cero hacen que la atención inicial sea un promedio equiponderado, igualando el residual estándar en el paso cero.
- **Hyper-Connexiones Restringidas por Variedad** (`residual_type` combinado con `mhc.enabled=true`, documentado por separado en el Apéndice 11): el residual de n streams [98] cuya matriz de mezcla de flujo se restringe al politopo de Birkhoff mediante Sinkhorn–Knopp.

AttnRes se integra ortogonalmente con mHC y con Mixture-of-Depths: el campo `model.residuals.mhc_stream` selecciona si la atención sobre la profundidad corre por stream (`independent`) o conjuntamente sobre la proyección aplanada nC (`joint`) cuando mHC está activo. La formulación completa, las cuatro estrategias, el cableado de implementación y los resultados reportados se detallan en el Apéndice 12. mHC por sí solo se detalla en el Apéndice 11.

4. Taxonomía de Arquitectura e Implementación

4.1. Familias de Atención y Mezcladores de Secuencias

Este sistema implementa cuarenta y tres variantes de mezcladores de secuencia organizadas en ocho categorías funcionales que reflejan las tendencias de investigación en el diseño de modelado de secuencias. La organización taxonómica refleja la comprensión evolutiva de cómo equilibrar expresividad, eficiencia computacional y restricciones de memoria.

1. **Líneas Base de Atención Densas** (3): La atención softmax estándar, la atención sigmoide y la Atención por Consultas Agrupadas (GQA) proporcionan contextualización global completa a costo computacional cuadrático, sirviendo como líneas base de referencia para comparación con alternativas más eficientes.
2. **Arquitecturas Recurrentes y Retentivas** (5): RetNet, Mamba, bloques estilo ODE, Titans y Engram mantienen representaciones de estado que permiten un costo de inferencia $\mathcal{O}(1)$ mientras preservan la expresividad mediante dinámicas recurrentes, parámetros selectivos o adaptación de memoria en tiempo de prueba.
3. **Patrones de Atención Dispersa** (9): Sparse Transformer, Longformer, BigBird, SparseK, NSA, SpargeAttn, FASA, MSA y SparDA reducen la complejidad cuadrática mediante dispersión estructurada, selección de tokens o estrategias de poda sin entrenamiento.
4. **Mecanismos de Memoria con Compuerta** (8): GLA, DeltaNet, Gated DeltaNet, Gated DeltaNet-2, HGRN2, FoX, Gated Softmax y KDA introducen control dependiente de datos sobre la retención de memoria, el olvido y la fuerza de actualización.
5. **Compresión Latente y de Rango Bajo** (10): MLA, GQLA, MLRA, Tucker, IHA, GTA, MTLA, CCA, CCGQA y GMA comprimen las representaciones clave–valor en cuellos de botella latentes de rango bajo (o, para GMA, enrutan a través de una memoria latente de mezcla Gaussiana aprendida), intercambiando un pequeño error de reconstrucción por ahorros sustanciales de memoria y cómputo.




Figura 2: Taxonomía completa de cuarenta y tres variantes de mezcladores de secuencia en ocho categorías funcionales. Las líneas base densas proporcionan enrutamiento global completo a costo cuadrático. Las arquitecturas recurrentes permiten inferencia en tiempo constante mediante compresión de estado. Las variantes dispersas reducen la complejidad mediante patrones estructurados o selección de tokens. Los mecanismos con compuerta introducen control dependiente de datos sobre la retención y el olvido de memoria. Los métodos latentes comprimen representaciones clave-valor en cuellos de botella de rango bajo o enrutan a través de latentes probabilísticos de mezcla Gaussiana. La memoria condicional proporciona lectura/escritura en tiempo de prueba sobre un banco de memoria externo. Los métodos de peso rápido tratan la transición de estado recurrente como una regla de aprendizaje continuo en línea. Los métodos de campo geométrico codifican sesgos inductivos espaciales o de estructura de grafo sobre la matriz de atención.

6. **Memoria Condicional** (1): Engram proporciona memoria en tiempo de prueba mediante operaciones de lectura/escritura aprendidas sobre un banco de memoria externo.
7. **Atención de Peso Rápido** (6): Falcon-1, Falcon-2, Falcon-3, Falcon-1A, Falcon-2A y Falcon-3A [110] tratan la transición recurrente del estado de peso rápido como una regla de aprendizaje continuo en línea bajo semántica de lectura tras escritura, con tamaños de paso normalizados, olvido por ridge explícito y repetición opcional con ventana deslizante acotada.
8. **Campo Geométrico** (1): SSOG [71] aplica un campo geométrico/de dispersión estructurada sobre la matriz de atención, codificando sesgos inductivos espaciales o de estructura de grafo específicos del dominio que las otras siete familias no capturan.

4.2. Familias Densas y Recurrentes

Las líneas base densas (softmax estándar [92] y sigmoide [77]) y la familia recurrente/retentiva (RetNet [88], Mamba [33], bloques continuos estilo ODE [108] y memoria en tiempo de prueba Titans [7]) proporcionan la compensación fundamental entre expresividad y eficiencia. Las formulaciones matemáticas, las formas paralela y recurrente, el pseudocódigo algorítmico y una tabla comparativa arquitectónica se recopilan en el Apéndice 5. El algoritmo de despacho de mezclador guiado por patrón (incluyendo la política de cumplimiento sin entrenamiento para `fasa_attn` y `sparge_attn`) se detalla igualmente allí.

4.3. Familia de Atención Latente y de Rango Bajo

Una familia complementaria comprime el estado clave-valor por token en un latente de rango bajo: Atención Latente Multi-Cabeza (MLA), Atención Latente por Consultas Agrupadas




Figura 3: Mapa conceptual de las estrategias de diseño de atención dispersa utilizadas en el código base. Diferentes métodos reducen el costo restringiendo vecindarios, construyendo grafos dispersos o seleccionando solo tokens/bloques de alto valor.




Figura 4: Tres líneas base de atención densa. La atención softmax estándar y la sigmoide calculan matrices $QK^\top$ completas. La Atención por Consultas Agrupadas (GQA) comparte cabezas clave-valor entre grupos de consultas, reduciendo el ancho de banda de memoria mientras preserva la expresividad completa de la atención.

(GQLA), Atención Multi-Cabeza de Rango Bajo (MLRA), Atención Tucker, Atención de Cabezas Entrelazadas (IHA), Atención laTenT por Cabezas Agrupadas (GTA) y Atención Latente Temporal Multi-Cabeza (MTLA). Estos métodos unifican diseños de consulta agrupada, latente, factorizado y latente temporal bajo un cuello de botella de rango bajo común. La Atención de Mezcla Gaussiana (GMA) toma una ruta diferente: reemplaza la interacción pareada $QK^\top$ con enrutamiento probabilístico a través de K componentes de mezcla Gaussiana aprendidos por cabeza, escribiendo valores en una memoria latente de K slots y leyendo de vuelta mediante responsabilidades posteriores, dando un almacenamiento de activaciones $\mathcal{O}(NK)$ para K fijo. Las formulaciones completas, el pseudocódigo y una tabla comparativa se recopilan en el Apéndice 6.

4.4. Extensiones de Atención Dispersa

El registro de mezcladores incluye nueve bloques dispersos: `sparse_transformer_attn`, `longformer_attn`, `bigbird_attn`, `sparsek_attn`, `nsa_attn`, `sparge_attn`, `fasa_attn`, `msa_attn` y `sparda_attn` [16, 8, 105, 59, 103, 109, 95]. La implementación impone una política de ejecución explícita para métodos dispersos sin entrenamiento: `fasa_attn` y `sparge_attn` son solo para evaluación/inferencia y generan errores en tiempo de ejecución si se usan mientras el modelo está en modo de entrenamiento. Las formulaciones matemáticas, el pseudocódigo algorítmico, las características por bloque y una tabla comparativa se recopilan en el Apéndice 7.

4.5. Extensiones de Atención con Compuerta

El registro de mezcladores incluye ocho bloques con compuerta: `gla_attn`, `deltanet_attn`, `gated_deltanet_attn`, `gated_deltanet2_attn`, `hgrn2_attn`, `fox_attn`, `gated_softmax_attn` y `kda_attn` [99, 100, 101, 36, 74, 54, 75, 47]. La idea unificadora es que las compuertas controlan *qué información sobrevive*: algunas compuertas actúan sobre actualizaciones de estado recurrente (GLA, variantes de DeltaNet, HGRN2), mientras que otras modifican la ruta de atención completa (FoX y Gated Softmax). KDA extiende Gated DeltaNet con un mecanismo de com-




Figura 5: Familia de arquitecturas recurrentes y retentivas. RetNet proporciona formas duales paralela y recurrente. Mamba utiliza parámetros selectivos de espacio de estados. Los bloques ODE modelan dinámicas de profundidad continua. Titans introduce adaptación de memoria en tiempo de prueba. Todas logran inferencia en tiempo constante por paso.

puerta (decaimiento) más fino y por canal sobre la actualización de estado de la regla delta $S_t = (I - \beta_t k_t k_t^\top) D_t S_{t-1} + \beta_t k_t v_t^\top$, donde $D_t = \text{Diag}(d_t)$ aplica un decaimiento por canal. Esto hace que las compuertas sean especialmente útiles cuando el modelo debe equilibrar recuerdo, actualidad y memoria limitada. Las formulaciones matemáticas, el pseudocódigo algorítmico, una plantilla de compuerta genérica y una tabla comparativa se recopilan en el Apéndice 8.

Una sexta familia replantea la propia actualización recurrente de peso rápido como una regla de aprendizaje continuo en línea: el registro de mezcladores incluye seis bloques de peso rápido — `falcon1_attn`, `falcon2_attn`, `falcon3_attn`, `falcon1a_attn`, `falcon2a_attn` y `falcon3a_attn` [110]. Falcon unifica las escrituras aditivas estilo DeltaNet y de atención lineal bajo semántica de lectura tras escritura (RAW), con tamaños de paso normalizados $\eta_t = \beta_t / (\text{estadístico}_t + \lambda_t + \varepsilon)$, un arrastre derivado del objetivo $\gamma_t = 1 - \eta_t \lambda_t$ y repetición acotada con ventana deslizante en las variantes Falcon-3. Cada variante proporciona un escaneo recurrente de referencia y un kernel chunk-parallel estilo SSD, compartiendo un único bloque de configuración. Las formulaciones matemáticas, el pseudocódigo algorítmico, la renormalización de decaimiento positivo, las perillas de configuración y los resultados publicados se recopilan en el Apéndice 16.

5. Familias de Optimizadores y Dinámicas de Entrenamiento

La optimización de arquitecturas transformer altamente parametrizadas presenta desafíos significativos debido a paisajes de pérdida no convexos, puntos de silla y heterogeneidad de bloques entre grupos de parámetros. Este sistema aborda estos desafíos mediante un marco unificado que soporta veintitrés familias de optimizadores que abarcan seis categorías algorítmicas: (1) líneas base clásicas (SGD, AdamW), (2) momento avanzado y reducción de varianza (Adan, ADOPT, AdEMAMix, MARS, Cautious), (3) variantes eficientes en memoria (Adafactor, GaLore, Lion, APOLLO, APOLLO-Mini, Q-APOLLO), (4) métodos sin programación y sin parámetros (Schedule-Free AdamW, Prodigy) más escalado de lotes grandes mediante LAMB, (5) conscientes de curvatura y segundo orden (Sophia, Shampoo, SOAP), (6) orientados a geometría (Muon, Turbo-Muon), y (7) optimizadores con adaptabilidad ajustable (Anon). Las descripciones algorítmicas detalladas, pseudocódigo y una tabla comparativa de memoria/complejidad para todos los optimizadores se proporcionan en el Apéndice 4.

6. Cuantización y Despliegue

El stack de despliegue utiliza empaquetado ternario de pesos más cuantización de activaciones INT8 para producir artefactos eficientes.




Figura 6: Concepto de atención latente y de rango bajo. Los pares clave–valor se comprimen mediante una proyección descendente a un espacio latente de rango bajo ($r \ll d$), donde la atención se calcula a costo reducido, y luego se proyectan de vuelta. Las variantes difieren en la estructura de factorización (MLA, GQLA, MLRA, Tucker), entrelazado de cabezas (IHA, GTA), compresión temporal (MTLA), formulaciones de covarianza cruzada (CCA, CCGQA) y enrutamiento probabilístico de mezcla Gaussiana (GMA).

6.1. Cuantización Ternaria y Escalado de Activaciones

La etapa de despliegue transforma un checkpoint entrenado en un artefacto compacto mediante empaquetado ternario de pesos estilo BitNet [94], escalado de activaciones INT8 y aproximación de almacenamiento de 1.58 bits alineada con objetivos de despliegue ligero [80, 12]. Las formulaciones matemáticas del escalado ternario de pesos, la cuantización/des-cuantización de activaciones INT8 y las estimaciones de tamaño FP32/FP16/1.58 bits se diferencian al Apéndice 9.

7. Tareas Posteriores de SBERT

El embedding de oraciones se construye sobre entrenamiento estilo Siamese [78]. Para el par de oraciones (s_1, s_2) con embeddings (e_1, e_2) :

$$\cos(e_1, e_2) = \frac{e_1^\top e_2}{\|e_1\| \|e_2\|}$$

y pérdida coseno estilo regresión:

$$\mathcal{L}_{\cos} = (\cos(e_1, e_2) - y)^2$$

con $y \in [-1, 1]$ en este pipeline.

Modos posteriores soportados:




Figura 7: Plantilla de compuerta genérica. Una compuerta puede atenuar la memoria existente, regular la fuerza de escritura o modular las salidas de atención densa, dependiendo de la familia del bloque.




Figura 8: Selección de optimizador en la práctica: la clase determina la regla de actualización, mientras que el esquema controla cómo se aplican los hiperparámetros entre embeddings, normas, bloques recurrentes, bloques de atención y otros parámetros.

- **Similitud:** puntuación por pares entre dos oraciones.
- **Búsqueda:** k vecinos más cercanos sobre un corpus.
- **Clustering:** agrupación de embeddings (ej., k-means).
- **Codificación:** exportación persistente de embeddings para recuperación posterior.

El pseudocódigo del enrutador de modo de inferencia SBERT—despachando entre los modos de similitud, búsqueda, cluster y codificación sobre un codificador compartido—se difiere al Apéndice 9.

8. Integración Sin Código: El Plugin dashai-frankenstein

El CLI basado en esquemas y el generador web descritos en la Sección 3 sirven a investigadores cómodos con archivos de configuración YAML. Una audiencia complementaria—especialistas de dominio, educadores y analistas que necesitan un modelo entrenado pero no un script de entrenamiento—está mejor servida por un entorno gráfico sin código. Para alcanzar a esa audiencia, Frankenstein Transformer distribuye un paquete adaptador complementario, *dashai-frankenstein*, que registra las clases de modelo de Frankenstein como componentes de *dashAI* (<https://github.com/DashAISoftware/dashAI>), una aplicación de escritorio open-source y local-first para aprendizaje automático desarrollada por un consorcio académico chileno (Universidad de Chile/FCFM, CENIA, IMFD y financiamiento ANID). Como ambos sistemas son basados en esquemas en esencia—dashAI genera sus formularios de configuración directamente desde esquemas Pydantic, mientras que Frankenstein valida su YAML contra un JSON




Figura 9: Ruta de despliegue desde un checkpoint entrenado hasta un artefacto compacto. El código base trata la cuantización como una transformación de la etapa de despliegue en lugar de una familia de modelos separada.




Figura 10: Reutilización del flujo de trabajo SBERT. Un único codificador soporta puntuación de pares en línea, recuperación sobre corpus, clustering y exportación persistente de embeddings.

Schema estricto—la integración no requirió cambios en el backend de dashAI: el plugin se descubre mediante el grupo de entry-points estándar `dashai.plugins` al inicio, exactamente como documenta la guía de plugins de dashAI (<https://docs.dash-ai.com/learn/guides/plugins/>), donde los plugins son paquetes PyPI ordinarios cuyas capacidades generativas de primera parte se distribuyen ellos mismos como plugins.

8.1. Componentes Registrados

Un único grupo de entry-points `dashai.plugins` registra cinco componentes en el registro de componentes de dashAI, cubriendo toda la amplitud de las clases de modelo del toolkit:

- **FrankensteinMLMModel** (`BaseModel`) — se vincula a la `TextClassificationTask` de dashAI. Entrena el encoder de Frankenstein con una cabeza de clasificación de precisión completa con pooling sobre la salida del encoder (Estrategia A de la auditoría de integración), heredando todos los mezcladores de secuencia, normalizadores y familias de optimizadores del motor subyacente; `predict` devuelve una matriz de probabilidades por clase.
- **FrankensteinDecoderModel** (`BaseGenerativeModel`) — se vincula a `TextToTextGenerationTask`. Fuerza `model_class: frankensteindecoder` (que a su vez fuerza `mode: decoder`) y expone muestreo autorregresivo top- k ; los parámetros de generación (`max_new_tokens`, `temperature`, `top_k`) permanecen como campos nativos del formulario de dashAI porque son ajustes de tiempo de inferencia sin lugar en el esquema de entrenamiento de Frankenstein.
- **FrankensteinViTClassifier** (`BaseModel`) — se vincula a `ImageClassificationTask`, reutilizando la cabeza de clasificación integrada del Vision Transformer (Apéndice 13).
- **FrankensteinViTSegmenter** (`BaseModel`) — se vincula a una `SegmentationTask` proporcionada por el plugin, una nueva componente `BaseTask` que dashAI no incluye; usa la cabeza de segmentación del ViT y devuelve mapas de clases por píxel.
- **SegmentationTask** (`BaseTask`) — la tarea complementaria que declara tipos de columna imagen-entrada/máscara-salida para el segmentador.

Los cinco componentes comparten una fachada delgada sobre la API de motor reutilizable de Frankenstein (la interfaz sin CLI y sin supervisor extraída en la Fase 0 del plan de integración), de modo que existe exactamente una dependencia pesada (`frankenstein-transformer`) detrás del plugin.

8.2. Esquema de Configuración de Passthrough

La integración preserva la filosofía basada en esquemas de Frankenstein (Sección 3) manteniendo el JSON Schema de Frankenstein como la única fuente de verdad en lugar de traducir sus más de 150 campos de modelo y 38 campos de entrenamiento a campos nativos de formulario de dashAI—una traducción que sería frágil frente a un esquema en evolución activa. En su lugar, cada componente expone un esquema Pydantic mínimo cuyo único campo visible para el usuario, `frankenstein_json`, es una cadena que contiene una configuración completa de entrenamiento de Frankenstein como documento *JSON de una sola línea* (una concesión a los campos de texto de una sola línea de dashAI; los usuarios construyen el YAML con el generador web basado en esquemas y lo convierten con una sola línea). Antes de que cualquier entrenamiento o construcción de modelo se lance, el adaptador ejecuta un pipeline de validación de tres etapas:

1. **Parseo JSON** — detecta errores de sintaxis en la carga de una sola línea.
2. **Validación JSON Schema** — `jsonschema.validate` contra el esquema de Frankenstein resuelto, imponiendo `additionalProperties: false` y todos los rangos de enums (mezcladores, optimizadores, normalizaciones, activaciones).
3. **Validación del cargador de configuración** — el propio `load_training_config` de Frankenstein impone las restricciones cruzadas entre componentes (divisibilidad de `hidden_size` entre `num_heads`, `num_kv_heads` dividiendo `num_heads`, acuerdo vocabulario/tokenizador, reglas de flags BitNet, presencia del optimizador por tarea, `frankenstein_decoder` forzando `mode: decoder`).

Cualquier fallo se presenta al usuario de dashAI como un único `ValueError` legible etiquetado con la etapa fallida, de modo que las configuraciones inválidas nunca alcanzan el bucle de entrenamiento—el mismo contrato fail-fast que provee el CLI. La inyección de datasets la manejan adaptadores que mapean el `DashAIDataset` de dashAI (un envoltorio de Hugging Face `datasets`) sobre las expectativas de dataset de Frankenstein, inyectan `vocab_size` desde el tokenizador resuelto para que la matriz de embeddings coincida con el vocabulario, y transmiten las métricas por época de vuelta al almacén de métricas de dashAI para que el progreso del entrenamiento sea visible en la UI. Dos casillas booleanas controlan la fuente de datos: `use_dashai_dataset` (entrenar con el dataset del run vs. el bloque `text_dataset` del JSON) y `use_dashai_dataset_for_tokenizer` (cuando el config establece `tokenizer.source=train_from_dataset`, si el tokenizador se entrena desde el dataset del run o desde el corpus configurado en el JSON); en este último modo el tokenizador se entrena *primero* y el tamaño de vocabulario resultante se inyecta en `model.dims.vocab_size` antes de construir el modelo.

8.3. Trabajo en Proceso

El plugin es un trabajo en proceso. Sus fases están implementadas—el MVP de clasificación de texto MLM (Fase 1), el decoder generativo y el clasificador ViT (Fase 2), y el segmentador ViT más la `SegmentationTask` proporcionada por el plugin (Fase 3)—pero el paquete aún no se ha ejecutado dentro de una instancia viva de dashAI: el contrato de componentes se implementó a partir de una auditoría del registro de plugins, las clases base y la arquitectura de cola de trabajos de dashAI en lugar de validarse de extremo a extremo. La publicación en PyPI también está pendiente, tanto del propio plugin como de su piso de dependencia (`frankenstein-transformer` $\geq 1.1.0$, el release con la API de motor que reemplaza al 1.0.0 pre-motor ya en PyPI). Las limitaciones conocidas que se arrastran a la siguiente iteración incluyen: el componente MLM ejecuta un bucle de clasificación supervisada directa en lugar de una receta de preentrenamiento MLM seguido de ajuste fino; el esquema de passthrough difiere los campos nativos curados para ajustes de alto impacto (clase de modelo, patrón de

mezclador, familia de optimizador) a una versión futura; y la capacidad de dashAI para renderizar columnas de salida de máscaras de segmentación no está confirmada y puede requerir una adición local al frontend. Estos ítems están registrados en la auditoría de integración del repositorio (<https://github.com/erickfmm/frankenstein-transformer>), y el diseño deja intencionalmente el núcleo del backend de dashAI intacto, de modo que futuros releases de dashAI no puedan romper el adaptador mediante acoplamiento.

La integración completa la historia de accesibilidad del toolkit: el mismo contrato de configuración validado que impulsa el CLI, el generador Streamlit y el pipeline de exportación ahora también impulsa una aplicación de trabajo sin código de terceros, permitiendo que el espacio arquitectónico de Frankenstein se explore desde una interfaz gráfica sin sacrificar las garantías de esquema de las que depende la reproducibilidad.

9. Discusión

Las decisiones de diseño en Transformer Encoder Frankenstein reflejan varias tensiones de ingeniería e investigación en las herramientas modernas de aprendizaje profundo.

9.1. Compromisos de Diseño Basado en Esquemas

El enfoque basado en esquemas proporciona beneficios significativos de reproducibilidad al imponer contratos explícitos y fallar rápidamente ante configuraciones inválidas. Sin embargo, este enfoque también introduce rigidez: agregar nuevas arquitecturas u optimizadores requiere extensiones del esquema en lugar de argumentos de línea de comandos flexibles. El sistema de hiperparámetros prefijados permite un control detallado pero aumenta la complejidad de configuración para usuarios acostumbrados a interfaces más simples.

La decisión de imponer `additionalProperties: false` en todos los niveles del esquema elimina la absorción silenciosa de parámetros que ha afectado a sistemas de configuración anteriores, pero esta rigurosidad requiere un mantenimiento cuidadoso del esquema al extender las capacidades del sistema. Cada nuevo mecanismo de atención o variante de optimizador debe integrarse adecuadamente en el marco de validación, incluyendo definiciones de campos del esquema con tipos y restricciones apropiados, mapeo de hiperparámetros prefijados para grupos específicos de optimizadores, valores predeterminados alineados con las mejores prácticas de investigación y cadenas de documentación para la representación en la interfaz web.

9.2. Cobertura Arquitectónica y Vacíos

Las diecisiete arquitecturas de mezclador implementadas abarcan las principales direcciones de investigación en modelado de secuencias, pero ciertos vacíos permanecen. El sistema carece de arquitecturas híbridas recientes como Griffin [84] y Jamba [34], que combinan compuertas con modelos de espacio de estados. El enrutamiento MoE (Mezcla de Expertos) está implementado para capas FFN pero no para el cómputo de atención, donde trabajos recientes han mostrado beneficios [52].

La cobertura de atención dispersa es completa, pero la implementación de métodos sin entrenamiento (FASA, SpargeAttn) genera errores en tiempo de ejecución durante el entrenamiento, reflejando restricciones arquitectónicas: estos métodos requieren checkpoints preentrenados de modelos de atención completa o procedimientos específicos de ajuste fino que actualmente no están automatizados.

La cobertura de mecanismos de compuerta y peso rápido es sólida en todas las categorías principales (GLA, DeltaNet, Gated DeltaNet, Gated DeltaNet-2, HGRN2, FoX, Gated Softmax y las seis variantes Falcon [110]). El macro-diseño del flujo residual está cubierto mediante el flujo residual de n streams restringido por variedad (mHC) [98], cuya proyección Sinkhorn–Knopp sobre el politopo de Birkhoff restaura la propiedad de mapeo de identidad que pierden

las Hyper-Connexions sin restricción; mHC está validado solo al nivel de los experimentos MoE publicados de 3B–27B, y el marco se beneficiaría de reproducciones independientes a escalas menores (ver Apéndice 11).

9.3. Fragmentación del Panorama de Optimizadores

El soporte para veintidós familias de optimizadores en seis categorías algorítmicas demuestra exhaustividad pero también resalta el estado fragmentado de la investigación en optimización. Los usuarios enfrentan una complejidad significativa de decisión al elegir entre métodos de reducción de varianza (Adan, MARS), variantes eficientes en memoria (GaLore, Adafactor, APOLLO) y enfoques conscientes de curvatura (Sophia, Shampoo). El sistema de hiperparámetros prefijados, aunque poderoso, requiere comprender qué parámetros son relevantes para cada clase de optimizador.

La calidad de implementación varía entre optimizadores: los métodos clásicos (AdamW, SGD con momento) están altamente optimizados en PyTorch, mientras que los métodos más nuevos (Muon, Turbo-Muon, SOAP) pueden requerir implementaciones personalizadas que afectan la estabilidad numérica y las características de rendimiento.

9.4. Consideraciones de Despliegue y Producción

El pipeline de cuantización demuestra preocupaciones prácticas de despliegue pero realiza compromisos de ingeniería específicos. El empaquetado ternario de pesos reduce el almacenamiento a aproximadamente 1,58 bits por parámetro, pero esta compresión agresiva puede degradar el rendimiento, especialmente para modelos más pequeños donde el error de cuantización es más significativo. La implementación actual aplica cuantización uniforme entre todos los tipos de parámetros.

Los flujos de trabajo SBERT proporcionan utilidad práctica para tareas de similitud semántica y recuperación, pero la implementación asume estrategias de pooling estándar (token CLS, pooling promedio). Avances recientes como los embeddings Matryoshka [65] y los refinamientos de aprendizaje contrastivo [46] aún no están incorporados.

9.5. Desafíos de Integración y Extensibilidad

La estructura actual del código base, aunque funcional, presenta desafíos de mantenimiento a medida que se expanden las familias de arquitecturas y optimizadores. El patrón de despachador para la selección de mezcladores y el enrutamiento de optimizadores maneja la extensibilidad pero corre el riesgo de convertirse en un “cajón de sastre” de lógica condicional. Las versiones futuras se beneficiarían de arquitecturas basadas en plugins donde nuevos mezcladores y optimizadores puedan registrarse de forma declarativa en lugar de modificar la lógica central de despacho.

La interfaz de configuración web proporciona mejoras significativas de usabilidad pero introduce complejidad de despliegue: ejecutar Streamlit junto con trabajos de entrenamiento requiere recursos adicionales y consideraciones de infraestructura que pueden no ser apropiadas para todos los entornos, particularmente clústeres HPC sin acceso web.

10. Conclusión

Transformer Encoder Frankenstein presenta una plataforma de experimentación unificada, impulsada por configuración, que aborda desafíos críticos en la investigación moderna de aprendizaje profundo: fragmentación arquitectónica entre atención densa, modelos recurrentes, patrones dispersos, mecanismos de compuerta y memorias de peso rápido; complejidad del panorama de

optimizadores que abarca líneas base clásicas, métodos de reducción de varianza, variantes eficientes en memoria, enfoques sin programación, algoritmos conscientes de curvatura y métodos orientados a geometría; y flujos de trabajo de despliegue de extremo a extremo que abarcan cuantización y aplicaciones de embeddings de oraciones.

Las contribuciones principales del sistema son:

1. **Diseño Basado en Esquemas:** Un contrato de configuración estricto basado en YAML con validación y enrutamiento de hiperparámetros prefijados que permite experimentos reproducibles en diecisiete arquitecturas de mezclador y veintitrés familias de optimizadores.
2. **Soporte Arquitectónico Integral:** Implementación que abarca las principales categorías de investigación incluyendo líneas base densas (atención estándar, sigmoide), alternativas recurrentes (RetNet, Mamba, estilo EDO, Titans), atención dispersa (Sparse Transformer, Longformer, BigBird, SparseK, NSA, SpargeAttn, FASA) mecanismos de compuerta (GLA, DeltaNet, Gated DeltaNet, Gated DeltaNet-2, HGRN2, FoX, Gated Softmax, KDA) y atención de peso rápido (Falcon-1/2/3, Falcon-1A/2A/3A) [110].
3. **Marco Unificado de Optimizadores:** Grupos de hiperparámetros prefijados que permiten control detallado sobre embeddings, capas de normalización, bloques recurrentes, pesos de atención y parámetros FFN en líneas base clásicas (SGD+Momentum, AdamW), reducción de varianza (Adan, ADOPT, AdEMAMix, MARS, Cautious), eficientes en memoria (Adafactor, GaLore, Lion, APOLLO, APOLLO-Mini, Q-APOLLO), lotes grandes y simplificación de programación (LAMB, Schedule-Free AdamW, Prodigy), conscientes de curvatura (Sophia), segundo orden (Shampoo, SOAP) y orientados a geometría (Muon, Turbo-Muon).
4. **Flujos de Trabajo de Extremo a Extremo:** Pipeline de despliegue integrado que soporta empaquetado ternario de pesos y cuantización de activaciones INT8; entrenamiento e inferencia inspirados en SBERT para similitud semántica, recuperación y tareas de clustering.
5. **Configuración Interactiva:** Interfaz web basada en Streamlit que proporciona generación de formularios impulsada por esquemas, validación en tiempo real, documentación en línea y síntesis de comandos CLI.

Este sistema permite iteración experimental rápida mientras mantiene reproducibilidad mediante contratos de configuración estrictos. Al consolidar diversas contribuciones de investigación en un conjunto de herramientas unificado, reduce las barreras para explorar arquitecturas y estrategias de optimización novedosas, particularmente para investigadores que pueden carecer de recursos para implementar y validar cada variante de forma independiente.

10.1. Limitaciones y Direcciones Futuras

Varias limitaciones y direcciones prometedoras para trabajo futuro surgen del diseño e implementación de este sistema:

1. **Integración Arquitectónica:** Arquitecturas híbridas recientes (Griffin, Jamba, Mamba-X) demuestran beneficios de combinar múltiples mecanismos en bloques unificados. Versiones futuras deberían integrar estas arquitecturas y explorar patrones de composición sistemática.
2. **Cuantización Avanzada:** La implementación actual utiliza empaquetado ternario uniforme en todos los parámetros. La investigación sobre cuantización por capas, por canales y consciente de importancia sugiere que estrategias más sofisticadas podrían mejorar los compromisos calidad-eficiencia.
3. **Extensibilidad Basada en Plugins:** El patrón de despacho actual se vuelve cada vez más complejo con cada nueva adición. Una arquitectura de plugins que permita el registro

declarativo de nuevos mezcladores, optimizadores y métodos de normalización mejoraría el mantenimiento y reduciría el riesgo de errores en la lógica central de despacho.

4. **Optimización Automatizada de Hiperparámetros:** El esquema soporta espacios extensos de hiperparámetros, pero los usuarios deben explorar estos espacios manualmente. La integración con optimización bayesiana, estrategias de bandidos multi-brazo o ajuste de hiperparámetros basado en gradientes podría automatizar el descubrimiento de configuraciones efectivas.
5. **Despliegue en Producción:** La interfaz web mejora la usabilidad pero puede no ser apropiada para todos los entornos de despliegue. Modos de configuración sin interfaz gráfica, gestión de configuración basada en API o ergonomía CLI mejorada podrían servir a flujos de trabajo HPC y de producción.
6. **Evaluación Comparativa:** Si bien el sistema permite entrenamiento con diversas arquitecturas, una evaluación comparativa exhaustiva que compare el rendimiento entre mezcladores y optimizadores en tareas estandarizadas proporcionaría orientación valiosa para la selección de configuraciones.
7. **Garantías de Estabilidad de Entrenamiento:** La implementación actual incluye guardas contra NaN/Inf y recorte de gradiente, pero el análisis formal de condiciones de estabilidad para diferentes combinaciones mezclador-optimizador, particularmente con bloques en bucle y cuantización agresiva, sigue abierto.
8. **Extensiones Multimodales y Específicas de Tarea:** El diseño actual se centra en modelado de secuencias. Extensiones para modelos de visión-lenguaje, arquitecturas multimodales y flujos de trabajo de ajuste fino específicos de tarea (ej., ajuste por instrucciones, RLHF) ampliarían la aplicabilidad.

La trayectoria de investigación del modelado de secuencias continúa hacia enfoques híbridos que combinan fortalezas de múltiples paradigmas—compresión de la recurrencia, selectividad de la atención, compuertas para gestión de memoria y dispersión para eficiencia. Una plataforma de experimentación unificada como Transformer Encoder Frankenstein es cada vez más valiosa a medida que esta convergencia se acelera, permitiendo a los investigadores explorar sistemáticamente este creciente espacio de diseño con infraestructura reproducible y bien diseñada.

Bibliografía

- [1] Martín Abadi, Paul Barham, Jianmin Chen, Zhifeng Chen, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Geoffrey Irving, Michael Isard, Manjunath Kudlur, Josh Levenberg, Rajat Monga, Sherry Moore, Derek G. Murray, Benoit Steiner, Paul Tucker, Vijay Vasudevan, Pete Warden, Martin Wicke, Yuan Yu, and Xiaoqiang Zheng. TensorFlow: A system for large-scale machine learning. In *12th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*, pages 265–283, 2016.
- [2] Joshua Ainslie, James Lee-Thorp, Michiel de Jong, Yury Zemlyansky, Federico Lebrón, and Sumit Sanghai. Gqa: Training generalized multi-query transformer models from multi-head checkpoints, 2023. URL <https://arxiv.org/abs/2305.13245>.
- [3] Anonymous authors. Anon: Extrapolating adaptivity beyond sgd and adam, 2026. URL <https://arxiv.org/abs/2605.02317>.
- [4] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. Layer normalization, 2016. URL <https://arxiv.org/abs/1607.06450>.

- [5] Jonathan T. Barron. Continuously differentiable exponential linear units. *arXiv preprint arXiv:1704.07483*, 2017.
- [6] Mina Basirat and Peter M. Roth. The quest for a better ReLU: ELiSH and HardELiSH activation functions. *arXiv preprint arXiv:1905.10144*, 2019.
- [7] Ali Behrouz, Peilin Zhong, and Vahab Mirrokni. Titans: Learning to memorize at test time, 2025. URL <https://arxiv.org/abs/2501.00663>. Version Number: 1.
- [8] Iz Beltagy, Matthew E. Peters, and Arman Cohan. Longformer: The long-document transformer, 2020. URL <https://arxiv.org/abs/2004.05150>.
- [9] Arthur S. Bianchessi, Yasmin C. Aguirre, Rodrigo C. Barros, and Lucas S. Kupssinskü. Bayesian attention mechanism: A probabilistic framework for positional encoding and context length extrapolation, 2025. URL <http://arxiv.org/abs/2505.22842>.
- [10] Thibaut Boissin, Thomas Massena, Franck Mamalet, and Mathieu Serrurier. Turbo-muon: Accelerating orthogonality-based optimization with pre-conditioning, 2025. URL <https://arxiv.org/abs/2512.04632>. Version Number: 1.
- [11] James Bradbury, Roy Frostig, Peter Hawkins, Matthew J. Johnson, Chris Leary, Dougal Maclaurin, George Necula, Adam Paszke, Jake VanderPlas, Skye Wanderman-Milne, and Qiao Zhang. JAX: composable transformations of Python+NumPy programs, 2018. URL <http://github.com/jax-ml/jax>.
- [12] Riccardo Bravin, Massimo Pavan, Hazem Hesham Yousef Shalby, Fabrizio Pittorino, and Manuel Roveri. EmbBERT: Attention under 2 MB memory, 2026. URL <http://arxiv.org/abs/2502.10001>.
- [13] Mingzhi Chen, Taiming Lu, Jiachen Zhu, Mingjie Sun, and Zhuang Liu. Stronger normalization-free transformers, 2025. URL <http://arxiv.org/abs/2512.10938>.
- [14] Xiangning Chen, Chen Liang, Da Huang, Esteban Real, Kaiyuan Wang, Yao Liu, Hieu Pham, Xuanyi Dong, Thang Luong, Cho-Jui Hsieh, Yifeng Lu, and Quoc V. Le. Symbolic discovery of optimization algorithms, 2023. URL <https://arxiv.org/abs/2302.06675>. Version Number: 4.
- [15] Xin Cheng, Wangding Zeng, Damai Dai, Qinyu Chen, Bingxuan Wang, Zhenda Xie, Kezhao Huang, Xingkai Yu, Zhewen Hao, Yukun Li, Han Zhang, Huishuai Zhang, Dongyan Zhao, and Wenfeng Liang. Conditional memory via scalable lookup: A new axis of sparsity for large language models, 2026. URL <https://arxiv.org/abs/2601.07372>.
- [16] Rewon Child, Scott Gray, Alec Radford, and Ilya Sutskever. Generating long sequences with sparse transformers, 2019. URL <https://arxiv.org/abs/1904.10509>.
- [17] Djork-Arné Clevert, Thomas Unterthiner, and Sepp Hochreiter. Fast and accurate deep network learning by exponential linear units (ELUs). *arXiv preprint arXiv:1511.07289*, 2016.
- [18] Chang Dai, Hongyu Shan, Mingyang Song, and Di Liang. HoPE: Hyperbolic rotary positional encoding for stable long-range dependency modeling in large language models, 2025. URL <http://arxiv.org/abs/2509.05218>.
- [19] Aaron Defazio, Xingyu Alice Yang, Harsh Mehta, Konstantin Mishchenko, Ahmed Khaled, and Ashok Cutkosky. The road less scheduled, 2024. URL <https://arxiv.org/abs/2405.15682>. Version Number: 4.

- [20] Keqi Deng and Philip C. Woodland. Multi-head temporal latent attention, 2025. URL <https://arxiv.org/abs/2505.13544>.
- [21] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding, 2019. URL <http://arxiv.org/abs/1810.04805>.
- [22] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, 2021. URL <http://arxiv.org/abs/2010.11929>.
- [23] Shiv Ram Dubey, Satish Kumar Singh, and Bidyut Baran Chaudhuri. Activation functions in deep learning: A comprehensive survey and benchmark. *Neurocomputing*, 453:1–24, 2021. doi: 10.1016/j.neucom.2021.03.063.
- [24] Sai Surya Duvvuri, Chanakya Ekbote, Rachit Bansal, Rishabh Tiwari, Devvrit Khatri, David Brandfonbrener, Paul Liang, Inderjit Dhillon, and Manzil Zaheer. Interleaved head attention, 2026. URL <https://arxiv.org/abs/2602.21371>.
- [25] Stefan Elfving, Eiji Uchibe, and Kenji Doya. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning. *Neural Networks*, 106:300–312, 2018. doi: 10.1016/j.neunet.2018.07.012.
- [26] Aiming Fang, Suhyune Lee, Nafise Sadat Moosavi, and Iryna Gurevych. Transformers with learnable activation functions. In *Findings of the Association for Computational Linguistics: EACL 2023*, pages 1736–1746, 2023. doi: 10.48550/arXiv.2208.14111.
- [27] Tomas Figliola, Nicholas Alonso, Rishi Iyer, Quentin Anthony, and Beren Millidge. Compressed convolutional attention: Efficient attention in a compressed latent space, 2025. URL <https://arxiv.org/abs/2510.04476>.
- [28] Yaosheng Fu, Guangxuan Xiao, Xin Dong, Song Han, and Oreste Villa. Sparda: Sparse decoupled attention for efficient long-context llm inference, 2026. URL <https://arxiv.org/abs/2606.04511>.
- [29] Xavier Glorot, Antoine Bordes, and Yoshua Bengio. Deep sparse rectifier neural networks. *Proceedings of the 14th International Conference on Artificial Intelligence and Statistics (AISTATS)*, pages 315–323, 2011.
- [30] Luke B. Godfrey and Michael S. Gashler. A continuum among logarithmic, linear, and exponential functions, and its potential to improve generalization in neural networks. In *Proceedings of the International Conference on Knowledge Discovery and Information Retrieval (KDIR)*, 2015.
- [31] Ian J. Goodfellow, David Warde-Farley, Mehdi Mirza, Aaron Courville, and Yoshua Bengio. Maxout networks. In *Proceedings of the 30th International Conference on Machine Learning (ICML)*, pages 1319–1327, 2013.
- [32] Nils Graef, Filip Makraduli, Andrew Wasielewski, and Matthew Clapp. FlashNorm: Fast normalization for transformers, 2026. URL <http://arxiv.org/abs/2407.09577>.
- [33] Albert Gu and Tri Dao. Mamba: Linear-time sequence modeling with selective state spaces, 2023. URL <https://arxiv.org/abs/2312.00752>. Version Number: 2.
- [34] Albert Gu, AI21 Labs, et al. Jamba: A hybrid transformer-mamba language model, 2024. URL <https://arxiv.org/abs/2403.19887>.

- [35] Vineet Gupta, Tomer Koren, and Yoram Singer. Shampoo: Preconditioned stochastic tensor optimization, 2018. URL <https://arxiv.org/abs/1802.09568>. Version Number: 2.
- [36] Ali Hatamizadeh, Yejin Choi, and Jan Kautz. Gated deltanet-2: Decoupling erase and write in linear attention, 2026. URL <https://arxiv.org/abs/2605.22791>.
- [37] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 1026–1034, 2015.
- [38] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778. IEEE, 2016. doi: 10.1109/CVPR.2016.90. URL <http://arxiv.org/abs/1512.03385>.
- [39] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked Autoencoders Are Scalable Vision Learners, 2022. URL <http://arxiv.org/abs/2111.06377>.
- [40] Dan Hendrycks and Kevin Gimpel. Gaussian error linear units (GELU). In *arXiv preprint arXiv:1606.08415*, 2016.
- [41] Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, Bo Chen, Mingxing Tan, Weijun Wang, Yukun Zhu, Ruoming Pang, Vijay Vasudevan, Quoc V. Le, and Hartwig Adam. Searching for MobileNetV3. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 1314–1325, 2019.
- [42] Andrew G. Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. MobileNets: Efficient convolutional neural networks for mobile vision applications. In *arXiv preprint arXiv:1704.04861*, 2017.
- [43] Yongchao Huang and Hassan Raza. Gaussian mixture attention: Linear-time sequence mixing via probabilistic latent routing, 2026. URL <https://arxiv.org/abs/2606.18283>.
- [44] Amirhossein Kazemnejad, Inkit Padhi, Karthikeyan Natesan Ramamurthy, Payel Das, and Siva Reddy. The impact of positional encoding on length generalization in transformers, 2023. URL <http://arxiv.org/abs/2305.19466>.
- [45] Daan Kerssies, Quentin Sartenauer, Fabio Ferraro, Gabriel Y. da Silva, Harkanwarpreet Maan, Matthieu Galon, Arsha Nagrani, Nathan Beeler, Bartłomiej Twardowski, Joost van de Weijer, Robert Dangooski, and Luca Berton. Your ViT is Secretly an Image Segmentation Model, 2025. URL <http://arxiv.org/abs/2503.19108>.
- [46] Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschinot, Ce Liu, and Dilip Krishnan. Supervised contrastive learning, 2020. URL <https://arxiv.org/abs/2004.11362>.
- [47] Kimi Team, Yu Zhang, Zongyu Lin, Xingcheng Yao, Jiaxi Hu, Fanqing Meng, Chengyin Liu, Xin Men, Songlin Yang, Zhiyuan Li, Wentao Li, Enzhe Lu, Weizhou Liu, Yanru Chen, Weixin Xu, Longhui Yu, Yejie Wang, Yu Fan, Longguang Zhong, Enming Yuan, Dehao Zhang, Yizhi Zhang, T. Y. Liu, Haiming Wang, Shengjun Fang, Weiran He, Shaowei Liu, Yiwei Li, Jianlin Su, Jiezhong Qiu, Bo Pang, Junjie Yan, Zhejun Jiang, Weixiao Huang, Bohong Yin, Jiacheng You, Chu Wei, Zhengtao Wang, Chao Hong, Yutian Chen, Guanduo Chen, Yucheng Wang, Huabin Zheng, Feng Wang, Yibo Liu, Mengnan Dong, Zheng Zhang, Siyuan Pan, Wenhao Wu, Yuhao Wu, Longyu Guan, Jiawen Tao, Guohong

- Fu, Xinran Xu, Yuzhi Wang, Guokun Lai, Yuxin Wu, Xinyu Zhou, Zhilin Yang, and Yulun Du. Kimi linear: An expressive, efficient attention architecture, 2025. URL <https://arxiv.org/abs/2510.26692>.
- [48] Günter Klambauer, Thomas Unterthiner, Andreas Mayr, and Sepp Hochreiter. Self-normalizing neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
 - [49] Timon Klein, Jonas Kusch, Sebastian Sager, Stefan Schnake, and Steffen Schotthöfer. Tucker attention: A generalization of approximate attention mechanisms, 2026. URL <https://arxiv.org/abs/2603.30033>.
 - [50] Xunhao Lai, Weiqi Xu, Yufeng Yang, Qiaorui Chen, Yang Xu, Lunbin Zeng, Xiaolong Li, Haohai Sun, Haichao Zhu, Vito Zhang, Jinkai Hu, Jiayao Li, Rui Gao, Zekun Li, Songquan Zhu, Jingkai Zhou, and Pengyu Zhao. Minimax sparse attention, 2026. URL <https://arxiv.org/abs/2606.13392>.
 - [51] Johannes Lederer. Activation functions in artificial neural networks: A systematic overview. *arXiv preprint arXiv:2101.09957*, 2021. doi: 10.48550/arXiv.2101.09957.
 - [52] Mike Lewis, Shruti Bhosale, Tim Dettmers, Douwe Kiela, and Luke Zettlemoyer. Base layers: Simplifying training of large, sparse models, 2021. URL <https://arxiv.org/abs/2103.16716>.
 - [53] Kaizhao Liang, Lizhang Chen, Bo Liu, and Qiang Liu. Cautious optimizers: Improving training with one line of code, 2024. URL <https://arxiv.org/abs/2411.16085>. Version Number: 4.
 - [54] Zhixuan Lin, Ke Wang, et al. Forgetting transformer: Softmax attention with a forget gate, 2025. URL <https://arxiv.org/abs/2503.02130>.
 - [55] Hong Liu, Zhiyuan Li, David Hall, Percy Liang, and Tengyu Ma. Sophia: A scalable stochastic second-order optimizer for language model pre-training, 2023. URL <https://arxiv.org/abs/2305.14342>. Version Number: 4.
 - [56] Liyuan Liu, Haoming Jiang, Pengcheng He, Weizhu Chen, Xiaodong Liu, Jianfeng Gao, and Jiawei Han. On the variance of the adaptive learning rate and beyond, 2019. URL <https://arxiv.org/abs/1908.03265>. Version Number: 4.
 - [57] Songtao Liu, Hongwu Peng, Zhiwei Zhang, Zhengyu Chen, and Yue Guo. Multi-head low-rank attention, 2026. URL <https://arxiv.org/abs/2603.02188>.
 - [58] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization, 2017. URL <https://arxiv.org/abs/1711.05101>. Version Number: 3.
 - [59] Tianyu Lou, Zheyu Chen, Tao Yu, et al. Efficient sparse attention for long-range transformers, 2024. URL <https://arxiv.org/abs/2406.16747>.
 - [60] Andrew L. Maas, Awni Y. Hannun, and Andrew Y. Ng. Rectifier nonlinearities improve neural network acoustic models. In *Proc. ICML Workshop on Deep Learning for Audio, Speech and Language Processing*, 2013.
 - [61] Sushant Mehta, Raj Dandekar, Rajat Dandekar, and Sreedath Panat. Latent multi-head attention for small language models, 2025. URL <https://arxiv.org/abs/2506.09342>.
 - [62] Fanxu Meng. Gqla: Group-query latent attention for hardware-adaptive large language model decoding, 2026. URL <https://arxiv.org/abs/2605.15250>.

- [63] Konstantin Mishchenko and Aaron Defazio. Prodigy: An expeditiously adaptive parameter-free learner, 2023. URL <https://arxiv.org/abs/2306.06101>. Version Number: 4.
- [64] Diganta Misra. Mish: A self regularized non-monotonic activation function. *arXiv preprint arXiv:1908.08681*, 2019.
- [65] Niklas Muennighoff et al. Matryoshka representation learning, 2022. URL <https://arxiv.org/abs/2205.13147>.
- [66] Vinod Nair and Geoffrey E. Hinton. Rectified linear units improve restricted Boltzmann machines. In *Proceedings of the 27th International Conference on Machine Learning (ICML)*, pages 807–814, 2010.
- [67] Christoffer Koo Øhrstrøm, Rafael I. Cabral Muchacho, Yifei Dong, Filippos Moutziddelīs, Ronja Gldenring, Florian T. Pokorny, and Lazaros Nalpantidis. Parabolic position encoding: Vision-centric, principled, extrapolatable, general, 2026. URL <http://arxiv.org/abs/2602.01418>.
- [68] Matteo Pagliardini, Pierre Ablin, and David Grangier. The AdEMAMix optimizer: Better, faster, older, 2024. URL <https://arxiv.org/abs/2409.03137>. Version Number: 2.
- [69] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kpf, Edward Yang, Zach DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems 32 (NeurIPS)*, pages 8024–8035, 2019.
- [70] Fabian Pedregosa, Gal Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [71] Raphael Pisoni. A few gaussians is all you need: Ssog-attention that steers instead of scores, 2026. URL <https://www.pisoni.ai/posts/ssog/>. Reference implementation: <https://github.com/4rtemi5/ssog>.
- [72] Boris T. Polyak. Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics*, 4(5):1–17, 1964. doi: 10.1016/0041-5553(64)90137-5.
- [73] Ofir Press, Noah A. Smith, and Mike Lewis. Train short, test long: Attention with linear biases enables input length extrapolation, 2022. URL <http://arxiv.org/abs/2108.12409>.
- [74] Zhen Qin, Xu Han, et al. Hgrn2: Gated linear rnns with state expansion, 2024. URL <https://arxiv.org/abs/2404.07904>.
- [75] Yuxiang Qiu, Qwen Team, et al. Gated attention for large language models, 2025. URL <https://arxiv.org/abs/2505.06708>.
- [76] Prajit Ramachandran, Barret Zoph, and Quoc V. Le. Searching for activation functions. In *arXiv preprint arXiv:1710.05941*, 2017.

- [77] Jason Ramapuram, Federico Danieli, Eeshan Dhekane, Floris Weers, Dan Busbridge, Pierre Ablin, Tatiana Likhomanenko, Jagrit Digani, Zijin Gu, Amitis Shidani, and Russ Webb. Theory, analysis, and best practices for sigmoid self-attention, 2024. URL <https://arxiv.org/abs/2409.04431>. Version Number: 2.
- [78] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks, 2019. URL <http://arxiv.org/abs/1908.10084>.
- [79] Susmita Roy, Souvik Manna, Subhash Bagui, et al. LiSHT: Non-parametric linearly scaled hyperbolic tangent activation function for neural networks. *arXiv preprint arXiv:1811.05870*, 2019.
- [80] Hema Hariharan Samson. Lightweight transformer architectures for edge devices in real-time applications, 2026. URL <http://arxiv.org/abs/2601.03290>.
- [81] Noam Shazeer. GLU variants improve transformer. *arXiv preprint arXiv:2002.05202*, 2020.
- [82] Noam Shazeer and Mitchell Stern. Adafactor: Adaptive learning rates with sublinear memory cost, 2018. URL <https://arxiv.org/abs/1804.04235>. Version Number: 1.
- [83] Wei Shen, Ruichuan Huang, Minhui Huang, Cong Shen, and Jiawei Zhang. On the convergence analysis of muon, 2025. URL <https://arxiv.org/abs/2505.23737>. Version Number: 1.
- [84] Rafael Soares et al. Griffin: Mixing gated linear recurrences with local attention for efficient sequence modeling, 2024. URL <https://arxiv.org/abs/2402.19427>.
- [85] Rupesh Kumar Srivastava, Klaus Greff, and Jürgen Schmidhuber. Training very deep networks. In *Advances in Neural Information Processing Systems*, volume 28. Curran Associates, Inc., 2015. URL https://proceedings.neurips.cc/paper_files/paper/2015/hash/a58f4765a99bf77336cf034926677066-Abstract.html.
- [86] Jianlin Su, Yu Lu, Shengfeng Pan, Ahmed Murtadha, Bo Wen, and Yunfeng Liu. RoFormer: Enhanced transformer with rotary position embedding, 2024. URL <http://arxiv.org/abs/2104.09864>.
- [87] Luoyang Sun, Cheng Deng, Jiwen Jiang, Xinjian Wu, Haifeng Zhang, Lei Chen, Lionel Ni, and Jun Wang. Gta: Grouped-head latent attention, 2025. URL <https://arxiv.org/abs/2506.17286>.
- [88] Yutao Sun, Li Dong, Shaohan Huang, Shuming Ma, Yuqing Xia, Jilong Xue, Jianyong Wang, and Furu Wei. Retentive network: A successor to transformer for large language models, 2023. URL <https://arxiv.org/abs/2307.08621>. Version Number: 4.
- [89] Yutao Sun et al. Attention residuals. URL <http://arxiv.org/abs/2603.15031>.
- [90] Shohei Taniguchi, Keno Harada, Gouki Minegishi, Yuta Oshima, Seong Cheol Jeong, Go Nagahara, Tomoshi Iiyama, Masahiro Suzuki, Yusuke Iwasawa, and Yutaka Matsuo. ADOPT: Modified adam can converge with any β_2 with the optimal rate, 2024. URL <https://arxiv.org/abs/2411.02853>. Version Number: 3.
- [91] Ludovic Trottier, Philippe Giguère, and Brahim Chaib-draa. Parametric exponential linear unit for deep convolutional neural networks. In *Proceedings of the 16th IEEE International Conference on Machine Learning and Applications (ICMLA)*, pages 207–214, 2017. doi: 10.1109/ICMLA.2017.0-133.

- [92] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2017. URL <https://arxiv.org/abs/1706.03762>. Version Number: 7.
- [93] Nikhil Vyas, Depen Morwani, Rosie Zhao, Mujin Kwun, Itai Shapira, David Brandfonbrenner, Lucas Janson, and Sham Kakade. SOAP: Improving and stabilizing shampoo using adam, 2024. URL <https://arxiv.org/abs/2409.11321>. Version Number: 2.
- [94] Hongyu Wang, Shuming Ma, Li Dong, Shaohan Huang, Huaijie Wang, Lingxiao Ma, Fan Yang, Ruiping Wang, Yi Wu, and Furu Wei. BitNet: Scaling 1-bit transformers for large language models, 2023. URL <http://arxiv.org/abs/2310.11453>.
- [95] Zhe Wang, Ming Liu, et al. Fasa: Frequency-aware sparse attention, 2026. URL <https://arxiv.org/abs/2602.03152>.
- [96] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, and Alexander M. Rush. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (EMNLP)*, pages 38–45, 2020.
- [97] Xingyu Xie, Pan Zhou, Huan Li, Zhouchen Lin, and Shuicheng Yan. Adan: Adaptive nesterov momentum algorithm for faster optimizing deep models, 2022. URL <https://arxiv.org/abs/2208.06677>. Version Number: 5.
- [98] Zhenda Xie, Yixuan Wei, Huanqi Cao, Chenggang Zhao, Chengqi Deng, Jiashi Li, Damai Dai, Huazuo Gao, Jiang Chang, Kuai Yu, Liang Zhao, Shangyan Zhou, Zhean Xu, Zhengyan Zhang, Wangding Zeng, Shengding Hu, Yuqing Wang, Jingyang Yuan, Lean Wang, and Wenfeng Liang. mhc: Manifold-constrained hyper-connections, 2025. URL <https://arxiv.org/abs/2512.24880>.
- [99] Songlin Yang, Bailin Wang, et al. Gated linear attention transformers with hardware-efficient training, 2023. URL <https://arxiv.org/abs/2312.06635>.
- [100] Songlin Yang, Bailin Wang, et al. Parallelizing linear transformers with the delta rule over sequence length, 2024. URL <https://arxiv.org/abs/2406.06484>.
- [101] Songlin Yang, Bailin Wang, et al. Gated delta networks: Improving mamba2 with delta rule, 2024. URL <https://arxiv.org/abs/2412.06464>.
- [102] Yang You, Jing Li, Sashank Reddi, Jonathan Hseu, Sanjiv Kumar, Srinadh Bhojanapalli, Xiaodan Song, James Demmel, and Cho-Jui Hsieh. Large batch optimization for deep learning: Training BERT in 76 minutes, 2020. URL <https://arxiv.org/abs/1904.00962>. Version Number: 3.
- [103] Han Yuan, DeepSeek-AI, et al. Native sparse attention: Hardware-aligned and natively trainable sparse attention, 2025. URL <https://arxiv.org/abs/2502.11089>.
- [104] Huizhuo Yuan, Yifeng Liu, Shuang Wu, Xun Zhou, and Quanquan Gu. MARS: Unleashing the power of variance reduction for training large models, 2024. URL <https://arxiv.org/abs/2411.10438>. Version Number: 4.

- [105] Manzil Zaheer, Guru Guruganesh, Kumar Avinava Dubey, Joshua Ainslie, Chris Alberti, Santiago Ontanon, Pike Pham, Anirudh Ravula, Qifan Wang, Li Yang, and Amr Ahmed. Big bird: Transformers for longer sequences. In *Advances in Neural Information Processing Systems*, 2020. doi: 10.48550/ARXIV.2007.14062. URL <https://arxiv.org/abs/2007.14062>.
- [106] Abbas Zeitoun, Lucas Torroba-Hennigen, and Yoon Kim. Hyperloop transformers, 2026. URL <https://arxiv.org/abs/2604.21254>.
- [107] Biao Zhang and Rico Sennrich. Root Mean Square Layer Normalization, 2019. URL <http://arxiv.org/abs/1910.07467>.
- [108] Jing Zhang, Peng Zhang, Baiwen Kong, Junqiu Wei, and Xin Jiang. Continuous self-attention models with neural ODE networks. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(16):14393–14401, 2021. ISSN 2374-3468, 2159-5399. doi: 10.1609/aaai.v35i16.17692. URL <https://ojs.aaai.org/index.php/AAAI/article/view/17692>.
- [109] Yichi Zhang, Yizhong Wang, et al. Accurate and training-free sparse attention accelerating any model inference, 2025. URL <https://arxiv.org/abs/2502.18137>.
- [110] Yifan Zhang, Steve Ta, Jasper Zhang, Jichen Feng, Shuzhen Li, Yongxin Zhang, Yifeng Liu, Huizhuo Yuan, Mengdi Wang, Quanquan Gu, and Andrew Chi-Chih Yao. Fast weight attention for continual learning, 2026. URL <https://arxiv.org/abs/2608.27763>.
- [111] Jiawei Zhao, Zhenyu Zhang, Beidi Chen, Zhangyang Wang, Anima Anandkumar, and Yuandong Tian. GaLore: Memory-efficient LLM training by gradient low-rank projection, 2024. URL <https://arxiv.org/abs/2403.03507>. Version Number: 2.
- [112] Hanqing Zhu, Zhenyu Zhang, Wenyan Cong, Xi Liu, Sem Park, Vikas Chandra, Bo Long, David Z. Pan, Zhangyang Wang, and Jinwon Lee. Apollo: Sgd-like memory, adamw-level performance, 2025. URL <https://arxiv.org/abs/2412.05270>.
- [113] Jiachen Zhu, Xinlei Chen, Kaiming He, Yann LeCun, and Zhuang Liu. Transformers without normalization, 2025. URL <http://arxiv.org/abs/2503.10622>.
- [114] Lianghui Zhu, Yuxin Fang, Bencheng Liao, Shijie Wang, Tianheng Cheng, Zilong Huang, Chen Chen, Lai Wei, Yutao Zeng, Ya Wang, Yi Lin, Yu Li, and Xinggang Wang. Mixture-of-depths attention, 2026. URL <https://arxiv.org/abs/2603.15619>.

1. Introducción Conceptual—Transformers y Atención para Principiantes

Este apéndice proporciona una introducción accesible a los conceptos fundamentales de los transformers y el mecanismo de atención, dirigido a lectores sin conocimientos profundos previos en aprendizaje profundo. Los transformers son el motor detrás de los sistemas modernos de inteligencia artificial como ChatGPT, pero su funcionamiento puede entenderse mediante analogías del mundo real.

1.1. ¿Qué es un Transformer?

Un transformer es una arquitectura neuronal que procesa texto o secuencias de datos interpretando el significado de cada palabra mientras considera todas las demás palabras en contexto. Imagina que lees una oración:

“El banco estaba lleno de gente esperando. María fue al banco.”

¿Qué significa “banco” en cada caso? En la primera oración, se refiere a una institución financiera (o un asiento). En la segunda, no está claro sin contexto. Un transformer resuelve esto automáticamente al mirar todas las palabras circundantes. En la segunda oración, al ver “María fue”, el modelo comprende mejor que probablemente se trata de una ribera (donde va a nadar) o una institución financiera (donde va a realizar una transacción).

Esta capacidad de entender el significado completo de una palabra considerando toda la oración se llama *contextualización*, y es el corazón de cómo funcionan los transformers modernos.

1.2. El Mecanismo de Atención: Una Analogía

El mecanismo de atención es el “truco mágico” que permite a los transformers entender el contexto. Piensa en ello como participar en una conversación importante en una habitación ruidosa:

1. **Mucho ruido:** Alguien está hablando y es muy importante para ti.
2. **Ignoras el resto:** Tu cerebro automáticamente enfoca la atención en esa persona, ignorando otros sonidos.
3. **Entiendes mejor:** Al concentrarte, captas cada palabra claramente.

El mecanismo de atención neuronal funciona de la misma manera: cada palabra “pregunta” qué tan importante es cada otra palabra para entender su significado, luego “enfoca” su atención en las más relevantes.

1.3. Ejemplo Práctico Paso a Paso

Veamos cómo un transformer entiende la palabra “come” en dos contextos diferentes:

1.3.1. Contexto 1: “El gato come pescado”

El transformer, al procesar “come”, pregunta internamente:

- ¿Qué tan relevante es “El”? Poco (es solo un artículo). **Atención baja.**
- ¿Qué tan relevante es “gato”? Muy relevante (es el sujeto, quien come). **Atención alta.**
- ¿Qué tan relevante es “pescado”? Muy relevante (es lo que se come). **Atención alta.**

Por lo tanto, la representación mental de “come” se enfoca principalmente en “gato” y “pescado”.

1.3.2. Contexto 2: “El restaurante come los márgenes de beneficio”

Aquí el transformer pregunta en un contexto diferente:

- ¿Qué tan relevante es “restaurante”? Muy relevante (es el sujeto). **Atención alta.**
- ¿Qué tan relevante es “beneficio”? Muy relevante (se ve afectado). **Atención alta.**
- ¿Qué tan relevante es “márgenes”? Muy relevante (es lo que se consume). **Atención alta.**

La palabra “come” obtiene una representación completamente diferente porque “atiende” a palabras distintas en contextos distintos.

1.4. Cómo Funciona la Atención Matemáticamente (Versión Simple)

Detrás del cambio de atención hay matemáticas. Aquí está la versión simplificada sin demasiado detalle técnico:

1.4.1. Paso 1: Consultas, Claves y Valores

Cada palabra en la oración se transforma en tres versiones:

- **Consulta:** “¿Qué información necesito saber?”
- **Clave:** “¿Qué información tengo?”
- **Valor:** “Aquí está mi información importante.”

Imagina en una biblioteca, cada visitante es una “consulta”, cada libro es una “clave” y el contenido es el “valor”. El bibliotecario (atención) empareja las consultas con las claves más relevantes para acceder al valor correcto.

1.4.2. Paso 2: Compatibilidad

El sistema examina qué tan *compatible* es cada consulta con cada clave. Las consultas similares a las claves obtienen un puntaje de compatibilidad *alto*. Esto se calcula multiplicando la consulta por la clave (matemáticamente, el producto punto).

1.4.3. Paso 3: Enfoque

Los puntajes de compatibilidad se convierten en “pesos de enfoque”. Las compatibilidades altas significan “enfocar atención aquí”, y las bajas significan “ignorar esto”. Matemáticamente, una función llamada **softmax** convierte los puntajes en porcentajes (como: 40 % atención aquí, 35 % aquí, 25 % allá).

1.4.4. Paso 4: Combinar

Finalmente, el sistema combina todos los valores, ponderados por los pesos de enfoque. Si una palabra tiene un 80 % de atención en el sujeto, el 80 % de la información del sujeto se mezcla en la representación de esa palabra.

1.5. Múltiples Cabezas de Atención: Múltiples Perspectivas

Una característica clave es que los transformers no usan una única atención sino *múltiples cabezas de atención* en paralelo. Es como si tuvieras 8 personas analizando la oración *simultáneamente*, cada una prestando atención a diferentes aspectos:

- **Persona 1:** “Me enfoco en las relaciones sujeto-verbo.”
- **Persona 2:** “Busco el objeto directo.”
- **Persona 3:** “Sigo la información sobre el tiempo verbal.”
- **Persona 4:** “Busco modificadores y adjetivos.”

Cada “cabeza” aprende a enfocarse en diferentes patrones del lenguaje. Juntas, capturan una comprensión mucho más rica que una sola cabeza.

1.6. Apilar Capas

Los transformers procesan información en *múltiples capas* (generalmente de 12 a 48 para modelos prácticos). Imagina editar un ensayo:

1. **Primera pasada:** Corrige ortografía y gramática básica.
2. **Segunda pasada:** Mejora la claridad y la estructura de las oraciones.
3. **Tercera pasada:** Asegura consistencia y flujo narrativo.

Los transformers funcionan de la misma manera: cada capa refina la comprensión del texto. La primera capa captura características básicas (palabras simples, géneros), mientras que las capas posteriores entienden conceptos complejos (relaciones entre palabras, significados abstractos).

1.7. ¿Por Qué es Importante?

El mecanismo de atención fue revolucionario porque:

1. **Paralelismo:** Encuentra contexto para *cualquier palabra con cualquier otra palabra*, sin procesarlas secuencialmente (a diferencia de sistemas anteriores). Esto lo hace muy rápido.
2. **Flexibilidad:** Aprende qué patrones buscar automáticamente a partir de los datos, sin necesidad de programar reglas manualmente.
3. **Escalabilidad:** Funciona desde textos pequeños hasta contextos con millones de palabras.
4. **Capacidades generales:** El mismo mecanismo funciona para traducción, resumen, preguntas-respuestas, generación de texto, visión por computadora y más.

1.8. Desafíos Prácticos

A pesar del extraordinario éxito de los transformers, presentan desafíos:

1.8.1. Complejidad Computacional

Si una oración tiene 1,000 palabras, el mecanismo de atención estándar debe comparar cada palabra con las otras 1,000 palabras. Eso es $1,000 \times 1,000 = 1,000,000$ de comparaciones. Para documentos largos con millones de palabras, esto se vuelve prohibitivamente costoso en tiempo y memoria.

1.8.2. Requisitos de Memoria

Especialmente durante la inferencia (cuando se usan modelos entrenados), almacenar la matriz de atención completa puede consumir enormes cantidades de RAM o memoria de GPU, limitando las longitudes de secuencia que se pueden procesar.

1.8.3. Eficiencia del Dispositivo

Los transformers fueron diseñados para TPUs y GPUs potentes. Ejecutarlos en teléfonos o dispositivos integrados es un desafío.

1.9. Soluciones Modernas

Para resolver estos desafíos, la investigación ha propuesto muchas variantes:

- **Atención Dispersa:** En lugar de comparar cada palabra con TODAS las demás, compara solo con un subconjunto estratégico (vecinos cercanos, patrones periódicos). Reduce la complejidad de $\mathcal{O}(n^2)$ a $\mathcal{O}(n \log n)$ o $\mathcal{O}(n)$.
- **Modelos Recurrentes:** Como Mamba, incorporan aspectos de las antiguas redes neuronales recurrentes pero con mejor eficiencia moderna.
- **Atención con Compuerta:** Mecanismos que aprenden selectivamente qué información pasar hacia adelante, reduciendo las necesidades de almacenamiento.
- **Cuantización:** Usar números más pequeños (enteros en lugar de decimales) para reducir la memoria sin perder demasiada precisión.

Estas innovaciones son lo que este kit de herramientas (Frankenstein) te permite experimentar fácilmente.

1.10. Conclusiones Clave

- Un **transformer** es una red neuronal que entiende el contexto del lenguaje muy bien.
- El **mecanismo de atención** permite que cada palabra “se enfoque” en qué otras palabras son relevantes para entender su significado.
- La atención funciona calculando la **compatibilidad** entre cada palabra (consulta) y todas las demás (claves), luego combinando información basada en esa compatibilidad (valores).
- **Múltiples cabezas** de atención exploran diferentes patrones en paralelo.
- **Múltiples capas** refinan progresivamente la comprensión.
- El principal desafío es que la atención estándar tiene complejidad cuadrática, lo que es costoso para textos largos.
- Muchas **soluciones modernas** (atención dispersa, modelos recurrentes, cuantización) abordan estos desafíos, y este kit de herramientas te permite explorarlas todas.

2. Estructura del Esquema de Configuración

El conjunto de herramientas Frankenstein Transformer impone un esquema de configuración YAML estricto con `additionalProperties: false` en todos los niveles. El esquema se define en `src/schema.yaml`, que referencia sub-esquemas modulares en `src/schema/`. Cada campo configurable debe declararse en el esquema; las claves no reconocidas se rechazan en tiempo de validación. Este anexo documenta la estructura completa del esquema, incluyendo todos los campos, sus tipos, restricciones y reglas de validación entre componentes.

2.1. Estructura de Nivel Superior

El objeto raíz del esquema tiene cinco propiedades de nivel superior. Todas son opcionales excepto `training`, que es obligatorio:

- `base_model` (string) — Identificador de modelo HuggingFace o ruta local para preentrenamiento continuo o ajuste fino SBERT. Cuando se establece, `model_class` y `model` no son obligatorios (la arquitectura se infiere del checkpoint).

- `tokenizer` (object) — Configuración del tokenizador, disponible tanto para la ruta `base_model` como para modelos personalizados desde cero. Dos modos se seleccionan mediante `source`: `hf_repo` (por defecto) carga un tokenizador preentrenado desde `name_or_path`; `train_from_dataset` entrena un tokenizador nuevo desde el texto del dataset (ver §2.4). Obligatorio cuando se usa `base_model` con la tarea `mlm`.
- `model_class` (enum) — Variante de arquitectura del modelo: `frankenstein` (codificador de arquitectura mixta) o `franksteindencoder` (decodificador causal autorregresivo). Obligatorio cuando `base_model` no está establecido.
- `model` (object) — Parámetros de arquitectura del modelo (ver §2.2). Obligatorio cuando `base_model` no está establecido.
- `training` (object, **obligatorio**) — Configuración de entrenamiento (ver §2.3).

El esquema impone una regla de exclusión mutua: o bien `base_model` debe estar presente, o bien tanto `model_class` como `model` deben estar presentes.

2.2. Configuración del Modelo

El objeto `model` define todos los hiperparámetros arquitectónicos. Los campos obligatorios son `dims.vocab_size`, `dims.hidden_size`, `dims.num_layers`, `dims.num_heads` y `dims.layer_pattern`. La Tabla 1 enumera todos los campos del modelo con sus tipos y descripciones.

Campo	Tipo	Descripción
<i>model.dims.*</i>		
<code>dims.mode</code>	enum (encoder, decoder)	Modo de enmascaramiento de atención: <code>encoder</code> = bidireccional; <code>decoder</code> = causal.
<code>dims.vocab_size</code>	int ≥ 1 (obligatorio)	Número de tokens únicos en el vocabulario. Debe coincidir con el tamaño de vocabulario del tokenizador.
<code>dims.hidden_size</code>	int ≥ 1 (obligatorio)	Dimensión oculta. Debe ser divisible por <code>num_heads</code> . Típico: 512–2048.
<code>dims.num_layers</code>	int ≥ 1 (obligatorio)	Número de capas físicas del transformador. Típico: 6–24.
<code>dims.num_loops</code>	int ≥ 1	Número de bucles lógicos. Cada capa física ejecuta <code>num_loops</code> veces <code>layer_pattern</code> . Por defecto: 1.
<code>dims.num_heads</code>	int ≥ 1 (obligatorio)	Número de cabezas de atención por capa. Debe dividir <code>hidden_size</code> exactamente.
<code>dims.retention_heads</code>	int ≥ 1	Número de cabezas para capas Retention. Debe dividir <code>hidden_size</code> exactamente.
<code>dims.dropout</code>	float [0,1]	Tasa de dropout global. Típico: 0.1 (como en BERT).
<code>dims.layer_pattern</code>	array of enum (obligatorio)	Secuencia ordenada de tipos de capas. La longitud debe igualar <code>num_layers</code> . Más de 3 tipos de capas mezclados disponibles (ver Tabla 2).
<i>model.norm.*</i>		
<code>norm.type</code>	enum	Estrategia de normalización: <code>layer_norm</code> , <code>dynamic_tanh</code> , <code>derf</code> , <code>rms_norm</code> , <code>prn</code> .
<code>norm.partial_ratio</code>	float (0,1]	Fracción de dimensiones ocultas para <code>prn</code> y <code>pRMSNorm</code> . Por defecto: 0.0625.

continúa en la p

Campo	Tipo	Descripción
<i>model.embedding.factorized.*</i>		
<code>embedding.factorized.enabled</code>	bool	Activar factorización de matriz de embeddings para reducir parámetros.
<code>embedding.factorized.dim</code>	$\text{int} \geq 1$	Dimensión intermedia para embeddings factorizados. Típico: 64–256.
<i>model.embedding.conv.*</i>		
<code>embedding.conv.enabled</code>	bool	Aplicar Conv1d sobre embeddings para capturar patrones locales de n-gramas.
<code>embedding.conv.kernel</code>	$\text{int} \geq 1$	Tamaño de kernel para Conv1d de embeddings. Típico: 3.
<i>model.attention.titan.*</i>		
<code>attention.titan.positional_encoding</code>	enum (hope, rope)	Método de codificación posicional para Titan. titan_attn .
<code>attention.titan.use_hope</code>	bool	Bandera heredada para HoPE en Titan. Obsoleta; preferir positional_encoding .
<code>attention.titan.hope.base</code>	$\text{float} \geq 0$	Escala de frecuencia base para HoPE. Típico: 10000.
<code>attention.titan.hope.damping</code>	$\text{float} \geq 0$	Coefficiente de amortiguación para HoPE. Típico: 0.01.
<code>attention.titan.rope.base</code>	$\text{float} \geq 0$	Frecuencia base para RoPE. Típico: 10000.
<code>attention.titan.rope.scaling</code>	$\text{float} \geq 0$	Multiplicador para índices de posición. Típico: 1.0.
<i>model.attention.mla.*</i>		
<code>attention.mla.latent_rank</code>	$\text{int} \geq 1$	Rango del latente KV conjunto para MLA. Por defecto: <code>hidden_size // 2</code> .
<i>model.attention.gqla.*</i>		
<code>attention.gqla.latent_rank</code>	$\text{int} \geq 1$	Rango del latente KV conjunto para GQLA. Por defecto: <code>hidden_size // 2</code> .
<code>attention.gqla.num_groups</code>	$\text{int} \geq 1$	Número de grupos GQA para la ruta de decodificación GQLA. Debe dividir <code>latent_rank</code> .
<code>attention.gqla.decode_path</code>	enum (mq_a_absorb, gqa)	Ruta de decodificación para GQLA. Típico: <code>mq_a_absorb</code> .
<i>model.attention.mlra.*</i>		
<code>attention.mlra.latent_rank</code>	$\text{int} \geq 1$	Rango latente total para MLRA. Por defecto: <code>hidden_size // 2</code> .
<code>attention.mlra.num_latent_heads</code>	$\text{int} \geq 1$	Número de sub-espacios latentes para MLRA. Por defecto: 4.
<i>model.attention.tucker.*</i>		
<code>attention.tucker.query_rank</code>	$\text{int} \geq 1$	Rango Tucker para el tensor de pesos de consulta. Por defecto: <code>hidden_size</code> .
<code>attention.tucker.key_rank</code>	$\text{int} \geq 1$	Rango Tucker para el tensor de pesos de clave. Por defecto: <code>hidden_size // 2</code> .

continúa en la p

Campo	Tipo	Descripción
<code>attention.tucker.value_rank</code>	<code>int</code> ≥ 1	Rango Tucker para el tensor de peso. Por defecto: <code>hidden_size // 2</code> .
<i>model.attention.iha.*</i>		
<code>attention.iha.num_pseudo_heads</code>	<code>int</code> ≥ 1	Número de pseudo-cabezas por cabeza. Por defecto: <code>num_heads</code> .
<i>model.attention.gta.*</i>		
<code>attention.gta.num_shared_groups</code>	<code>int</code> ≥ 1	Número de grupos de cabezas que comparten el mapa de atención para GTA. Debe ser divisor de <code>num_heads</code> .
<code>attention.gta.value_latent_rank</code>	<code>int</code> ≥ 1	Rango del latente de caché de valores. Por defecto: <code>hidden_size // 2</code> .
<i>model.attention.mtla.*</i>		
<code>attention.mtla.latent_rank</code>	<code>int</code> ≥ 1	Rango latente para MTLA. Por defecto: <code>hidden_size // 2</code> .
<code>attention.mtla.merge_factor</code>	<code>int</code> ≥ 1	Número de entradas KV consecutivas por slot temporal. Por defecto: 2.
<code>attention.mtla.stride</code>	<code>int</code> ≥ 1	Stride entre slots temporales fusionados. Por defecto: <code>mtla_merge_factor</code> .
<i>model.attention.cca.*</i>		
<code>attention.cca.latent_rank</code>	<code>int</code> ≥ 1	Ancho latente para CCA. Por defecto: <code>hidden_size // 4</code> . Debe ser divisible por <code>num_heads</code> .
<code>attention.cca.num_conv_layers</code>	<code>enum</code> (0, 1, 2)	Número de capas de convolución en CCA. Por defecto: 2.
<code>attention.cca.conv_kernel_seq</code>	<code>int</code> ≥ 1	Tamaño de kernel de convolución causal depth-wise de secuencia. Por defecto: 3.
<code>attention.cca.conv_kernel_ch</code>	<code>int</code> ≥ 1	Tamaño de kernel de convolución aglutinada de canales por cabeza. Por defecto: 3.
<code>attention.cca.qk_mean</code>	<code>bool</code>	Activar sesgo q-k-mean en CCA. Por defecto: <code>true</code> .
<code>attention.cca.value_shift</code>	<code>bool</code>	Activar value-shift en CCA. Por defecto: <code>false</code> .
<i>model.attention.ccgqa.*</i>		
<code>attention.ccgqa.query_latent_rank</code>	<code>int</code> ≥ 1	Ancho latente de consulta para CCGQA. Por defecto: <code>hidden_size // 2</code> .
<code>attention.ccgqa.kv_latent_rank</code>	<code>int</code> ≥ 1	Ancho latente KV para CCGQA. Por defecto: <code>hidden_size // 8</code> .
<code>attention.ccgqa.num_kv_heads</code>	<code>int</code> ≥ 1	Número de cabezas KV para CCGQA. Debe dividir <code>num_heads</code> .
<code>attention.ccgqa.num_conv_layers</code>	<code>enum</code> (0, 1, 2)	Número de capas de convolución en CCGQA. Por defecto: 2.
<code>attention.ccgqa.conv_kernel_seq</code>	<code>int</code> ≥ 1	Tamaño de kernel de convolución causal depth-wise de secuencia. Por defecto: 3.
<code>attention.ccgqa.conv_kernel_ch</code>	<code>int</code> ≥ 1	Tamaño de kernel de convolución aglutinada de canales por cabeza. Por defecto: 3.

continúa en la p.

Campo	Tipo	Descripción
<code>attention.ccgqa.qk_mean</code>	bool	Activar sesgo q-k-mean en CCGQA. Por defecto: true .
<code>attention.ccgqa.value_shift</code>	bool	Activar value-shift en CCGQA. Por defecto: false .
<i>model.attention.msa.*</i>		
<code>attention.msa.block_size</code>	int ≥ 1	Tamaño de bloque para MiniMax Scaled Dot-Product Attention. Por defecto: 128.
<code>attention.msa.topk_blocks</code>	int ≥ 1	Número de bloques seleccionados por consulta. Por defecto: 16.
<code>attention.msa.index_dim</code>	int ≥ 1	Dimensionalidad de las cabezas de índice. Por defecto: 64.
<code>attention.msa.kl_loss_weight</code>	float ≥ 0	Peso de la pérdida de alineación KL entre los índices MSA. Por defecto: 0.0.
<i>model.attention.sparda.*</i>		
<code>attention.sparda.block_size</code>	int ≥ 1	Tamaño de bloque KV para SparDA. Por defecto: 128.
<code>attention.sparda.topk_blocks</code>	int ≥ 1	Número de bloques KV seleccionados por consulta. Por defecto: 16.
<code>attention.sparda.forecast_dim</code>	int ≥ 1	Dimensionalidad de la proyección F. Por defecto: 64.
<i>model.attention.engram.*</i>		
<code>attention.engram.max_ngram_size</code>	int ≥ 2	Tamaño máximo de N-grama para memoria Engram.
<code>attention.engram.n_heads_per_ngram</code>	int ≥ 1	Número de cabezas hash por orden de N-gramas.
<code>attention.engram.embed_dim_per_head</code>	int ≥ 1	Dimensión de embedding por cabeza.
<code>attention.engram.kernel_size</code>	int ≥ 1	Ancho de kernel de convolución de memoria para Engram.
<code>attention.engram.seed</code>	int	Semilla aleatoria para multiplicador de memoria N-gramas.
<i>model.mhc.*</i>		
<code>mhc.enabled</code>	bool	Activar el flujo residual de n stream por variedad (mHC, arXiv:2512.248). Por defecto: false .
<code>mhc.expansion_rate</code>	int ≥ 1	Factor de expansión del flujo residual. El flujo residual pasa a ser $n \times \text{hidden_size}$. 1 recupera la identidad. Por defecto: 4.
<code>mhc.sinkhorn_iters</code>	int ≥ 1	Rondas de normalización Sinkhorn-restringen H^{res} a ser doblemente espectral. Por defecto: 20.
<code>mhc.gating_init</code>	float > 0	Valor inicial de los escalares de gating. Por defecto: 0.01.
<code>mhc.checkpoint</code>	bool	Gradient checkpointing en capas mhc para mitigar el aumento de $\sim n \times$ en memoria. Por defecto: false .
<code>mhc.full_prec_under_bitnet</code>	bool	Mantener la proyección de coeficientes de precisión completa bajo BitNet. Por defecto: false .

continúa en la p.

Campo	Tipo	Descripción
<i>model.* (nivel superior plano)</i>		
<code>use_moe</code>	bool	Activar Mezcla de Expertos en capa
<code>num_experts</code>	int ≥ 1	Número total de redes expertas en c Requiere <code>use_moe=true</code> .
<code>top_k_experts</code>	int ≥ 1	Número de expertos activados por t Debe ser $\leq$ <code>num_experts</code> .
<code>use_bitnet</code>	bool	Activar cuantización ternaria de pes Por defecto: <code>true</code> .
<code>bitnet_routers</code>	bool	Cuantizar también proyecciones de enrutamiento/puntuación. Requiere <code>use_bitnet=true</code> . Por defecto: <code>false</code> .
<code>use_bitnet_conv</code>	bool	Cuantizar Conv1d de embedding co Requiere <code>use_bitnet=true</code> y <code>embedding.conv.enabled=true</code> . Po <code>false</code> .
<code>use_mixture_of_depths</code>	bool	Activar enrutamiento de tokens Mixture-of-Depths.
<code>mixture_of_depths_capacity_ratio</code>	float (0,1]	Fracción de tokens actualizados por
<code>mixture_of_depths_router_aux_loss_weight</code>	float ≥ 0	Peso para la pérdida auxiliar del en
<code>ffn_hidden_size</code>	int ≥ 1	Dimensión intermedia de capas feed Típico: $4 \times$ <code>hidden_size</code> .
<code>ffn_activation</code>	enum (silu, gelu)	Activación no lineal para capas FFM
<code>ffn_activation_config</code>	object	Parámetros anidados para activacio (grados/versión/init de RAF, init P
<code>ode_solver</code>	enum (rk4, euler)	Método de integración numérica pa
<code>ode_steps</code>	int ≥ 1	Número de pasos de integración par Típico: 2–4.

Cuadro 1: Campos completos de configuración del modelo.
Todos los campos son opcionales a menos que se indique como obligatorio.

Los campos se agrupan bajo sub-objetos jerárquicos (`dims`, `norm`, `embedding.factorized`, `embedding.conv`, `attention.titan`, `attention.mla`, `attention.gqla`, etc.); cada fila de sub-encabezado marca el prefijo vigente para las filas que le siguen. Los campos listados bajo `model.*` permanecen como claves planas de nivel superior.

2.2.1. Enumeración del Patrón de Capas

El array `model.dims.layer_pattern` acepta los siguientes 36 tipos de mezclador. Cada elemento define una capa física en la pila del modelo. La Tabla 2 enumera todos los tipos disponibles con su soporte de entrenamiento e inferencia.

Tipo	Descripción	Entrenar	Infer
<code>standard_attn</code>	Atención multi-cabeza clásica (estilo BERT)	✓	✓
<code>sigmoid_attn</code>	Atención con compuerta sigmoide	✓	✓

continúa en la página siguiente

Tipo	Descripción	Entrenar	Infer
<code>gated_softmax_attn</code>	Atención softmax con compuerta sigmoide post-SDPA	✓	✓
<code>titan_attn</code>	Atención Titan con codificación posicional (HoPE/RoPE)	✓	✓
<code>retnet / retnet_attn</code>	Red de Retención (híbrido RNN+transformer)	✓	✓
<code>mamba</code>	Modelo de espacio de estado selectivo (SSM)	✓	✓
<code>ode</code>	Capa ODE de profundidad continua	✓	✓
<code>gla_attn</code>	Atención Lineal con Compuerta con decaimiento multiplicativo	✓	✓
<code>deltanet_attn / gated_deltanet_attn</code>	DeltaNet con regla delta correctiva	✓	✓
<code>gated_deltanet2_attn</code>	Gated DeltaNet-2 con compuertas de borrado/escritura canalizadas desacopladas	✓	✓
<code>hgrn2_attn</code>	HGRN2 con compuertas de olvido jerárquicas	✓	✓
<code>fox_attn</code>	Forgetting Transformer (FoX) con sesgo de olvido en logits	✓	✓
<code>nsa_attn</code>	Native Sparse Attention (tres ramas)	✓	✓
<code>engram_attn</code>	Búsqueda condicional de memoria de N-gramas	✓	✓
<code>gqa_attn</code>	Atención por Consultas Agrupadas con cabezas KV configurables	✓	✓
<code>longformer_attn</code>	Longformer: ventanas deslizantes + tokens globales	✓	✓
<code>bigbird_attn</code>	BigBird: atención local + aleatoria + global	✓	✓
<code>sparse_transformer_attn</code>	Sparse Transformer: patrones factorizados	✓	✓
<code>sparsek_attn</code>	SparseK: selección KV top-k diferenciable	✓	✓
<code>sparge_attn</code>	SpargeAttn — poda de bloques en dos etapas	×	✓
<code>fasa_attn</code>	FASA — selección de tokens consciente de frecuencia	×	✓
<code>msa_attn</code>	MiniMax Sparse Attention — bloques dispersos sobre GQA	✓	✓
<code>sparda_attn</code>	SparDA — atención dispersa desacoplada con proyección Forecast	✓	✓
<code>kda_attn</code>	Kimi Delta Attention — decaimiento por canal + compuerta de escritura escalar	✓	✓

continúa en la página siguiente

Tipo	Descripción	Entrenar	Infer
falcon1_attn / falcon2_attn / falcon3_attn	Familia de regresión Falcon — regla delta NLMS prefix-alineada (RAW)	✓	✓
falcon1a_attn / falcon2a_attn / falcon3a_attn	Familia de producto interno Falcon — escrituras aditivas desplazadas con decaimiento por ridge	✓	✓
m1a_attn	Atención Latente Multi-Cabeza + RoPE	✓	✓
gqla_attn	Atención Latente por Consultas Agrupadas — dos rutas de decodificación	✓	✓
mlra_attn	Atención Multi-Cabeza de Rango Bajo — latente particionable	✓	✓
tucker_attn	Atención Tucker — factorización de rango bajo generalizada	✓	✓
iha_attn	Atención de Cabezas Entrelazadas — pseudo-cabezas entre cabezas	✓	✓
gta_attn	Atención laTenT por Cabezas Agrupadas — mapa compartido + valores latentes	✓	✓
mtla_attn	Atención Latente Temporal Multi-Cabeza — fusión temporal KV	✓	✓
cca_attn	Atención Convolutiva Comprimida — atención en espacio latente + convs	✓	✓
ccgqa_attn	Atención Convolutiva Comprimida por Consultas Agrupadas — CCA + GQA en latente	✓	✓
gma_attn	Atención de Mezcla Gaussiana — enrutamiento latente probabilístico, $\mathcal{O}(NK)$ tiempo lineal	✓	✓

Cuadro 2: Enumeración completa de `layer_pattern`. ✓ = soportado, × = no soportado.

2.3. Configuración de Entrenamiento

El objeto `training` controla todo el pipeline de entrenamiento. El único campo obligatorio es `task`. La Tabla 3 enumera todos los campos de entrenamiento.

Campo	Tipo	Descripción
<code>task</code>	enum (mlm, sbert, causal_lm) (obligatorio)	Objetivo de entrenamiento. <code>mlm</code> = Modelo de Lenguaje Enmascarado; <code>sbert</code> = ajuste de Sentence-BERT; <code>causal_lm</code> = predicción autorregresiva del siguiente token (requiere <code>model_class='frankensteindecoder'</code>).
<code>num_epochs</code>	int ≥ 1	Pasadas completas por el dataset de entrenamiento (solo MLM).
<code>batch_size</code>	int ≥ 1	Ejemplos por paso del optimizador (antes de la acumulación de gradientes).
<code>dataloader_workers</code>	int ≥ 0	Procesos trabajadores paralelos para cargar datos.
<code>max_length</code>	int ≥ 1	Longitud máxima de secuencia de tokens. 128–2048.
<code>mlm_probability</code>	float [0,1]	Fracción de tokens enmascarados para pre-entrenamiento MLM. Estándar: 0.15.
<code>max_samples</code>	int ≥ 1	Muestras totales antes de detenerse, independientemente de épocas.
<code>dataset_batch_size</code>	int ≥ 1	Tamaño de lote interno para dataset de streaming.
<code>num_workers</code>	int ≥ 0	Trabajadores paralelos para pipeline de streaming de dataset.
<code>cache_dir</code>	string	Directorio para cachear datasets procesados.
<code>local_parquet_dir</code>	string	Ruta a archivos parquet locales para streaming offline.
<code>prefer_local_cache</code>	bool	Verificar caché local primero antes de descargar remota.
<code>stream_local_parquet</code>	bool	Hacer streaming desde parquet local cuando <code>local_parquet_dir</code> está configurado.
<code>join_temp_data_context_window</code>	int ≥ 0	Si > 0 , une fragmentos de tokens en cache de secuencias de esta longitud.
<code>join_temp_data_min_remainder_tokens</code>	int ≥ 0	Tokens de contenido mínimos en la última secuencia parcial unida.
<code>use_amp</code>	bool	Activar precisión mixta FP16.
<code>gradient_accumulation_steps</code>	int ≥ 1	Acumular gradientes sobre N mini-lotes antes de cada paso del optimizador.
<code>optimizer</code>	object	Configuración del optimizador (ver §2.5). Obligatorio cuando <code>task=mlm</code> o <code>task=causal_lm</code> .
<code>sbert</code>	object	Configuración de entrenamiento SBERT (ver §2.6). Obligatorio cuando <code>task=sbert</code> .
<code>scheduler_total_steps</code>	int ≥ 1	Pasos totales del optimizador para la programación de LR.
<code>scheduler_warmup_ratio</code>	float [0,1]	Fracción de <code>scheduler_total_steps</code> para el calentamiento de LR.
<code>scheduler_type</code>	enum (cosine, linear, near_warmup_then_constant)	Estrategia de decaimiento de LR.
<code>grad_clip_max_norm</code>	float ≥ 0	Norma máxima permitida del gradiente. 0 = desactivado.

continúa en la página

Campo	Tipo	Descripción
<code>inf_post_clip_threshold</code>	<code>float</code> ≥ 0	Umbral para marcar explosiones de gradientes post-recorte.
<code>max_nan_retries</code>	<code>int</code> ≥ 0	Reintentos máximos ante gradientes NaN antes de detenerse.
<code>checkpoint_every_n_steps</code>	<code>int</code> ≥ 1	Guardar checkpoint rotativo cada N pasos.
<code>max_rolling_checkpoints</code>	<code>int</code> ≥ 1	Máximo de checkpoints rotativos mantenidos; el más antiguo se elimina al exceder.
<code>num_best_checkpoints</code>	<code>int</code> ≥ 1	Número de mejores checkpoints conservadas permanentemente (por pérdida de validación).
<code>nan_check_interval</code>	<code>int</code> ≥ 1	Pasos entre verificaciones de NaN/Inf.
<code>log_gradient_stats</code>	<code>bool</code>	Registrar normas de gradiente por capa, por paso.
<code>gradient_log_interval</code>	<code>int</code> ≥ 1	Pasos entre registros de estadísticas de gradientes.
<code>csv_log_path</code>	<code>string</code>	Ruta de archivo para métricas de entrenamiento en nivel de paso en formato CSV.
<code>csv_rotate_on_schema_change</code>	<code>bool</code>	Rotar archivo CSV cuando cambia el esquema.
<code>gpu_metrics_backend</code>	<code>enum</code> (nvml, none)	Backend de telemetría GPU.
<code>nvml_device_index</code>	<code>int</code> ≥ 0	Índice de GPU a monitorear (0 = primera GPU disponible).
<code>enable_block_grad_norms</code>	<code>bool</code>	Registrar normas de gradiente por bloque (embeddings, atención, FFN, etc.).
<code>telemetry_log_interval</code>	<code>int</code> ≥ 1	Pasos entre registros de telemetría pesada.
<code>gpu_temp_guard_enabled</code>	<code>bool</code>	Monitoreo estricto de temperatura GPU. Requiere <code>gpu_metrics_backend=nvml</code> .
<code>switch_on_thermal</code>	<code>bool</code>	Temperatura crítica activa fallback GPU-temperatura para reanudación automática al enfriarse.
<code>gpu_temp_pause_threshold_c</code>	<code>float</code>	Temperatura (°C) para pausar entrenamiento.
<code>gpu_temp_resume_threshold_c</code>	<code>float</code>	Temperatura (°C) para reanudar entrenamiento tras pausa.
<code>gpu_temp_critical_threshold_c</code>	<code>float</code>	Marcador de registro informativo para eventos térmicos severos.
<code>gpu_temp_poll_interval_seconds</code>	<code>float</code>	Segundos entre verificaciones de temperatura durante espera de enfriamiento.
<code>use_galore</code>	<code>bool</code>	Activar Proyección de Gradiente de Bajo Rango para entrenamiento eficiente en memoria.
<code>galore_rank</code>	<code>int</code> ≥ 1	Dimensión de proyección de bajo rango para GaLore.
<code>galore_update_interval</code>	<code>int</code> ≥ 1	Pasos entre recomputaciones de la matriz de proyección.
<code>galore_scale</code>	<code>float</code> ≥ 0	Factor de escala para gradientes proyectados.
<code>galore_max_dim</code>	<code>int</code> ≥ 1	Dimensión máxima del tensor para proyección GaLore.
<code>hf_output_dir</code>	<code>string</code>	Directorio para guardar el modelo final mediante <code>save_pretrained()</code> .

Cuadro 3: Campos completos de configuración de entrenamiento.

2.4. Configuración del Tokenizador

El objeto `tokenizer` de nivel superior está disponible para ambas rutas de entrenamiento: la ruta `base_model` (preentrenamiento continuo / ajuste fino, donde el tokenizador debe coincidir

con el checkpoint preentrenado) y la ruta personalizada desde cero (donde resuelve el vocabulario antes de asignar la matriz de embeddings). El campo `source` selecciona entre dos modos:

- `hf_repo` (por defecto) — carga un tokenizador preentrenado desde `name_or_path` (id de repo de HuggingFace o ruta local) mediante `AutoTokenizer.from_pretrained()`. Banderas complementarias: `use_fast` (tokenizador rápido Rust, por defecto `true`) y `trust_remote_code` (por defecto `false`).
- `train_from_dataset` — entrena un tokenizador *nuevo* desde el texto del corpus con la biblioteca `tokenizers` de HuggingFace. El corpus es el bloque `text_dataset` de nivel superior (id de HF hub, opcionalmente en streaming, o un directorio local parquet/json); cuando el config es dirigido por un host de embedding como dashAI, el dataset del run del host puede suministrarlo. El tamaño de vocabulario resultante se inyecta en `model.dims.vocab_size` antes de construir el modelo, de modo que la matriz de embeddings siempre coincide con el tokenizador. En este modo `name_or_path` debe omitirse. La Tabla 4 enumera los campos del sub-objeto `tokenizer.training`.

Campo	Tipo	Descripción
<code>algorithm</code>	enum (bpe, wordpiece, wordlevel, unigram)	Algoritmo de entrenamiento del tokenizador. bpe (Byte Pair Encoding, estilo GPT-2, por defecto); wordpiece (BERT original); wordlevel (tabla de palabras); unigram (modelo de lenguaje de sub-palabras, con poda automática).
<code>vocab_size</code>	<code>int ≥ 1</code>	Tamaño de vocabulario objetivo. Obligatorio para bpe/wordpiece/wordlevel ; opcional para unigram .
<code>min_frequency</code>	<code>int ≥ 1</code>	Frecuencia mínima de token a conservar (por defecto 2).
<code>special_tokens</code>	array de string	Tokens especiales registrados en el tokenizador (por defecto <code>[PAD]/[UNK]/[CLS]/[SEP]/[MASK]</code>).
<code>save_dir</code>	string	Directorio persistido vía <code>save_pretrained()</code> .
<code>lowercase</code>	bool	Convertir todo el texto a minúsculas antes de entrenar (por defecto <code>false</code>).
<code>strip_accents</code>	bool	Quitar diacríticos antes de entrenar (por defecto <code>false</code>).
<code>pre_tokenizer</code>	enum (whitespace, bytelevel, bert)	Estrategia de pre-tokenización (por defecto whitespace).
<code>max_token_length</code>	<code>int ≥ 0</code>	Límite de caracteres por token; 0 desactiva el límite.

Cuadro 4: Campos `tokenizer.training.*` (obligatorio cuando `source=train_from_dataset`).

2.5. Configuración del Optimizador

El objeto `training.optimizer` tiene dos campos:

- `optimizer_class` (enum, obligatorio) — Uno de 23 algoritmos optimizadores: `sgd_momentum`, `adamw`, `adafactor`, `galore_adamw`, `prodigy`, `lion`, `sophia`, `muon`, `turbo_muon`, `radam`, `adan`, `adopt`, `ademamix`, `mars_adamw`, `cautious_adamw`, `lamb`, `schedulefree_adamw`, `shampoo`, `soap`, `anon`, `apollo`, `apollo_mini`, `q_apollo`.
- `parameters` (object) — Hiperparámetros del optimizador con claves prefijadas en el formato `<optimizador>-<grupo>-<param>`.

2.5.1. Sufijos Compartidos por Grupo

Todos los optimizadores soportan los siguientes sufijos por grupo de parámetros, prefijados por el nombre de la clase del optimizador (ej., `adamw-lr_embeddings`):

- **Grupos de tasa de aprendizaje:** `lr_embeddings`, `lr_norms`, `lr_attention`, `lr_other`
- **Grupos de decaimiento de peso:** `wd_embeddings`, `wd_norms`, `wd_attention`, `wd_other`
- **Grupos beta:** `betas_embeddings`, `betas_norms`, `betas_attention`, `betas_other`
- **Grupos epsilon:** `eps_embeddings`, `eps_norms`, `eps_attention`, `eps_other`

Nota: los parámetros de los mezcladores ODE, RetNet y Mamba se enrutan al grupo `attention` en lugar de tener grupos dedicados.

2.5.2. Sufijos Globales Específicos del Optimizador

La Tabla 5 enumera los sufijos globales adicionales soportados por cada optimizador (prefijados por el nombre del optimizador).

Optimizador	Sufijos Globales Específicos
<code>sgd_momentum</code>	<code>momentum</code> , <code>nesterov</code>
<code>adamw</code>	(ninguno — solo sufijos compartidos)
<code>adafactor</code>	<code>beta2_decay</code> , <code>clip_threshold</code> , <code>eps1</code> , <code>eps2</code>
<code>galore_adamw</code>	<code>rank</code> , <code>update_proj_gap</code>
<code>prodigy</code>	<code>d_coef</code>
<code>lion</code>	(ninguno — solo sufijos compartidos)
<code>sophia</code>	<code>rho</code> , <code>update_k</code>
<code>muon</code>	<code>momentum</code> , <code>nesterov</code> , <code>ns_steps</code> , <code>ns_eps</code>
<code>turbo_muon</code>	<code>momentum</code> , <code>nesterov</code> , <code>ns_steps</code> , <code>ns_eps</code>
<code>radam</code>	(ninguno — solo sufijos compartidos)
<code>adan</code>	(ninguno — solo sufijos compartidos)
<code>adopt</code>	(ninguno — solo sufijos compartidos)
<code>ademamix</code>	(ninguno — solo sufijos compartidos)
<code>mars_adamw</code>	(ninguno — solo sufijos compartidos)
<code>cautious_adamw</code>	<code>cautious_clip</code>
<code>lamb</code>	(ninguno — solo sufijos compartidos)
<code>schedulefree_adamw</code>	(ninguno — solo sufijos compartidos)
<code>shampoo</code>	(ninguno — solo sufijos compartidos)
<code>soap</code>	(ninguno — solo sufijos compartidos)
<code>anon</code>	<code>gamma</code>
<code>apollo</code>	<code>rank</code> , <code>update_proj_gap</code> , <code>scale</code> , <code>scale_type</code> , <code>proj_type</code> , <code>scale_front</code> , <code>disable_nl</code>
<code>apollo_mini</code>	<code>update_proj_gap</code> , <code>scale</code> , <code>proj_type</code> , <code>scale_front</code> , <code>disable_nl</code>
<code>q_apollo</code>	<code>rank</code> , <code>update_proj_gap</code> , <code>scale</code> , <code>scale_type</code> , <code>proj_type</code> , <code>scale_front</code> , <code>disable_nl</code> , <code>quant_bits</code>

Cuadro 5: Sufijos de parámetros globales específicos del optimizador. Todas las claves están prefijadas con el nombre de la clase del optimizador (ej., `sgd_momentum-momentum`).

2.6. Configuración SBERT

El objeto `training.sbert` configura el ajuste fino Sentence-BERT. Es obligatorio cuando `training.task=sbert`. Los campos clave incluyen:

- `dataset_name` (string) — Identificador de dataset HuggingFace o ruta local.
- `dataset_type` (enum) — `paired_similarity`, `triplets` o `qa`.
- `columns` (object) — Sobrescrituras opcionales de nombres de columna para campos del dataset.
- `query_prefix` / `document_prefix` (string) — Texto antepuesto a campos de consulta/documento durante la tokenización.
- `output_dir` (string) — Directorio para artefactos SBERT.
- `batch_size` (int) — Ejemplos por lote. Típico: 16–64.
- `gradient_accumulation_steps` (int) — Pasos de acumulación para SBERT.
- `max_grad_norm` (float) — Umbral de recorte de gradiente. Típico: 0.5–2.0.
- `epochs` (int) — Pasadas completas por el dataset SBERT. Típico: 1–10.
- `warmup_steps` (int) — Pasos para calentamiento de LR.
- `evaluation_steps` (int) — Evaluar cada N pasos.
- `checkpoint_save_steps` (int) — Guardar checkpoint rotativo cada N pasos.
- `resume_from_checkpoint` (bool) — Reanudar desde el último checkpoint.
- `learning_rate` (float) — LR inicial. Típico: 1×10^{-5} a 1×10^{-4} .
- `max_train_samples` / `max_eval_samples` (int) — Limitar muestras de entrenamiento/evaluación.
- `max_seq_length` (int) — Longitud máxima de tokens para textos de entrada. Típico: 128–512.
- `pooling_mode` (enum) — `mean`, `cls` o `max`.
- `trust_remote_code` (bool) — Permitir código personalizado del repositorio del modelo.
- `use_amp` (bool) — Activar precisión mixta FP16.
- `resample_balanced` (bool) — Remuestrear a distribución balanceada sobre puntajes de similitud.
- `standardize_scores` (bool) — Normalizar puntajes de similitud con puntuación Z.
- `resample_std` (float) — Desviación estándar objetivo cuando `standardize_scores=true`.
- `optimizer` (object) — Optimizador personalizado para SBERT (mismas clases que el entrenamiento MLM).
- `wandb_project` (string) — Nombre del proyecto Weights & Biases para telemetría.

2.7. Reglas de Validación

El esquema impone las siguientes reglas de validación entre componentes, implementadas tanto en el JSON Schema (`_conditional_rules.yaml`) como en tiempo de ejecución en el cargador de configuración:

1. `additionalProperties: false` se aplica en todos los niveles de anidamiento. Cualquier clave no reconocida en cualquier objeto desencadena un error de validación.
2. `model.dims.hidden_size` debe ser divisible por `model.dims.num_heads`. La dimensión por cabeza es `hidden_size/num_heads`.
3. `model.dims.num_kv_heads` debe dividir `model.dims.num_heads` exactamente cuando se usa Atención por Consultas Agrupadas.
4. `vocab_size` debe coincidir con el tamaño de vocabulario del tokenizador. Una discrepancia causa corrupción de IDs de token y fallo de entrenamiento irrecuperable.
5. Cuando `base_model` está configurado, `training.task` es obligatorio. Si `task=mlm`, `tokenizer.name_or_path` también es obligatorio — salvo cuando `tokenizer.source=train_from_dataset`, en cuyo caso el tokenizador se entrena desde el corpus y no se necesita nombre.
6. `tokenizer.source=train_from_dataset` requiere el sub-objeto `tokenizer.training` (con `vocab_size` para `bpe/wordpiece/wordlevel`) y es mutuamente excluyente con `tokenizer.name_or_path`. El vocabulario entrenado sobrescribe `model.dims.vocab_size` antes de construir el modelo.
7. `task: mlm` requiere `training.optimizer`; `task: sbert` requiere `training.sbert`; `task: causal_lm` requiere `training.optimizer` y `model_class='frankensteindecoder'`.

8. `bitnet_routers=true` requiere `use_bitnet=true`. La bandera no tiene efecto en caso contrario.
9. `use_mhc=true` (flujo residual de n streams mHC) y `use_mixture_of_depths=true` son mutuamente excluyentes. Habilitar ambos lanza un `ValueError`: el enrutamiento MoD de tokens opera sobre un flujo C -dimensional único, en conflicto con el flujo residual de n streams.
10. `fasa_attn` y `sparge_attn` son tipos de capa solo para evaluación. Lanzas `RuntimeError` si se usan durante el entrenamiento. No deben aparecer en `model.dims.layer_pattern` para ejecuciones de entrenamiento.
11. `model_class: frankensteindecoder` fuerza `model.dims.mode: decoder` en tiempo de ejecución. Establecer `model.dims.mode: encoder` con esta clase se sobrescribe.
12. O bien `base_model` debe estar presente, o bien tanto `model_class` como `model` deben estar presentes. El esquema rechaza configuraciones que no proporcionen ninguno o una combinación incompleta.

3. Tablas de Resumen Completas

Este anexo proporciona una referencia completa de todos los componentes implementados en el código base de Frankenstein Transformer: 43 mezcladores de secuencia en ocho familias, 23 optimizadores, 6 variantes de normalización, 43 funciones de activación y 4 métodos de embedding. Cada tabla es autocontenida y referencia la bibliografía.

3.1. Resumen de Mezcladores de Secuencia

La Tabla 6 enumera cada mezclador de secuencia soportado por el campo de esquema `layer_pattern`, organizado por familia arquitectónica. La complejidad de entrenamiento e inferencia se expresa en términos de la longitud de secuencia n , la dimensión oculta d y parámetros específicos de cada familia.

Nombre	Familia	Entrenamiento	Inferencia	Característica Clave	Referencia
Denso (3)					
<code>standard_attn</code>	Denso	$\mathcal{O}(n^2 d)$	$\mathcal{O}(n)$ caché	Contexto global completo; cuello de botella KV en secuencias largas	[92]
<code>sigmoid_attn</code>	Denso	$\mathcal{O}(n^2 d)$	$\mathcal{O}(n)$ caché	Compuerta elemento a elemento; reemplazo eficiente en hardware para softmax	[77]
<code>gqa</code>	Denso	$\mathcal{O}(n^2 d)$	$\mathcal{O}(n)$ caché	Compresión KV ajustable; reducción de caché $G \times$ mediante cabezas compartidas	[2]
Recurrente (5)					
<code>retnet_attn</code>	Recurrente	$\mathcal{O}(n^2 d)$ paralelo	$\mathcal{O}(1)$	Decaimiento multi-escala; triple modo de cómputo (paralelo/recurrente/por fragmentos)	[88]
<code>mamba</code>	Recurrente	$\mathcal{O}(nd)$	$\mathcal{O}(1)$	Modelo de espacio de estado selectivo; escaneo paralelo consciente del hardware	[33]
<code>ode</code>	Recurrente	$\mathcal{O}(k \cdot n^2 d)$	$\mathcal{O}(kn)$	Integración RK4 de profundidad continua; solucionador de paso adaptativo	[108]

continúa en la página siguiente

Nombre	Familia	Entrenamiento	Inferencia	Característica Clave	Referencia
titan_attn	Recurrente	$\mathcal{O}(c^2 + nf)$	$\mathcal{O}(c^2 + 1)$	Adaptación de memoria en tiempo de prueba; dinámica de escritura impulsada por sorpresa	[7]
engram_attn	Memoria	$\mathcal{O}(n \cdot N \cdot H)$	$\mathcal{O}(1)$ lookup	Memoria condicional de N-gramas; recuperación escalable basada en hash	[15]
Disperso (9)					
sparse_transformer_attn	Disperso	$\mathcal{O}(n\sqrt{n} \cdot d)$	$\mathcal{O}(n)$	Máscaras factorizadas estrideadas + fijas; patrón de dispersidad $\sqrt{n}$	[16]
longformer_attn	Disperso	$\mathcal{O}(n \cdot w \cdot d)$	$\mathcal{O}(n)$	Ventana deslizante + dilatación + tokens globales; lineal en n	[8]
bigbird_attn	Disperso	$\mathcal{O}(n)$	$\mathcal{O}(n)$	Aleatorio + local + global; atención Turing completa	[105]
sparsek_attn	Disperso	$\mathcal{O}(n \cdot d)$	$\mathcal{O}(k)$	Selección top- k diferenciable; máscara de dispersidad aprendida	[59]
nsa_attn	Disperso	$\mathcal{O}((t/d + n_l + w)d)$	$\mathcal{O}(n)$	Diseño de 3 ramas alineado con hardware; token/vecino/ventana	[103]
sparge_attn	Disperso	$\mathcal{O}(n^2 \cdot s \cdot d)$	$\mathcal{O}(n)$	Filtrado de bloques en dos etapas; solo evaluación (sin entrenamiento)	[109]
fasa_attn	Disperso	$\mathcal{O}(t \cdot N_{\text{tip}} + N_{\text{fac}} \cdot d)$	$\mathcal{O}(n)$	Dispersidad consciente de frecuencia RoPE; solo evaluación	[95]
msa_attn	Disperso	$\mathcal{O}(H_{kv} \cdot d_{\text{idx}} \cdot N^2 + H_q \cdot d_h \cdot N \cdot k \cdot B_k)$	$\mathcal{O}(n)$	Bloques dispersos con rama índice; desplegado a escala 109B	[50]
sparda_attn	Disperso	$\mathcal{O}(H_{kv} \cdot d_f \cdot N \cdot N_b + H_q \cdot d_h \cdot N \cdot k \cdot B_k)$	$\mathcal{O}(n)$	Prefetch anticipado guiado por pronóstico; dispersidad predictiva	[28]
Con Compuerta (8)					
gla_attn	Con compuerta	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Decaimiento diagonal dependiente de datos; atención lineal con compuerta	[99]
deltanet_attn	Con compuerta	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Regla delta; atención lineal con corrección de errores	[100]
gated_deltanet_attn	Con compuerta	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Síntesis de decaimiento + compuerta de escritura; marco delta unificado	[101]
gated_deltanet2_attn	Con compuerta	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Compuertas de borrado/escritura canalizadas desacopladas; compuerta mejorada	[36]
hgrn2_attn	Con compuerta	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Compuertas de olvido acotadas jerárquicas; recurrencia multi-escala	[74]
fox_attn	Con compuerta	$\mathcal{O}(L^2d)$	$\mathcal{O}(L)$ KV	Sesgo de recencia en espacio de logits; compatible con FlashAttn	[54]
gated_softmax_attn	Con compuerta	$\mathcal{O}(L^2d)$	$\mathcal{O}(L)$ KV	Compuerta sigmoide post-SDPA; mitigación del sumidero de atención	[75]

continúa en la página siguiente

Nombre	Familia	Entrenamiento	Inferencia	Característica Clave	Referencia
kda_attn	Con com-puerta	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Decaimiento por canal + escritura escalar; diseño Kimi Linear	[47]
Peso Rápido (6)					
falcon1_attn	Peso rápido	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Regla delta NLMS prefix-alineada (RAW); mejor complejidad LM de la familia	[110]
falcon2_attn	Peso rápido	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Tamaños de paso NLMS por canal de valor	[110]
falcon3_attn	Peso rápido	$\mathcal{O}(Ld^2B)$	$\mathcal{O}(d^2) + \mathcal{O}(B)$ + cola	Repetición de minilote con ventana deslizante y estadísticos exactos	[110]
falcon1a_attn	Peso rápido	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Atención lineal aditiva desplazada con decaimiento por ridge	[110]
falcon2a_attn	Peso rápido	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2)$	Decaimientos aditivos por canal	[110]
falcon3a_attn	Peso rápido	$\mathcal{O}(Ld^2)$	$\mathcal{O}(d^2) + \mathcal{O}(B)$ + cola	Aditivo con ventana; mejor extrapolación de longitud	[110]
Latente (9)					
m1a_attn	Latente	$\mathcal{O}(n^2d)$	$\mathcal{O}(r_{kv} \cdot n)$	KV latente de rango $r_{kv} \approx d/2$; estilo DeepSeek	[61]
gqla_attn	Latente	$\mathcal{O}(n^2d)$	$\mathcal{O}(r_{kv} \cdot n)$	Rutas de decodificación duales adaptativas al hardware; fusión GQA + latente	[62]
mlra_attn	Latente	$\mathcal{O}(n^2d)$	$\mathcal{O}(r_{kv} \cdot n)$	L sub-cabezas; compatible con tensor-paralelismo de 4 vías	[57]
tucker_attn	Latente	$\mathcal{O}(n^2d)$	$\mathcal{O}(k_{\text{rank}} \cdot n)$	Factorización Tucker; unifica MHA/GQA/MLA	[49]
iha_attn	Latente	$\mathcal{O}(n^2H^2)$	$\mathcal{O}(H \cdot n \cdot d_h)$	Pseudo-cabezas; escalado de parámetros $\Theta(\sqrt{k})$	[24]
gta_attn	Latente	$\mathcal{O}(n^2 \cdot G \cdot d_h)$	$\mathcal{O}(r_v \cdot n)$	Mapa compartido + decodificador SiLU; reducción de FLOPs del 62.5%	[87]
mtla_attn	Latente	$\mathcal{O}(n^2d/m)$	$\mathcal{O}(r_{kv} \cdot n/m)$	Fusión temporal; aceleración de decodificación de $5,3\times$	[20]
cca_attn	Latente	$\mathcal{O}(n^2d/C)$	$\mathcal{O}(\tilde{e} \cdot n)$	Atención completa en latente comprimido; $C\times$ menos FLOPs	[27]
ccgqa_attn	Latente	$\mathcal{O}(n^2d/C_1)$	$\mathcal{O}(\tilde{e}_{kv} \cdot n)$	CCA + GQA desacoplada; mejor pérdida a $8\times$ reducción de caché	[27]
gma_attn	Latente	$\mathcal{O}(nKd_r + nKd_v)$	$\mathcal{O}(K)/\text{paso}$	Atención de Mezcla Gaussiana; enrutamiento latente probabilístico a través de K componentes GMM aprendidos por cabeza; tiempo lineal para K fijo; causal vía cumsums de prefijo	[43]
ssog_attn	Campo geométrico	$\mathcal{O}(R \cdot n\sqrt{n} \cdot d)$	$\mathcal{O}(R \cdot n\sqrt{n} \cdot d)/\text{pasada}$	SSOG: campo Gaussiano separable sobre posición relativa; el contenido dirige (residuos acotados $\mu/\sigma/\lambda$ detrás de compuertas de arranque en frío), nunca puntúa; solo encoder	[71]

Cuadro 6: Catálogo completo de mezcladores de secuencia. n = longitud de secuencia, d = tamaño oculto, w = tamaño de ventana, r = dimensión de rango bajo, k = parámetro de dispersidad, C = razón de compresión. Los parámetros específicos de cada familia se definen en el anexo correspondiente.

3.2. Resumen de Optimizadores

La Tabla 7 cataloga los 23 optimizadores soportados con su huella de memoria, costo computacional por paso e hiperparámetros clave. Los búferes de estado se expresan como el número de tensores propiedad del optimizador por parámetro; el costo por paso se enfoca en el término dominante más allá del cálculo del gradiente.

Optimizador	Familia	Búferes de Estado	Costo por Paso	Hiperparámetros Clave	Referencia
Líneas Base Clásicas y Adaptativas					
SGD+Momentum	Clásico	1 (m)	$\mathcal{O}(n)$	lr, momentum, wd	[72]
AdamW	Adaptativo	2 (m, v)	$\mathcal{O}(n)$	lr, β_1, β_2 , eps, wd	[58]
RAAdam	Adaptativo	2 (m, v)	$\mathcal{O}(n)$	lr, β_1, β_2 , eps, wd	[56]
Reducción de Varianza y Momentum Avanzado					
Adan	Reducción de varianza	3 (m, v, s)	$\mathcal{O}(n)$	lr, $\beta_1, \beta_2, \beta_3$, eps, wd	[97]
ADOPT	Variante Adam	2 (m, v)	$\mathcal{O}(n)$	lr, β_1, β_2 , eps, wd	[90]
AdEMAMix	Multi-EMA	3 (m_1, m_2, v)	$\mathcal{O}(n)$	lr, $\beta_1, \beta_2, \beta_3$, eps, wd	[68]
MARS	Varianza reducida	3 (m, v, z)	$\mathcal{O}(n)$	lr, β_1, β_2 , eps, wd, γ	[104]
Cautious AdamW	Momentum enmascarado	2 (m, v)	$\mathcal{O}(n)$	lr, β_1, β_2 , eps, wd	[53]
Lote Grande, Eficientes en Memoria y Sin Parámetros					
LAMB	Adaptativo por capas	2 (m, v)	$\mathcal{O}(n)$	lr, β_1, β_2 , eps, wd	[102]
Schedule-Free	Sin programación	3 (z, x, n)	$\mathcal{O}(n)$	lr, β_1, β_2 , wd	[19]
Adafactor	Eficiente en memoria	1-2 (fila/col)	$\mathcal{O}(n)$	lr, β_1, β_2 , eps, wd	[82]
GaLore	Proyección de bajo rango	2 (m, v) + SVD	$\mathcal{O}(nr)$	lr, rango r , β_1, β_2 , eps, wd	[111]
Prodigy	Sin parámetros	3 (m, v, d)	$\mathcal{O}(n)$	β_1, β_2 , eps, wd, d_0	[63]
Lion	Momentum de signo	1 (m)	$\mathcal{O}(n)$	lr, β_1, β_2 , wd	[14]
Segundo Orden, Geométricos y Ortogonalidad					
Shampoo	Segundo orden	$2d$ (L_i, R_i)	$\mathcal{O}(n^{1+2/d})$	lr, eps, wd	[35]
SOAP	Segundo orden	$2d + 2$ (m, v)	$\mathcal{O}(n^{1+1/d})$	lr, β_1, β_2 , eps, wd	[93]
Sophia	Consciente de curvatura	3 (m, v, h)	$\mathcal{O}(n)$	lr, β_1, β_2 , eps, wd, k	[55]
Muon	Ortogonalidad	2 (m, v)	$\mathcal{O}(n \cdot k)$	lr, momentum, wd, pasos NS k	[83]
Turbo-Muon	Ortogonalidad	2 (m, v)	$\mathcal{O}(n \cdot k)$	lr, momentum, wd, pasos NS k	[10]
Adaptativos de Bajo Rango y Adaptividad Ajustable					

continúa en la página siguiente

Optimizador	Familia	Búferes de Estado	de	Costo Paso	por	Hiperparámetros Clave	Referencia
APOLLO	Adaptativo de bajo rango	2 bajo rango + proy		$\mathcal{O}(nr)$		lr, rango r , intervalo de actualización, escala, betas, eps, wd	[112]
APOLLO-Mini	Adaptativo de bajo rango	2 rango-1 + proy		$\mathcal{O}(n)$		lr, intervalo de actualización, escala, betas, eps, wd	[112]
Q-APOLLO	Bajo rango cuantizado	2 cuantizados + proy		$\mathcal{O}(nr)$		lr, rango r , intervalo de actualización, escala, bits de cuantización, betas, eps, wd	[112]
Anon	Adaptividad ajustable	3 (m , v , fi - xed_lr)		$\mathcal{O}(n)$		lr, β_1 , β_2 , eps, wd, γ	[3]

Cuadro 7: Catálogo completo de optimizadores. n = número de parámetros, d = dimensionalidad del tensor, r = dimensión de rango bajo, k = número de iteraciones de Newton–Schulz. Búferes de estado enumera el número de tensores de estado del optimizador mantenidos por grupo de parámetros.

3.3. Variantes de Normalización

La Tabla 8 resume los seis métodos de normalización disponibles a través del campo de esquema `norm_type`, desde enfoques clásicos basados en estadísticas hasta transformaciones acotadas sin normalización y RMSNorm sin pesos con ejecución norm-then-project fusionada.

Método	Fórmula	Estadísticas Necesarias	Referencia
LayerNorm	$\gamma_i(x_i - \mu)/\sqrt{\sigma^2 + \epsilon} + \beta_i$	media + varian-za	[4]
RMSNorm	$\gamma_i x_i / \sqrt{\frac{1}{d} \sum_j x_j^2 + \epsilon}$	solo RMS	[107]
pRMSNorm	$\gamma_i x_i / \sqrt{\frac{1}{k} \sum_{j \leq k} x_j^2 + \epsilon}$	RMS parcial (p %)	[107]
Dynamic Tanh (DyT)	$\tanh(\alpha x)$	ninguna	[113]
Dynamic Erf (Derf)	$\text{erf}(\alpha x + s)$	ninguna	[13]
FlashNorm	$x_i / \sqrt{\frac{1}{d} \sum_j x_j^2 + \epsilon}$	solo RMS (sin pesos)	[32]

Cuadro 8: Variantes de normalización. d = dimensión oculta, $k = \lceil d \cdot p \rceil$ para razón parcial p , α y s son parámetros aprendibles. FlashNorm es sin pesos (sin parámetros aprendibles); la escala por dimensión se pliega en la capa lineal subsecuente según la Prop. 1 de [32].

3.4. Conexiones Residuales

La Tabla 9 compara los esquemas de conexión residual disponibles en el código base: el residual de identidad estándar, las cuatro estrategias de Residuales de Atención (AttnRes) [89] y el flujo residual de n streams restringido por variedad (mHC) [98]. L es la profundidad lógica, C la dimensión oculta, n el factor de expansión del flujo, $t_{\text{máx}}$ el número de iteraciones Sinkhorn–Knopp, α los escalares de compuerta de mHC y $\mathbf{w}_l$ el pseudo-query por capa de AttnRes (inicializado a cero). HC (Hyper-Connexions sin restricción) se lista como referencia pero

no está expuesto en este código base.

Esquema	Actualización del Flujo	Restricción	Referencia
Residual estándar	$x_{l+1} = x_l + F(x_l, W_l)$	Mapeo de identidad (por construcción)	[38]
Sin residual (experimental)	$x_{l+1} = F(x_l, W_l)$	Sin ruta skip	—
Full AttnRes	$x_{l+1} = \sum_{i=0}^l \text{softmax}_i(\mathbf{w}_l^\top \text{RMSNorm}(v_i)) \text{RMSNorm}(v_l)$	$\mathbf{w}_l$ aprendido, init a zeros ; RMSNorm en keys; $L \cdot C$ parámetros	[89]
Block Attn-Res	$x_{l+1} = \sum_{m=0}^n \text{softmax}_m(\mathbf{w}_l^\top \text{RMSNorm}(v_m)) \text{RMSNorm}(v_l)$	$\mathbf{w}_l$ aprendido, init a zeros ; RMSNorm en keys; N reps de bloque + suma parcial; $L \cdot C$ parámetros	[89]
Hyper-Connexions (HC)	$x_{l+1} = (H_l^{\text{post}})^\top F(H_l^{\text{pre}} x_l, W_l)$	Sin restricción	[98]
mHC (este código base)	misma actualización que HC	H_l^{res} doblemente estocástica vía Sinkhorn–Knopp ($t_{\text{máx}} = 20$), $H^{\text{pre}} = \sigma(\cdot)$, $H^{\text{post}} = 2\sigma(\cdot)$, init α en 0,01	[98]
Hyperloop (este código base)	$y_t^{(l+1)} = H_l^{\text{res}} y_t^{(l)} + H_l^{\text{post}} \otimes (F(H_l^{\text{pre}} y_t^{(l)} + e_l))$	HC a nivel de bucle sobre un bloque intermedio en bucle de ciclo medio; $\{W_l, b_l, \alpha_l, e_l\}$ por bucle; expansión por copia/promedio; H^{res} diagonal (por defecto), Sinkhorn o identidad	[106]

Cuadro 9: Esquemas de conexión residual. $x_l \in \mathbb{R}^C$ (estándar / AttnRes / sin residual) o $\mathbb{R}^{n \times C}$ (mHC) es el flujo en la capa l , F la función de capa y $H^{\text{pre}}, H^{\text{post}}, H^{\text{res}}$ los mapeos aprendidos de mHC. Las estrategias AttnRes se controlan con `model.residuals.type`; mHC con `model.mhc`. Detalles completos en los anexos de mHC y AttnRes.

3.5. Funciones de Activación

La Tabla 10 cataloga las 43 funciones de activación disponibles a través del campo de esquema `ffn_activation` (40 elementales más 3 variantes de FFN con compuerta), agrupadas por familia. “Aprend.” marca las activaciones con parámetros entrenables; las fórmulas completas están en el Anexo 8.

Nombre	Familia	Fórmula	Aprend. Referencia
Clásicas / Sigmoid–Tanh (12)			

continúa en la próxima página

Nombre	Familia	Fórmula	Aprend.	Referencia
silu / swish	Clásica	$x \sigma(\beta x)$	no / β	[76]
gelu	Clásica	$x \Phi(x)$	no	[40]
gelu_tanh	Clásica	$\frac{x}{2} (1 + \tanh \sqrt{\frac{2}{\pi}} (x + 0,044715x^3))$	no	[40]
relu	Clásica	$\max(0, x)$	no	[66]
sigmoid	Clásica	$1/(1 + e^{-x})$	no	[51]
tanh	Clásica	$(e^x - e^{-x})/(e^x + e^{-x})$	no	[51]
arctan	Clásica	$\arctan(x)$	no	[51]
softsign / eliott	Clásica	$x/(1 + x)$	no	[51]
identity	Clásica	x	no	(interno)
softplus	Clásica	$\log(1 + e^x)$	no	[29]
mish	Clásica	$x \tanh(\log(1 + e^x))$	no	[64]
Familia rectificada (12)				
leaky_relu	Rectificada	$\max(0, x) + a \min(0, x)$, $a=0,01$	no	[60]
relu6	Rectificada	$\min(\max(0, x), 6)$	no	[41]
hardswish	Rectificada	$x \text{ReLU6}(x+3)/6$	no	[41]
prelu	Rectificada	$\max(0, x) + \mathbf{p} \odot \min(0, x)$	sí	[37]
abs_relu	Rectificada	$\max(0, x) - \max(0, -x)$	no	[23]
nl_relu	Rectificada	$\beta \log(1 + \max(0, x))$	no	[23]
breu	Rectificada	$\min(\max(0, x), t)$	no	[23]
vrelu	Rectificada	$ x $	no	[23]
hexpo	Rectificada	$a \max(0, x) - c \max(0, -x)$	no	[23]
ptanh	Rectificada	$\max(0, \tanh(x))$	no	[23]
dis_relu	Rectificada	$\max(0, x - \delta)$	no	[23]
lisht	Rectificada	$x \tanh(x)$	no	[79]
Familia exponencial / ELU (12)				
elu	Exponencial	x si $x \geq 0$ si no $\alpha(e^x - 1)$	no	[17]
selu	Exponencial	$\lambda \text{ELU}_{\alpha'}(x)$	no	[48]
celu	Exponencial	x si $x \geq 0$ si no $\alpha(e^{x/\alpha} - 1)$	no	[5]
pelu	Exponencial	$\frac{\alpha}{\beta} x / \alpha(e^{x/\beta} - 1)$	sí	[23]
mpelu	Exponencial	$\text{ELU} + \alpha, \beta$ aprendibles	sí	[23]
felu / eelu / pdelu / preu	Exponencial	variantes ELU c/ params aprendibles	sí	[23]
softexp	Exponencial	interpolación exp/lineal/log	sí	[23]
elish / hardelish	Exponencial	Swish $\cup$ ramas ELU con compuerta	no	[6]
Aprendibles / Adaptativas (4)				
swish_trainable	Aprendible	$x \sigma(\beta x)$, β entrenable	sí	[76]
maxout	Aprendible	$\max_i(W_i x + b_i)$	sí	[31]
raf	Aprendible	$P(x)/Q(x)$ Padé(5, 4), versión A	sí	[26]
Variantes FFN con compuerta (3)				
swiglu	Compuerta	$\text{SiLU}(xW_g) \odot (xW_u)W_d$	sí	[81]
geglu	Compuerta	$\text{GELU}(xW_g) \odot (xW_u)W_d$	sí	[81]
reglu	Compuerta	$\text{ReLU}(xW_g) \odot (xW_u)W_d$	sí	[81]

Cuadro 10: Catálogo de funciones de activación. “Aprend.” indica la presencia de parámetros entrenables. RAF = Rational Activation Function (razón de Padé aprendible). σ es la sigmoide logística.

3.6. Variantes de Embedding

La Tabla 11 cataloga las codificaciones posicionales y optimizaciones estructurales de embedding soportadas por el código base. Las 12 codificaciones posicionales se configuran mediante el campo `positional_encoding` de todo el modelo (ver Anexo 12 para las formulaciones completas); las dos optimizaciones estructurales se controlan con sus propias banderas.

Método	Descripción	Referencia
Codificaciones Posicionales (12)		
RoPE	Embedding Posicional Rotatorio; rotación basada en frecuencia de Q/K, codificando posición relativa mediante geometría de producto interno	[86]

continúa en la página siguiente

Método	Descripción	Referencia
HoPE	Codificación Posicional Rotatoria Hiperbólica; rotación inspirada en Lorentz usando funciones hiperbólicas; decaimiento monótono de atención con la distancia; RoPE es un caso especial	[18]
NoPE	Sin Codificación Posicional; el modelo aprende posición implícitamente de la máscara causal; supera a PE explícita en generalización de longitud	[44]
ALiBi	Atención con Sesgos Lineales; penalización estática proporcional a distancia en puntuaciones de atención; habilita extrapolación de longitud	[73]
BAM	Mecanismo de Atención Bayesiana; sesgo de posición relativa con Gaussiana Generalizada, forma (β) y escala (α) aprendibles por cabeza; recupera ALiBi en $\beta = 1$; reescalado SSMax vía <code>use_ssm</code>	[9]
PaPE	Codificación Posicional Parabólica; funciones base parabólicas concatenadas a Q/K; centrada en visión, n -D, extrapolable	[67]
PaPE-Eficiente	PaPE en PyTorch puro; sin kernels Triton personalizados, misma matemática	[67]
PaPE-RI	PaPE invariante a rotación (PaPE-RI)	[67]
Sinusoidal Absoluta	Sinusoidal fijo añadido a embeddings (Transformer original)	[92]
Sinusoidal Rotatoria	Frecuencias sinusoidales como matriz de rotación en Q/K	[92]
Absoluta Aprendida	Matriz de parámetros aprendible añadida a embeddings	[92]
None	Módulo nulo; ninguna información posicional inyectada	—
Optimizaciones Estructurales de Embedding (2)		
Embeddings Factorizados	Descompone la matriz de embedding $V \times H$ en factores $V \times R$ y $R \times H$; reduce parámetros de $\mathcal{O}(VH)$ a $\mathcal{O}(VR + RH)$; controlado por <code>factorized_embedding_dim</code>	(interno)
Convolución de Embedding	Conv1d depthwise aplicada sobre el flujo de embeddings antes del primer bloque transformer; proporciona filtrado ligero de contexto local; controlado por <code>embedding_conv_kernel</code>	(interno)

Cuadro 11: Variantes de embedding. V = tamaño de vocabulario, H = tamaño oculto, R = dimensión intermedia factorizada. Las primeras 12 filas son codificaciones posicionales (Anexo 12); las últimas dos son optimizaciones estructurales de embedding.

4. Familias de Optimizadores

4.1. La Evolución de la Optimización en Redes Neuronales

El estudio de optimizadores enmarca la optimización de transformadores como una respuesta a tres presiones estructurales: paisajes de pérdida no convexos, heterogeneidad severa de curvatura entre bloques de parámetros y el costo de memoria de almacenar el estado del optimizador para modelos muy grandes. El informe sostiene que el campo se ha diversificado en varias trayectorias: líneas base adaptativas de primer orden, métodos de reducción de varianza, métodos eficientes en memoria, preconditionadores estructurados de segundo orden, métodos sin programación de tasa de aprendizaje y actualizaciones orientadas a ortogonalidad.

4.2. Línea Base Estándar y Optimizadores Adaptativos

SGD con Momentum. La actualización clásica acumula un búfer de momentum y luego aplica una tasa de aprendizaje fija. En cada iteración t , el algoritmo mantiene un promedio móvil exponencial m_t de los gradientes pasados:

$$m_t = \beta m_{t-1} + g_t \quad (1)$$

$$\theta_{t+1} = \theta_t - \eta m_t \quad (2)$$

donde $g_t = \nabla f(\theta_t)$, $\beta \in [0, 0.99]$ controla la decadencia del momentum y η es la tasa de aprendizaje fija. El término de momentum actúa como velocidad: acelera el movimiento en direcciones consistentes mientras amortigua oscilaciones en direcciones variables. Sus fortalezas son la baja sobrecarga de memoria (un único búfer de momentum por parámetro) y una fuerte generalización cuando se ajusta cuidadosamente. Su principal debilidad en cargas de trabajo de transformadores es la escasa robustez frente a la heterogeneidad de curvatura (diferentes espectros del Hessiano entre grupos de parámetros) y una fuerte dependencia de las programaciones de tasa de aprendizaje.

Algorithm 1 SGD con Momentum

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , coeficiente de momentum β , decadencia de peso λ

Ensure: Parámetros actualizados θ_T

- 1: Inicializar: búfer de momentum $m \leftarrow 0$
 - 2: **for** $t = 0, 1, 2, \dots, T - 1$ **do**
 - 3: Calcular gradiente: $g_t \leftarrow \nabla f(\theta_t)$
 - 4: **if** $\text{decadencia_de_peso} > 0$ **then**
 - 5: $g_t \leftarrow g_t + \lambda \theta_t$ ▷ Regularización L2
 - 6: **end if**
 - 7: Actualizar momentum: $m \leftarrow \beta \cdot m + g_t$
 - 8: Actualizar parámetros: $\theta_{t+1} \leftarrow \theta_t - \eta \cdot m$
 - 9: **end for** **return** θ_T
-

Adam y AdamW. Adam rastrea promedios móviles exponenciales tanto del primer momento (media) como del segundo momento (varianza no centrada) para lograr tasas de aprendizaje adaptativas elemento a elemento. La regla de actualización es:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (3)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (4)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (\text{corrección de sesgo}) \quad (5)$$

$$\theta_{t+1} = \theta_t - \eta \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \right) \quad (6)$$

AdamW introduce una modificación crucial: la decadencia de peso se aplica directamente a los parámetros (desacoplada de los gradientes): $\theta_t \leftarrow \theta_t (1 - \eta \lambda)$ en lugar de añadir $\lambda \theta_t$ al gradiente. Este desacoplamiento evita que el escalado adaptativo interfiera con la fuerza de la regularización. El informe trata a AdamW como la línea base práctica para el ajuste fino de transformadores porque converge rápidamente y es relativamente tolerante a la variación de hiperparámetros. La desventaja es el costo de memoria: ambos tensores de momento deben almacenarse para cada parámetro, duplicando la memoria del estado del optimizador en relación con SGD.

Algorithm 2 AdamW (Adam con Decadencia de Peso Desacoplada)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , tasas de decadencia exponencial $\beta_1, \beta_2 \in [0, 1)$

Require: Constante de momentum ϵ , decadencia de peso λ

Ensure: Parámetros actualizados θ_T

- 1: Inicializar: primer momento $m \leftarrow 0$, segundo momento $v \leftarrow 0$, contador de pasos $t \leftarrow 0$
 - 2: **for** $t = 1, 2, \dots, T$ **do**
 - 3: Calcular gradiente: $g_t \leftarrow \nabla f(\theta_{t-1})$
 - 4: Decadencia de peso (desacoplada): $\theta_{t-1} \leftarrow \theta_{t-1}(1 - \eta\lambda)$
 - 5: Actualizar momentos: $m \leftarrow \beta_1 m + (1 - \beta_1)g_t$
 - 6: $v \leftarrow \beta_2 v + (1 - \beta_2)g_t^2$
 - 7: Corrección de sesgo: $\hat{m} \leftarrow m/(1 - \beta_1^t)$, $\hat{v} \leftarrow v/(1 - \beta_2^t)$
 - 8: Actualizar parámetros: $\theta_t \leftarrow \theta_{t-1} - \eta(\hat{m}/(\sqrt{\hat{v}} + \epsilon))$
 - 9: **end for** **return** θ_T
-

RAdam (Adam Rectificado). RAdam aborda la inestabilidad de Adam en el entrenamiento temprano rectificando dinámicamente la tasa de aprendizaje adaptativa. La observación clave es que el segundo momento v_t tiene una varianza muy alta en los primeros pasos, causando un escalado adaptativo poco fiable. RAdam calcula la longitud efectiva de la ventana de promedio móvil simple (SMA):

$$\rho_t = \rho_\infty - \frac{2t\beta_2^t}{1 - \beta_2^t}, \quad \text{donde} \quad \rho_\infty = \frac{2}{1 - \beta_2} - 1$$

Cuando $\rho_t > 4$ (suficientes muestras para la estimación de varianza), RAdam aplica el escalado adaptativo con un término de rectificación:

$$r_t = \sqrt{\frac{(\rho_t - 4)(\rho_t - 2)\rho_\infty}{(\rho_\infty - 4)(\rho_\infty - 2)\rho_t}}, \quad \theta_{t+1} = \theta_t - \eta r_t \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

Cuando $\rho_t \leq 4$, RAdam retrocede a SGD con momentum: $\theta_{t+1} = \theta_t - \eta \hat{m}_t$. Esta transición gradual elimina la necesidad de programaciones manuales de calentamiento de la tasa de aprendizaje y mejora la robustez.

Algorithm 3 RAdam (Adam Rectificado)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1, β_2 , decadencia de peso λ

Ensure: Parámetros actualizados θ_T

```
1: Inicializar:  $m \leftarrow 0, v \leftarrow 0, t \leftarrow 0$ 
2: Calcular:  $\rho_\infty \leftarrow 2/(1 - \beta_2) - 1$ 
3: for  $t = 1, 2, \dots, T$  do
4:    $g_t \leftarrow \nabla f(\theta_{t-1})$ 
5:   if decadencia_de_peso  $> 0$  then
6:      $\theta_{t-1} \leftarrow \theta_{t-1}(1 - \eta\lambda)$ 
7:   end if
8:    $m \leftarrow \beta_1 m + (1 - \beta_1)g_t$ 
9:    $v \leftarrow \beta_2 v + (1 - \beta_2)g_t^2$ 
10:   $\hat{m} \leftarrow m/(1 - \beta_1^t), \hat{v} \leftarrow v/(1 - \beta_2^t)$ 
11:   $\rho_t \leftarrow \rho_\infty - 2t\beta_2^t/(1 - \beta_2^t)$ 
12:  if  $\rho_t > 4$  then
13:     $r_t \leftarrow \sqrt{((\rho_t - 4)(\rho_t - 2)\rho_\infty)/((\rho_\infty - 4)(\rho_\infty - 2)\rho_t)}$ 
14:     $\theta_t \leftarrow \theta_{t-1} - \eta r_t \hat{m}/(\sqrt{\hat{v}} + \epsilon)$ 
15:  else
16:     $\theta_t \leftarrow \theta_{t-1} - \eta \hat{m}$  ▷ SGD con momentum
17:  end if
18: end for return  $\theta_T$ 
```

4.3. Momentum Avanzado y Reducción de Varianza (2024–2025)

Adan (Momentum Nesterov Adaptativo). Adan reformula la aceleración de Nesterov sin el cálculo de gradiente adicional requerido por el SGD Nesterov clásico. El algoritmo mantiene tres búferes de momentum:

$$m_t = (1 - \beta_1)m_{t-1} + \beta_1 g_t \quad (\text{primer momento}) \quad (7)$$

$$v_t = (1 - \beta_2)v_{t-1} + \beta_2(g_t - g_{t-1}) \quad (\text{velocidad/diferencia de gradientes}) \quad (8)$$

$$n_t = (1 - \beta_3)n_{t-1} + \beta_3[g_t + (1 - \beta_1)(g_t - g_{t-1})]^2 \quad (\text{segundo momento Nesterov}) \quad (9)$$

El término de **Estimación de Momentum Nesterov** (NME) $\bar{g}_t = g_t + (1 - \beta_1)(g_t - g_{t-1})$ estima el gradiente en una posición futura sin evaluarlo. La actualización combina el momentum con la velocidad:

$$\bar{m}_t = m_t + (1 - \beta_1)v_t, \quad \theta_{t+1} = \theta_t - \eta \frac{\bar{m}_t}{\sqrt{n_t} + \epsilon}$$

Adan logra una convergencia rápida en diversas arquitecturas (CNN, GAN, Transformadores) mediante esta aceleración. El costo es mantener tres búferes similares al momentum, aumentando la sobrecarga de memoria en relación con Adam.

Algorithm 4 Adan (Momentum Nesterov Adaptativo)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , $\beta_1, \beta_2, \beta_3 \in (0, 1)$

Ensure: Parámetros actualizados θ_T

```
1: Inicializar:  $m \leftarrow 0$ ,  $v \leftarrow 0$ ,  $n \leftarrow 0$ ,  $g_{-1} \leftarrow 0$  (gradiente anterior)
2: for  $t = 1, 2, \dots, T$  do
3:    $g_t \leftarrow \nabla f(\theta_{t-1})$ 
4:    $m \leftarrow (1 - \beta_1)m + \beta_1 g_t$ 
5:    $\Delta g_t \leftarrow g_t - g_{t-1}$ 
6:    $v \leftarrow (1 - \beta_2)v + \beta_2 \Delta g_t$ 
7:   Estimación Nesterov:  $\bar{g}_t \leftarrow g_t + (1 - \beta_1)\Delta g_t$ 
8:    $n \leftarrow (1 - \beta_3)n + \beta_3 \bar{g}_t^2$ 
9:   Momentum combinado:  $\bar{m} \leftarrow m + (1 - \beta_1)v$ 
10:   $\theta_t \leftarrow \theta_{t-1} - \eta(\bar{m}/(\sqrt{n} + \epsilon))$ 
11:   $g_{t-1} \leftarrow g_t$ 
12: end for return  $\theta_T$ 
```

ADOPT (Adam con Ajuste Óptimo Podado). ADOPT corrige un problema teórico fundamental en Adam: el gradiente aparece tanto en la estimación del primer momento como en la del segundo momento, creando circularidad. ADOPT **desacopla** utilizando el segundo momento del paso anterior para el denominador:

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (10)$$

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \frac{g_t}{\sqrt{v_{t-1}} + \epsilon} \quad (\text{usa } v_{t-1}, \text{ no } v_t) \quad (11)$$

$$\theta_{t+1} = \theta_t - \eta m_t \quad (12)$$

Este simple reordenamiento logra la tasa de convergencia óptima $O(1/\sqrt{T})$ con **cualquier** elección de $\beta_2 \in (0, 1)$, sin suposiciones de ruido acotado. La consecuencia práctica es que ADOPT es un reemplazo directo de Adam con garantías teóricas más sólidas y un rendimiento empírico comparable o superior en los dominios de visión, PLN, RL y modelado generativo.

Algorithm 5 ADOPT (Adam con Ajuste Óptimo Podado)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1, β_2 , tolerancia ϵ

Ensure: Parámetros actualizados θ_T

```
1: Inicializar:  $m \leftarrow 0$ ,  $v \leftarrow 0$ 
2: for  $t = 1, 2, \dots, T$  do
3:    $g_t \leftarrow \nabla f(\theta_{t-1})$ 
4:   if  $\text{decadencia\_de\_peso} > 0$  then
5:      $\theta_{t-1} \leftarrow \theta_{t-1}(1 - \eta\lambda)$ 
6:   end if
7:   Usar segundo momento anterior:  $\text{denom} \leftarrow \sqrt{\max(v, \epsilon)} + \epsilon$ 
8:   Actualizar primer momento usando varianza anterior:  $m \leftarrow \beta_1 m + (1 - \beta_1)(g_t/\text{denom})$ 
9:   Actualizar segundo momento con gradiente actual:  $v \leftarrow \beta_2 v + (1 - \beta_2)g_t^2$ 
10:   $\theta_t \leftarrow \theta_{t-1} - \eta m$ 
11: end for return  $\theta_T$ 
```

AdEMAMix (Mezcla de Promedios Móviles Exponenciales). AdEMAMix reemplaza el EMA único de gradientes de Adam por una **mezcla de dos EMA**: uno de decadencia rápida y otro de decadencia lenta. Esto aborda la observación de que los gradientes siguen siendo

informativos durante decenas de miles de pasos, no solo cientos:

$$m_{1,t} = \beta_1 m_{1,t-1} + (1 - \beta_1) g_t \quad (\text{EMA rápido, } \beta_1 \approx 0,9) \quad (13)$$

$$m_{2,t} = \beta_3 m_{2,t-1} + (1 - \beta_3) g_t \quad (\text{EMA lento, } \beta_3 \approx 0,9999) \quad (14)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (15)$$

$$m_t = m_{1,t} + \alpha_t m_{2,t} \quad (\text{mezcla con peso programado } \alpha_t) \quad (16)$$

$$\theta_{t+1} = \theta_t - \eta \frac{m_t}{\sqrt{v_t} + \epsilon} \quad (17)$$

El peso de la mezcla α_t típicamente aumenta durante el entrenamiento, permitiendo que el EMA rápido proporcione adaptación inmediata mientras que el EMA lento acumula correlaciones de gradiente a largo plazo. Empíricamente, un modelo de 1.3B parámetros en 101B tokens alcanza una pérdida similar a AdamW en 197B tokens (ganancia del 95 % en eficiencia de datos), lo que sugiere que el EMA lento reduce significativamente el olvido del modelo.

Algorithm 6 AdEMAMix (Mezcla de Promedios Móviles Exponenciales)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1 (rápido), β_3 (lento), β_2 (segundo momento)

Require: Peso de mezcla α_t (típicamente creciente), tolerancia ϵ

Ensure: Parámetros actualizados θ_T

```

1: Inicializar:  $m_1 \leftarrow 0$  (EMA rápido),  $m_2 \leftarrow 0$  (EMA lento),  $v \leftarrow 0$ 
2: for  $t = 1, 2, \dots, T$  do
3:    $g_t \leftarrow \nabla f(\theta_{t-1})$ 
4:   if  $\text{decadencia\_de\_peso} > 0$  then
5:      $\theta_{t-1} \leftarrow \theta_{t-1}(1 - \eta\lambda)$ 
6:   end if
7:    $m_1 \leftarrow \beta_1 m_1 + (1 - \beta_1) g_t$  ▷ EMA rápido
8:    $m_2 \leftarrow \beta_3 m_2 + (1 - \beta_3) g_t$  ▷ EMA lento
9:    $v \leftarrow \beta_2 v + (1 - \beta_2) g_t^2$ 
10:   $m_t \leftarrow m_1 + \alpha_t m_2$  ▷ Mezcla
11:   $\theta_t \leftarrow \theta_{t-1} - \eta(m_t / (\sqrt{v} + \epsilon))$ 
12: end for return  $\theta_T$ 

```

MARS (Haciendo Brillar las Tasas de Aprendizaje Adaptativas). MARS combina métodos de gradiente preconditionado (ej., AdamW) con **reducción de varianza** mediante momentum recursivo estocástico escalado. La innovación central es una estimación del gradiente con varianza reducida:

$$c_t = g_t + \gamma(c_{t-1} - g_{t-1}) \quad (\text{estimación recursiva tipo SVRG}) \quad (18)$$

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) c_t \quad (19)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) c_t^2 \quad (20)$$

$$\theta_{t+1} = \theta_t - \eta \frac{m_t}{\sqrt{v_t} + \epsilon} \quad (21)$$

donde $\gamma \in [0,01,0,1]$ controla cuánta información de gradiente histórico se retiene. El gradiente con varianza reducida c_t actúa como un filtro de ruido implícito, amplificando las direcciones de señal consistentes y amortiguando el ruido contradictorio. MARS-AdamW supera consistentemente a AdamW por márgenes significativos en el preentrenamiento de GPT-2, lo que sugiere que la reducción de varianza mejora sustancialmente la convergencia en el entrenamiento estocástico por mini-lotes.

Algorithm 7 MARS (Haciendo Brillar las Tasas de Aprendizaje Adaptativas)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1, β_2 , decadencia de peso λ

Require: Coeficiente de reducción de varianza $\gamma \in [0, 0.1, 0, 1]$

Ensure: Parámetros actualizados θ_T

```
1: Inicializar:  $m \leftarrow 0$ ,  $v \leftarrow 0$ ,  $c \leftarrow 0$  (gradiente con varianza reducida),  $g_{-1} \leftarrow 0$ 
2: for  $t = 1, 2, \dots, T$  do
3:    $g_t \leftarrow \nabla f(\theta_{t-1})$ 
4:   Reducción de varianza:  $c \leftarrow g_t + \gamma(c - g_{t-1})$ 
5:    $m \leftarrow \beta_1 m + (1 - \beta_1)c$ 
6:    $v \leftarrow \beta_2 v + (1 - \beta_2)c^2$ 
7:   if  $\text{decadencia\_de\_peso} > 0$  then
8:      $\theta_{t-1} \leftarrow \theta_{t-1}(1 - \eta\lambda)$ 
9:   end if
10:   $\theta_t \leftarrow \theta_{t-1} - \eta(m/(\sqrt{v} + \epsilon))$ 
11:   $g_{t-1} \leftarrow g_t$ 
12: end for return  $\theta_T$ 
```

Optimizadores Cautelosos (Cautious AdamW, Cautious Lion). El marco Cauteloso aplica una **modificación de una línea** a cualquier optimizador basado en momentum: enmascarar la actualización de modo que solo se apliquen las dimensiones donde el momentum y la dirección del gradiente coinciden:

$$\text{mask}_i = \begin{cases} 1 & \text{si } m_t[i] \cdot g_t[i] > 0 \quad (\text{acuerdo}) \\ 0 & \text{en caso contrario} \end{cases} \quad (22)$$

$$u_t = \left(\frac{m_t}{\sqrt{v_t} + \epsilon} \right) \odot \text{mask} \quad (\text{enmascaramiento elemento a elemento}) \quad (23)$$

$$\theta_{t+1} = \theta_t - \eta u_t \quad (24)$$

La intuición: el momentum m_t estima la dirección del gradiente a partir del historial; el gradiente actual g_t es la señal instantánea. Cuando ambos coinciden, el optimizador está seguro y debe actualizar agresivamente. Cuando discrepan, el optimizador está en conflicto—la tendencia histórica apunta hacia una región que pudo haber sido buena antes, pero la evidencia actual la contradice. Al enmascarar las dimensiones en conflicto, Cauteloso se vuelve más conservador y evita pasos corruptos. Empíricamente, este simple enmascaramiento logra hasta **1.47× de aceleración** en el preentrenamiento de Llama y MAE mientras preserva las garantías de convergencia.

Algorithm 8 Cautious AdamW (Enmascaramiento de Actualización por Consenso)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1, β_2 , decadencia de peso λ

Ensure: Parámetros actualizados θ_T

```
1: Inicializar:  $m \leftarrow 0, v \leftarrow 0$ 
2: for  $t = 1, 2, \dots, T$  do
3:    $g_t \leftarrow \nabla f(\theta_{t-1})$ 
4:    $m \leftarrow \beta_1 m + (1 - \beta_1)g_t$ 
5:    $v \leftarrow \beta_2 v + (1 - \beta_2)g_t^2$ 
6:   Máscara de consenso:  $\text{mask}_i \leftarrow 1$  si  $m[i] \cdot g_t[i] > 0$ , si no 0 ▷ Acuerdo
7:   Actualización base Adam:  $u \leftarrow m/(\sqrt{v} + \epsilon)$ 
8:   Aplicar máscara:  $u_{\text{masked}} \leftarrow u \odot \text{mask}$  ▷ Elemento a elemento
9:   if  $\text{decadencia\_de\_peso} > 0$  then
10:     $\theta_{t-1} \leftarrow \theta_{t-1}(1 - \eta\lambda)$ 
11:   end if
12:    $\theta_t \leftarrow \theta_{t-1} - \eta u_{\text{masked}}$ 
13: end for return  $\theta_T$ 
```

4.4. Optimizadores de Lote Grande, Eficientes en Memoria y Sin Tasa de Aprendizaje

LAMB (Layer-wise Adaptive Moments optimizer for Batch training). LAMB extiende Adam con **escalado de tasa adaptativo por capas** (inspirado en LARS), permitiendo entrenamiento estable con tamaños de lote extremos (e.g., 64K en BERT):

$$m_t^L = \beta_1 m_{t-1}^L + (1 - \beta_1)g_t^L \quad (\text{momento de primer orden por capas}) \quad (25)$$

$$v_t^L = \beta_2 v_{t-1}^L + (1 - \beta_2)(g_t^L)^2 \quad (26)$$

$$u_{\text{adam}}^L = \frac{m_t^L}{\sqrt{v_t^L} + \epsilon} + \lambda \theta_{t-1}^L \quad (\text{paso adaptativo base con decaimiento}) \quad (27)$$

$$\phi^L = \frac{\|\theta_{t-1}^L\|_2}{\|u_{\text{adam}}^L\|_2} \quad (\text{razón de confianza: normalización por capas}) \quad (28)$$

$$\theta_t^L = \theta_{t-1}^L - \eta \cdot \phi^L \cdot u_{\text{adam}}^L \quad (29)$$

La **razón de confianza** $\phi^L = \|\theta_{t-1}^L\|_2 / \|u_{\text{adam}}^L\|_2$ normaliza el paso de actualización efectivo en relación con la magnitud de los pesos. En lotes muy grandes, el ruido estocástico del gradiente puede superar a la señal, desestabilizando las tasas de aprendizaje por capas. Al escalar las actualizaciones proporcionalmente a las normas de los pesos, LAMB asegura cambios relativos en lugar de absolutos, evitando que actualizaciones pequeñas y seguras en vectores grandes dominen. LAMB preserva los beneficios de generalización de lotes pequeños mientras permite entrenamiento eficiente con lotes grandes.

Algorithm 9 LAMB (Layer-wise Adaptive Moments optimizer for Batch training)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1, β_2 , decaimiento de pesos λ

Ensure: Parámetros actualizados θ_T

```
1: Inicializar: Para cada capa  $L$ :  $m^L \leftarrow 0$ ,  $v^L \leftarrow 0$ 
2: for  $t = 1, 2, \dots, T$  do
3:   for cada capa  $L$  do
4:      $g_t^L \leftarrow \nabla f(\theta_t^L)$ 
5:      $m^L \leftarrow \beta_1 m^L + (1 - \beta_1) g_t^L$ 
6:      $v^L \leftarrow \beta_2 v^L + (1 - \beta_2) (g_t^L)^2$ 
7:     Adam base:  $u_{\text{adam}}^L \leftarrow m^L / (\sqrt{v^L} + \epsilon)$ 
8:     if weight_decay > 0 then
9:        $u_{\text{adam}}^L \leftarrow u_{\text{adam}}^L + \lambda \theta_{t-1}^L$ 
10:    end if
11:    Razón de confianza:  $\phi^L \leftarrow \|\theta_{t-1}^L\|_2 / \|u_{\text{adam}}^L\|_2$  si ambos son no nulos, sino 1
12:     $\theta_t^L \leftarrow \theta_{t-1}^L - \eta \phi^L u_{\text{adam}}^L$ 
13:  end for
14: end for return  $\theta_T$ 
```

Schedule-Free AdamW. Los métodos Schedule-Free eliminan el diseño explícito de programación de la receta de optimización. El algoritmo mantiene dos flujos de parámetros: z_t (exploración) y x_t (promedio suavizado):

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (\text{varianza}) \quad (30)$$

$$z_t = z_{t-1} (1 - \eta \lambda) - \eta \frac{g_t}{\sqrt{v_t} + \epsilon} \quad (\text{paso adaptativo con decaimiento}) \quad (31)$$

$$c_t = \frac{1}{t + 1} \quad (\text{coeficiente de promediado, decrece con el tiempo}) \quad (32)$$

$$x_t = (1 - c_t) x_{t-1} + c_t z_t \quad (\text{promediado de iteraciones}) \quad (33)$$

$$y_t = (1 - \beta) z_t + \beta x_t \quad (\text{interpolación para el punto de evaluación}) \quad (34)$$

El coeficiente de promediado $c_t = 1/(t + 1)$ implementa una programación de tasa de aprendizaje implícita sin especificar explícitamente el número total de pasos T . Este marco unifica la programación y el promediado de iteraciones: el algoritmo explora mediante z_t mientras acumula dirección estable mediante x_t . El punto de evaluación y_t (usado para el cómputo del gradiente) interpola entre exploración y estabilidad. Schedule-Free logra convergencia de última generación en optimización convexa, aprendizaje profundo a gran escala y aprendizaje por refuerzo, eliminando un hiperparámetro importante.

Algorithm 10 Schedule-Free AdamW

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η (fija), β_1, β_2 , decaimiento de pesos λ

Ensure: Parámetros actualizados θ_T o promediado x_T

```
1: Inicializar:  $z \leftarrow \theta_0$  (exploración),  $x \leftarrow \theta_0$  (promedio),  $v \leftarrow 0$ ,  $t \leftarrow 0$ 
2: for  $t = 1, 2, \dots, T$  do
3:    $g_t \leftarrow \nabla f(y_{t-1})$  (gradiente en el punto de interpolación)
4:    $v \leftarrow \beta_2 v + (1 - \beta_2) g_t^2$  ▷ Varianza
5:   Decaimiento de pesos sobre  $z$ :  $z \leftarrow z(1 - \eta \lambda)$ 
6:    $z \leftarrow z - \eta g_t / (\sqrt{v} + \epsilon)$  ▷ Paso adaptativo sobre el gradiente crudo
7:    $c_t \leftarrow 1/(t + 1)$  ▷ Coeficiente de promediado
8:    $x \leftarrow (1 - c_t) x + c_t z$  ▷ Promediado de iteraciones
9:    $y_t \leftarrow (1 - \beta_1) z + \beta_1 x$  ▷ Interpolación para la siguiente evaluación
10: end for return  $x_T$  o  $y_T$ 
```

Adafactor. Adafactor reduce la memoria del optimizador **factorizando** estadísticas de segundo momento para parámetros con forma de matriz, almacenando solo acumuladores de filas y columnas en lugar de estados de varianza densos. Para una matriz de gradiente $G_t \in \mathbb{R}^{m \times n}$:

$$R_t = \beta_2 R_{t-1} + (1 - \beta_2)(G_t^2) \mathbf{1}_n^T \quad (\text{varianza por filas}) \quad (35)$$

$$C_t = \beta_2 C_{t-1} + (1 - \beta_2) \mathbf{1}_m^T (G_t^2) \quad (\text{varianza por columnas}) \quad (36)$$

$$\hat{V}_t = \frac{R_t C_t}{\mathbf{1}_n^T R_t} \quad (\text{varianza reconstruida mediante producto exterior}) \quad (37)$$

$$U_t = \frac{G_t}{\sqrt{\hat{V}_t} + \epsilon} \quad (\text{paso adaptativo normalizado}) \quad (38)$$

$$\hat{U}_t = \frac{U_t}{\max(1, \text{RMS}(U_t))} \quad (\text{recorte de estabilidad}) \quad (39)$$

En lugar de almacenar $m \times n$ valores de segundo momento, Adafactor almacena solo $m + n$ acumuladores, reduciendo la memoria de $O(n_{\text{params}})$ a $O(\sqrt{n_{\text{params}}})$. Esto es más atractivo cuando la VRAM está dominada por el estado del optimizador en lugar de las activaciones. La contrapartida es una expresividad de optimización reducida y posible inestabilidad en algunas tareas.

Algorithm 11 Adafactor (Estadísticas de Segundo Momento Factorizadas)

Require: Matriz de gradiente $G_t \in \mathbb{R}^{m \times n}$, tasa de aprendizaje η , $\beta_2 \approx 0,999$

Ensure: Parámetros actualizados

- 1: Inicializar: Acumuladores de fila $R \leftarrow \epsilon \mathbf{1}_m^T$, Columna $C \leftarrow \epsilon \mathbf{1}_n$
 - 2: **for** $t = 1, 2, \dots, T$ **do**
 - 3: $G_t \leftarrow \nabla f(\theta_t)$ (gradiente matricial)
 - 4: $R \leftarrow \beta_2 R + (1 - \beta_2)(G_t^2) \mathbf{1}_n^T$ ▷ Productos internos por filas
 - 5: $C \leftarrow \beta_2 C + (1 - \beta_2) \mathbf{1}_m^T (G_t^2)$ ▷ Productos internos por columnas
 - 6: Varianza reconstruida: $\hat{V} \leftarrow (R \cdot C) / (\mathbf{1}_n^T R)$ ▷ Mediante producto exterior
 - 7: Paso adaptativo normalizado: $U_t \leftarrow G_t / (\sqrt{\hat{V}} + \epsilon)$
 - 8: Recorte RMS por fila: $\hat{U}_t \leftarrow U_t / \max(1, \text{RMS}(U_t))$
 - 9: $\theta_{t+1} \leftarrow \theta_t - \eta \hat{U}_t$
 - 10: **end for**
-

GaLore (Gradient Low-Rank Projection). GaLore proyecta gradientes 2D en un subespacio de bajo rango antes de la optimización, reduciendo la memoria del estado del optimizador mientras mantiene el escalado adaptativo del paso. Para una matriz de parámetros 2D $W \in \mathbb{R}^{m \times n}$:

$$U, S, V = \text{SVD}(G_t) \quad (\text{calcular descomposición singular}) \quad (40)$$

$$P \in \mathbb{R}^{n \times r} \quad \text{o} \quad P^T \in \mathbb{R}^{r \times m} \quad (\text{seleccionar los } r \text{ vectores singulares superiores}) \quad (41)$$

$$G_{\text{low}} = P^T G_t \quad (\text{proyectar al espacio de bajo rango}) \quad (42)$$

$$\Delta_{\text{low}} = \text{Adam}(G_{\text{low}}) \quad (\text{optimizar en el espacio comprimido}) \quad (43)$$

$$\Delta = P \Delta_{\text{low}} \quad (\text{reconstruir en el espacio original}) \quad (44)$$

Al proyectar en un subespacio de rango r (típicamente $r \ll \min(m, n)$), el estado del optimizador se reduce de $O(mn)$ a $O(r(m+n))$ para parámetros 2D. Este enfoque complementario de ahorro de memoria es especialmente relevante cuando el modelo es demasiado grande para el estado completo del optimizador. GaLore funciona sinérgicamente con otras técnicas y ha mostrado resultados empíricos sólidos en modelos de miles de millones de parámetros.

Algorithm 12 GaLore (Gradient Low-Rank Projection)

Require: Matriz de parámetros 2D $W \in \mathbb{R}^{m \times n}$, tasa de aprendizaje η , rango $r \ll \min(m, n)$

Ensure: Parámetros actualizados

```
1: Inicializar: Estado de Adam en el espacio de bajo rango (si es variante de rango 2)
2: for  $t = 1, 2, \dots, T$  do
3:    $G_t \leftarrow \nabla f(W_t)$ 
4:   if  $t \bmod K = 1$  then ▷ SVD periódico
5:      $U_t, S_t, V_t^\top \leftarrow \text{SVD}(G_t)$  (completa o delgada)
6:     Seleccionar proyección:  $P \leftarrow U_t[:, :r]$  o  $P \leftarrow V_t[:, :r]$ 
7:   end if
8:   Proyectar gradiente:  $G_{\text{low}} \leftarrow P^\top G_t$  (o  $G_t P^\top$  para proyección derecha)
9:   Ejecutar Adam en bajo rango:  $\Delta_{\text{low}} \leftarrow \text{Adam}(G_{\text{low}})$ 
10:  Reconstruir en espacio original:  $\Delta \leftarrow P \Delta_{\text{low}}$  (o  $\Delta_{\text{low}} P^\top$ )
11:   $W_t \leftarrow W_t - \eta \Delta$ 
12: end for
```

APOLLO, APOLLO-Mini, y Q-APOLLO. La familia APOLLO [112] parte de la observación de que el denominador elemento a elemento de AdamW puede **transformarse en una actualización estructurada de la tasa de aprendizaje**. En lugar de almacenar momentos densos para cada entrada de parámetro, APOLLO proyecta un gradiente matricial $G_t \in \mathbb{R}^{m \times n}$ en un subespacio aleatorio compacto y rastrea momentos estilo Adam allí:

$$R_t = P_t G_t \quad \text{o} \quad R_t = G_t P_t^\top \quad (45)$$

$$M_t^R = \beta_1 M_{t-1}^R + (1 - \beta_1) R_t \quad (46)$$

$$V_t^R = \beta_2 V_{t-1}^R + (1 - \beta_2) R_t^2 \quad (47)$$

$$\tilde{R}_t = \frac{M_t^R}{\sqrt{V_t^R} + \epsilon} \quad (48)$$

El estado proyectado *no* se expande de vuelta a una actualización densa de bajo rango como en los métodos basados en SVD. En su lugar, APOLLO estima un tensor de escalado estructurado S_t en el espacio original. En la variante estándar de APOLLO, ese escalado es **por canales**: cada fila o canal recibe su propia razón de norma. En APOLLO-Mini, el escalado se reduce a un único escalar **por tensor**, correspondiente al caso extremo de rango 1 descrito en el artículo. La actualización de parámetros resultante es, por tanto, similar a Adam en adaptación pero mucho más cercana a SGD en costo de estado:

$$W_t \leftarrow (1 - \eta\lambda)W_{t-1} - \eta\alpha(G_t \odot S_t)$$

donde α es el factor de escala adicional usado para estabilizar variantes altamente comprimidas.

La contribución práctica del artículo es doble. Primero, APOLLO reemplaza el costoso SVD repetido con **proyección aleatoria gaussiana** actualizada periódicamente, de modo que la carga computacional es multiplicación de matrices ordinaria en lugar de descomposición espectral. Segundo, el optimizador es inusualmente tolerante a la compresión extrema: incluso **APOLLO-Mini**, que mantiene solo estado auxiliar de rango 1, sigue siendo competitivo o mejor que AdamW en los experimentos de preentrenamiento reportados, mientras se acerca al costo de memoria de SGD.

Algorithm 13 APOLLO / APOLLO-Mini Escalado de Gradiente Estructurado

Require: Matriz de pesos $W \in \mathbb{R}^{m \times n}$ con $m \leq n$, tasa de aprendizaje η , factor de escala α , tasas de decaimiento (β_1, β_2) , decaimiento de pesos λ , rango r , intervalo de actualización de proyección T

Ensure: Parámetros actualizados W_T

```
1: Inicializar momentos proyectados:  $M^R \leftarrow 0, V^R \leftarrow 0$ , paso  $t \leftarrow 0$ 
2: repeat
3:   Calcular gradiente:  $G_t \leftarrow \nabla_W \phi(W_t)$ 
4:   if  $t \bmod T = 0$  then
5:     Muestrear proyector gaussiano  $P_t \sim \mathcal{N}(0, 1/r)$  con una semilla nueva
6:   end if
7:   Proyectar gradiente:  $R_t \leftarrow P_t G_t$   $\triangleright$  o  $G_t P_t^\top$  según la disposición
8:   Actualizar momentos proyectados AdamW:  $M_t^R, V_t^R \leftarrow \text{AdamWState}(R_t; \beta_1, \beta_2)$ 
9:   Normalizar estado proyectado:  $\tilde{R}_t \leftarrow M_t^R / (\sqrt{V_t^R} + \epsilon)$ 
10:  if APOLLO then
11:     $S_t \leftarrow \text{diag}(s_1^R, \dots, s_m^R)$ , donde  $s_i^R = \|\tilde{R}_t[i, :]\|_2 / \|R_t[i, :]\|_2$ 
12:  else
13:     $S_t \leftarrow s_t^R$ , donde  $s_t^R = \|\tilde{R}_t\|_2 / \|R_t\|_2$ 
14:  end if
15:  Actualizar pesos:  $W_t \leftarrow (1 - \eta\lambda)W_{t-1} - \eta\alpha(G_t \odot S_t)$ 
16:   $t \leftarrow t + 1$ 
17: until convergencia
```

APOLLO-Mini. APOLLO-Mini es el miembro de la familia optimizado para **eficiencia de memoria extrema**. El artículo lo motiva argumentando que, en un espacio compacto de rango 1, el escalado por canales se vuelve demasiado ruidoso, por lo que la actualización se simplifica aún más a un único escalar por tensor. La pérdida de granularidad se compensa parcialmente con el factor de escala explícito α (el artículo discute valores como 128 en este régimen), proporcionando un punto útil en la frontera de Pareto de optimización: estado muy pequeño, sin sobrecarga de SVD, y aún un comportamiento sólido en preentrenamiento.

Q-APOLLO. El artículo de APOLLO también enfatiza que la familia se combina naturalmente con **cuantización** para entrenamiento con memoria ultra-baja. Este repositorio convierte esa observación de sistemas en una variante concreta del optimizador, **q_apollo**. En la implementación, los momentos de primer y segundo orden de bajo rango de APOLLO se almacenan en forma cuantizada junto con escalas y desplazamientos por tensor, y se descuantizan solo cuando es necesario para el siguiente paso. Q-APOLLO preserva, por tanto, la lógica de gradiente proyectado de APOLLO mientras reduce la precisión del estado restante del optimizador, convirtiéndolo en el miembro más agresivo en ahorro de memoria de la pila local de optimizadores.

Anon (Adaptivity Non-restricted Optimizer with Novel convergence technique). Anon [3] introduce adaptividad ajustable continuamente mediante un único parámetro $\gamma \in \mathbb{R}$, cerrando la brecha entre comportamientos tipo SGD ($\gamma = 0$) y tipo Adam ($\gamma = 1$), y extrapolando más allá de ambos. La innovación central es el mecanismo Incremental Delay Update (IDU), que permite convergencia estable a través de todo el espectro de adaptividad de valores reales:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (\text{momento de primer orden}) \quad (49)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (\text{momento de segundo orden}) \quad (50)$$

$$\bar{v}_t = \frac{v_t}{1 - \beta_2^{\max(t,1)}} + \epsilon \quad (\text{momento de segundo orden con corrección de sesgo}) \quad (51)$$

$$\text{fixed_lr}_k = \begin{cases} \bar{v}_k^{-\gamma/2} & \text{si } k = 0 \\ \sqrt{2 / \left(\frac{1}{\text{fixed_lr}_{k-1}^2} + \bar{v}_k^\gamma \right)} & \text{si } k > 0 \end{cases} \quad (52)$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{1 - \beta_1^t} \cdot m_t \odot \text{fixed_lr}_{\lfloor \log_2 t \rfloor} \quad (53)$$

A diferencia de los optimizadores adaptativos estándar, IDU actualiza el preconditionador solo en potencias de dos ($t = 2^k$), acumulando estadísticas de gradiente entre actualizaciones y agregándolas recursivamente. Este acumulador suave y multiescala evita el seguimiento estricto del máximo de AMSGrad mientras estabiliza demostrablemente la convergencia para cualquier $\gamma \in \mathbb{R}$. El parámetro γ controla directamente la adaptividad: $\gamma > 1$ acelera la salida de puntos de silla (favorable para arquitecturas complejas), $\gamma = 1$ recupera el comportamiento tipo Adam, $\gamma = 0$ produce escalado tipo SGD, y $\gamma < 0$ se sesga hacia mínimos más planos (beneficioso para arquitecturas clásicas como CNNs).

Anon mantiene tres buffers de estado ($m, v, \text{fixed_lr}$) con costo $O(n)$ por paso, situándolo en la misma clase de complejidad que AdamW pero con la flexibilidad adicional de adaptividad ajustable. La técnica IDU converge demostrablemente con regret $O(\sqrt{T})$ para problemas convexos y $O(\ln T / \sqrt{T})$ para entornos no convexos, igualando las garantías de los optimizadores adaptativos convencionales mientras soporta todo el rango de adaptividad de valores reales.

Algorithm 14 Anon (Adaptivity Non-restricted Optimizer con IDU)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1, β_2 , tolerancia ϵ , adaptividad $\gamma \in \mathbb{R}$

Ensure: Parámetros actualizados θ_T

```

1: Inicializar:  $m \leftarrow 0, v \leftarrow 0, \text{fixed\_lr} \leftarrow 0$ , paso  $t \leftarrow 0$ , contador IDU  $k \leftarrow -1$ 
2: for  $t = 1, 2, \dots, T$  do
3:    $g_t \leftarrow \nabla f(\theta_{t-1})$ 
4:    $m \leftarrow \beta_1 m + (1 - \beta_1) g_t$ 
5:    $v \leftarrow \beta_2 v + (1 - \beta_2) g_t^2$ 
6:   if  $t = 2^k$  then
7:      $k \leftarrow k + 1$ 
8:      $\bar{v} \leftarrow v / (1 - \beta_2^{\max(t/2, 1)}) + \epsilon$ 
9:     if  $k = 0$  then
10:       $\text{fixed\_lr} \leftarrow \bar{v}^{-\gamma/2}$ 
11:     else
12:       $\text{fixed\_lr} \leftarrow \sqrt{2 / (1 / \text{fixed\_lr}^2 + \bar{v}^\gamma)}$ 
13:     end if
14:      $v \leftarrow 0$ 
15:   end if
16:    $\theta_t \leftarrow \theta_{t-1} - \frac{\eta}{1 - \beta_1^t} \cdot m \odot \text{fixed\_lr}$ 
17: end for return  $\theta_T$ 

```

Prodigy (Approximating the Distance Estimate). Prodigy adapta la escala efectiva del paso mediante una estadística tipo distancia acumulativa, eliminando la necesidad de ajuste

explícito de la tasa de aprendizaje. El algoritmo mantiene una estimación de distancia acumulativa:

$$u_t = \frac{g_t}{\sqrt{v_t} + \epsilon} \quad (\text{paso adaptativo no normalizado}) \quad (54)$$

$$s_t = s_{t-1} + \langle u_t, \theta_t - \theta_0 \rangle \quad (\text{distancia signada acumulativa}) \quad (55)$$

$$d_t = \text{máx}(d_{t-1}, d_0 + d_{\text{coef}} \cdot s_t) \quad (\text{estimación de distancia con cota inferior}) \quad (56)$$

$$\theta_{t+1} = \theta_t - \eta \cdot d_t \cdot u_t \quad (57)$$

donde d_0 es una cota inicial y d_{coef} controla qué tan agresivamente se adapta la estimación. La estimación de distancia d_t captura la magnitud combinada de gradientes pasados ponderada por el desplazamiento real de los parámetros, implementando una tasa de aprendizaje efectiva implícita. Este escalado consciente de la distancia logra convergencia robusta en distintas escalas de problemas y tamaños de lote sin requerir una programación de la tasa de aprendizaje. Prodigy reduce la sensibilidad a hiperparámetros estimando los tamaños de paso a partir de la geometría de optimización en lugar del conocimiento previo específico del problema.

Algorithm 15 Prodigy (Approximating the Distance Estimate)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , coeficiente d_{coef} , distancia inicial $d_0 > 0$

Ensure: Parámetros actualizados θ_T

- 1: Inicializar: $s \leftarrow 0$ (distancia signada acumulativa), $d \leftarrow d_0$
 - 2: **for** $t = 1, 2, \dots, T$ **do**
 - 3: $g_t \leftarrow \nabla f(\theta_{t-1})$
 - 4: $v_t \leftarrow \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$ ▷ Segundo momento
 - 5: $u_t \leftarrow g_t / (\sqrt{v_t} + \epsilon)$ ▷ Adaptativo no normalizado
 - 6: Actualizar distancia: $s \leftarrow s + \langle u_t, \theta_t - \theta_0 \rangle$ ▷ Distancia signada
 - 7: $d \leftarrow \text{máx}(d, d_0 + d_{\text{coef}} \cdot s)$ ▷ Distancia con cota inferior
 - 8: $\theta_t \leftarrow \theta_{t-1} - \eta \cdot d \cdot u_t$ ▷ Actualización escalada por distancia
 - 9: **end for** **return** θ_T
-

4.5. Optimizadores de Segundo Orden, Geométricos y de Ortogonalidad

Algorithm 16 Shampoo (Precondicionamiento Matricial mediante Productos de Kronecker)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , intervalo de eigendescomposición K

Ensure: Parámetros actualizados θ_T

- 1: Inicializar: $L \leftarrow \epsilon I_m$, $R \leftarrow \epsilon I_n$ (matrices de Gram izquierda y derecha)
 - 2: **for** $t = 1, 2, \dots, T$ **do**
 - 3: $G \leftarrow \nabla f(\theta_{t-1})$ ▷ Gradiente
 - 4: Actualizar matrices de Gram: $L \leftarrow L + GG^\top$, $R \leftarrow R + G^\top G$
 - 5: **if** $t \bmod K == 0$ **then**
 - 6: $Q_L, \Lambda_L \leftarrow \text{eigh}(L)$ ▷ Eigendescomposición de L
 - 7: $Q_R, \Lambda_R \leftarrow \text{eigh}(R)$ ▷ Eigendescomposición de R
 - 8: $L^{-1/4} \leftarrow Q_L(\Lambda_L + \epsilon)^{-1/4} Q_L^\top$
 - 9: $R^{-1/4} \leftarrow Q_R(\Lambda_R + \epsilon)^{-1/4} Q_R^\top$
 - 10: **end if**
 - 11: $\Delta\theta \leftarrow L^{-1/4} G R^{-1/4}$ ▷ Gradiente precondicionado
 - 12: $\theta_t \leftarrow \theta_{t-1} - \eta \cdot \Delta\theta$
 - 13: **end for** **return** θ_T
-

Shampoo (Precondicionamiento Matricial mediante Productos de Kronecker). Shampoo es un método estructurado de segundo orden que calcula preconditionadores matri-

ciales a partir de estadísticas de producto exterior con estructura de Kronecker. Para una matriz de parámetros 2D $W \in \mathbb{R}^{m \times n}$:

$$L_t = L_{t-1} + G_t G_t^\top \quad (\text{matriz de Gram izquierda/filas, } m \times m) \quad (58)$$

$$R_t = R_{t-1} + G_t^\top G_t \quad (\text{matriz de Gram derecha/columnas, } n \times n) \quad (59)$$

$$L_t^{-1/4} = Q_L(\Lambda_L)^{-1/4} Q_L^\top \quad (\text{mediante eigendescomposición}) \quad (60)$$

$$R_t^{-1/4} = Q_R(\Lambda_R)^{-1/4} Q_R^\top \quad (61)$$

$$\Delta W_t = L_t^{-1/4} G_t R_t^{-1/4} \quad (\text{gradiente preconditionado}) \quad (62)$$

Shampoo aproxima el preconditionador de matriz completa de Adagrad $H^{-1/2}$ (donde H es el Hessiano) utilizando estructura factorizada de Kronecker. En lugar de almacenar un preconditionador de $(mn) \times (mn)$, Shampoo mantiene dos matrices más pequeñas ($m \times m$ y $n \times n$), capturando correlaciones entre parámetros dentro y entre grupos. El método ha demostrado ser efectivo a escala (sistemas de producción de Google) y es adecuado para arquitecturas transformer con estructura de alto rango. Las eigendescomposiciones se realizan periódicamente (e.g., cada $K = 10$ pasos) para amortizar el costo. Contrapartida: mayor cómputo por paso y eigendescomposición $O(m^3 + n^3)$ periódica frente a mejor condicionamiento y convergencia acelerada.

SOAP (Shampoo with Adam in eigenbasis). SOAP es una variante simplificada de Shampoo que desacopla el preconditionamiento del seguimiento de momento. En lugar de álgebra matricial compleja sobre gradientes preconditionados, SOAP ejecuta Adam estándar en la base de eigenvectores de los preconditionadores de Shampoo:

$$L_t = L_{t-1} + G_t G_t^\top, \quad R_t = R_{t-1} + G_t^\top G_t \quad (\text{acumulación de Gram}) \quad (63)$$

$$Q_L, \Lambda_L = \text{eigh}(L_t), \quad Q_R, \Lambda_R = \text{eigh}(R_t) \quad (\text{eigendescomposición periódica}) \quad (64)$$

$$G_t^{\text{rot}} = Q_L^\top G_t Q_R \quad (\text{rotar gradiente a la base de eigenvectores}) \quad (65)$$

$$m_t^{\text{rot}} = \beta_1 m_{t-1}^{\text{rot}} + (1 - \beta_1) G_t^{\text{rot}} \quad (66)$$

$$v_t^{\text{rot}} = \beta_2 v_{t-1}^{\text{rot}} + (1 - \beta_2) (G_t^{\text{rot}})^2 \quad (\text{Adam en el espacio rotado}) \quad (67)$$

$$U_t^{\text{rot}} = \frac{m_t^{\text{rot}}}{\sqrt{v_t^{\text{rot}} + \epsilon}}, \quad U_t = Q_L U_t^{\text{rot}} Q_R^\top \quad (\text{rotar de vuelta}) \quad (68)$$

La idea clave: todo el seguimiento de momento ocurre en la base de eigenvectores bien condicionada, simplificando la estabilidad numérica y el análisis teórico. SOAP combina los beneficios de Shampoo (estructura de curvatura explícita) y Adam (mecánica de momento probada), siendo más limpio y a menudo más estable que Shampoo completo. Las eigendescomposiciones se recalculan cada K pasos, amortizando el costo.

Algorithm 17 SOAP (Shampoo with Adam in Eigenbasis)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1, β_2 , intervalo de eigendescomposición K

Ensure: Parámetros actualizados θ_T

```
1: Inicializar:  $L \leftarrow \epsilon I_m, R \leftarrow \epsilon I_n, m \leftarrow 0, v \leftarrow 0$ 
2: for  $t = 1, 2, \dots, T$  do
3:    $G \leftarrow \nabla f(\theta_{t-1})$  ▷ Gradiente
4:   Actualizar Gram:  $L \leftarrow L + GG^\top, R \leftarrow R + G^\top G$ 
5:   if  $t \bmod K == 0$  then
6:      $Q_L, \Lambda_L \leftarrow \text{eigh}(L), Q_R, \Lambda_R \leftarrow \text{eigh}(R)$ 
7:   end if
8:    $G^{\text{rot}} \leftarrow Q_L^\top G Q_R$  ▷ Rotar gradiente a la base de eigenvectores
9:    $m \leftarrow \beta_1 m + (1 - \beta_1) G^{\text{rot}}$  ▷ Media móvil exponencial (corregir sesgo externamente)
10:   $v \leftarrow \beta_2 v + (1 - \beta_2) (G^{\text{rot}})^2$  ▷ Segundo momento (corregir sesgo externamente)
11:   $u \leftarrow m / (\sqrt{v} + \epsilon)$  ▷ Paso adaptativo en la base de eigenvectores
12:   $\Delta\theta \leftarrow Q_L u Q_R^\top$  ▷ Rotar de vuelta al espacio de parámetros
13:   $\theta_t \leftarrow \theta_{t-1} - \eta \cdot \Delta\theta$ 
14: end for return  $\theta_T$ 
```

Lion (EvoLved Sign Momentum). Lion logra un **sobrecosto de memoria mínimo** al usar actualizaciones basadas en signo en lugar de escalado adaptativo completo:

$$c_t = \beta_1 m_t + (1 - \beta_1) g_t \quad (\text{entrada de momento}) \quad (69)$$

$$\theta_{t+1} = \theta_t - \eta (\text{sign}(c_t) + \lambda \theta_t) \quad (\text{actualización con operador signo}) \quad (70)$$

$$m_{t+1} = \beta_2 m_t + (1 - \beta_2) g_t \quad (\text{acumulación de momento}) \quad (71)$$

Todas las operaciones de escalado elemento a elemento se reemplazan con `sign()`, que produce $\{-1, 0, +1\}$. Esto reduce drásticamente la memoria en comparación con métodos tipo Adam: Lion almacena solo el buffer de momento, sin varianza de segundo momento. La contrapartida: las actualizaciones basadas en signo sacrifican la adaptación de tasa de aprendizaje elemento a elemento que hace efectivo a Adam. Lion se posiciona no como un optimizador universalmente superior sino como una alternativa especializada de baja memoria y alto rendimiento para escenarios donde la memoria de activaciones domina y se puede sacrificar algo de sofisticación del optimizador. Funciona bien en regímenes de lotes grandes y cuando el rendimiento del hardware es la restricción principal.

Algorithm 18 Lion (EvoLved Sign Momentum)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1, β_2 , decaimiento de pesos λ

Ensure: Parámetros actualizados θ_T

```
1: Inicializar:  $m \leftarrow 0$  (buffer de momento)
2: for  $t = 1, 2, \dots, T$  do
3:    $g \leftarrow \nabla f(\theta_{t-1})$  ▷ Gradiente
4:    $c \leftarrow \beta_1 m + (1 - \beta_1) g$  ▷ Entrada de momento
5:    $\theta_t \leftarrow \theta_{t-1} - \eta (\text{sign}(c) + \lambda \theta_{t-1})$  ▷ Actualización basada en signo con decaimiento de pesos
6:    $m \leftarrow \beta_2 m + (1 - \beta_2) g$  ▷ Acumulación de momento (desacoplada)
7: end for return  $\theta_T$ 
```

Sophia (Second-Order Hessian Information with Optimized Approximation). Sophia utiliza **estimaciones diagonales del Hessiano** para escalado consciente de la curvatura sin

el costo de memoria y cómputo de los métodos densos de segundo orden.

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (\text{momento de primer orden}) \quad (72)$$

$$h_t = \beta_2 h_{t-(k-1)} + (1 - \beta_2) \hat{h}_t \quad (\text{Hessiano diagonal, actualizado cada } k \text{ pasos}) \quad (73)$$

$$\text{clip}(x, C) = \min(\max(x, -C), C) \quad (\text{recorte elemento a elemento}) \quad (74)$$

$$\theta_{t+1} = \theta_t - \eta \cdot \text{clip}\left(\frac{m_t}{\max(\gamma h_t, \epsilon)}, 1\right) \quad (75)$$

donde $\hat{h}_t$ es una estimación diagonal (e.g., estimador de traza de Hutchinson) y γ es un factor de escala. El Hessiano diagonal h_t captura la curvatura local, permitiendo que el optimizador tome pasos más pequeños en direcciones pronunciadas y pasos más grandes en direcciones planas. La operación de recorte $\text{clip}(\cdot, 1)$ evita que los pasos adaptativos exploten. Sophia pertenece a la familia de métodos conscientes de la curvatura que buscan mejor condicionamiento sin el costo $O(n^2)$ o $O(n^3)$ de los métodos completos de segundo orden. Funciona particularmente bien en escenarios de ajuste fino de segunda pasada.

Algorithm 19 Sophia (Hessiano Diagonal con Actualizaciones Recortadas)

Require: Parámetros iniciales θ_0 , tasa de aprendizaje η , β_1, β_2 , frecuencia de actualización del Hessiano k , umbral de recorte C

Ensure: Parámetros actualizados θ_T

```

1: Inicializar:  $m \leftarrow 0$ ,  $h \leftarrow \epsilon$  (estimación diagonal del Hessiano)
2: for  $t = 1, 2, \dots, T$  do
3:    $g \leftarrow \nabla f(\theta_{t-1})$ 
4:    $m \leftarrow \beta_1 m + (1 - \beta_1) g$   $\triangleright$  Momento de primer orden (corregir sesgo externamente)
5:   if  $t \bmod k == 0$  then
6:      $\hat{h} \leftarrow \text{HutchinsonEstimate}(g)$   $\triangleright$  Hessiano diagonal mediante Hutchinson
7:      $h \leftarrow \beta_2 h + (1 - \beta_2) \hat{h}$   $\triangleright$  Actualizar estimación del Hessiano
8:   end if
9:    $u \leftarrow \frac{m}{\max(\gamma h, \epsilon)}$   $\triangleright$  Paso adaptativo (elemento a elemento)
10:   $u \leftarrow \text{clip}(u, C)$   $\triangleright$  Recorte elemento a elemento a  $[-C, C]$ 
11:   $\theta_t \leftarrow \theta_{t-1} - \eta \cdot u$ 
12: end for return  $\theta_T$ 

```

Muon y Turbo-Muon (Optimizadores Basados en Ortogonalidad). Muon y Turbo-Muon son **optimizadores orientados a la ortogonalidad** que reformulan la geometría de actualización utilizando iteraciones polinomiales de Newton-Schulz para ortogonalización. Para una matriz de parámetros 2D W con gradiente G_t :

$$X_0 = \frac{G_t}{\|G_t\|_F + \epsilon} \quad (\text{gradiente normalizado}) \quad (76)$$

$$A_k = X_k X_k^\top \quad (\text{Gramiana}) \quad (77)$$

$$B_k = b A_k + c A_k^2 \quad (\text{paso polinomial, coeficientes } b, c \text{ de Newton-Schulz}) \quad (78)$$

$$X_{k+1} = a X_k + B_k X_k \quad (\text{iteración } k = 0, 1, \dots, 4) \quad (79)$$

$$W_{t+1} = W_t - \eta X_K \quad (\text{actualización con dirección ortogonalizada}) \quad (80)$$

Muon realiza 5 iteraciones de Newton-Schulz para producir una dirección aproximadamente ortogonal, asegurando que las actualizaciones respeten restricciones geométricas. Turbo-Muon añade un paso de **precondicionamiento casi-ortogonal** (AOL) antes de las iteraciones, reduciendo el número de pasos de ortogonalización requeridos a 4. La justificación: las actualizaciones ortogonales preservan las normas durante el entrenamiento, evitando la deriva de norma observada en

métodos basados en momento. Estos optimizadores muestran potencial en entrenamiento a gran escala pero requieren kernels CUDA personalizados para eficiencia. Contrapartida: alto cómputo por paso (multiplicaciones de matrices e iteraciones polinomiales) frente a una geometría de actualización fundamentalmente mejor condicionada.

Algorithm 20 Muon (Ortogonalización de Newton-Schulz)

Require: Parámetros iniciales θ (matrices), tasa de aprendizaje η , iteraciones Newton-Schulz K

Ensure: Parámetros actualizados θ

```

1: for cada matriz de parámetros 2D  $W$  do
2:    $G \leftarrow \nabla f(W)$  ▷ Gradiente
3:    $X_0 \leftarrow \frac{G}{\|G\|_{F+\epsilon}}$  ▷ Normalizar gradiente por norma de Frobenius
4:   for  $k = 0, 1, \dots, K - 1$  do
5:      $A_k \leftarrow X_k X_k^\top$  ▷ Gramiana (costo:  $O(mn^2)$  o  $O(m^2n)$  para matrices altas/anchas)
6:      $B_k \leftarrow (3/2)A_k - (1/2)A_k^2$  ▷ Coeficientes de Newton-Schulz
7:      $X_{k+1} \leftarrow B_k X_k$  ▷ Paso polinomial
8:   end for
9:    $W \leftarrow W - \eta X_K$  ▷ Actualizar con dirección ortogonalizada
10: end for return  $\theta$  ▷ actualizado

```

Algorithm 21 Turbo-Muon (Ortogonalización Precondicionada con AOL)

Require: Parámetros iniciales θ (matrices), tasa de aprendizaje η , iteraciones Newton-Schulz K' (típicamente 4)

Ensure: Parámetros actualizados θ

```

1: for cada matriz de parámetros 2D  $W$  do
2:    $G \leftarrow \nabla f(W)$  ▷ Gradiente
3:    $X_0 \leftarrow \frac{G}{\|G\|_{F+\epsilon}}$  ▷ Normalizar gradiente
4:   AOL (Almost-Orthogonal preconditioner): ▷ Paso de preconditionamiento
5:    $P \leftarrow (1,5I - 0,5X_0 X_0^\top)$  ▷ Matriz de preconditionamiento
6:    $X_0 \leftarrow P X_0$  ▷ Inicio preconditionado
7:   for  $k = 0, 1, \dots, K' - 1$  do
8:      $A_k \leftarrow X_k X_k^\top$ 
9:      $B_k \leftarrow (3/2)A_k - (1/2)A_k^2$ 
10:     $X_{k+1} \leftarrow B_k X_k$  ▷ Iteraciones reducidas gracias al preconditionamiento AOL
11:   end for
12:    $W \leftarrow W - \eta X_{K'}$  ▷ Actualizar con dirección ortogonalizada preconditionada
13: end for return  $\theta$  ▷ actualizado

```

Grupo	Métodos	Objetivo Principal	Interpretación desde el Estudio
Línea base clásica	SGD, AdamW, RADam	estabilidad y referencias base	Definen el piso de comparación para las afirmaciones de optimizadores más nuevos.
Rediseño de momento	Adan, AdEMAMix, MARS, Cautious AdamW	adaptación de primer orden más rápida o segura	Mejor cuando la velocidad de convergencia o la estabilidad ante gradiente ruidoso es la preocupación principal.

Grupo	Métodos	Objetivo Principal	Interpretación desde el Estudio
Simplificación de lotes grandes y programación	LAMB, Schedule-Free AdamW	robustez operacional a escala	Reducen la fragilidad debida al crecimiento del tamaño de lote o la ingeniería de programación.
Eficiencia de memoria	Adafactor, GaLore, APOLLO, APOLLO-Mini, Q-APOLLO, Lion	reducción del estado del optimizador	Más útil cuando la VRAM está dominada por el estado del optimizador en lugar de las activaciones; los métodos de la familia APOLLO reemplazan los momentos densos de AdamW con escalado estructurado proyectado o cuantizado.
Consciente de curvatura	Shampoo, Sophia	mejor condicionamiento	Preferir cuando una geometría más rica justifica la sobrecarga de implementación y cómputo.
Orientado a geometría	Muon, Turbo-Muon	estructura de actualización ortogonalizada	Opciones especializadas para geometría matricial y modelado de representaciones.

5. Transformadores Densos, Recurrentes y Aumentados con Memoria

Este anexo sintetiza las familias densas, recurrentes y aumentadas con memoria de transformers. El campo ha evolucionado hacia varios paradigmas principales: atención densa global con variantes, compresión de cabezas clave-valor mediante atención por consultas agrupadas, compresión de estado recurrente con decaimiento, modelos de espacio de estado selectivos, integración numérica de profundidad continua y arquitecturas aumentadas con memoria. Comprender esta taxonomía ilumina las compensaciones fundamentales entre expresividad, costo computacional, huella de memoria y simplicidad de despliegue.

5.1. Atención Densa de Referencia: Estándar y Sigmoide

5.1.1. Atención Softmax Estándar

La atención multi-cabeza estándar [92] calcula la similitud de producto punto escalado entre embeddings de tokens:

- 1: **Entrada:** Matriz de consulta $\mathbf{Q} \in \mathbb{R}^{n \times d}$, Matriz de clave $\mathbf{K} \in \mathbb{R}^{n \times d}$, Matriz de valor $\mathbf{V} \in \mathbb{R}^{n \times d}$
- 2: puntajes $\leftarrow \frac{\mathbf{QK}^\top}{\sqrt{d}} \in \mathbb{R}^{n \times n}$ ▷ calcular similitudes por pares
- 3: pesos_atencion $\leftarrow \text{softmax}(\text{puntajes}, \text{eje} = 1) \in \mathbb{R}^{n \times n}$ ▷ normalizar sobre las claves
- 4: **Salida:** $\mathbf{Y} = \text{pesos_atencion} \cdot \mathbf{V} \in \mathbb{R}^{n \times d}$ ▷ combinación ponderada de valores

Para generación autorregresiva, el almacenamiento en caché KV guarda claves y valores pasados para evitar el recálculo $\mathcal{O}(n^2)$. Sin embargo, este caché de crecimiento lineal ocupa $\sim n \cdot d_{\text{oculto}}$ bytes, lo que puede consumir cientos de gigabytes para modelos de miles de millones de parámetros. La atención estándar logra una **expresividad perfecta** dentro de la ventana de contexto—cualquier token puede atender a cualquier otro token con pesos aprendidos—pero paga el precio del cómputo denso.

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d)$ tiempo, $\mathcal{O}(n^2)$ espacio (materialización de la matriz de atención).
- **Complejidad de inferencia:** $\mathcal{O}(n)$ tiempo por token, $\mathcal{O}(n)$ espacio (caché KV).

- **Fortalezas:** Expresividad incomparable; recuperación perfecta del historial; altamente paralelizable.
- **Debilidades:** El cuello de botella cuadrático prohíbe contextos muy largos; el caché KV domina la memoria durante la generación.

5.1.2. Atención Sigmoides

La atención sigmoides reemplaza el softmax por filas con una activación sigmoides elemento a elemento [77]:

- 1: **Entrada:** $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ como arriba, sesgo aprendible $\mathbf{b} \in \mathbb{R}^{n \times n}$
- 2: $\text{logits} \leftarrow \frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}} + \mathbf{b}$
- 3: $\text{pesos_atencion} \leftarrow \sigma(\text{logits})$ ▷ sigmoides elemento a elemento, no softmax
- 4: **Salida:** $\mathbf{Y} = \text{pesos_atencion} \odot \mathbf{V}$

A diferencia de softmax, la sigmoides no impone una distribución de probabilidad (los pesos no necesitan sumar 1), lo que permite una independencia de tokens más fuerte. El análisis teórico mediante mezcla de expertos muestra que la sigmoides alcanza una complejidad muestral superior: convergencia $\mathcal{O}(n^{-0.51})$ para expertos ReLU frente a $\mathcal{O}(n^{-0.24})$ de softmax. Sin embargo, el entrenamiento empírico reveló inestabilidades de gradiente a escala. El remedio es la **norma híbrida**—agregar normalización después de la salida de atención—que estabiliza los gradientes sin sacrificar los beneficios teóricos del enrutamiento elemento a elemento.

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d)$ (idéntico al estándar), pero las operaciones elemento a elemento permiten una aceleración de inferencia del 17 % mediante FlashSigmoid.
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token con caché KV (asintóticamente igual, pero con factores constantes más bajos).
- **Fortalezas:** Supera la competencia de suma cero; evita la sincronización por filas; implementación eficiente en hardware.
- **Debilidades:** Requiere estabilización cuidadosa (norma híbrida); inestabilidad de entrenamiento a grandes escalas sin pérdida auxiliar.

5.1.3. Atención por Consultas Agrupadas (GQA)

La atención por consultas agrupadas (GQA) [2] tiende un puente entre la atención multi-cabeza (MHA) y la atención multi-consulta (MQA) al particionar las cabezas de consulta en grupos, cada uno compartiendo una sola cabeza clave-valor. Si h es el número total de cabezas de atención, h_k es el número de cabezas clave-valor, y $G = h/h_k$ es el tamaño del grupo, entonces cada grupo de G cabezas de consulta comparte una cabeza KV:

- 1: **Entrada:** $\mathbf{Q} \in \mathbb{R}^{n \times h \cdot d_h}, \mathbf{K} \in \mathbb{R}^{n \times h_k \cdot d_h}, \mathbf{V} \in \mathbb{R}^{n \times h_k \cdot d_h}$
- 2: $\mathbf{K}_{\text{completo}} \leftarrow \text{repeat_interleave}(\mathbf{K}, G)$ ▷ expandir de h_k a h cabezas
- 3: $\mathbf{V}_{\text{completo}} \leftarrow \text{repeat_interleave}(\mathbf{V}, G)$
- 4: $\text{puntajes} \leftarrow \frac{\mathbf{Q}\mathbf{K}_{\text{completo}}^\top}{\sqrt{d_h}} \in \mathbb{R}^{n \times n}$ ▷ producto punto estándar tras expansión
- 5: $\text{pesos_atencion} \leftarrow \text{softmax}(\text{puntajes}, \text{eje} = 1)$
- 6: **Salida:** $\mathbf{Y} = \text{pesos_atencion} \cdot \mathbf{V}_{\text{completo}} \in \mathbb{R}^{n \times h \cdot d_h}$

GQA interpola suavemente entre MHA ($h_k = h, G = 1$) y MQA ($h_k = 1, G = h$). La ventaja clave es un balance ajustable entre la huella del caché KV y la capacidad representacional. Cada cabeza KV adicional consume $2 \cdot d_h \cdot n$ bytes extra en el caché, por lo que reducir h_k produce ahorros proporcionales de memoria.

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot h \cdot d_h)$ (idéntico a MHA tras la expansión de cabezas).
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token, espacio de caché KV $\mathcal{O}(h_k \cdot n \cdot d_h)$.
- **Fortalezas:** Balance flexible de cabezas; probado a escala (Llama 2 y 3 usan $h_k = 8$ cabezas KV con $h = 32$ cabezas de consulta); reduce el caché KV en factor $G\times$; soporta inferencia rápida con FlashAttention.
- **Debilidades:** Menos cabezas KV pueden reducir la capacidad representacional en modelos pequeños; requerir que h_k divida a h restringe las opciones arquitectónicas.

5.2. Arquitecturas Recurrentes y Retentivas

5.2.1. Redes Retentivas (RetNet)

RetNet [88] unifica tres paradigmas de cómputo: entrenamiento paralelo, inferencia recurrente y despliegue por fragmentos. Su innovación central es el **mecanismo de retención**, que utiliza una matriz de decaimiento exponencial fija para modelar la importancia temporal:

1: **Forma paralela (entrenamiento):**

- 2: $\text{matriz_decaimiento}[i, j] \leftarrow \gamma^{i-j}$ para $i \geq j$, si no 0 ▷ decaimiento exponencial causal
- 3: $\text{matriz_decaimiento}[i, j] \leftarrow 0$ para $i < j$ ▷ enmascaramiento causal
- 4: $\mathbf{Y}_{\text{paralelo}} \leftarrow (\mathbf{QK}^\top \odot \text{matriz_decaimiento})\mathbf{V}$ ▷ multiplicación elemento a elemento con decaimiento

1: **Forma recurrente (inferencia):**

- 2: **for** $t = 1, \dots, n$ **do**
- 3: $\mathbf{s}_t \leftarrow \gamma \mathbf{s}_{t-1} + \mathbf{k}_t \mathbf{v}_t^\top$ ▷ actualización de estado con decaimiento
- 4: $\mathbf{y}_t \leftarrow \mathbf{q}_t \mathbf{s}_t$ ▷ salida mediante interacción consulta-estado
- 5: **end for**

El escalar de decaimiento $\gamma \in (0, 1)$ controla la ventana temporal. RetNet utiliza **retención multi-escala** con diferentes valores de γ por cabeza (ej., $\gamma = 1 - 2^{-5}, 1 - 2^{-6}, \dots$), permitiendo dependencias a corto y largo plazo simultáneamente. El modo recurrente por fragmentos divide las secuencias en fragmentos, procesa cada fragmento en paralelo y enhebra un estado recurrente entre fragmentos.

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d)$ (paralela), o $\mathcal{O}(n \cdot c \cdot d)$ (recurrente por fragmentos con tamaño de fragmento c).
- **Complejidad de inferencia:** $\mathcal{O}(1)$ por token, $\mathcal{O}(d^2)$ espacio de estado (matriz fija).
- **Fortalezas:** Inferencia en tiempo constante; triple paradigma de cómputo; consolidación multi-escala.
- **Debilidades:** El decaimiento fijo impone un sesgo inductivo rígido; puede truncar patrones de largo alcance aprendidos.

5.2.2. Mamba: Modelos de Espacio de Estado Selectivos

Mamba [33] enmarca la recurrencia como un sistema dinámico de tiempo continuo con parámetros dependientes de la entrada, logrando tanto entrenamiento lineal como inferencia en tiempo constante:

- 1: **Dinámica continua:** $h'(t) = \mathbf{A}h(t) + \mathbf{B}x(t), \quad y(t) = \mathbf{C}h(t)$
- 2: **Discretización con tamaño de paso Δ_t :**
- 3: $\bar{\mathbf{A}}_t \leftarrow \exp(\Delta_t \mathbf{A})$

```

4:  $\bar{\mathbf{B}}_t \leftarrow (\Delta_t \mathbf{A})^{-1}(\exp(\Delta_t \mathbf{A}) - \mathbf{I})\Delta_t \mathbf{B}_t$ 
5: Actualización recurrente:
6: for  $t = 1, \dots, n$  do
7:    $\Delta_t \leftarrow \text{softplus}(\text{Lineal}(x_t))$  ▷ tamaño de paso dependiente de la entrada
8:    $\mathbf{B}_t \leftarrow \text{Lineal}(x_t), \quad \mathbf{C}_t \leftarrow \text{Lineal}(x_t)$  ▷ matrices de proyección dependientes de la entrada
9:    $h_t \leftarrow \bar{\mathbf{A}}_t h_{t-1} + \bar{\mathbf{B}}_t x_t$  ▷ transición de estado
10:   $y_t \leftarrow \mathbf{C}_t h_t$  ▷ proyección de salida
11: end for

```

La innovación crítica es que $\mathbf{A}$ (la matriz del sistema) *no* depende de la entrada, pero Δ_t , $\mathbf{B}_t$ y $\mathbf{C}_t$ sí, haciendo que el sistema sea **variante en el tiempo**. Esta selectividad permite al modelo *ignorar* información irrelevante estableciendo Δ_t cerca de cero, creando efectivamente una compuerta. Un algoritmo de escaneo paralelo consciente del hardware implementa la recurrencia eficientemente en GPUs fusionando el cómputo dentro de SRAM, evitando el costoso ancho de banda de HBM.

- **Complejidad de entrenamiento:** $\mathcal{O}(n \cdot d)$ mediante escaneo consciente del hardware (lineal en la longitud de la secuencia).
- **Complejidad de inferencia:** $\mathcal{O}(1)$ por token, $\mathcal{O}(d)$ estado (vector oculto).
- **Fortalezas:** Logra entrenamiento lineal e inferencia constante simultáneamente; práctico en secuencias largas (millones de tokens).
- **Debilidades:** La compresión del vector de estado puede debilitar la copia exacta y la recuperación asociativa densa en comparación con la atención completa.

5.3. Transformers de Profundidad Continua: Integración EDO

5.3.1. Transformer EDO

El Transformer EDO [108] interpreta la profundidad de la red como integración numérica de un sistema dinámico continuo, utilizando solucionadores Runge-Kutta de orden superior para reducir el error de truncamiento:

- 1: **Formulación continua:** $\frac{dh(t)}{dt} = f_\theta(h(t), t)$ donde f_θ es la subred del transformer
- 2: **Aproximación discreta Runge-Kutta-4:**
- 3: $k_1 \leftarrow f_\theta(h_t, t)$
- 4: $k_2 \leftarrow f_\theta(h_t + \frac{1}{2}k_1, t + \frac{1}{2}\Delta t)$
- 5: $k_3 \leftarrow f_\theta(h_t + \frac{1}{2}k_2, t + \frac{1}{2}\Delta t)$
- 6: $k_4 \leftarrow f_\theta(h_t + k_3, t + \Delta t)$
- 7: $h_{t+1} \leftarrow h_t + \frac{\Delta t}{6}(k_1 + 2k_2 + 2k_3 + k_4)$ ▷ combinación ponderada

En lugar de las conexiones residuales simples de Euler $h_{t+1} = h_t + f_\theta(h_t)$, el bloque RK4 calcula cuatro evaluaciones intermedias y las combina con los pesos clásicos de RK4. Para evitar gradientes que se desvanecen, la arquitectura introduce **compuertas aprendidas** que interpolan entre aproximaciones intermedias:

- 1: $g \leftarrow \sigma(\text{Lineal}([k_1, k_2, k_3, k_4]))$ ▷ compuerta aprendible
- 2: $h_{t+1} \leftarrow h_t + g \cdot k_1 + (1 - g) \cdot k_2$ ▷ refinamiento interpolado

Esta formulación reduce el número efectivo de parámetros mediante el uso compartido de pesos—la misma f_θ se evalúa múltiples veces—proporcionando un refinamiento de trayectoria más rico.

- **Complejidad de entrenamiento:** $\mathcal{O}(k \cdot n^2 \cdot d)$ donde k es el orden RK (4 para RK4).

- **Complejidad de inferencia:** $\mathcal{O}(k \cdot n)$ por token (mayor sobrecarga constante).
- **Fortalezas:** Precisión significativamente mayor en tareas de generación (BLEU de última generación); eficiente en parámetros mediante uso compartido de pesos.
- **Debilidades:** Alto costo de cómputo por paso; la latencia de inferencia aumenta por un factor constante k ; requiere compuertas complejas para la estabilidad.

5.4. Memoria en Tiempo de Prueba: Titans

La arquitectura Titans [7] introduce una dimensión ortogonal: en lugar de pesos estáticos, el modelo mantiene una memoria aprendible que se *actualiza durante la inferencia* basada en una señal impulsada por sorpresa:

- 1: **Atención local a corto plazo:** Aplicar atención estándar o dispersa dentro de una ventana de contexto fija c
- 2: $y_t^{\text{local}} \leftarrow \text{Atencion}(q_t, k_{[t-c:t]}, v_{[t-c:t]})$
- 3: **Señal de actualización de memoria (sorpresa):**
- 4: $S_t \leftarrow \eta_t S_{t-1} - \theta_t \nabla_\ell(\mathcal{M}_{t-1}; x_t)$ $\triangleright$ sorpresa como gradiente de la pérdida respecto a la memoria
- 5: $\mathcal{M}_t \leftarrow (1 - \alpha_t) \mathcal{M}_{t-1} + S_t$ $\triangleright$ memoria actualizada mediante EMA
- 6: **Recuperación de memoria a largo plazo:**
- 7: $y_t^{\text{memoria}} \leftarrow \mathcal{M}_t^*(q_t)$ $\triangleright$ consultar módulo de memoria para información recuperada
- 8: **Combinación de salida:**
- 9: $y_t \leftarrow y_t^{\text{local}} + \text{compuerta}(y_t^{\text{memoria}})$ $\triangleright$ combinar memoria local y recuperada

El módulo de memoria $\mathcal{M}$ se actualiza literalmente durante el paso hacia adelante calculando gradientes de una pérdida asociativa y aplicando pasos de SGD con momento. Las tasas de decaimiento $\eta_t, \theta_t, \alpha_t$ son en sí mismas dependientes de la entrada, permitiendo al modelo cambiar de paradigma de memoria cuando el contexto cambia.

- **Complejidad de entrenamiento:** Aproximadamente $\mathcal{O}(c^2 + n \cdot f)$ donde c es la ventana local y f es la sobrecarga de actualización de memoria.
- **Complejidad de inferencia:** $\mathcal{O}(c^2)$ atención local más $\mathcal{O}(1)$ recuperación de memoria por token.
- **Fortalezas:** Maneja longitudes de contexto extremas; permite recuperación asociativa real; la memoria se adapta a la entrada.
- **Debilidades:** Significativamente más complejo; la inferencia incluye cálculos de gradientes; mayor sobrecarga de coordinación.

5.5. Despacho de Mezclador Guiado por Patrón

El código base selecciona un mezclador por bloque a partir del `layer_pattern` configurado. La lógica de despacho impone la política sin entrenamiento para bloques de solo evaluación y enruta a la implementación de familia correspondiente.

El campo exhibe una progresión clara a lo largo de dos ejes: (i) **eficiencia computacional**, pasando de $\mathcal{O}(n^2)$ a $\mathcal{O}(n)$ u $\mathcal{O}(1)$, y (ii) **adaptabilidad de memoria**, pasando de pesos estáticos a modelos dinámicos actualizados en tiempo de prueba. La atención estándar sigue siendo la línea base de expresividad; Mamba y RetNet representan la frontera práctica de eficiencia; Titans introduce un eje de innovación ortogonal (aprendizaje en tiempo de prueba). La elección de arquitectura refleja la restricción fundamental de ingeniería: expresividad versus costo de despliegue. La familia de atención latente, que comprime el caché KV en un latente de rango bajo, se cubre en el Apéndice 6.

Algorithm 22 Paso Adelante del Mezclador Guiado por Patrón (Conceptual)

Require: Estados ocultos H , patrón P , índice de capa ℓ

```
1:  $m \leftarrow P[\ell \bmod |P|]$ 
2: if  $m \in \{\text{fasa\_attn}, \text{sparge\_attn}\}$  y el modelo está en modo entrenamiento then
3:   lanzar error de configuración/tiempo de ejecución (bloque sin entrenamiento en modo
   entrenar)
4: else if  $m = \text{standard\_attn}$  then
5:    $H \leftarrow \text{softmax-attention}(H)$ 
6: else if  $m = \text{sigmoid\_attn}$  then
7:    $H \leftarrow \text{sigmoid-attention}(H)$ 
8: else if  $m \in \{\text{retnet}, \text{retnet\_attn}\}$  then
9:    $H \leftarrow \text{retention}(H)$ 
10: else if  $m = \text{mamba}$  then
11:    $H \leftarrow \text{selective-ssm}(H)$ 
12: else if  $m = \text{ode}$  then
13:    $H \leftarrow \text{rk-step}(H)$ 
14: else if  $m$  es una clave de atención dispersa then
15:    $H \leftarrow \text{sparse-attention-family}(H)$ 
16: else if  $m$  es una clave de atención con compuerta then
17:    $H \leftarrow \text{gated-attention-family}(H)$ 
18: else
19:    $H \leftarrow \text{memory-augmented-attn}(H)$ 
20: end if
21: return  $H$ 
```

6. Familias de Atención Latente y de Rango Bajo

Este anexo cubre la familia de mecanismos de atención de compresión latente / de rango bajo de KV. Estas arquitecturas comprimen el estado clave-valor por token en un vector latente de rango bajo que es la única cantidad materializada en el caché KV durante la decodificación, luego reconstruyen las claves y valores completos de todas las cabezas al vuelo. La familia unifica diseños de consulta agrupada, latente, factorizado y latente temporal bajo un cuello de botella de rango bajo común.

6.1. Atención Latente Multi-Cabeza (MLA)

La Atención Latente Multi-Cabeza (MLA, por sus siglas en inglés) [61] comprime el estado clave-valor por token en un único vector latente de rango bajo c_{KV} de rango r_{kv} , el cual es la única cantidad materializada en el caché KV durante la decodificación. Un par de matrices de up-proyección reconstruye las claves y valores completos de todas las cabezas al vuelo, mientras que RoPE se aplica a los tensores de consulta y clave descomprimidos para preservar la estructura posicional. Los autores muestran que el ancho latente óptimo de Pareto se sitúa cerca de $r_{kv} = d_{\text{oculto}}/2$, punto en el cual MLA reduce a la mitad el caché KV pero iguala la calidad de la atención multi-cabeza (MHA) en modelos pequeños.

6.1.1. Formulación Matemática

$$c_{KV} = W_{DKV} x \in \mathbb{R}^{r_{kv}}, \quad k = W_{UK} c_{KV}, \quad v = W_{UV} c_{KV}, \quad q = W_Q x.$$
$$\tilde{q} = \text{RoPE}(q), \quad \tilde{k} = \text{RoPE}(k), \quad \text{atencion} = \text{softmax}\left(\frac{\tilde{q}\tilde{k}^\top}{\sqrt{d_h}}\right) v.$$

6.1.2. Pseudocódigo Algorítmico

- 1: **Entrada:** estado oculto $x \in \mathbb{R}^{n \times d}$, rango r_{kv} , proyecciones $W_{DKV}, W_{UK}, W_{UV}, W_Q$
- 2: $c_{KV} \leftarrow W_{DKV} x$ ▷ down-proyección a latente de rango r_{kv} (en caché en inferencia)
- 3: $k \leftarrow W_{UK} c_{KV}, \quad v \leftarrow W_{UV} c_{KV}$ ▷ up-proyección a cabezas completas
- 4: $q \leftarrow W_Q x$
- 5: $\tilde{q} \leftarrow \text{RoPE}(q), \quad \tilde{k} \leftarrow \text{RoPE}(k)$ ▷ aplicar embeddings rotatorios
- 6: pesos $\leftarrow \text{softmax}(\tilde{q} \tilde{k}^\top / \sqrt{d_h})$
- 7: **Salida:** $Y = \text{pesos} \cdot v$

6.1.3. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d)$ (atención completa sobre cabezas descomprimidas).
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token, espacio de caché KV $\mathcal{O}(r_{kv} \cdot n)$ (sólo latente).
- **Entrenable:** totalmente entrenable; r_{kv} es un hiperparámetro (óptimo de Pareto $\approx d/2$).
- **Fortalezas:** reduce a la mitad el caché KV frente a MHA con calidad equivalente; compatible con RoPE; cuello de botella latente limpio.
- **Limitaciones:** la up-proyección añade FLOPs de decodificación; el rango latente es un presupuesto global fijo compartido entre cabezas.

6.2. Atención Latente por Consultas Agrupadas (GQLA)

La Atención Latente por Consultas Agrupadas (GQLA, por sus siglas en inglés) [62] es una modificación mínima de MLA que expone dos rutas de decodificación algebraicamente equivalentes sobre los mismos pesos entrenados: una ruta MQA-absorb (que fusiona la up-proyección en la consulta, óptima en hardware tipo H100) y una ruta GQA-expanded (que materializa claves/valores completos, óptima en hardware H20 / predicción multi-token). Las dos rutas son matemáticamente idénticas porque la up-proyección es lineal, de modo que $\text{softmax}(q_{\text{absorbido}} \cdot c_{KV}^\top) = \text{softmax}((q \cdot W_{UK}^\top) \cdot c_{KV}^\top)$, permitiendo un despacho adaptativo al hardware sin reentrenamiento.

6.2.1. Formulación Matemática

Mismo latente que MLA:

$$c_{KV} = W_{DKV} x, \quad k = W_{UK} c_{KV}, \quad v = W_{UV} c_{KV}, \quad q = W_Q x.$$

$$\text{Ruta A (MQA-absorb): } \text{atencion} = \text{softmax}\left(\frac{(q W_{UK}^\top) c_{KV}^\top}{\sqrt{d_h}}\right) (W_{UV} c_{KV}).$$

$$\text{Ruta B (GQA-expanded): } \text{atencion} = \text{softmax}\left(\frac{q k^\top}{\sqrt{d_h}}\right) v, \quad k = W_{UK} c_{KV}, \quad v = W_{UV} c_{KV}.$$

6.2.2. Pseudocódigo Algorítmico

- 1: **Entrada:** x , pesos $W_{DKV}, W_{UK}, W_{UV}, W_Q$, bandera de hardware $hw \in \{\text{H100}, \text{H20}\}$
- 2: $c_{KV} \leftarrow W_{DKV} x$ ▷ latente compartido, en caché
- 3: $q \leftarrow W_Q x$
- 4: **if** $hw == \text{H100}$ **then** ▷ ruta MQA-absorb
- 5: $q_{\text{abs}} \leftarrow q W_{UK}^\top$ ▷ absorber up-proyección en la consulta
- 6: pesos $\leftarrow \text{softmax}(q_{\text{abs}} c_{KV}^\top / \sqrt{d_h})$

```

7:    $\mathbf{Y} \leftarrow \text{pesos} \cdot (W_{UV} c_{KV})$ 
8: else ▷ ruta GQA-expanded
9:    $k \leftarrow W_{UK} c_{KV}, \quad v \leftarrow W_{UV} c_{KV}$ 
10:   $\text{pesos} \leftarrow \text{softmax}(q k^\top / \sqrt{d_h})$ 
11:   $\mathbf{Y} \leftarrow \text{pesos} \cdot v$ 
12: end if
13: Salida:  $\mathbf{Y}$ 

```

6.2.3. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d)$, idéntica a MLA.
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token, estado latente $\mathcal{O}(r_{kv} \cdot n)$; ruta elegida por hardware.
- **Entrenable:** se entrena una sola vez; las dos rutas de decodificación reutilizan los mismos pesos.
- **Fortalezas:** decodificación adaptativa al hardware sin pérdida de calidad; la equivalencia algebraica garantiza consistencia.
- **Limitaciones:** mismas compensaciones de rango latente que MLA; la selección de ruta es una heurística de despliegue.

6.3. Atención Multi-Cabeza de Rango Bajo (MLRA)

La Atención Multi-Cabeza de Rango Bajo (MLRA, por sus siglas en inglés) [57] refactoriza el latente único de MLA en L sub-cabezas disjuntas cada una de rango r/L , de modo que el caché KV puede partitionarse entre L dispositivos para una decodificación tensor-paralela de 4 vías (cada dispositivo carga sólo $1/L$ del caché). Las up-proyecciones por sub-cabeza reconstruyen la porción correspondiente de las cabezas completas y se concatenan, logrando una aceleración de decodificación de $2.8\times$ sobre MLA preservando el presupuesto latente global.

6.3.1. Formulación Matemática

$$\begin{aligned}
c_{KV} &= [c_1, c_2, \dots, c_L], \quad c_i \in \mathbb{R}^{r/L}, \quad c_{KV} = W_{DKV} x. \\
k_i &= W_{UK}^{(i)} c_i, \quad v_i = W_{UV}^{(i)} c_i, \quad k = [k_1; \dots; k_L], \quad v = [v_1; \dots; v_L]. \\
\text{atencion} &= \text{softmax}\left(\frac{q k^\top}{\sqrt{d_h}}\right) v.
\end{aligned}$$

6.3.2. Pseudocódigo Algorítmico

```

1: Entrada:  $x$ , número de sub-cabezas  $L$ , proyecciones por sub-cabeza  $W_{UK}^{(i)}, W_{UV}^{(i)}$ 
2:  $c_{KV} \leftarrow W_{DKV} x = [c_1, \dots, c_L]$  ▷ particionar latente en  $L$  bloques
3: for  $i = 1, \dots, L$  (en paralelo entre  $L$  dispositivos) do
4:    $k_i \leftarrow W_{UK}^{(i)} c_i, \quad v_i \leftarrow W_{UV}^{(i)} c_i$ 
5: end for
6:  $k \leftarrow \text{concat}(k_1, \dots, k_L), \quad v \leftarrow \text{concat}(v_1, \dots, v_L)$ 
7:  $\text{pesos} \leftarrow \text{softmax}(q k^\top / \sqrt{d_h})$ 
8: Salida:  $\mathbf{Y} = \text{pesos} \cdot v$ 

```

6.3.3. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d)$ (atención completa sobre cabezas concatenadas).
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token, estado $\mathcal{O}(r_{kv} \cdot n)$ particionado entre L dispositivos.
- **Entrenable:** totalmente entrenable; L controla la granularidad de partición.
- **Fortalezas:** aceleración de decodificación de $2.8\times$; particionamiento limpio tensor-paralelo de 4 vías del caché; preserva el presupuesto latente total.
- **Limitaciones:** requiere que L divida a r_{kv} ; más matrices de proyección que MLA; all-reduce inter-dispositivo en la salida.

6.4. Atención Tucker

La Atención Tucker [49] unifica MHA, GQA y MLA bajo una única factorización estilo Tucker de los tensores de pesos de consulta/clave/valor con rangos independientes $q_{\text{rank}}, k_{\text{rank}}, v_{\text{rank}}$. Se recupera MHA cuando todos los rangos igualan el tamaño oculto, GQA cuando $k_{\text{rank}} = v_{\text{rank}} < d$, y MLA cuando $k_{\text{rank}} = v_{\text{rank}}$ es igual al rango latente. Como la factorización es una repas lineal de pesos, el método es totalmente compatible con FlashAttention y RoPE, y produce un orden de magnitud menos parámetros para métricas comparables.

6.4.1. Formulación Matemática

$$\mathbf{Q} = W_{Q,\text{core}} W_{Q,\text{factor}} x, \quad \mathbf{K} = W_{K,\text{core}} W_{K,\text{factor}} x, \quad \mathbf{V} = W_{V,\text{core}} W_{V,\text{factor}} x.$$

$$\text{atencion} = \text{softmax}\left(\frac{\mathbf{Q} \mathbf{K}^\top}{\sqrt{d_h}}\right) \mathbf{V}.$$

Casos especiales: MHA $\Leftrightarrow q_{\text{rank}} = k_{\text{rank}} = v_{\text{rank}} = d$; GQA $\Leftrightarrow k_{\text{rank}} = v_{\text{rank}} < d$; MLA $\Leftrightarrow k_{\text{rank}} = v_{\text{rank}} = r_{kv}$.

6.4.2. Pseudocódigo Algorítmico

- 1: **Entrada:** x , rangos $q_{\text{rank}}, k_{\text{rank}}, v_{\text{rank}}$, matrices core/factor
- 2: $\mathbf{Q} \leftarrow W_{Q,\text{core}} W_{Q,\text{factor}} x$ ▷ consulta factorizada de rango q_{rank}
- 3: $\mathbf{K} \leftarrow W_{K,\text{core}} W_{K,\text{factor}} x$ ▷ clave factorizada de rango k_{rank}
- 4: $\mathbf{V} \leftarrow W_{V,\text{core}} W_{V,\text{factor}} x$ ▷ valor factorizado de rango v_{rank}
- 5: **Aplicar RoPE a $\mathbf{Q}, \mathbf{K}$ si se usa codificación posicional**
- 6: $\text{pesos} \leftarrow \text{softmax}(\mathbf{Q} \mathbf{K}^\top / \sqrt{d_h})$ ▷ compatible con FlashAttention
- 7: **Salida:** $\mathbf{Y} = \text{pesos} \cdot \mathbf{V}$

6.4.3. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d)$ sobre los tensores reconstruidos.
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token; tamaño de caché gobernado por k_{rank} .
- **Entrenable:** los rangos son hiperparámetros; la factorización es una repas de pesos directa.
- **Fortalezas:** unifica MHA/GQA/MLA; reducción de parámetros de un orden de magnitud con métricas equivalentes; compatible con FlashAttention/RoPE.
- **Limitaciones:** dos matmuls por proyección añaden latencia; la selección de rango es un problema de ajuste por tarea.

6.5. Atención de Cabezas Entrelazadas (IHA)

La Atención de Cabezas Entrelazadas (IHA, por sus siglas en inglés) [24] construye P pseudo-cabezas por cabeza original (típicamente $P = H$) donde cada consulta/clave/valor pseudo es una combinación lineal aprendida de todas las H cabezas originales. Esto induce hasta P^2 patrones de atención distintos por cabeza con una sobrecarga de $\mathcal{O}(H^2P)$. Teóricamente, IHA necesita sólo $\Theta(\sqrt{k}n^2)$ parámetros frente a $\Theta(kn^2)$ de MHA en la tarea Polinomial; empíricamente entrega +10–20 % en RULER de recuperación multi-clave, +5,8 % en GSM8K y +2,8 % en MATH-500.

6.5.1. Formulación Matemática

$$q_{\text{pseudo}}[p] = \sum_{h=1}^H \text{mix}_q[p, h] q[h], \quad k_{\text{pseudo}}[p] = \sum_h \text{mix}_k[p, h] k[h], \quad v_{\text{pseudo}}[p] = \sum_h \text{mix}_v[p, h] v[h].$$

$$\text{atencion}_p = \text{softmax}\left(\frac{q_{\text{pseudo}}[p] k_{\text{pseudo}}[p]^\top}{\sqrt{d_h}}\right) v_{\text{pseudo}}[p], \quad \mathbf{Y}[h] = \frac{1}{P} \sum_p \text{atencion}_p[h].$$

6.5.2. Pseudocódigo Algorítmico

- 1: **Entrada:** por cabeza $q[h], k[h], v[h]$, matrices de mezcla $\text{mix}_q, \text{mix}_k, \text{mix}_v \in \mathbb{R}^{P \times H}$
- 2: **for** $p = 1, \dots, P$ **do**
- 3: $q_p \leftarrow \sum_h \text{mix}_q[p, h] q[h]$ ▷ mezcla aprendida entre cabezas
- 4: $k_p \leftarrow \sum_h \text{mix}_k[p, h] k[h], \quad v_p \leftarrow \sum_h \text{mix}_v[p, h] v[h]$
- 5: $\text{atencion}_p \leftarrow \text{softmax}(q_p k_p^\top / \sqrt{d_h}) v_p$
- 6: **end for**
- 7: **Salida:** $\mathbf{Y}[h] \leftarrow \frac{1}{P} \sum_p \text{atencion}_p[h]$ ▷ promediar salidas pseudo-cabeza por cabeza

6.5.3. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot H \cdot P)$ con $P \approx H$, es decir $\mathcal{O}(n^2 \cdot H^2)$.
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token con caché KV; sobrecarga extra de mezcla $\mathcal{O}(H^2P)$.
- **Entrenable:** las matrices de mezcla se aprenden; P es un hiperparámetro.
- **Fortalezas:** eficiencia de parámetros $\Theta(\sqrt{k})$ en Polinomial; grandes ganancias en recuperación y razonamiento.
- **Limitaciones:** costo de mezcla cuadrático en cabezas; más patrones de atención a computar; latencia añadida con H grande.

6.6. Atención laTenT por Cabezas Agrupadas (GTA)

La Atención laTenT por Cabezas Agrupadas (GTA, por sus siglas en inglés) [87] combina dos compresiones: (1) un *mapa de atención compartido* — un tensor de puntajes de atención por grupo de cabezas, reutilizado entre todas las cabezas del grupo, reduciendo el caché de claves; y (2) un *decodificador de valores no lineal* — el caché de valores se comprime a un latente mediante una down-proyección y se reconstruye por una up-proyección con compuerta SiLU antes de la proyección de salida. GTA reduce los FLOPs de atención hasta 62.5 % frente a GQA, encoge el caché KV hasta 70 %, y produce una aceleración de inferencia de $2\times$ de extremo a extremo.

6.6.1. Formulación Matemática

$$q_g = \text{mean}(q[\text{grupo } g]), \quad k_g = \text{mean}(k[\text{grupo } g]), \quad \text{atencion}_g = \text{softmax}\left(\frac{q_g k_g^\top}{\sqrt{d_h}}\right) \quad (\text{reutilizado en el grupo}).$$

$$v_{\text{latente}} = W_{DV} x, \quad v = \text{SiLU}(W_{UV} v_{\text{latente}}), \quad \mathbf{Y} = \text{atencion}_g \cdot v.$$

6.6.2. Pseudocódigo Algorítmico

- 1: **Entrada:** q, k por cabeza, oculto x , partición de grupos $\{g\}$
- 2: $v_{\text{latente}} \leftarrow W_{DV} x$ ▷ comprimir valores a latente (en caché)
- 3: $v \leftarrow \text{SiLU}(W_{UV} v_{\text{latente}})$ ▷ decodificación no lineal de valores
- 4: **for** cada grupo g **do**
- 5: $q_g \leftarrow \text{mean}(q[g]), \quad k_g \leftarrow \text{mean}(k[g])$ ▷ consultas/claves compartidas por grupo
- 6: $\text{atencion}_g \leftarrow \text{softmax}(q_g k_g^\top / \sqrt{d_h})$
- 7: $\mathbf{Y}[g] \leftarrow \text{atencion}_g \cdot v[g]$ ▷ un mapa reutilizado para todas las cabezas en g
- 8: **end for**
- 9: **Salida:** $\mathbf{Y}$

6.6.3. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot G \cdot d_h)$ donde G es el número de grupos (frente a H cabezas en GQA).
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token; caché de valores $\mathcal{O}(r_v \cdot n)$, caché de claves reducido por compartición de grupo.
- **Entrenable:** la asignación de grupo y el rango latente son entrenables/hiperparámetros.
- **Fortalezas:** hasta 62.5 % de reducción de FLOPs de atención, 70 % de encogimiento de caché KV, $2\times$ de aceleración de extremo a extremo.
- **Limitaciones:** el mapa compartido reduce la diversidad por cabeza; el decodificador no lineal añade latencia; el agrupamiento debe elegirse con cuidado.

6.7. Atención Latente Temporal Multi-Cabeza (MTLA)

La Atención Latente Temporal Multi-Cabeza (MTLA, por sus siglas en inglés) [20] extiende MLA a lo largo del eje temporal: una hyper-red fusiona dinámicamente m vectores temporalmente adyacentes del caché KV en un único slot, reduciendo la longitud temporal por un factor de m . Una máscara causal consciente del stride mantiene el entrenamiento paralelo consistente con la inferencia autorregresiva, produciendo una aceleración de decodificación de $5.3\times$ y una reducción de memoria GPU de $8.3\times$ frente a MHA en traducción de voz En-De.

6.7.1. Formulación Matemática

$$c_{KV}^{(t)} = W_{DKV} x^{(t)} \in \mathbb{R}^{r_{kv}} \quad (\text{latente por token}).$$

$$\bar{c}_{KV}^{(j)} = \sum_{i=0}^{m-1} \alpha_i c_{KV}^{(sj+i)}, \quad \alpha_i = \text{sigmoid}(\text{HyperNet}(c_{KV}^{(sj+i)})),$$

donde s es el stride y m la ventana de fusión. Las consultas atienden sobre slots fusionados $\bar{c}_{KV}$ con una máscara causal consciente del stride M_{stride} :

$$\text{atencion} = \text{softmax}\left(\frac{q \bar{k}^\top}{\sqrt{d_h}} + M_{\text{stride}}\right) \bar{v}, \quad \bar{k} = W_{UK} \bar{c}_{KV}, \quad \bar{v} = W_{UV} \bar{c}_{KV}.$$

6.7.2. Pseudocódigo Algorítmico

- 1: **Entrada:** latentes por token $c_{KV}^{(t)}$, ventana de fusión m , stride s
- 2: **Fase de fusión (hyper-red):**
- 3: **for** cada slot fusionado $j = 0, 1, \dots$ **do**
- 4: $\alpha_i \leftarrow \text{sigmoid}(\text{HyperNet}(c_{KV}^{(sj+i)}))$ para $i = 0, \dots, m-1$
- 5: $\bar{c}_{KV}^{(j)} \leftarrow \sum_{i=0}^{m-1} \alpha_i c_{KV}^{(sj+i)}$ ▷ promedio con compuerta sobre la ventana
- 6: **end for**
- 7: $\bar{k} \leftarrow W_{UK} \bar{c}_{KV}$, $\bar{v} \leftarrow W_{UV} \bar{c}_{KV}$
- 8: pesos $\leftarrow \text{softmax}(q \bar{k}^\top / \sqrt{d_h} + M_{\text{stride}})$ ▷ máscara causal consciente del stride
- 9: **Salida:** $\mathbf{Y} = \text{pesos} \cdot \bar{v}$

6.7.3. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d/m)$ sobre la secuencia fusionada (longitud $\lceil n/m \rceil$) más costo de la hyper-red.
- **Complejidad de inferencia:** $\mathcal{O}(n/m)$ por token sobre slots fusionados; estado $\mathcal{O}(r_{kv} \cdot n/m)$.
- **Entrenable:** la hyper-red y la ventana de fusión m se aprenden/eligen; la máscara consciente del stride garantiza consistencia.
- **Fortalezas:** aceleración de decodificación de $5.3\times$, reducción de memoria GPU de $8.3\times$ frente a MHA; compresión temporal ortogonal a la compresión de rango.
- **Limitaciones:** la ventana de fusión puede difuminar detalle temporal fino; la hyper-red añade cómputo; el diseño de la máscara no es trivial.

6.8. Comparación y Síntesis Arquitectónica

6.9. Atención Convolutiva Comprimida (CCA)

La Atención Convolutiva Comprimida (CCA, por sus siglas en inglés) [27] adopta un enfoque fundamentalmente diferente para la atención latente: en lugar de comprimir el caché KV y luego up-proyectar al ancho completo antes de atender (como MLA/GQLA/MLRA), CCA proyecta consultas, claves y valores a un latente compartido y realiza la operación de atención *completa* dentro de él. No hay matrices de up-proyección para Q/K/V — sólo una única up-proyección de salida $\tilde{W}_O$ mapea la salida latente de vuelta al flujo residual. Esto reduce simultáneamente parámetros, caché KV, y FLOPs de atención por el factor de compresión $C = E/\tilde{e}$, mientras que MLA sólo reduce el caché.

Para hacer viable la atención en el latente comprimido, CCA introduce tres innovaciones: (1) dos convoluciones causales sobre el tensor empaquetado q/k (una convolución de secuencia depth-wise y una convolución agrupada de canales por cabeza), (2) q-k-mean (añade la media pre-convolución de q y k a los valores post-convolución), y (3) value-shift (cada cabeza recibe la mitad de sus valores del token actual y la mitad del token anterior mediante dos proyecciones independientes). Tras estos pasos, se aplica normalización L2 de QK y una temperatura de clave aprendible β , RoPE se aplica *directamente en el latente* (sin cabeza RoPE separada), y se computa la atención softmax estándar.

6.9.1. Formulación Matemática

$$\begin{aligned}
\tilde{q}_{\text{pre}} &= \tilde{W}_Q x, & \tilde{k}_{\text{pre}} &= \tilde{W}_K x, & \tilde{e} &= E/C. \\
\tilde{q} &= \text{Conv}(\tilde{q}_{\text{pre}}) + \frac{1}{2}(\tilde{q}_{\text{pre}} + \tilde{k}_{\text{pre}}), & \tilde{k} &= \text{Conv}(\tilde{k}_{\text{pre}}) + \frac{1}{2}(\tilde{q}_{\text{pre}} + \tilde{k}_{\text{pre}}). \\
\tilde{v} &= [\tilde{W}_{V_1} x_t \parallel \tilde{W}_{V_2} x_{t-1}], & \hat{q} &= \frac{\tilde{q}\sqrt{d_h}}{\|\tilde{q}\|}, & \hat{k} &= \frac{\tilde{k}\sqrt{d_h}}{\|\tilde{k}\|} e^\beta. \\
\text{atencion} &= \text{softmax}\left(\frac{\text{RoPE}(\hat{q}) \text{RoPE}(\hat{k})^\top}{\sqrt{d_h}}\right) \tilde{v}, & \mathbf{Y} &= \tilde{W}_O \text{atencion}.
\end{aligned}$$

6.9.2. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d/C)$ (atención en latente comprimido, $C \times$ menos FLOPs que MHA).
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token, espacio de caché KV $\mathcal{O}(\tilde{e} \cdot n)$.
- **Entrenable:** C , tamaños de kernel de conv, y los tres trucos (convs, qk-mean, value-shift) son configurables.
- **Fortalezas:** Reduce params, caché Y FLOPs simultáneamente; RoPE se integra nativamente; $>2\times$ menos params que MLA a igual compresión.
- **Limitaciones:** No elimina la cuadrática S^2 (sólo la divide por C); conv/qk-mean/v-shift añaden sesgo inductivo; se necesita kernel fusionado para la aceleración teórica.

6.10. Atención Convolutiva Comprimida por Consultas Agrupadas (CCGQA)

La Atención Convolutiva Comprimida por Consultas Agrupadas (CCGQA, por sus siglas en inglés) [27] extiende CCA con compartición de cabezas clave/valor estilo GQA aplicada *dentro* del latente comprimido, y **desacopla** las tasas de compresión de query y KV: las consultas se comprimen por C_1 y las claves/valores por $C_2 \geq C_1$. La dimensión latente por cabeza d_h debe coincidir entre cabezas de query y clave, imponiendo la restricción $C_2/C_1 = n_h/n_{kv}$. Las cabezas KV se comparten por grupo (replicadas para coincidir con las cabezas de query), y el sesgo qk-mean usa operadores de broadcast/reducción B_{group} (replicar cabezas KV a cabezas query) y E_{group} (promediar cabezas query dentro de cada grupo). CCGQA logra la mejor pérdida reportada a $8\times$ reducción de caché KV sin pérdida de calidad frente a MHA.

6.10.1. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(n^2 \cdot d/C_1)$ (el término S^2 escala por $1/C_1$; los términos de proyección por $1/C_1 + 1/C_2$).
- **Complejidad de inferencia:** $\mathcal{O}(n)$ por token, espacio de caché KV $\mathcal{O}(\tilde{e}_{kv} \cdot n)$ (comprimido por C_2 , compartido por grupo).
- **Entrenable:** C_1 , C_2 , n_{kv} , y todos los trucos CCA son configurables. Restricción: $C_2/C_1 = n_h/n_{kv}$.
- **Fortalezas:** Compresión desacoplada permite frontera de Pareto suave; misma intensidad aritmética que GQA; mejor pérdida a $8\times$ reducción de caché.

- **Limitaciones:** Misma cuadrática S^2 (sólo reducida por C_1); se necesita kernel fusionado; dos proyecciones de valor añaden complejidad.

La familia latente muestra una progresión clara a lo largo de dos ejes: (i) **compresión de rango**, pasando de cabezas completas (MHA) a un latente compartido (MLA) a sub-cabezas latentes particionadas (MLRA), y (ii) **adaptividad de despliegue**, pasando de una sola ruta de decodificación a despacho adaptativo al hardware (GQLA) y fusión temporal de caché (MTLA). La Atención Tucker proporciona el marco algebraico unificador: MHA, GQA y MLA son todos casos especiales de una factorización Tucker con elecciones de rango apropiadas. CCA y CCGQA toman un enfoque fundamentalmente diferente: en lugar de comprimir el caché KV y luego up-proyectar para atención a ancho completo (MLA/GQLA/MLRA), realizan atención *completamente dentro* del espacio latente comprimido, reduciendo no sólo el caché sino también los FLOPs de atención por el factor de compresión. CCGQA además desacopla las tasas de compresión de query y KV, logrando la mejor pérdida reportada a $8\times$ reducción de caché KV. La Atención de Mezcla Gaussiana (GMA) cambia la filosofía de enrutamiento por completo: en lugar de un cuello de botella lineal de rango bajo, enruta a través de K componentes Gaussianos probabilísticos aprendidos, logrando mezcla de secuencias en tiempo lineal $\mathcal{O}(NK)$ para K fijo manteniendo una interpretación de atención normalizada.

6.11. Atención de Mezcla Gaussiana (GMA)

La Atención de Mezcla Gaussiana (GMA, por sus siglas en inglés) [43] reemplaza la interacción pareada explícita $QK^\top$ de la atención de producto punto estándar con enrutamiento probabilístico a través de K componentes de mezcla Gaussiana aprendidos por cabeza. Las consultas y claves se mapean a vectores de *responsabilidad* posteriores sobre un espacio de enrutamiento latente compartido; su solapamiento define una afinidad implícita en el espacio de responsabilidades, mientras que los valores se escriben y leen de una memoria latente de K slots. Al explotar la asociatividad de la multiplicación matricial, GMA evita materializar la matriz de afinidad $N \times N$ inducida y en su lugar usa dos matrices de responsabilidad $N \times K$ cuyo almacenamiento de activaciones dominante escala como $\mathcal{O}(NK)$ en lugar de $\mathcal{O}(N^2)$ para K fijo. Los parámetros de la mezcla Gaussiana—medias de componentes μ , covarianzas diagonales (reparametrizadas vía $\sigma^2 = \text{softplus}(\omega) + \epsilon_\sigma$) y logits de prior de mezcla α (con $\pi = \text{softmax}(\alpha)$)—son parámetros aprendibles totalmente diferenciables optimizados por retropropagación estándar, sin bucle EM ni pérdida auxiliar de clustering.

6.11.1. Formulación Matemática

Por cabeza, con dimensión de enrutamiento d_r y dimensión de valor d_v :

$$Q_X = XW_Q \in \mathbb{R}^{N \times d_r}, \quad K_X = XW_K \in \mathbb{R}^{N \times d_r}, \quad V_X = XW_V \in \mathbb{R}^{N \times d_v}.$$

La responsabilidad posterior del componente k para un vector de enrutamiento x_i es

$$\gamma_{i,k} = p(z=k \mid x_i) = \frac{\pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k)}{\sum_{\ell=1}^K \pi_\ell \mathcal{N}(x_i \mid \mu_\ell, \Sigma_\ell)}, \quad \Sigma_k = \text{diag}(\sigma_{k,1}^2, \dots, \sigma_{k,d_r}^2),$$

produciendo las matrices de responsabilidad $\Gamma^Q, \Gamma^K \in \mathbb{R}^{N \times K}$. La salida bidireccional se calcula mediante el par asociativo de escritura–lectura

$$\tilde{V} = (\Gamma^K)^\top V_X \in \mathbb{R}^{K \times d_v}, \quad Z = (\Gamma^K)^\top \mathbf{1}_N \in \mathbb{R}^K, \quad O = \frac{\Gamma^Q \tilde{V}}{\Gamma^Q Z + \epsilon},$$

que nunca materializa la afinidad normalizada implícita $A_{ij}^{\text{GMA}} = \frac{\sum_k \gamma_{i,k}^Q \gamma_{j,k}^K}{\sum_\ell \sum_k \gamma_{i,k}^Q \gamma_{\ell,k}^K + \epsilon}$. Para modelado autorregresivo, las estadísticas de escritura globales se reemplazan por sumas acumuladas restringidas al prefijo $\tilde{V}_k^{(i)} = \sum_{j \leq i} \gamma_{j,k}^K V_{X,j}$ y $Z_k^{(i)} = \sum_{j \leq i} \gamma_{j,k}^K$, imponiendo causalidad preservando el escalado lineal de K fijo.

6.11.2. Pseudocódigo Algorítmico

```

1: Entrada: estado oculto  $X \in \mathbb{R}^{N \times d}$ ,  $K$  componentes, dim. de enrutamiento  $d_r$ , dim. de valor  $d_v$ , params  $\{\mu_k, \omega_k, \alpha_k\}_{k=1}^K$ 
2:  $Q_X \leftarrow XW_Q$ ,  $K_X \leftarrow XW_K$ ,  $V_X \leftarrow XW_V$  ▷ proyecciones por cabeza
3:  $\sigma_k^2 \leftarrow \text{softplus}(\omega_k) + \epsilon_\sigma$ ,  $\pi_k \leftarrow \text{softmax}(\alpha)_k$  ▷ reparametrizar
4:  $\Gamma^Q \leftarrow \text{softmax}_k \left( \log \pi_k - \frac{d_r}{2} \log 2\pi - \frac{1}{2} \sum_m \log \sigma_{k,m}^2 - \frac{1}{2} \sum_m \frac{(q_{i,m} - \mu_{k,m})^2}{\sigma_{k,m}^2} \right)$ 
5:  $\Gamma^K \leftarrow$  igual que  $\Gamma^Q$  aplicado a  $K_X$ 
6: if causal then
7:    $\tilde{V} \leftarrow \text{cumsum}_n(\Gamma^K \otimes V_X)$ ,  $Z \leftarrow \text{cumsum}_n(\Gamma^K)$  ▷ restringido al prefijo
8: else
9:    $\tilde{V} \leftarrow (\Gamma^K)^\top V_X$ ,  $Z \leftarrow (\Gamma^K)^\top \mathbf{1}_N$  ▷ escritura global
10: end if
11:  $O \leftarrow \Gamma^Q \tilde{V} / (\Gamma^Q Z + \epsilon)$  ▷ lectura normalizada
12: Salida:  $Y = OW_O$ 

```

6.11.3. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(NKd_r + NKd_v)$ para K fijo, lineal en la longitud de secuencia N .
- **Complejidad de inferencia:** $\mathcal{O}(K)$ por token (responsabilidades + lectura latente), almacenamiento de activaciones $\mathcal{O}(NK)$.
- **Entrenable:** parámetros GMM totalmente diferenciables $\{\mu, \omega, \alpha\}$ por cabeza, optimizados end-to-end sin EM.
- **Fortalezas:** Mezcla de secuencias en tiempo lineal con K fijo; enrutamiento probabilístico interpretable; variantes bidireccional y causal; interpretación de afinidad de rango bajo no negativa $A^{\text{GMA}} = \text{diag}(d)^{-1} \Gamma^Q (\Gamma^K)^\top$.
- **Limitaciones:** La calidad depende de K y la dimensión de enrutamiento d_r ; la GMA causal queda por debajo de SDPA optimizada y modelos de espacio de estados en WikiText-103 en la implementación actual del paper; no es un reemplazo universal para la atención softmax.

7. Mecanismos de Atención Dispersa Exhaustivos

7.1. Resumen Ejecutivo

Los mecanismos de atención dispersa abordan la prohibitiva complejidad computacional y de memoria $\mathcal{O}(n^2)$ de la atención de producto punto escalado estándar al restringir el conjunto de pares clave-valor atendidos. La atención dispersa moderna abarca un rico espacio de diseño distinguido por cuatro dimensiones ortogonales: (i) **patrón de dispersidad** (geométrico fijo, dependiente de datos o basado en frecuencia), (ii) **capacidad de entrenamiento** (entrenado de extremo a extremo o solo inferencia), (iii) **unidad de dispersidad** (tokens individuales, ventanas locales o bloques), y (iv) **mecanismo** (enmascaramiento, selección, filtrado o compresión). Este anexo sintetiza siete familias principales de atención dispersa—Sparse Transformer, Longformer, BigBird, SparseK, NSA, SpargeAttn y FASA—proporcionando formulaciones matemáticas, pseudocódigo algorítmico y comparaciones arquitectónicas exhaustivas.

7.2. Sparse Transformer: Patrones Estrideados y Fijos Factorizados

7.2.1. Formulación Matemática

Sparse Transformer [16] reduce la complejidad cuadrática a $\mathcal{O}(n\sqrt{n})$ factorizando la atención dispersa en dos cabezas dispersas complementarias. Sea n la longitud de la secuencia y $l = \lfloor \sqrt{n} \rfloor$ el stride.

Cabeza de atención estrideada : Cada posición i atiende a cada l -ésima posición anterior:

$$\mathcal{A}_i^{(\text{estrídeada})} = \{j : j \leq i, (i - j) \bmod l = 0\}$$

Cabeza de atención fija : Cada posición i atiende a posiciones dentro de su bloque local más columnas de resumen fijas:

$$\mathcal{A}_i^{(\text{fija})} = \{j : \lfloor j/l \rfloor = \lfloor i/l \rfloor\} \cup \{j : j \bmod l \in \{l - c, \dots, l - 1\}\}$$

donde c es un hiperparámetro que controla el número de columnas de resumen (típicamente $c = 1$ o $c = 2$).

El cálculo de atención para cada cabeza h sigue las reglas estándar de producto punto escalado restringido al conjunto disperso:

$$\text{Attn}_h(Q, K, V)_i = \text{softmax} \left(\frac{q_i^h K_{\mathcal{A}_i}^h \top}{\sqrt{d_k}} \right) V_{\mathcal{A}_i}^h$$

La idea clave es que con las dos cabezas factorizadas operando en paralelo a través de una profundidad de L capas transformer, cada posición puede alcanzar cualquier otra posición a través de un camino de longitud máxima $L + 1$, preservando la alcanzabilidad de largo alcance con una fracción del costo de la atención densa.

7.2.2. Pseudocódigo Algorítmico

Algorithm 23 Atención Sparse Transformer: Cabezas Duales Estrídeada + Fija

Require: Consulta $\mathbf{Q} \in \mathbb{R}^{n \times d}$, Clave $\mathbf{K} \in \mathbb{R}^{n \times d}$, Valor $\mathbf{V} \in \mathbb{R}^{n \times d}$

Require: Stride $l = \lfloor \sqrt{n} \rfloor$, columnas de resumen $c \in \{1, 2\}$

Ensure: Salida $\mathbf{Y} \in \mathbb{R}^{n \times d}$

```

1: Cabeza 1: Atención Estrídeada
2: for  $i = 1, \dots, n$  do
3:    $\mathcal{A}_i \leftarrow \{j : j \leq i \text{ y } (i - j) \bmod l = 0\}$  ▷ Cada  $l$ -ésima posición
4:    $\text{puntajes}_i \leftarrow \mathbf{q}_i \mathbf{K}_{\mathcal{A}_i}^\top / \sqrt{d_k}$ 
5:    $\text{attn}_i \leftarrow \text{softmax}(\text{puntajes}_i)$ 
6:    $\mathbf{y}_i^{(1)} \leftarrow \text{attn}_i \mathbf{V}_{\mathcal{A}_i}$ 
7: end for
8: Cabeza 2: Atención de Bloque Fijo + Resumen
9: for  $i = 1, \dots, n$  do
10:   $\text{inicio\_bloque} \leftarrow \lfloor i/l \rfloor \cdot l$ ,  $\text{fin\_bloque} \leftarrow \min(i + 1, \text{inicio\_bloque} + l)$ 
11:   $\mathcal{A}_i \leftarrow [\text{inicio\_bloque}, \text{fin\_bloque}) \cup \{\text{columnas de las últimas } c \text{ columnas}\}$ 
12:   $\text{puntajes}_i \leftarrow \mathbf{q}_i \mathbf{K}_{\mathcal{A}_i}^\top / \sqrt{d_k}$ 
13:   $\text{attn}_i \leftarrow \text{softmax}(\text{puntajes}_i)$ 
14:   $\mathbf{y}_i^{(2)} \leftarrow \text{attn}_i \mathbf{V}_{\mathcal{A}_i}$ 
15: end for
16: Concatenar:  $\mathbf{Y} = [\mathbf{y}^{(1)} \parallel \mathbf{y}^{(2)}]$  y proyectar mediante capa lineal de salida return  $\mathbf{Y}$ 

```

7.2.3. Características Clave

- **Complejidad:** $\mathcal{O}(n\sqrt{n} \cdot d)$ durante el entrenamiento; $\mathcal{O}(n)$ por token durante la generación.
- **Entrenable:** Sí; retropropagación completa a través de las posiciones seleccionadas.
- **Patrón de dispersidad:** Fijo e independiente de los datos; los patrones no se adaptan al contenido.
- **Fortaleza:** Alcanzabilidad estructurada que garantiza dependencias de largo alcance; demostrado efectivo en secuencias largas (Enwik8, imágenes de texto).
- **Limitación:** Los patrones fijos pueden pasar por alto relaciones importantes pero no continuas; requiere kernels CUDA personalizados para eficiencia práctica.

7.3. Longformer: Ventana Deslizante, Dilatación y Tokens Globales

7.3.1. Formulación Matemática

Longformer [8] logra una complejidad lineal $\mathcal{O}(n \cdot w)$ combinando tres patrones de atención complementarios.

Atención de ventana deslizante : Vecindario local de tamaño w :

$$\mathcal{A}_i^{(\text{ventana})} = \{j : |i - j| \leq w/2\}$$

Ventana deslizante dilatada : Atención con ventana y dilatación d , saltando stride $d + 1$:

$$\mathcal{A}_i^{(\text{dilatada})} = \{j : |i - j| \leq (w/2)(d + 1) \text{ y } (i - j) \bmod (d + 1) = 0\}$$

Atención global : Tokens globales designados (ej., [CLS]) atienden a todas las posiciones y todos atienden a ellos:

$$\mathcal{A}_i^{(\text{global})} = \begin{cases} \{1, \dots, n\} & \text{si } i \in \mathcal{G} \\ \mathcal{A}_i^{(\text{ventana})} \cup \mathcal{G} & \text{en otro caso} \end{cases}$$

Los tres patrones se aplican mediante proyecciones separadas. La atención local y global pueden usar las mismas proyecciones o unas separadas específicas para cada tarea.

7.3.2. Pseudocódigo Algorítmico

Algorithm 24 Longformer: Ventana Deslizante + Dilatada + Global

Require: Consulta $\mathbf{Q} \in \mathbb{R}^{n \times d}$, Clave $\mathbf{K}$, Valor $\mathbf{V}$, tamaño de ventana w , dilatación d , índices de tokens globales $\mathcal{G}$

Ensure: Salida $\mathbf{Y}$

```

1: for  $i = 1, \dots, n$  do
2:   if  $i \in \mathcal{G}$  then
3:      $\mathcal{A}_i \leftarrow \{1, \dots, n\}$  ▷ Token global atiende a todos
4:   else
5:     Ventana local:  $\mathcal{A}^{(\text{local})} \leftarrow [i - w/2, i + w/2] \cap [1, n]$ 
6:     Desplazamientos dilatados:  $\mathcal{A}^{(\text{dilatada})} \leftarrow \{j : (i - j) \bmod (d + 1) = 0\} \cap \mathcal{A}^{(\text{rango dilatado})}$ 
7:     Combinar:  $\mathcal{A}_i \leftarrow \mathcal{A}^{(\text{local})} \cup \mathcal{A}^{(\text{dilatada})} \cup \mathcal{G}$ 
8:   end if
9:    $\text{puntajes}_i \leftarrow \mathbf{q}_i \mathbf{K}_{\mathcal{A}_i}^\top / \sqrt{d_k}$ 
10:   $\text{attn}_i \leftarrow \text{softmax}(\text{puntajes}_i)$ 
11:   $\mathbf{y}_i \leftarrow \text{attn}_i \mathbf{V}_{\mathcal{A}_i}$ 
12: end for return  $\mathbf{Y}$ 

```

7.3.3. Características Clave

- **Complejidad:** $\mathcal{O}(n \cdot w)$ donde w es el tamaño de ventana (lineal cuando $w \ll n$).
- **Entrenable:** Sí; reemplazo directo para la atención estándar.
- **Cobertura:** Con L capas y tamaño de ventana w , el campo receptivo crece a $L \times w$, cubriendo toda la secuencia con redes poco profundas.
- **Fortaleza:** Práctico para tareas a nivel de documentos; la dilatación expande los campos receptivos locales con sobrecarga mínima; los tokens globales proporcionan correspondencia consulta-documento.
- **Limitación:** El tamaño de ventana sigue siendo un hiperparámetro de diseño; subóptimo para tareas que requieren patrones de atención densos.

7.4. BigBird: Grafo Disperso Aleatorio, Local y Global

7.4.1. Formulación Matemática

BigBird [105] preserva la aproximación universal y la completitud de Turing utilizando una combinación fundamentada de tres patrones de dispersidad.

Conexiones aleatorias : Cada posición se conecta a r posiciones muestreadas aleatoriamente:

$$\mathcal{A}_i^{(\text{aleatoria})} = \text{MuestraAleatoria}(\{1, \dots, n\}, r)$$

Ventana local : Vecindario de ventana deslizante:

$$\mathcal{A}_i^{(\text{local})} = \{j : |i - j| \leq w/2\}$$

Tokens globales : Ancas globales específicas de la tarea:

$$\mathcal{A}_i^{(\text{global})} = \begin{cases} \{1, \dots, n\} & \text{si } i \in \mathcal{G} \\ \mathcal{A}_i^{(\text{aleatoria})} \cup \mathcal{A}_i^{(\text{local})} \cup \mathcal{G} & \text{en otro caso} \end{cases}$$

La máscara dispersa compuesta M es:

$$M_{ij} = \mathbf{1}[j \in \mathcal{A}_i^{(\text{aleatoria})} \cup \mathcal{A}_i^{(\text{local})} \cup \mathcal{A}_i^{(\text{global})}]$$

En la práctica, BigBird agrupa tokens en bloques de tamaño b y aplica la decisión de dispersidad a nivel de bloque, permitiendo implementaciones eficientes de bloques dispersos.

7.4.2. Garantía Teórica

Los autores demuestran que con $O(1)$ conexiones aleatorias y tokens globales, el grafo disperso mantiene las mismas propiedades de aproximación universal y completitud de Turing que la atención densa. Formalmente, cualquier función computable puede representarse y cualquier secuencia de operaciones puede simularse dentro del grafo de conectividad de BigBird.

7.4.3. Pseudocódigo Algorítmico

Algorithm 25 BigBird: Atención Dispersa por Bloques Aleatoria + Local + Global

Require: Consulta $\mathbf{Q}$, Clave $\mathbf{K}$, Valor $\mathbf{V}$, tamaño de bloque b , enlaces aleatorios por bloque r , índices globales $\mathcal{G}$

Ensure: Salida $\mathbf{Y}$

```

1: Reformar en bloques:  $n_b = \lceil n/b \rceil$  bloques
2: for bloque  $i = 0, \dots, n_b - 1$  do
3:   for posición  $j$  en bloque  $i$  do
4:     Ventana local:  $\mathcal{A}_j^{(\text{local})} =$  posiciones cercanas en el bloque  $\cup$  posiciones frontera
5:     Muestreo aleatorio de bloques: Muestrear  $r$  bloques uniformemente al azar, agregar todas las posiciones de esos bloques
6:     Global: Agregar todas las posiciones de tokens globales
7:      $\mathcal{A}_j \leftarrow \mathcal{A}_j^{(\text{local})} \cup \mathcal{A}_j^{(\text{aleatoria})} \cup \mathcal{G}$ 
8:   end for
9: end for
10: for  $i = 1, \dots, n$  do
11:    $\text{puntajes}_i \leftarrow \mathbf{q}_i \mathbf{K}_{\mathcal{A}_i}^\top / \sqrt{d_k}$ 
12:    $\text{attn}_i \leftarrow \text{softmax}(\text{puntajes}_i)$ 
13:    $\mathbf{y}_i \leftarrow \text{attn}_i \mathbf{V}_{\mathcal{A}_i}$ 
14: end for return  $\mathbf{Y}$ 

```

7.4.4. Características Clave

- **Complejidad:** $\mathcal{O}(n)$ o casi lineal en implementación óptima de bloques dispersos.
- **Entrenable:** Sí.
- **Base teórica:** Mantiene demostrablemente la aproximación universal y la completitud de Turing con conectividad dispersa.
- **Fortaleza:** Rendimiento sólido en documentos largos para preguntas-respuestas, resúmenes y tareas de genómica.
- **Limitación:** El muestreo aleatorio introduce varianza y no determinismo; el ajuste de los hiperparámetros r, w, g sigue dependiendo de la tarea.

7.5. Atención SparseK: Selección Diferencial Top- k

7.5.1. Formulación Matemática

SparseK [59] permite dispersidad aprendible mediante un **operador top- k diferenciable**. Una red de puntuación ϕ_θ evalúa la importancia de cada par clave-valor:

$$u_j = \phi_\theta(\mathbf{k}_j, \mathbf{q}_i) \in \mathbb{R}$$

El **operador SparseK** selecciona los puntajes top- k manteniéndose diferenciable. Calcula un umbral $\tau(u)$ tal que la suma de los puntajes activos sea igual a k :

$$\text{SparseK}(u, k)_j = \max(u_j - \tau(u), 0), \quad \text{donde} \quad \sum_j \max(u_j - \tau, 0) = k$$

El umbral τ se encuentra mediante bisección. La atención se convierte en:

$$m_j = \text{SparseK}(u, k)_j, \quad \text{Attn}_i = \text{softmax} \left(\frac{\mathbf{q}_i K_{\text{sel}}^\top}{\sqrt{d_k}} \right) V_{\text{sel}}$$

donde $K_{\text{sel}}, V_{\text{sel}}$ contienen solo las entradas top- k (aquellas con $m_j > 0$).

7.5.2. Pseudocódigo Algorítmico

Algorithm 26 SparseK: Atención Top- k Diferenciable

Require: Consulta $\mathbf{q} \in \mathbb{R}^d$, Matriz de clave $\mathbf{K} \in \mathbb{R}^{n \times d}$, Matriz de valor $\mathbf{V} \in \mathbb{R}^{n \times d}$

Require: Red de puntuación ϕ_θ , dispersidad objetivo k

Ensure: Salida de atención $\mathbf{y}$

```

1: Calcular puntajes de importancia:
2: for  $j = 1, \dots, n$  do
3:    $u_j \leftarrow \phi_\theta(\mathbf{k}_j, \mathbf{q})$ 
4: end for
5: Calcular top- $k$  diferenciable mediante umbral:
6:  $u_{\text{ordenado}} \leftarrow \text{ordenar}(u, \text{descendente} = \text{Verdadero})$ 
7:  $\text{suma\_acum} \leftarrow \text{suma\_acumulada}(u_{\text{ordenado}})$ 
8: Encontrar  $\rho = \max\{i : u_{\text{ordenado}}[i] > 0 \text{ y } \text{suma\_acum}[i] \leq k\}$ 
9:  $\tau \leftarrow (u_{\text{ordenado}}[\rho] - k) / (\rho + 1)$  ▷ Umbral para  $k$  elementos activos
10:  $m \leftarrow \max(u - \tau, 0)$  ▷ Máscara de selección diferenciable
11: Aplicar máscara y calcular atención:
12:  $K_{\text{sel}} \leftarrow K[m > 0], V_{\text{sel}} \leftarrow V[m > 0]$ 
13:  $\text{puntajes} \leftarrow \mathbf{q} K_{\text{sel}}^\top / \sqrt{d_k}$ 
14:  $\text{attn} \leftarrow \text{softmax}(\text{puntajes})$ 
15:  $\mathbf{y} \leftarrow \text{attn} \cdot V_{\text{sel}}$  return  $\mathbf{y}$ 

```

7.5.3. Características Clave

- **Complejidad:** $\mathcal{O}(n \cdot d)$ durante el entrenamiento (lineal en la longitud de la secuencia); $\mathcal{O}(k)$ por token durante la generación.
- **Entrenable:** Sí; flujo de gradiente de extremo a extremo a través del operador SparseK.
- **Generación incremental:** Soporta generación autorregresiva eficiente con memoria constante.

- **Fortaleza:** Se integra perfectamente en arquitecturas LLM existentes; mínimo ajuste fino necesario.
- **Limitación:** El acceso a memoria disperso de la selección top- k puede limitar la eficiencia de caché en algunos hardwares; la red de puntuación añade sobrecarga.

7.6. NSA (Native Sparse Attention): Ramas Jerárquicas Alineadas con el Hardware

7.6.1. Formulación Matemática

NSA [103] descompone la atención dispersa en tres ramas paralelas que se combinan mediante compuertas aprendidas.

Rama de compresión : Un MLP aprendible φ comprime bloques de clave-valor:

$$\tilde{K}_t^{\text{cmp}} = [\varphi(k_{id+1:id+l})]_{1 \leq i \leq \lfloor (t-l)/d \rfloor}, \quad \tilde{V}_t^{\text{cmp}} = [\varphi(v_{id+1:id+l})]$$

Rama de selección : Los bloques de alta importancia se seleccionan basándose en puntajes comprimidos:

$$p_t^{\text{cmp}} = \text{softmax}(q_t^\top \tilde{K}_t^{\text{cmp}} / \sqrt{d}), \quad I_t = \text{TopK}(p_t^{\text{cmp}}, n), \quad \tilde{K}_t^{\text{sel}} = \text{Recolectar}(K, I_t)$$

Rama de ventana deslizante : Contexto local fijo:

$$\tilde{K}_t^{\text{win}} = K_{t-w:t}, \quad \tilde{V}_t^{\text{win}} = V_{t-w:t}$$

Combinación con compuertas : Las tres salidas de atención se combinan mediante compuertas aprendidas:

$$\alpha_t^{(\text{cmp})} = \sigma(\text{Lineal}_{\text{cmp}}(q_t)), \quad \alpha_t^{(\text{sel})} = \sigma(\text{Lineal}_{\text{sel}}(q_t)), \quad \alpha_t^{(\text{win})} = \sigma(\text{Lineal}_{\text{win}}(q_t))$$

$$y_t = \alpha_t^{(\text{cmp})} \cdot \text{Attn}(q_t, \tilde{K}^{\text{cmp}}, \tilde{V}^{\text{cmp}}) + \alpha_t^{(\text{sel})} \cdot \text{Attn}(q_t, \tilde{K}^{\text{sel}}, \tilde{V}^{\text{sel}}) + \alpha_t^{(\text{win})} \cdot \text{Attn}(q_t, \tilde{K}^{\text{win}}, \tilde{V}^{\text{win}})$$

7.6.2. Pseudocódigo Algorítmico

Algorithm 27 NSA: Ramas Comprimida + Seleccionada + Ventana con Compuertas Aprendidas

Require: Consulta $\mathbf{q}_t$, secuencias de Clave/Valor almacenadas en caché, tamaño de bloque l , stride d , conteo de selección n , ventana w

Require: MLP de compresión φ , redes de compuerta $\text{Lineal}_{\text{cmp}}$, $\text{Lineal}_{\text{sel}}$, $\text{Lineal}_{\text{win}}$

Ensure: Salida $\mathbf{y}_t$

```

1: Rama de compresión:
2: for  $i = 1$  to  $\lfloor t/d \rfloor$  do
3:    $k_i^{\text{cmp}} \leftarrow \varphi(\mathbf{K}_{id+1:id+l})$  ▷ Comprimir bloque mediante MLP
4:    $v_i^{\text{cmp}} \leftarrow \varphi(\mathbf{V}_{id+1:id+l})$ 
5: end for
6:  $\tilde{\mathbf{K}}^{\text{cmp}} \leftarrow [k_1^{\text{cmp}}, \dots, k_{\lfloor t/d \rfloor}^{\text{cmp}}]$ ,  $\tilde{\mathbf{V}}^{\text{cmp}} \leftarrow [v_1^{\text{cmp}}, \dots, v_{\lfloor t/d \rfloor}^{\text{cmp}}]$ 
7:  $\mathbf{y}_t^{(\text{cmp})} \leftarrow \text{SDPA}(\mathbf{q}_t, \tilde{\mathbf{K}}^{\text{cmp}}, \tilde{\mathbf{V}}^{\text{cmp}})$ 
8: Rama de selección:
9: Calcular puntajes sobre comprimidos:  $\mathbf{s} \leftarrow \text{softmax}(\mathbf{q}_t \tilde{\mathbf{K}}^{\text{cmp}\top} / \sqrt{d})$ 
10: Seleccionar los  $n$  bloques más importantes:  $I \leftarrow \text{TopK}(\mathbf{s}, n)$ 
11: Recolectar bloques completos:  $\tilde{\mathbf{K}}^{\text{sel}} \leftarrow [\mathbf{K}_{I_i d+1:I_i d+l}]_i$ ,  $\tilde{\mathbf{V}}^{\text{sel}} \leftarrow [\mathbf{V}_{I_i d+1:I_i d+l}]_i$ 
12:  $\mathbf{y}_t^{(\text{sel})} \leftarrow \text{SDPA}(\mathbf{q}_t, \tilde{\mathbf{K}}^{\text{sel}}, \tilde{\mathbf{V}}^{\text{sel}})$ 
13: Rama de ventana:
14:  $\mathbf{y}_t^{(\text{win})} \leftarrow \text{SDPA}(\mathbf{q}_t, \mathbf{K}_{t-w:t}, \mathbf{V}_{t-w:t})$ 
15: Fusión con compuertas:
16:  $\alpha^{(\text{cmp})} \leftarrow \sigma(\text{Lineal}_{\text{cmp}}(\mathbf{q}_t))$ ,  $\alpha^{(\text{sel})} \leftarrow \sigma(\text{Lineal}_{\text{sel}}(\mathbf{q}_t))$ ,  $\alpha^{(\text{win})} \leftarrow \sigma(\text{Lineal}_{\text{win}}(\mathbf{q}_t))$ 
17:  $\mathbf{y}_t \leftarrow \alpha^{(\text{cmp})} \mathbf{y}_t^{(\text{cmp})} + \alpha^{(\text{sel})} \mathbf{y}_t^{(\text{sel})} + \alpha^{(\text{win})} \mathbf{y}_t^{(\text{win})}$  return  $\mathbf{y}_t$ 

```

7.6.3. Características Clave

- **Complejidad:** $\mathcal{O}(t/d + n \cdot l + w)$ tokens atendidos por paso (significativamente reducido frente a $\mathcal{O}(t)$ para densa).
- **Entrenable:** Sí; entrenamiento directo con todas las ramas diferenciables.
- **Alineación con hardware:** Diseñado para utilización eficiente de núcleos tensoriales; la compresión y selección reducen la presión sobre el ancho de banda de memoria.
- **Fortaleza:** $11.6\times$ de aceleración en decodificación y $9\times$ de aceleración hacia adelante en secuencias de 64k; supera a la atención completa en muchas tareas.
- **Limitación:** Requiere kernels Triton/CUDA personalizados; la arquitectura multi-rama compleja aumenta la sobrecarga de ingeniería.

7.7. FASA: Atención Dispersa Consciente de la Frecuencia

7.7.1. Formulación Matemática

FASA [95] es un **método en tiempo de inferencia sin entrenamiento** que explota la estructura del embedding de posición rotatorio (RoPE). Bajo RoPE, el embedding del token se rota por $\theta_i = B^{-2(i-1)/d}$, descomponiendo el espacio d -dimensional en $d/2$ fragmentos de frecuencia (FC).

Idea clave : Solo un subconjunto pequeño ($< 1\%$) de los FC importa para la conciencia contextual; la mayoría codifica patrones posicionales.

Identificación de fragmento de frecuencia dominante : Para cada capa l y cabeza h , identificar FC dominantes mediante concordancia contextual (CA):

$$\text{CA}^{l,h,i} = \frac{|\text{TopK}(\alpha^{l,h}) \cap \text{TopK}(\alpha^{l,h,i})|}{K}$$

donde $\alpha^{l,h}$ es la máscara de atención completa y $\alpha^{l,h,i}$ es la máscara usando solo el FC i . Los FC dominantes tienen CA alta—contribuyen significativamente al patrón de atención final.

Eta de predicción de importancia de tokens (TIP) : Usando solo FC dominantes, calcular importancia ligera por token:

$$S_t^{l,h} = \sum_{i \in \mathcal{I}_{\text{dom}}^{l,h}} \alpha^{l,h,i}(\mathbf{q}_t, \mathbf{K}_{1:t}), \quad \mathcal{T}_t = \text{TopK-Índices}(S_t, N_{\text{fac}})$$

Eta de cálculo de atención enfocada (FAC) : Calcular atención de precisión completa en los tokens seleccionados:

$$\hat{\alpha}_{\text{FAC}} = \text{softmax} \left(\frac{\mathbf{q}_t \mathbf{K}_{\mathcal{T}_t}^\top}{\sqrt{d}} \right), \quad \mathbf{o}_t = \hat{\alpha}_{\text{FAC}} \mathbf{V}_{\mathcal{T}_t}$$

7.7.2. Pseudocódigo Algorítmico

Algorithm 28 FASA: Atención Dispersa Consciente de la Frecuencia (en Tiempo de Inferencia)

Require: Consulta actual $\mathbf{q}_t$, Clave/Valor almacenados en caché $\mathbf{K}_{1:t}, \mathbf{V}_{1:t}$, base RoPE B , FC dominantes $\mathcal{I}_{\text{dom}}$

Require: Presupuesto TIP N_{tip} , presupuesto FAC N_{fac}

Ensure: Salida $\mathbf{o}_t$

```

1: Eta 1: Predicción de Importancia de Tokens (TIP)
2: for capa  $l$  y cabeza  $h$  do
3:   for posición  $i = 1$  to  $t$  do
4:     Calcular importancia desde FC dominantes:  $s_i \leftarrow 0$ 
5:     for  $fc \in \mathcal{I}_{\text{dom}}^{l,h}$  do
6:       Rotar consulta y clave en FC  $fc$ :  $\mathbf{q}^{(fc)}, \mathbf{k}_i^{(fc)}$ 
7:        $s_i^{(fc)} \leftarrow \text{softmax}(\mathbf{q}^{(fc)} \mathbf{k}_i^{(fc)\top} / \sqrt{d})$ 
8:        $s_i \leftarrow s_i + s_i^{(fc)}$ 
9:     end for
10:   end for
11:    $\mathcal{T}_t \leftarrow \text{TopK-Índices}([s_1, \dots, s_t], N_{\text{fac}})$  ▷ Seleccionar tokens principales
12: end for
13: Eta 2: Cálculo de Atención Enfocada (FAC)
14:  $\text{puntajes}_{\text{fac}} \leftarrow \mathbf{q}_t \mathbf{K}_{\mathcal{T}_t}^\top / \sqrt{d}$  ▷ Producto punto de precisión completa
15:  $\alpha_{\text{fac}} \leftarrow \text{softmax}(\text{puntajes}_{\text{fac}})$  ▷ Softmax completo
16:  $\mathbf{o}_t \leftarrow \alpha_{\text{fac}} \mathbf{V}_{\mathcal{T}_t}$  ▷ Suma ponderada de valores return  $\mathbf{o}_t$ 

```

7.7.3. Características Clave

- **Complejidad:** TIP es $\mathcal{O}(t \cdot N_{\text{tip}})$; FAC es $\mathcal{O}(N_{\text{fac}} \cdot d)$.
- **Entrenable:** No; optimización de inferencia sin entrenamiento.

- **Aplicabilidad:** Requiere modelos basados en RoPE; extendido a ALiBi y MLA con modificaciones.
- **Fortaleza:** Precisión cercana a la óptima con ≤ 256 tokens de entre millones; hasta $2.56\times$ de aceleración en decodificación; ortogonal a la cuantización.
- **Limitación:** Requiere calibración fuera de línea; la identificación de FC dominantes añade sobrecarga de preprocesamiento.

7.8. SpargeAttn: Filtrado de Dos Etapas a Nivel de Bloques

7.8.1. Formulación Matemática

SpargeAttn [109] es un **método universal sin entrenamiento** que predice qué bloques de la matriz de atención contendrán valores insignificantes y omite el cálculo para esos bloques.

Etapas 1 — Predicción dispersa : Calcular importancia proxy de bajo costo $\hat{s}_{ij}$ para el bloque (i, j) :

$$\hat{s}_{ij} = f_{\text{pred}}(\mathbf{Q}_i, \mathbf{K}_j; \text{hiperparámetros}), \quad \text{omitir si } \hat{s}_{ij} < \epsilon_1$$

Los predictores comunes incluyen similitud de media de bloque o estadísticas de autosimilitud.

Etapas 2 — Filtrado consciente de softmax : Después de calcular $\tilde{P}_{ij} = \text{softmax}(Q_i K_j^\top / \sqrt{d})$, verificar si la probabilidad máxima del bloque es insignificante en relación con el máximo de softmax en ejecución:

$$\text{omitir } P_{ij} V_j \quad \text{si} \quad \max(\tilde{P}_{ij}) < e^{m_{\text{antiguo}} - m_{\text{nuevo}}} \cdot \epsilon_2$$

donde $m_{\text{antiguo}}, m_{\text{nuevo}}$ son máximos del softmax en línea en ejecución (calculados mediante numéricos estilo FlashAttention).

7.8.2. Pseudocódigo Algorítmico

Algorithm 29 SparseAttn: Filtrado Disperso de Dos Etapas por Bloques

Require: Bloques de consulta $\mathbf{Q}_i$ para $i = 1, \dots, n_b$, Bloques de clave $\mathbf{K}_j$ para $j = 1, \dots, n_b$, Bloques de valor $\mathbf{V}_j$

Require: Umbral de predicción ϵ_1 , umbral de softmax ϵ_2 , tamaño de bloque b_s

Ensure: Salida $\mathbf{Y}$

```

1: Inicializar: máximo de softmax en línea  $m_{\text{global}} \leftarrow -\infty$ 
2: for fila de bloque  $i = 1$  to  $n_b$  do
3:   Inicializar: salida de fila de bloque  $\mathbf{Y}_i \leftarrow 0$ , máximo local  $m_i \leftarrow -\infty$ 
4:   for columna de bloque  $j = 1$  to  $n_b$  do
5:     Etapas 1: Predicción Dispersa
6:     Calcular importancia proxy:  $\hat{s}_{ij} \leftarrow f_{\text{pred}}(\mathbf{Q}_i, \mathbf{K}_j)$ 
7:     if  $\hat{s}_{ij} < \epsilon_1$  then
8:       omitir este bloque  $[i, j]$  ▷ Terminación temprana
9:       continuar ▷ Pasar al siguiente bloque
10:    end if
11:    Etapas 2: Calcular y Filtrar
12:     $\tilde{P}_{ij} \leftarrow \text{softmax}(\mathbf{Q}_i \mathbf{K}_j^\top / \sqrt{d})$ 
13:     $m_{\text{bloque}} \leftarrow \text{máx}(\tilde{P}_{ij})$ 
14:    if  $m_{\text{bloque}} < e^{m_i - m_{\text{global}}} \cdot \epsilon_2$  then
15:      El bloque contribuye insignificamente; omitir ▷ Poda consciente de softmax
16:      continuar
17:    end if
18:    Actualizar máximo global:  $m_i \leftarrow \text{máx}(m_i, m_{\text{bloque}})$ 
19:    Acumular:  $\mathbf{Y}_i \leftarrow \mathbf{Y}_i + \tilde{P}_{ij} \mathbf{V}_j$ 
20:  end for
21:   $m_{\text{global}} \leftarrow \text{máx}(m_{\text{global}}, m_i)$ 
22: end for return  $\mathbf{Y}$ 

```

7.8.3. Características Clave

- **Complejidad:** Empírica $\mathcal{O}(n^2 \cdot s)$ donde s es la fracción de bloques no omitidos (típicamente 0.2–0.5).
- **Entrenable:** No; aceleración plug-and-play para modelos existentes.
- **Universalidad:** Funciona en modelos de lenguaje, modelos de difusión de imágenes y generación de video.
- **Fortaleza:** 2.5–5× de aceleración comparado con métodos densos o dispersos anteriores; compatible con cuantización (integración SageAttention).
- **Limitación:** La aceleración depende de la dispersidad inherente; la granularidad a nivel de bloque puede pasar por alto patrones más finos; se requiere ajuste de umbral por familia de modelos.

7.9. MSA (MiniMax Sparse Attention): Atención Dispersa por Bloques con Rama de Índice Ligera

7.9.1. Formulación Matemática

MSA [50] es un mecanismo de atención dispersa por bloques construido sobre atención agrupada por consultas (GQA) que combina una **Rama de Índice** ligera para la selección de bloques

con una **Rama Principal** para atención softmax dispersa por bloques exacta sobre los bloques seleccionados. Sea N la longitud de la secuencia, $B_k = 128$ el tamaño de bloque, y $k = 16$ el número de bloques seleccionados por consulta (lo que yield un presupuesto fijo por consulta de $k \cdot B_k = 2048$ tokens independientemente de N).

Rama de Índice : Una proyección de baja dimensionalidad produce consultas de índice $\mathbf{q}_t^{\text{idx}} \in \mathbb{R}^{d_{\text{idx}}}$ y representantes de bloque $\mathbf{r}_b \in \mathbb{R}^{d_{\text{idx}}}$ para cada bloque KV b . Los puntajes de índice por grupo GQA son:

$$s_{t,b}^{(g)} = \mathbf{q}_t^{\text{idx},(g)} \cdot \mathbf{r}_b, \quad \mathcal{I}_t^{(g)} = \text{TopK} \left(\{s_{t,b}^{(g)}\}_{b=1}^{N/B_k}, k \right)$$

La entrada del índice está **desconectada** (stop-gradient), de modo que los gradientes no fluyen hacia atrás a través de la entrada del indexador; la Rama de Índice se entrena en su lugar mediante una pérdida de alineación KL entre su distribución de atención y la distribución de la Rama Principal. Debido a que softmax preserva el orden, los puntajes crudos de índice se alimentan directamente al operador top- k *sin* un softmax explícito (**top- k sin exponencial**), reduciendo el costo numérico.

Bloque local forzado : El bloque que contiene la posición de consulta t **siempre** se incluye en $\mathcal{I}_t^{(g)}$, garantizando cobertura de contexto local.

Rama Principal : La atención estándar de producto punto escalado se calcula exactamente sobre la unión de los bloques seleccionados:

$$\mathbf{o}_t^{(h)} = \text{softmax} \left(\frac{\mathbf{q}_t^{(h)} \mathbf{K}_{\mathcal{I}_t}^{(h)\top}}{\sqrt{d_h}} \right) \mathbf{V}_{\mathcal{I}_t}^{(h)}$$

donde $\mathbf{K}_{\mathcal{I}_t}, \mathbf{V}_{\mathcal{I}_t}$ reúnen los tensores de clave/valor de precisión completa de los bloques seleccionados. La selección se realiza independientemente por grupo GQA, de modo que diferentes grupos de consulta dentro de la misma capa pueden atender a diferentes subconjuntos de bloques.

7.9.2. Pseudocódigo Algorítmico

Algorithm 30 MSA: Atención Dispersa MiniMax con Ramas de Índice + Principal

Require: Consulta $\mathbf{Q} \in \mathbb{R}^{N \times d}$, Clave $\mathbf{K}$, Valor $\mathbf{V}$, tamaño de bloque $B_k = 128$, bloques top- k $k = 16$

Require: Proyección de índice W_{idx} (entrada desconectada), representantes de bloque $\{\mathbf{r}_b\}$

Ensure: Salida $\mathbf{Y} \in \mathbb{R}^{N \times d}$

```

1: Calcular representantes de bloque:  $\mathbf{r}_b \leftarrow \text{mean}(\mathbf{K}_{bB_k:(b+1)B_k})$  para  $b = 1, \dots, N/B_k$ 
2: for posición de consulta  $t = 1, \dots, N$  do
3:   for cada grupo GQA  $g$  do
4:      $\mathbf{q}_t^{\text{idx}} \leftarrow \text{sg}(W_{\text{idx}} \mathbf{x}_t)$  ▷ consulta de índice desconectada
5:     Calcular puntajes de bloque:  $s_b \leftarrow \mathbf{q}_t^{\text{idx}} \cdot \mathbf{r}_b$ 
6:     Identificar bloque local:  $b_{\text{local}} \leftarrow \lfloor t/B_k \rfloor$ 
7:      $\mathcal{I}_t^{(g)} \leftarrow \text{TopK}(\{s_b\}, k) \cup \{b_{\text{local}}\}$  ▷ top- $k$  sin exp + local forzado
8:   end for
9:   Reunir KV seleccionado:  $\tilde{\mathbf{K}}_t \leftarrow \text{Gather}(\mathbf{K}, \mathcal{I}_t)$ ,  $\tilde{\mathbf{V}}_t \leftarrow \text{Gather}(\mathbf{V}, \mathcal{I}_t)$ 
10:  Rama principal SDPA:  $\mathbf{y}_t \leftarrow \text{softmax}(\mathbf{q}_t \tilde{\mathbf{K}}_t^\top / \sqrt{d_h}) \tilde{\mathbf{V}}_t$ 
11: end for
12: Agregar pérdida de alineación KL  $\mathcal{L}_{\text{KL}} = \text{KL}(\text{dist índice} \parallel \text{dist principal})$  durante el entre-
    namiento return  $\mathbf{Y}$ 

```

7.9.3. Características Clave

- **Complejidad:** Rama de índice $\mathcal{O}(H_{kv} \cdot d_{idx} \cdot N^2)$; Rama principal $\mathcal{O}(H_q \cdot d_h \cdot N \cdot k \cdot B_k)$. Presupuesto por consulta fijo en $k \cdot B_k = 2048$ tokens independientemente de N .
- **Entrenable:** Sí; de extremo a extremo (la Rama de Índice se entrena mediante una pérdida de alineación KL, no es solo inferencia).
- **Estado:** Caché KV $\mathcal{O}(N)$ (tamaño GQA); sin expansión de la dimensión de estado recurrente.
- **Fortaleza:** Desplegado en el modelo 109B MiniMax-M3, MSA logra una reducción de cómputo de atención por token de $28,4\times$ a contexto de 1M, con $14,2\times$ en prefill y $7,6\times$ en decodificación en GPUs H800.
- **Limitación:** La granularidad de selección es fija a nivel de bloque ($B_k = 128$); el bloque local forzado y la selección independiente por grupo aumentan la complejidad de ingeniería y requieren kernels personalizados de bloques dispersos.

7.10. SparDA (Atención Dispersa Desacoplada): Selección de Bloques Anticipada Guiada por Pronóstico

7.10.1. Formulación Matemática

SparDA [28] introduce un esquema de atención dispersa **desacoplado** que aumenta las proyecciones estándar por capa Q, K, V con una cuarta proyección, el **Pronóstico**, que predice los bloques KV que serán necesarios en la *siguiente* capa. Esta anticipación permite solapar el prefetch CPU-a-GPU de los bloques seleccionados de la siguiente capa con la ejecución de la capa actual, ocultando la latencia de offload que afecta a las implementaciones de atención dispersa en hardware con memoria limitada.

Proyección de Pronóstico : Para la entrada $\mathbf{x} \in \mathbb{R}^{N \times d}$,

$$\mathbf{F} = \mathbf{x} \mathbf{W}_F \in \mathbb{R}^{N \times H_{kv} \times d_f}$$

con **una cabeza de Pronóstico por grupo GQA**, lo que reduce la sobrecarga de selección frente a los selectores multi-cabeza usados en trabajos anteriores.

Puntuación y selección de bloques : Para cada consulta i y bloque KV b con representante $\mathbf{r}_b$:

$$S_{i,b} = \mathbf{F}_i \cdot \mathbf{r}_b, \quad \mathcal{I}_i = \text{TopK}(\{S_{i,b}\}_b, k)$$

Atención dispersa por bloques : La atención estándar de producto punto escalado se calcula entonces sobre los bloques seleccionados:

$$\mathbf{o}_i = \text{softmax} \left(\frac{\mathbf{q}_i \mathbf{K}_{\mathcal{I}_i}^\top}{\sqrt{d_h}} \right) \mathbf{V}_{\mathcal{I}_i}$$

Entrenamiento : SparDA añade menos del 0,5 % de parámetros adicionales. Solo las proyecciones de Pronóstico se entrenan, emparejando la distribución de atención del selector disperso original (congelado)—una destilación ligera que preserva el comportamiento del modelo base mientras habilita el prefetch anticipado.

7.10.2. Pseudocódigo Algorítmico

Algorithm 31 SparDA: Atención Dispersa Desacoplada con Prefetch de Pronóstico

Require: Entrada $\mathbf{x} \in \mathbb{R}^{N \times d}$, bloques de Clave/Valor en caché, bloques top- k k

Require: Proyecciones W_q, W_k, W_v, W_F ; selector base congelado π_{orig}

Ensure: Salida $\mathbf{Y}$; bloques prefetched para la siguiente capa

- 1: Calcular Pronóstico: $\mathbf{F} \leftarrow \mathbf{x} \mathbf{W}_F$ $\triangleright$ una cabeza por grupo GQA
 - 2: **for** consulta $i = 1, \dots, N$ **do**
 - 3: Calcular puntajes de bloque: $S_{i,b} \leftarrow \mathbf{F}_i \cdot \mathbf{r}_b$ para cada bloque b
 - 4: Seleccionar: $\mathcal{I}_i \leftarrow \text{TopK}(\{S_{i,b}\}, k)$
 - 5: **Prefetch** $\mathbf{K}_{\mathcal{I}_i}, \mathbf{V}_{\mathcal{I}_i}$ de CPU a GPU para la *siguiente* capa $\triangleright$ solapa con la capa actual
 - 6: **end for**
 - 7: Calcular SDPA dispersa por bloques sobre los bloques seleccionados de la capa actual: $\mathbf{Y} \leftarrow \text{BlockSparseSDPA}(\mathbf{Q}, \mathbf{K}, \mathbf{V}, \{\mathcal{I}_i\})$
 - 8: Pérdida de entrenamiento: $\mathcal{L} \leftarrow \text{KL}(\text{dist Pronóstico} \parallel \pi_{\text{orig}})$ $\triangleright$ solo se actualiza W_F **return** $\mathbf{Y}$
-

7.10.3. Características Clave

- **Complejidad:** Pronóstico $\mathcal{O}(H_{kv} \cdot d_f \cdot N \cdot N_{\text{bloques}})$; Atención principal $\mathcal{O}(H_q \cdot d_h \cdot N \cdot k \cdot B_k)$.
- **Entrenable:** Sí; solo las proyecciones de Pronóstico se entrenan ($< 0,5\%$ parámetros extra).
- **Fortaleza:** En dos modelos sparse-pretrained de 8B, SparDA logra hasta $1,25\times$ en prefill y $1,7\times$ en decodificación sobre el baseline de offload de atención dispersa, y hasta $5,3\times$ throughput de decodificación frente a un baseline disperso sin offload.
- **Limitación:** Requiere un pipeline de offload CPU–GPU y un selector base congelado; el beneficio anticipado depende de que la demanda de bloques de la siguiente capa sea predecible a partir del Pronóstico actual.

7.11. Espacio de Diseño y Criterios de Selección

Los siete métodos de atención dispersa ocupan posiciones complementarias en un espacio de diseño multidimensional:

- **Patrones geométricos/fijos** (Sparse Transformer, Longformer): Simples de implementar y analizar, pero los patrones no se adaptan al contenido.
- **Selección aprendida** (SparseK, NSA): Permiten adaptación mediante redes de selección entrenables, a costa de mayor complejidad de implementación.
- **Aceleración sin entrenamiento** (FASA, SpargeAttn): Permiten aceleración directa de modelos existentes sin reentrenamiento, adecuados para sistemas desplegados.
- **Garantías teóricas** (BigBird): Proporcionan demostraciones formales de completitud expresiva, importantes para comprender los márgenes de seguridad.

Orientación de selección:

1. **Entrenamiento de nuevos modelos** donde los recursos lo permitan: NSA o SparseK para máxima aceleración de inferencia; BigBird para garantía teórica.
2. **Comprensión de documentos de contexto largo:** Longformer o FASA por simplicidad práctica; NSA para escala extrema.

3. **Aceleración de modelos existentes:** FASA para LLMs basados en RoPE; SpargeAttn para cualquier arquitectura.
4. **Entornos con recursos limitados:** Sparse Transformer por simplicidad y eficiencia probada a escala moderada.

8. Familias de Atención con Compuerta—Análisis Exhaustivo de Literatura

8.1. Resumen Ejecutivo: Compuertas para el Control de Memoria

El campo emergente de los *mecanismos de atención con compuerta* aborda un desafío fundamental en el modelado de secuencias: ¿cómo debe retenerse, olvidarse y actualizarse la información a medida que el modelo procesa nuevos tokens? Los estados recurrentes aditivos tradicionales acumulan toda la información sin borrado, lo que lleva a la saturación de memoria y a la incapacidad de adaptarse a contextos cambiantes. La atención softmax proporciona expresividad completa pero usa un caché KV de $\mathcal{O}(Ld)$ durante la inferencia, limitando el tamaño de la ventana de contexto. Los mecanismos con compuerta proporcionan un punto intermedio: control selectivo sobre la supervivencia de la información.

El principio unificador entre las arquitecturas con compuerta es que las compuertas controlan *qué información sobrevive*. Las compuertas operan en tres niveles distintos:

1. **Decaimiento del estado recurrente** (GLA, HGRN2): Compuertas multiplicativas sobre la matriz de memoria S_t controlan cuánto del estado anterior persiste en el siguiente paso.
2. **Intensidad de escritura en actualizaciones recurrentes** (DeltaNet, Gated DeltaNet, Gated DeltaNet-2): Las compuertas controlan la magnitud y la dirección canalizada de la nueva información escrita en la memoria.
3. **Sesgo de logits softmax** (FoX): Las compuertas inyectan sesgo de actualidad a nivel de token en el cálculo de logits de atención.
4. **Dispersidad post-atención** (Gated Softmax): Las compuertas escalan selectivamente los canales de salida de SDPA.

Este apéndice sintetiza ocho arquitecturas principales de atención con compuerta publicadas entre 2023 y 2026, analizando sus fundamentos matemáticos, características de eficiencia en hardware y compensaciones empíricas.

8.2. 1. Atención Lineal con Compuerta (GLA)

8.2.1. Fundamento Matemático

La Atención Lineal con Compuerta [99] aumenta la atención lineal estándar (que usa un estado recurrente con valor de matriz) con decaimiento multiplicativo dependiente de los datos. La atención lineal estándar reformula el mecanismo softmax tradicional como una recurrencia sobre estados ocultos:

$$\mathbf{S}_t = \mathbf{S}_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top, \quad \mathbf{o}_t = \mathbf{S}_t \mathbf{q}_t$$

donde el estado $\mathbf{S}_t \in \mathbb{R}^{d_v \times d_k}$ acumula productos externos. Esta formulación puramente aditiva sufre de “sobrecarga de memoria”: la información se acumula monótonamente y no puede borrarse, degradando el rendimiento en tareas que requieren selección de contexto.

GLA introduce una **matriz de compuerta diagonal** $\mathbf{G}_t \in [0, 1]^{d_k \times d_k}$ dependiente de los datos:

$$\mathbf{S}_t = \mathbf{G}_t \odot \mathbf{S}_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top, \quad \mathbf{o}_t = \mathbf{S}_t \mathbf{q}_t$$

La compuerta $\mathbf{G}_t$ se parametriza con una estructura de producto externo:

$$\mathbf{G}_t = \mathbf{1}\alpha_t^\top, \quad \alpha_t = \text{logsigmoid}(\mathbf{W}_{gk}\mathbf{x}_t)/c$$

donde $\mathbf{W}_{gk}$ es una proyección de rango bajo ($\mathbb{R}^{d \rightarrow d_k}$) y $c \approx 16$ es un normalizador. La activación logsigmoid mapea $\alpha_t \in \mathbb{R}$ a aproximadamente $[-1/2, 0]$, y la división por c contrae esto aún más para que esté cerca de la identidad en la inicialización. La compuerta resultante $G_t = 1 + \alpha_t \approx 1$ cerca de la inicialización, luego aprende a decaer ($\alpha_t \rightarrow -\infty$) información histórica.

Algorithm 32 Atención Lineal con Compuerta (Forma Recurrente)

Require: Entrada $\mathbf{x}_t$; estado anterior $\mathbf{S}_{t-1}$

Require: Proyecciones: W_q, W_k, W_v (estándar); W_{gk} (proyección de compuerta)

Ensure: Salida $\mathbf{o}_t$ y estado actualizado $\mathbf{S}_t$

- 1: $\mathbf{q}_t \leftarrow W_q\mathbf{x}_t$
 - 2: $\mathbf{k}_t \leftarrow W_k\mathbf{x}_t$
 - 3: $\mathbf{v}_t \leftarrow W_v\mathbf{x}_t$
 - 4: Calcular compuerta: $\alpha_t \leftarrow \text{logsigmoid}(W_{gk}\mathbf{x}_t)/16$ $\triangleright$ Decaimiento por dimensión de clave
 - 5: Aplicar compuerta de producto externo: $\mathbf{G}_t \leftarrow \mathbf{1}\alpha_t^\top$ $\triangleright$ producto externo diagonal
 - 6: Decaer estado anterior: $\mathbf{S}_t^{\text{decaimiento}} \leftarrow \mathbf{G}_t \odot \mathbf{S}_{t-1}$ $\triangleright$ producto elemento a elemento
 - 7: Agregar nueva asociación: $\mathbf{S}_t \leftarrow \mathbf{S}_t^{\text{decaimiento}} + \mathbf{v}_t\mathbf{k}_t^\top$
 - 8: Recuperar mediante consulta: $\mathbf{o}_t^{\text{crudo}} \leftarrow \mathbf{S}_t\mathbf{q}_t$
 - 9: Aplicar compuerta de salida: $\mathbf{o}_t \leftarrow \text{GroupNorm}(\mathbf{o}_t^{\text{crudo}}) \otimes \text{SiLU}(W_g\mathbf{x}_t)$ **return** $\mathbf{o}_t, \mathbf{S}_t$
-

8.2.2. Entrenamiento Eficiente en Hardware

Para el entrenamiento paralelo, GLA usa un algoritmo por fragmentos que agrupa tokens en fragmentos C y calcula transiciones recurrentes en paralelo:

$$\mathbf{O}_{[t]} = \overleftarrow{\mathbf{Q}}_{[t]}\mathbf{S}_{[t]}^\top + \left(\mathbf{Q}_{[t]}\mathbf{K}_{[t]}^\top \odot \mathbf{\Gamma}_{[t]}\right)\mathbf{V}_{[t]}$$

donde $\overleftarrow{\mathbf{Q}}_{[t]}$ atiende al estado en el límite del fragmento (retrospectiva), y $\mathbf{\Gamma}_{[t]}$ es la máscara causal con escalado consciente del decaimiento:

$$\mathbf{\Gamma}_{[t],ij} = \begin{cases} \prod_{l=j}^{i-1} \alpha_l & \text{si } i > j \text{ (retrospectiva)} \\ \prod_{l=1}^{i-j} \alpha_l & \text{si } i \leq j \text{ (en-fragmento)} \end{cases}$$

Este diseño maximiza las operaciones matmul susceptibles de aceleración mediante núcleos tensoriales, logrando una complejidad total subcuadrática $\mathcal{O}(nLd^2/C)$ donde L es el número de cabezas de atención y C es el tamaño del fragmento.

8.2.3. Fortalezas y Limitaciones

Aspecto	Fortalezas	Limitaciones
Eficiencia computacional	Entrenamiento subcuadrático mediante paralelismo por fragmentos. Inferencia con memoria constante $O(d^2)$.	Requiere kernels CUDA/Triton personalizados; no disponible en todos los frameworks.
Generalización de contexto	Extiende entrenamiento de 2K tokens a más de 20K tokens con degradación de perplejidad insignificante.	Aún rinde por debajo de softmax en benchmarks con mucha recuperación (aguja en el pajar).
Selectividad	Decaimiento dependiente de los datos por dimensión de clave.	La estructura de compuerta limita la selectividad por par clave-valor; no hay control directo sobre qué asociaciones específicas borrar.

8.3. 2. DeltaNet: Atención Lineal con Corrección de Errores

8.3.1. Fundamento Matemático

DeltaNet [100] aplica una **regla de aprendizaje delta** clásica a las actualizaciones de estado de la atención lineal. En lugar de acumulación aditiva, DeltaNet calcula la diferencia entre el valor predicho (recuperado de la memoria) y el valor objetivo, luego realiza una actualización de corrección de errores:

$$\mathbf{S}_t = \mathbf{S}_{t-1}(\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) + \beta_t \mathbf{v}_t \mathbf{k}_t^\top$$

donde $\beta_t \in (0, 1)$ es un escalar de **intensidad de escritura** dependiente de los datos. Esta actualización puede descomponerse como una operación de borrado-escritura:

$$\mathbf{v}_t^{\text{anterior}} = \mathbf{S}_{t-1} \mathbf{k}_t \quad (\text{predicción actual}), \quad \mathbf{v}_t^{\text{actualizado}} = \beta_t \mathbf{v}_t + (1 - \beta_t) \mathbf{v}_t^{\text{anterior}} \quad (\text{mezcla anterior/nuevo})$$

de modo que:

$$\mathbf{S}_t = \mathbf{S}_{t-1} - \mathbf{v}_t^{\text{anterior}} \mathbf{k}_t^\top + \mathbf{v}_t^{\text{actualizado}} \mathbf{k}_t^\top$$

La idea clave es que esta regla de actualización minimiza una pérdida de ECM en línea en cada paso temporal:

$$\mathcal{L}_t(\mathbf{S}) = \frac{1}{2} \|\mathbf{S} \mathbf{k}_t - \mathbf{v}_t\|^2 \Rightarrow \nabla_{\mathbf{S}} \mathcal{L}_t = (\mathbf{S} \mathbf{k}_t - \mathbf{v}_t) \mathbf{k}_t^\top$$

Un paso de SGD con tasa de aprendizaje β_t produce la actualización de la regla delta. Esta conexión con el entrenamiento en tiempo de prueba (TTT) proporciona fundamentación teórica: DeltaNet optimiza directamente la predicción de valores en tiempo de inferencia.

8.3.2. Entrenamiento Paralelo Eficiente

La matriz de transición de DeltaNet $\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top$ es una matriz de Householder generalizada (actualización de rango 1 a la identidad). Para el entrenamiento por fragmentos, DeltaNet usa la **representación** $\mathbf{WY}$, que representa el producto de m de estas actualizaciones de rango 1 de forma compacta:

$$\prod_{i=1}^m (\mathbf{I} - \beta_i \mathbf{k}_i \mathbf{k}_i^\top) = \mathbf{I} - \mathbf{WY}^\top$$

donde $\mathbf{W}, \mathbf{Y} \in \mathbb{R}^{d \times m}$ se construyen recursivamente. Esta factorización permite paralelismo rico en matmul sin materializar el producto completo, manteniendo el entrenamiento por fragmentos eficiente.

Algorithm 33 Actualización de Estado de DeltaNet con Representación WY

Require: Fragmento de entrada $\mathbf{X}_{[t]}$; estado anterior $\mathbf{S}_{t-1}$

Require: Consultas normalizadas L2 $\hat{\mathbf{Q}}_t$, claves $\hat{\mathbf{K}}_t$, valores $\mathbf{V}_t$

Ensure: Salida $\mathbf{O}_{[t]}$ y estado actualizado $\mathbf{S}_t$

- 1: **Fase por fragmentos:**
 - 2: **for** posición $i = 1$ to tamaño fragmento **do**
 - 3: Normalizar: $\hat{\mathbf{k}}_i \leftarrow \hat{\mathbf{K}}_t[i] / \|\hat{\mathbf{K}}_t[i]\|$, $\hat{\mathbf{q}}_i \leftarrow \hat{\mathbf{Q}}_t[i] / \|\hat{\mathbf{Q}}_t[i]\|$
 - 4: Calcular intensidad de escritura: $\beta_i \leftarrow \text{sigmoid}(W_\beta \mathbf{x}_i)$
 - 5: Predicción: $\hat{\mathbf{v}}^{\text{pred}} \leftarrow \mathbf{S}_{i-1}^{\text{en-fragmento}} \hat{\mathbf{k}}_i$
 - 6: Mezcla consciente del error: $\mathbf{v}_i^{\text{actualización}} \leftarrow \beta_i (\mathbf{v}_i - \hat{\mathbf{v}}^{\text{pred}})$
 - 7: Borrar-escribir: $\mathbf{S}_i^{\text{en-fragmento}} \leftarrow \mathbf{S}_{i-1}^{\text{en-fragmento}} - \hat{\mathbf{v}}^{\text{pred}} \hat{\mathbf{k}}_i^\top + (\beta_i \mathbf{v}_i + (1 - \beta_i) \hat{\mathbf{v}}^{\text{pred}}) \hat{\mathbf{k}}_i^\top$
 - 8: Salida: $\mathbf{o}_i \leftarrow \mathbf{S}_i^{\text{en-fragmento}} \hat{\mathbf{q}}_i$
 - 9: **end for**
 - 10: **Fase entre fragmentos:** Usar representación WY de los productos de transición **return** $\mathbf{O}_{[t]}, \mathbf{S}_t$
-

8.3.3. Fortalezas y Limitaciones

Aspecto	Fortalezas	Limitaciones
Recuperación asociativa	Recuperación perfecta en el benchmark MQAR (Recuperación Asociativa Multi-Consulta); la semántica de corrección de errores se ajusta naturalmente a patrones de recuperación.	Sin olvido global, la memoria aún se satura en longitudes de secuencia extremas; requiere mecanismos de reinicio periódico para contexto ilimitado.
Teoría	Fundamentada en optimización de ECM en línea; conexión clara con el paradigma de entrenamiento en tiempo de prueba.	Requiere claves normalizadas L2 para estabilidad numérica; la normalización de doble ancho añade sobrecarga.
Rendimiento	La representación WY permite entrenamiento eficiente por fragmentos.	Ligeramente más lento que Mamba2 por token debido a matrices de transición más ricas (rango 1 en lugar de diagonales).

8.4. 3. Gated DeltaNet: Síntesis de Compuerta y Corrección de Errores

8.4.1. Fundamento Matemático

Gated DeltaNet [101] sintetiza las fortalezas de GLA y DeltaNet combinando una **compuerta de decaimiento** α_t (de GLA) con la **compuerta de intensidad de escritura** β_t (de DeltaNet):

$$\mathbf{S}_t = \mathbf{S}_{t-1} \left(\alpha_t (\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) \right) + \beta_t \mathbf{v}_t \mathbf{k}_t^\top$$

Reescribiendo para mayor claridad:

$$\mathbf{S}_t = \alpha_t \mathbf{S}_{t-1} (\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) + \beta_t \mathbf{v}_t \mathbf{k}_t^\top$$

Las dos compuertas son complementarias:

- $\alpha_t \rightarrow 0$ borra rápidamente el estado histórico: $\mathbf{S}_t \approx \beta_t \mathbf{v}_t \mathbf{k}_t^\top$ (reinicio de contexto).
- $\alpha_t \rightarrow 1$ recupera el comportamiento puro de regla delta: $\mathbf{S}_t \approx \mathbf{S}_{t-1} (\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) + \beta_t \mathbf{v}_t \mathbf{k}_t^\top$ (actualizaciones dirigidas).
- $\beta_t \rightarrow 0$ omite la escritura pero decae: $\mathbf{S}_t \approx \alpha_t \mathbf{S}_{t-1}$ (olvido puro).
- $\beta_t \rightarrow 1$ reemplaza la memoria agresivamente: $\mathbf{S}_t \approx \alpha_t \mathbf{S}_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top$ (reemplazo).

Desde una perspectiva de aprendizaje en línea, Gated DeltaNet corresponde a:

$$\min_{\mathbf{S}_t} \|\mathbf{S}_t - \alpha_t \mathbf{S}_{t-1}\|_F^2 - 2 \langle \mathbf{S}_t \mathbf{k}_t, \beta_t (\mathbf{v}_t - \alpha_t \mathbf{S}_{t-1} \mathbf{k}_t) \rangle$$

que introduce un decaimiento de pesos adaptativo α_t en una actualización tipo SGD—análogo al decaimiento de pesos desacoplado en la optimización de aprendizaje profundo.

Algorithm 34 Paso Adelante Paralelo por Fragmentos de Gated DeltaNet

Require: Fragmento de entrada $\mathbf{X}_{[i]}$; estado anterior $\mathbf{S}_{i-1}$; tamaño de fragmento C

Require: Proyecciones: $W_q, W_k, W_v, W_\alpha, W_\beta$

Ensure: Salida $\mathbf{O}_{[i]}$ y estado $\mathbf{S}_i$

1: **Cálculo en-fragmento:**

2: **for** $j = 1$ to C **do**

3: $\mathbf{q}_j \leftarrow W_q \mathbf{x}_j, \mathbf{k}_j \leftarrow W_k \mathbf{x}_j, \mathbf{v}_j \leftarrow W_v \mathbf{x}_j$

4: $\alpha_j \leftarrow \text{sigmoid}(W_\alpha \mathbf{x}_j), \beta_j \leftarrow \text{sigmoid}(W_\beta \mathbf{x}_j)$

5: Aplicar compuerta combinada: $\mathbf{S}_j \leftarrow \alpha_j \mathbf{S}_{j-1} (\mathbf{I} - \beta_j \mathbf{k}_j \mathbf{k}_j^\top) + \beta_j \mathbf{v}_j \mathbf{k}_j^\top$

6: $\mathbf{o}_j \leftarrow \mathbf{S}_j \mathbf{q}_j$

7: **end for**

8: **Recurrencia entre fragmentos:**

9: $\mathbf{S}_i \leftarrow \mathbf{S}_C$ del en-fragmento; propagar entre fragmentos mediante máscaras $\prod \alpha$ acumulativas

10: **Compuerta de salida:** $\mathbf{O}_{[i]} \leftarrow \text{GroupNorm}(\mathbf{O}^{\text{crudo}}) \otimes \text{SiLU}(W_g \mathbf{X}_{[i]})$ **return** $\mathbf{O}_{[i]}, \mathbf{S}_i$

8.4.2. Rendimiento Empírico y Compensaciones

Gated DeltaNet se ha integrado en los modelos de producción Qwen3-Next y Qwen3.5 de Alibaba. Empíricamente:

Tarea	Gated DeltaNet	Mamba2	DeltaNet	GLA
Modelado de Lenguaje	1,0×	1,08×	1,05×	1,12×
Recuperación Asociativa	1,0×	— — (<i>sinperfecto</i>)	1,0×	0,75
Extrapolación de Longitud	1,0×	0,98×	0,96×	0,94×
Rendimiento (tokens/seg)	0,85×	1,0×	0,82×	0,88×

Gated DeltaNet logra el mejor equilibrio entre diversas tareas a costa de un rendimiento ligeramente reducido debido a matrices de transición más ricas.

8.5. 4. HGRN2: Compuerta Jerárquica con Expansión de Producto Externo

8.5.1. Fundamento Matemático

HGRN2 [74] usa una expansión de estado basada en producto externo con **compuertas de olvido acotadas inferiormente de forma jerárquica**. La actualización de estado es:

$$\mathbf{S}_t = \text{diag}(\mathbf{g}_t) \cdot \mathbf{S}_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top, \quad \mathbf{o}_t = \mathbf{S}_t \mathbf{q}_t$$

donde $\mathbf{g}_t \in [b_\ell, 1]^d$ es una compuerta de olvido con cota inferior para la capa ℓ . Las cotas satisfacen:

$$0 \leq b_{\ell_{\text{poco profunda}}} < b_{\ell_{\text{media}}} < b_{\ell_{\text{profunda}}} \leq 1$$

es decir, las cotas aumentan (se vuelven menos restrictivas) en las capas más profundas. La compuerta en sí se calcula como:

$$\mathbf{g}_t = b_\ell + (1 - b_\ell) \cdot \sigma(W_g \mathbf{x}_t)$$

donde σ es sigmoide. Cuando W_g produce logits débilmente negativos, $\mathbf{g}_t \approx b_\ell$ (retención forzada en capas superficiales). Cuando las salidas son fuertemente positivas, $\mathbf{g}_t \approx 1$ (refresco de memoria en cualquier capa).

La estructura jerárquica anima a diferentes capas a especializarse en diferentes escalas temporales: las capas superficiales modelan dependencias locales (alta retención debido a la cota b_ℓ), mientras que las capas profundas capturan estructura de largo alcance (compuerta flexible con cota superior alta).

Algorithm 35 Paso Adelante de HGRN2 con Cotas Jerárquicas

Require: Entrada $\mathbf{x}_t$; estado anterior $\mathbf{S}_{t-1}$; índice de capa $\ell \in [0, L - 1]$

Require: Cotas no decrecientes: $0 \leq b_0 < b_1 < \dots < b_{L-1} \leq 1$

Ensure: Salida $\mathbf{o}_t$ y estado $\mathbf{S}_t$

- 1: Cota de retención específica de capa: $b \leftarrow b_\ell$
 - 2: Proyectar: $\mathbf{q}_t \leftarrow W_q \mathbf{x}_t$, $\mathbf{k}_t \leftarrow W_k \mathbf{x}_t$, $\mathbf{v}_t \leftarrow W_v \mathbf{x}_t$
 - 3: Calcular compuerta de olvido con cota: $\mathbf{g}_t \leftarrow b + (1 - b) \cdot \sigma(W_g \mathbf{x}_t)$ ▷ Confinado a $[b, 1]$
 - 4: Multiplicación diagonal (vectorizada): $\mathbf{S}_t \leftarrow \mathbf{S}_{t-1} \circ \text{diag}(\mathbf{g}_t) + \mathbf{v}_t \mathbf{k}_t^\top$
 - 5: Recuperar: $\mathbf{o}_t \leftarrow \mathbf{S}_t \mathbf{q}_t$
 - 6: Normalización opcional: $\mathbf{o}_t \leftarrow \text{RMSNORM}(\mathbf{o}_t)$ **return** $\mathbf{o}_t$, $\mathbf{S}_t$
-

8.5.2. Escalado y Resultados Empíricos

A escala de 3B en 100B tokens, HGRN2 supera ligeramente a Mamba2 y a los Transformers con arquitectura LLaMA en modelado de lenguaje. La compuerta jerárquica proporciona modelado temporal multi-escala sin variantes arquitectónicas explícitas por capa. Sin embargo, la compuerta diagonal con valor vectorial (en oposición a la selección elemento a elemento) proporciona menos flexibilidad por elemento que las variantes de regla delta.

8.6. 5. Forgetting Transformer (FoX): Compuerta en el Espacio de Logits Softmax

8.6.1. Fundamento Matemático

Forgetting Transformer (FoX), propuesto por Lin et al. [54], incrusta una compuerta de olvido directamente en los logits de atención softmax. En lugar de reemplazar softmax con recurrencia lineal, FoX preserva la expresividad completa de softmax mientras añade control de actualidad mediante un sesgo de logit dependiente de los datos.

Para cada posición de token t y todas las claves $j \leq t$, calcular un escalar de compuerta de olvido:

$$f_t = \sigma(w_f^\top \mathbf{x}_t + b_f)$$

El sesgo de logit en la posición (i, j) es el producto acumulativo log-olvido:

$$d_{ij} = \sum_{l=j+1}^i \log f_l = \log \prod_{l=j+1}^i f_l$$

La salida de atención completa se convierte en:

$$\mathbf{O} = \text{softmax} \left(\frac{\mathbf{QK}^\top}{\sqrt{d_k}} + \mathbf{D} \right) \mathbf{V}$$

donde $\mathbf{D}_{ij} = d_{ij}$. Equivalentemente:

$$\text{Atencion}(i, j) = \frac{\exp(\mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d_k} + d_{ij})}{\sum_{j'=1}^i \exp(\mathbf{q}_i^\top \mathbf{k}_{j'} / \sqrt{d_k} + d_{ij'})}$$

Esta ponderación reduce el peso de los tokens más antiguos multiplicativamente: un token de hace 10 pasos se escala por $\prod_{l=j+1}^i f_l$, que es típicamente mucho menor que 1 si $f_t < 1$ en promedio.

El mecanismo es matemáticamente equivalente a una **variante aprendible dependiente de los datos de ALiBi (Atención con Sesgos Lineales)**, donde trabajos anteriores usaban $d_{ij} = -\infty \cdot |i - j|$ fijo o $d_{ij} = -(i - j)$.

Algorithm 36 FoX: Atención con Olvido y Sesgo de Actualidad

Require: Consultas $\mathbf{Q}$, claves $\mathbf{K}$, valores $\mathbf{V}$; entrada $\mathbf{X}$

Require: Parámetros de compuerta de olvido: $w_f \in \mathbb{R}^d$, $b_f \in \mathbb{R}$

Ensure: Salida de atención $\mathbf{O}$

```

1: Calcular compuertas de olvido:
2: for  $t = 1$  to  $T$  do
3:    $f_t \leftarrow \sigma(w_f^\top \mathbf{x}_t + b_f)$  ▷ Probabilidad de olvido por token
4: end for
5: Calcular sesgos acumulativos de log-olvido:
6: for  $i = 1$  to  $T$  do
7:   for  $j = 1$  to  $i$  do
8:      $d_{ij} \leftarrow \sum_{l=j+1}^i \log f_l$  ▷ Producto acumulativo en espacio logarítmico
9:   end for
10: end for
11: SDPA estándar con sesgo:
12: Calcular puntajes:  $\mathbf{S} \leftarrow \mathbf{QK}^\top / \sqrt{d_k}$ 
13: Agregar sesgo:  $\mathbf{S} \leftarrow \mathbf{S} + \mathbf{D}$ 
14: Aplicar softmax:  $\mathbf{A} \leftarrow \text{softmax}(\mathbf{S}, \text{dim} = -1)$ 
15: Ponderar valores:  $\mathbf{O} \leftarrow \mathbf{AV}$  return  $\mathbf{O}$ 

```

8.6.2. Integración con FlashAttention

La ventaja clave de FoX es la compatibilidad con FlashAttention y las implementaciones optimizadas existentes. Los sesgos de olvido se añaden en el cálculo de logits softmax, que ya es una operación central en el algoritmo por bloques de FlashAttention. La sobrecarga es:

$$\text{Sobrecarga} \approx 0,5 - 2\% \text{ del tiempo de pared}$$

ya que la adición de sesgo se amortiza entre las operaciones matmul.

8.6.3. Fortalezas y Limitaciones

FoX logra resultados de última generación en extrapolación de longitud, recuperación casi perfecta de aguja en el pajar y comprensión superior de contexto largo en comparación con los Transformers. Sin embargo, sigue siendo $\mathcal{O}(L^2d)$ en entrenamiento y $\mathcal{O}(Ld)$ por paso en inferencia con caché KV, limitando las longitudes de secuencia extremas.

8.7. 6. Atención con Compuerta (Post-SDPA Sigmoides)

8.7.1. Fundamento Matemático

El Mejor Artículo de NeurIPS 2025 del equipo de Qwen propone aplicar una compuerta sigmoide **después** de la atención de producto punto escalado (SDPA):

$$\mathbf{Y} = \text{SDPA}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V}$$

$$\mathbf{Y}' = \mathbf{Y} \odot \sigma(\mathbf{X}\mathbf{W}_\theta)$$

donde el puntaje de compuerta $\sigma(\mathbf{X}\mathbf{W}_\theta)$ puede tener forma $\mathbb{R}^{n \times q \times d_k}$ (compuerta elemento a elemento por cabeza de consulta) o $\mathbb{R}^{n \times q}$ (compuerta fija por cabeza). En más de 30 variantes y modelos MoE de 15B + densos de 1.7B entrenados en 3.5T tokens, el equipo encontró:

- La compuerta por cabeza añade solo $\sim 1,6M$ parámetros a un modelo de 15B (sobrecarga insignificante).
- Las compuertas efectivas son **dispersas**: activación media $\approx 0,116$ (es decir, el 88 % son cero o casi cero).
- Las compuertas actúan como filtros dependientes de la consulta, suprimiendo canales de bajo valor mientras preservan señales de alto valor.
- Las compuertas eliminan demostrablemente el fenómeno de **sumidero de atención**, donde el patrón de atención se vuelve dominado por un único token temprano.

Algorithm 37 Atención Softmax con Compuerta (Post-SDPA)

Require: Consultas $\mathbf{Q}$, Claves $\mathbf{K}$, Valores $\mathbf{V}$; entrada $\mathbf{X}$

Require: Matriz de proyección de compuerta $\mathbf{W}_g \in \mathbb{R}^{d \rightarrow d_{\text{compuerta}}}$ donde $d_{\text{compuerta}} \in \{1, d_k\}$

Ensure: Salida con compuerta $\mathbf{Y}'$

- 1: **SDPA estándar:**
 - 2: Calcular atención: $\mathbf{A} \leftarrow \text{softmax}(\mathbf{Q}\mathbf{K}^\top / \sqrt{d_k})$
 - 3: Ponderar valores: $\mathbf{Y} \leftarrow \mathbf{A}\mathbf{V}$
 - 4: **Calcular compuertas:**
 - 5: Proyectar entrada: $\mathbf{G} \leftarrow \mathbf{X}\mathbf{W}_g$ ▷ forma: $[n, q, d_{\text{compuerta}}]$
 - 6: Aplicar sigmoide: $\mathbf{G} \leftarrow \sigma(\mathbf{G})$ ▷ Compuerta elemento a elemento
 - 7: **Aplicar compuerta:**
 - 8: **if** $d_{\text{compuerta}} = 1$ **then**
 - 9: Transmitir y escalar: $\mathbf{Y}' \leftarrow \mathbf{Y} \cdot \mathbf{G}$ ▷ Escalado por cabeza
 - 10: **else** ▷ $d_{\text{compuerta}} = d_k$
 - 11: Modulación elemento a elemento: $\mathbf{Y}' \leftarrow \mathbf{Y} \odot \mathbf{G}$ ▷ Compuerta por dimensión
 - 12: **end if return** $\mathbf{Y}'$
-

8.7.2. Hallazgos Clave

- **Supresión del sumidero de atención:** La compuerta rompe el ciclo de retroalimentación donde softmax se concentra en el primer token, permitiendo una atención más equilibrada.
- **Estabilidad de entrenamiento:** Los modelos con compuerta toleran tasas de aprendizaje más grandes (+30 % mayor η_{max} estable).
- **Sobrecarga mínima:** El impacto en latencia es solo del 1,6 % en GPUs H100; el rendimiento cae como máximo 2 – 3 %.
- **Mejora en la ley de escalado:** Mejora la pérdida en todas las escalas de modelo, desde 800M hasta 110B parámetros de forma consistente.

8.8. 7. Gated DeltaNet-2: Borrado y Escritura Canalizados Decouplados

8.8.1. Fundamento Matemático

Gated DeltaNet-2 [36] aborda una limitación compartida de Gated DeltaNet y Kimi Delta Attention (KDA): ambos usan una única *compuerta delta escalar* β_t para controlar simultáneamente (i) cuánto contenido antiguo se borra en la dirección de lectura del eje de claves y (ii) cuánto valor nuevo se escribe en el eje de valores. Gated DeltaNet-2 **desacopla** estos dos roles en una compuerta de borrado canalizada $\mathbf{b}_t$ (eje de claves) y una compuerta de escritura canalizada $\mathbf{w}_t$ (eje de valores), heredando además el decaimiento canalizado α_t de KDA. Con estado $\mathbf{S}_t \in \mathbb{R}^{d_k \times d_v}$, decaimiento $\mathbf{D}_t = \text{Diag}(\alpha_t)$, dirección de borrado $\mathbf{e}_t = \mathbf{b}_t \odot \mathbf{k}_t$ y objetivo de escritura $\mathbf{z}_t = \mathbf{w}_t \odot \mathbf{v}_t$, la actualización de estado es:

$$\mathbf{S}_t = \left(\mathbf{I} - \mathbf{k}_t \mathbf{e}_t^\top \right) \mathbf{D}_t \mathbf{S}_{t-1} + \mathbf{k}_t \mathbf{z}_t^\top, \quad \mathbf{o}_t = \mathbf{S}_t^\top \mathbf{q}_t$$

o, expandiendo los productos de las compuertas:

$$\mathbf{S}_t = \left(\mathbf{I} - \mathbf{k}_t (\mathbf{b}_t \odot \mathbf{k}_t)^\top \right) \mathbf{D}_t \mathbf{S}_{t-1} + \mathbf{k}_t (\mathbf{w}_t \odot \mathbf{v}_t)^\top$$

Las dos compuertas se producen mediante proyecciones lineales independientes seguidas de sigmoide:

$$\mathbf{b}_t = \sigma(\mathbf{W}_b \mathbf{x}_t), \quad \mathbf{w}_t = \sigma(\mathbf{W}_w \mathbf{x}_t)$$

y el decaimiento canalizado sigue una parametrización de log-decaimiento (calculada en fp32 para evitar pérdida de precisión en productos acumulativos largos):

$$\mathbf{g}_t = \mathbf{a} - \text{softplus}(\delta), \quad \alpha_t = \exp(\mathbf{g}_t)$$

Los roles estructurales de las dos compuertas son complementarios:

- $\mathbf{b}_t$ (eje de claves) hace que la **dirección de lectura** sea selectiva por canal: determina qué canales de clave se eliminan antes de escribir.
- $\mathbf{w}_t$ (eje de valores) hace que el **objetivo de escritura** sea selectivo por canal: determina qué canales de valor se depositan en memoria.
- α_t (por canal de clave) proporciona decaimiento global, como en KDA.

Reducciones. Fijar $\mathbf{b}_t = \beta_t \mathbf{1}_{d_k}$ y $\mathbf{w}_t = \beta_t \mathbf{1}_{d_v}$ recupera KDA; colapsar además α_t a un escalar recupera Gated DeltaNet. Desde la perspectiva de aprendizaje en línea/pesos rápidos, la actualización es el minimizador de:

$$\mathcal{L}_t(\mathbf{S}) = \frac{1}{2} \|\mathbf{S} - \mathbf{D}_t \mathbf{S}_{t-1}\|_F^2 - 2 \left\langle \mathbf{S}^\top \mathbf{k}_t, \mathbf{z}_t - (\mathbf{D}_t \mathbf{S}_{t-1})^\top \mathbf{e}_t \right\rangle$$

Algorithm 38 Avance Recurrente de Gated DeltaNet-2 (Forma de Referencia)

Require: Entrada $\mathbf{x}_t$; estado previo $\mathbf{S}_{t-1} \in \mathbb{R}^{d_k \times d_v}$ **Require:** Proyecciones: W_q, W_k, W_v, W_b, W_w ; parámetros de log-decaimiento $\mathbf{a}, \delta$ **Ensure:** Salida $\mathbf{o}_t$ y estado $\mathbf{S}_t$

- 1: $\mathbf{q}_t \leftarrow \text{normalize}(W_q \mathbf{x}_t)$, $\mathbf{k}_t \leftarrow \text{normalize}(W_k \mathbf{x}_t)$, $\mathbf{v}_t \leftarrow \text{silu}(W_v \mathbf{x}_t)$
 - 2: $\mathbf{b}_t \leftarrow \sigma(W_b \mathbf{x}_t)$ $\triangleright$ compuerta de borrado eje-clave, $\mathbb{R}^{d_k}$
 - 3: $\mathbf{w}_t \leftarrow \sigma(W_w \mathbf{x}_t)$ $\triangleright$ compuerta de escritura eje-valor, $\mathbb{R}^{d_v}$
 - 4: $\alpha_t \leftarrow \exp(\mathbf{a} - \text{softplus}(\delta))$ $\triangleright$ decaimiento canalizado, fp32
 - 5: Dirección de borrado: $\mathbf{e}_t \leftarrow \mathbf{b}_t \odot \mathbf{k}_t$; objetivo de escritura: $\mathbf{z}_t \leftarrow \mathbf{w}_t \odot \mathbf{v}_t$
 - 6: Decaer estado: $\mathbf{S}_t \leftarrow \text{Diag}(\alpha_t) \mathbf{S}_{t-1}$
 - 7: Lectura: $\mathbf{r}_t \leftarrow \mathbf{S}_t^\top \mathbf{e}_t$ $\triangleright$ suma sobre eje de claves
 - 8: Actualización delta: $\mathbf{S}_t \leftarrow \mathbf{S}_t - \mathbf{k}_t \mathbf{r}_t^\top + \mathbf{k}_t \mathbf{z}_t^\top$
 - 9: Recuperar: $\mathbf{o}_t \leftarrow \mathbf{S}_t^\top \mathbf{q}_t$
 - 10: Compuerta de salida: $\mathbf{o}_t \leftarrow \text{GroupNorm}(\mathbf{o}_t) \odot \text{silu}(W_g \mathbf{x}_t)$
 - 11: **return** $\mathbf{o}_t, \mathbf{S}_t$
-

El algoritmo de entrenamiento por fragmentos extiende la representación WY de KDA absorbiendo el decaimiento canalizado en una recurrencia delta asimétrica sobre un estado normalizado por decaimiento, permitiendo paralelismo rico en matmuls en tensor cores. Como $\mathbf{b}_t$ y $\mathbf{w}_t$ son operadores diagonales por canal que varían por fila, el atajo de post-escalado escalar de KDA se rompe: el paso hacia atrás requiere una **inversión WY consciente de las compuertas** que incorpora las compuertas en cada producto escalar que acumula el gradiente.

8.8.2. Rendimiento Empírico y Compromisos

A 1.3B parámetros entrenados con 100B tokens FineWeb-Edu, Gated DeltaNet-2 supera a Mamba-2, Mamba-3, Gated DeltaNet y KDA en modelado de lenguaje, razonamiento de sentido común y—más notablemente—recuperación de contexto largo del mundo real y RULER (especialmente multi-key needle-in-a-haystack). Su rendimiento en H100 se mantiene casi plano ($38,0 \rightarrow 36,1$ Kt/s) al crecer la longitud de secuencia de 2K a 16K, donde el de un Transformer cae bruscamente. Los estudios de ablación muestran que la compuerta de borrado $\mathbf{b}_t$ explica la mayor parte de la ganancia; la compuerta de escritura $\mathbf{w}_t$ aporta una mejora adicional menor. La variante híbrida (Gated DeltaNet-2 recurrente + atención de ventana deslizante) reduce aún más la brecha con los modelos de atención pura en tareas que requieren agregación de evidencia local.

Aspecto	Fortaleza	Limitación
Recuperación	La mejor entre modelos delta recurrentes en multi-key NIAH.	La variante recurrente aún supera al Transformer en NQ/DROP.
Rendimiento	Escalado casi plano 2K $\rightarrow$ 16K; pequeña sobrecarga vs KDA.	Requiere un nuevo kernel Triton WY consciente de las compuertas.
Memoria	Estado de inferencia constante $\mathcal{O}(d^2)$.	Rango de borrado de autovalores negativos $[0, 2]$ no da ganancia consistente a 1.3B.

Cuadro 13: Compromisos de Gated DeltaNet-2 a escala 1.3B / 100B tokens [36].

8.9. 8. Kimi Delta Attention (KDA): Compuerta de Decaimiento Canalizada para la Regla Delta

8.9.1. Fundamento Matemático

Kimi Delta Attention [47] es el módulo central de Kimi Linear y extiende Gated DeltaNet con una **compuerta de decaimiento canalizada** de grano más fino. Mientras que Gated

DeltaNet usa un único decaimiento escalar por cabeza α_t junto con la compuerta escalar de escritura delta β_t , KDA reemplaza el decaimiento escalar con un decaimiento **por canal de clave** $\alpha_t \in \mathbb{R}^{d_k}$, parametrizado mediante una formulación de log-decaimiento y aplicado como una matriz diagonal $\mathbf{D}_t = \text{diag}(\alpha_t)$ antes de la actualización de la regla delta. La regla delta en sí retiene una compuerta de escritura escalar por cabeza β_t :

$$\mathbf{S}_t = (\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) \mathbf{D}_t \mathbf{S}_{t-1} + \beta_t \mathbf{v}_t \mathbf{k}_t^\top, \quad \mathbf{o}_t = \mathbf{S}_t^\top \mathbf{q}_t$$

El decaimiento canalizado sigue una parametrización de log-decaimiento (calculada en fp32 por estabilidad numérica en productos acumulativos largos):

$$\mathbf{g} = \mathbf{a} - \text{softplus}(\boldsymbol{\delta}), \quad \alpha_t = \exp(\mathbf{g})$$

donde $\mathbf{a}$ y $\boldsymbol{\delta}$ son parámetros aprendidos por canal. Esto da a cada canal de clave una escala temporal de olvido independiente, permitiendo al modelo retener algunos canales más tiempo que otros dentro de la misma cabeza.

Reducción a Gated DeltaNet : Cuando α_t colapsa a un escalar (es decir, todos los canales comparten el mismo decaimiento), KDA se reduce exactamente a Gated DeltaNet. El decaimiento canalizado es por tanto una generalización estricta que añade selectividad por canal sobre el decaimiento/escritura escalares de Gated DeltaNet.

Entrenamiento por fragmentos : Un algoritmo por fragmentos ad hoc usa una variante **Diagonal-Plus-Low-Rank (DPLR)** especializada de la matriz de transición para mantener la eficiencia en hardware. El producto de las transiciones por paso $(\mathbf{I} - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) \mathbf{D}_t$ admite una descomposición DPLR que permite paralelismo rico en matmuls en tensor cores preservando la estructura de decaimiento canalizado.

Algorithm 39 Avance Recurrente de Kimi Delta Attention (Forma de Referencia)

Require: Entrada $\mathbf{x}_t$; estado previo $\mathbf{S}_{t-1} \in \mathbb{R}^{d_k \times d_v}$

Require: Proyecciones: W_q, W_k, W_v, W_β ; parámetros de log-decaimiento $\mathbf{a}, \boldsymbol{\delta}$

Ensure: Salida $\mathbf{o}_t$ y estado $\mathbf{S}_t$

- 1: $\mathbf{q}_t \leftarrow W_q \mathbf{x}_t, \mathbf{k}_t \leftarrow W_k \mathbf{x}_t, \mathbf{v}_t \leftarrow W_v \mathbf{x}_t$
 - 2: $\beta_t \leftarrow \text{sigmoid}(W_\beta \mathbf{x}_t)$ ▷ compuerta de escritura escalar por cabeza
 - 3: $\alpha_t \leftarrow \exp(\mathbf{a} - \text{softplus}(\boldsymbol{\delta}))$ ▷ decaimiento canalizado, fp32
 - 4: $\mathbf{D}_t \leftarrow \text{diag}(\alpha_t)$ ▷ matriz diagonal de decaimiento
 - 5: Decaer estado: $\mathbf{S}_t \leftarrow \mathbf{D}_t \mathbf{S}_{t-1}$
 - 6: Lectura: $\mathbf{r}_t \leftarrow \mathbf{S}_t^\top \mathbf{k}_t$ ▷ predicción actual a lo largo de la clave
 - 7: Actualización delta: $\mathbf{S}_t \leftarrow \mathbf{S}_t - \beta_t \mathbf{k}_t \mathbf{r}_t^\top + \beta_t \mathbf{v}_t \mathbf{k}_t^\top$
 - 8: Recuperar: $\mathbf{o}_t \leftarrow \mathbf{S}_t^\top \mathbf{q}_t$
 - 9: Compuerta de salida: $\mathbf{o}_t \leftarrow \text{GroupNorm}(\mathbf{o}_t) \odot \text{silu}(W_g \mathbf{x}_t)$
 - 10: **return** $\mathbf{o}_t, \mathbf{S}_t$
-

8.9.2. Rendimiento Empírico y Compromisos

KDA está desplegado en Kimi Linear, un modelo híbrido (3B activados / 48B parámetros totales) que combina capas KDA con Multi-head Latent Attention (MLA). Kimi Linear supera a un baseline de MLA completa en todas las tareas evaluadas, reduce el caché KV hasta un 75 %, y logra hasta 6× de throughput de decodificación para contexto de 1M de tokens. El decaimiento canalizado es el principal impulsor de la ganancia: permite control fino sobre qué canales de clave persisten, mejorando el recuerdo de contexto largo frente a Gated DeltaNet con decaimiento escalar.

Aspecto	Fortaleza	Limitación
Recuperación	El decaimiento canalizado mejora el recuerdo de contexto largo frente a baselines de decaimiento escalar; desplegado en Kimi Linear (híbrido 3B/48B).	El estado recurrente matricial $\mathcal{O}(d^2)$ es más pesado que la atención lineal con compuerta diagonal.
Rendimiento	Hasta 6× de throughput de decodificación a 1M de contexto; 75% de reducción de caché KV frente a MLA completa.	Requiere kernels por fragmentos conscientes de DPLR para eficiencia en hardware.
Memoria	Estado de inferencia constante $\mathcal{O}(d^2)$ (recurrente matricial).	El cálculo log-decaimiento en fp32 añade sobrecarga; la reducción a Gated DeltaNet pierde selectividad por canal.

Cuadro 14: Compromisos de KDA en Kimi Linear (3B activados / 48B total) [47].

8.10. Principio Unificado de Compuerta

Las ocho arquitecturas comparten un principio común: **la compuerta es un mecanismo para controlar el flujo de información y la retención selectiva de memoria**. Las decisiones de diseño específicas divergen a lo largo de varias dimensiones:

1. **Ubicación de la compuerta:** Actualizaciones de estado recurrente (GLA, DeltaNet, Gated DeltaNet, Gated DeltaNet-2, HGRN2) versus espacio de logits/salida softmax (FoX, Gated Softmax, RetNet).
2. **Granularidad de control:** Por dimensión (GLA, HGRN2 diagonal), por clave (DeltaNet), por token (FoX), por cabeza (Gated Softmax) o borrado/escritura canalizados decouplados (Gated DeltaNet-2).
3. **Dependencia de datos:** Completamente dependiente de datos (GLA, DeltaNet, Gated DeltaNet, Gated DeltaNet-2, FoX, Gated Softmax) versus esquemas fijos (RetNet con decaimiento exponencial).
4. **Compensación de expresividad:** Eficiencia recurrente lineal (GLA, DeltaNet, Gated DeltaNet, Gated DeltaNet-2, HGRN2, RetNet) versus expresividad completa de softmax (FoX, Gated Softmax).

8.11. Implementación y Orientación Práctica

8.11.1. Cuándo Usar Cada Arquitectura

1. **GLA:** Inferencia rápida con contextos moderados a largos (2K–20K tokens), cuando los kernels CUDA personalizados son aceptables y el rendimiento de recuperación no es crítico.
2. **DeltaNet:** Fuerte recuperación asociativa y tareas de aprendizaje en contexto; bueno para tareas sintéticas (MQAR) y pruebas de asociación clave-valor.
3. **Gated DeltaNet:** Modelos de producción que requieren el mejor equilibrio de recuperación, olvido y rendimiento (probado en Qwen3-Next; ICLR 2025).
4. **Gated DeltaNet-2:** Cargas de recuperación de contexto largo (multi-key NIAH) donde el borrado/escritura canalizado decouplado da el recuerdo más fuerte; cuando se dispone de un kernel WY consciente de las compuertas.
5. **RetNet:** Inferencia extremadamente eficiente sin almacenamiento en caché KV; adecuado para despliegues en dispositivos móviles/de borde o modelos de juguete.

6. **HGRN2**: Jerarquías temporales multi-escala; cuando los límites de olvido específicos por capa son deseables.
7. **FoX**: Extrapolación de longitud y comprensión de contexto largo; cuando el entrenamiento cuadrático es aceptable y no se desea reemplazar softmax.
8. **Gated Softmax**: Mejora rápida para modelos softmax existentes con cambios mínimos de código; mejor para profesionales que desean ganancias inmediatas sin una reestructuración importante.

8.11.2. Consideraciones de Hardware

Objetivo de Hardware	Arquitecturas Re-comendadas	Notas
GPU (H100/A100)	Gated Softmax, FoX, Gated DeltaNet, Gated DeltaNet-2	Implementaciones maduras de softmax/lineal. GLA/DeltaNet requieren kernels personalizados.
TPU (alta memoria)	GLA, DeltaNet, Gated DeltaNet, Gated DeltaNet-2, HGRN2	Hardware soporta matmuls eficientes; los métodos recurrentes lineales brillan.
Móvil/Borde	RetNet, Gated Softmax ligero	Inferencia con memoria constante es crítica.

9. Normalización, Cuantización, Enrutamiento de Profundidad y Algoritmos de Ejecución

Este anexo recopila el detalle a nivel de implementación para las variantes de normalización, cuantización ternaria estilo BitNet, enrutamiento adaptativo de profundidad (Mixture-of-Depths), memoria condicional (Engram), embeddings factorizados y los algoritmos de ejecución (controles de estabilidad del paso de entrenamiento, enrutador de inferencia SBERT) que soportan la tubería impulsada por configuración. (Las conexiones residuales restringidas por variedad de mHC se documentan por separado en el Anexo 9.) Las secciones principales difieren a este anexo para las formulaciones matemáticas y el pseudocódigo; las claves bibliográficas citadas aquí se resuelven contra `docs/bibliography/`.

9.1. Variantes de Normalización: LayerNorm, RMSNorm, pRMSNorm, Tanh Dinámico, Erf Dinámico y FlashNorm

La normalización determina cómo se controla la escala de activación a través de la profundidad. En este repositorio, la normalización no es solo una elección de modelado sino también una cuestión de compatibilidad con el esquema, porque solo ciertos valores son actualmente aceptados por `norm_type`. El contrato del esquema es:

$$\text{norm_type} \in \{\text{layer_norm}, \text{dynamic_tanh}, \text{derf}, \text{rms_norm}, \text{prms_norm}, \text{flash_norm}\}$$

Las formulaciones más relevantes para este código base son:

9.1.1. LayerNorm (Línea Base)

LayerNorm [4] es el normalizador por defecto; centra y reescala cada token por su media y varianza por token:

$$\mu = \frac{1}{d} \sum_{i=1}^d x_i, \quad \sigma^2 = \frac{1}{d} \sum_{i=1}^d (x_i - \mu)^2, \quad y_i = \gamma_i \frac{x_i - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta_i.$$

9.1.2. RMSNorm

RMSNorm elimina la centralización de la media y solo reescala por la magnitud de la raíz cuadrada media [107]:

$$\text{RMS}(x) = \sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon}, \quad y_i = \gamma_i \frac{x_i}{\text{RMS}(x)}.$$

En comparación con LayerNorm, RMSNorm es computacionalmente más simple (sin resta de la media de características) y se usa a menudo cuando es importante reducir la sobrecarga de normalización (p. ej., Llama, GPT-NeoX). Tiene una escala γ aprendible por dimensión pero sin término de bias.

9.1.3. RMSNorm Parcial (pRMSNorm)

pRMSNorm [107] reduce aún más la sobrecarga estimando el RMS de solo el primer $p\%$ de las dimensiones ocultas:

$$\text{RMS}(x) = \sqrt{\frac{1}{k} \sum_{i=1}^k x_i^2 + \epsilon}, \quad k = \lceil d \cdot p \rceil,$$

explotando el supuesto de que las neuronas dentro de una capa son aproximadamente i.i.d. La misma escala γ se aplica a todas las dimensiones. La razón parcial p se controla mediante el campo de configuración `prms_partial_ratio` (por defecto 6,25 %). El paper reporta que se pueden lograr resultados competitivos con tan solo el 6,25 % de las entradas, aunque puede surgir inestabilidad de gradiente con razones muy pequeñas.

9.1.4. Tanh Dinámico (DyT)

El Tanh Dinámico propone reemplazar la normalización explícita con un mapeo elemento a elemento acotado [113]:

$$\text{DyT}(x) = \tanh(\alpha x)$$

donde α se aprende. La idea central es que la contracción no lineal acotada puede proporcionar un escalado de señal estable sin calcular explícitamente estadísticas de normalización por token.

9.1.5. Erf Dinámico (Derf)

Derf extiende la misma dirección libre de normalización usando un mapeo basado en la función error [13]:

$$\text{Derf}(x) = \text{erf}(\alpha x + s)$$

con escala/desplazamiento aprendibles. Los resultados reportados en el trabajo citado indican un rendimiento superior al de DyT y las líneas base de normalización comunes en múltiples dominios.

9.1.6. FlashNorm (RMSNorm sin pesos)

FlashNorm [32] no es una nueva normalización matemática; es una *reescritura algebraica exacta* del ubicuo par “RMSNorm $\rightarrow$ Lineal” que (i) elimina la escala aprendible por dimensión $\mathbf{g}$ al plegarla en los pesos de la capa lineal subsecuente, y (ii) difiere la reducción escalar RMS a la salida de la multiplicación matricial, de modo que el `matmul` (unidad matricial) y la reducción RMS (unidad vectorial) se ejecuten en paralelo. Tres proposiciones formalizan la reescritura.

Proposición 1 (Plegado de pesos). Dada la activación $\mathbf{a} \in \mathbb{R}^n$, el peso RMSNorm $\mathbf{g} \in \mathbb{R}^n$ y una lineal subsecuente $\mathbf{W} \in \mathbb{R}^{n \times k}$,

$$\mathbf{z} = \text{RMSNorm}(\mathbf{a})\mathbf{W} = \frac{\mathbf{a}}{\text{RMS}(\mathbf{a})}\mathbf{W}^*, \quad W_{i,j}^* = g_i \cdot W_{i,j} \Leftrightarrow \mathbf{W}^* = \text{diag}(\mathbf{g})\mathbf{W}.$$

La escala por dimensión $\mathbf{g}$ se vuelve redundante y se pliega en $\mathbf{W}$ una única vez al cargar el modelo. El módulo autónomo `FlashNorm` de este repositorio aplica esto directamente: *no tiene parámetros aprendibles* (la escala está destinada a ser absorbida por la proyección subsecuente).

Proposición 2 (Normalización diferida). Para una lineal sin bias $\mathbf{W}^*$, la conmutatividad escalar–matricial produce

$$\frac{\mathbf{a}}{\text{RMS}(\mathbf{a})}\mathbf{W}^* = (\mathbf{a}\mathbf{W}^*) \cdot \frac{1}{\text{RMS}(\mathbf{a})}.$$

El `matmul` $\mathbf{a}\mathbf{W}^*$ y la reducción RMS son independientes entre sí; en hardware con unidades matriciales y vectoriales diferenciadas se ejecutan en paralelo, y solo una multiplicación vectorial–escalar los sincroniza. El módulo fusionado `FlashNormLinear` implementa esta reescritura: en la ruta sin bias calcula el `matmul` sobre la entrada *no normalizada* y multiplica el resultado por el RMS recíproco por token. Cuando la lineal tiene bias $\mathbf{c}$, la reescritura deja de ser exacta (Observación 1 del paper): $(\mathbf{a}\mathbf{W}^* + \mathbf{c})/\text{RMS}(\mathbf{a}) \neq \mathbf{a}\mathbf{W}^*/\text{RMS}(\mathbf{a}) + \mathbf{c}$; la capa entonces aplica el escalar a la entrada primero y deja que la lineal añada su bias como de costumbre.

Proposición 3 (Cancelación de RMS). Por la invariancia de escala de RMS, $\text{RMS}(\alpha\mathbf{a}) = \alpha \text{RMS}(\mathbf{a})$. Por tanto, un patrón “RMSNorm $\rightarrow$ Lineal $\rightarrow$ RMSNorm” permite que el *primer* RMSNorm se elimine por completo:

$$\text{RMSNorm}\left(\frac{\mathbf{a}}{\text{RMS}(\mathbf{a})}\mathbf{W}^*\right) = \text{RMSNorm}(\mathbf{a}\mathbf{W}^*).$$

Esta cancelación es relevante para la normalización QKV (Gemma 4) y la normalización latente MLA (DeepSeek-V2, Mistral Small 4); no se aplica automáticamente en este repositorio pero se documenta por completitud.

Composición con RMS parcial. FlashNorm se compone naturalmente con el truco pRMS-Norm (§9, subsección pRMSNorm): cuando `flashnorm_partial_ratio` = $p > 0$, el RMS se estima solo de los primeros $k = \lceil d \cdot p \rceil$ elementos de la entrada, reduciendo aún más el costo de la reducción RMS en la unidad vectorial.

Interacción con BitNet. Plegar un $\mathbf{g}$ de coma flotante en el tensor de pesos ternarios de BitNet $\{-1, 0, +1\}$ [94] destruiría la cuantización, y BitLinear aplica su propio LayerNorm interno antes de la cuantización de activaciones, el cual necesita la entrada normalizada. El módulo fusionado `FlashNormBitLinear` por tanto recurre a la composición secuencial FlashNorm $\rightarrow$ BitLinear: el `matmul` y la reducción RMS aún se ejecutan en paralelo, pero la multiplicación escalar post-`matmul` de la Prop. 2 se sacrifica. El plegado de $\mathbf{g}$ en coma flotante en un tensor de pesos de 1.58 bits se deja a trabajo futuro a nivel kernel.

Pseudocódigo PyTorch.

```

1: Entrada: activación  $\mathbf{a} \in \mathbb{R}^{T \times n}$ , peso RMSNorm  $\mathbf{g} \in \mathbb{R}^n$ , lineal  $\mathbf{W} \in \mathbb{R}^{n \times k}$ , bias  $\mathbf{c} \in \mathbb{R}^k$  o None
2: // Prop. 1: plegado de pesos al cargar
3:  $\mathbf{W}^* \leftarrow \mathbf{g} \odot \mathbf{W}$  ▷ por columnas;  $\mathbf{g}.\text{unsqueeze}(0) * \mathbf{W}$  en PyTorch
4:  $\mathbf{g} \leftarrow \mathbf{1}$  ▷ la norma autónoma ahora es sin pesos
5: // Prop. 2: paso forward con RMS diferida (ruta sin bias)
6:  $\mathbf{b} \leftarrow \mathbf{a} \mathbf{W}^{*\top}$  ▷ unidad matricial / tensor cores
7:  $\text{rms\_inv} \leftarrow \text{rsqrt}(\text{mean}(\mathbf{a}^2) + \epsilon)$  ▷ unidad vectorial, independiente de  $\mathbf{b}$ 
8: if  $\mathbf{c} = \text{None}$  then
9:   retornar  $\mathbf{b} \cdot \text{rms\_inv}$  ▷ una sola multiplicación vectorial-escalar
10: else
11:   // Observación 1: la ruta con bias es secuencial; matmul y RMS aún paralelizan
12:   retornar  $(\mathbf{a} \cdot \text{rms\_inv}) \mathbf{W}^{*\top} + \mathbf{c}$ 
13: end if

```

Latencia reportada (GPU NVIDIA T4). El paper reporta las siguientes aceleraciones sobre la operación *norm-then-project*, con un despacho adaptativo que cae al camino secuencial en el régimen limitada por memoria (decodificación):

Escala	Tokens	Secuencial (ms)	FlashNorm (ms)	Aceleración	Notas
SmolLM2-135M	4096	0.704	0.468	+33,6 %	limitada por cómputo (prefill)
SmolLM2-135M	8192	0.929	0.599	+35,5 %	limitada por cómputo (prefill)
Llama-7B	1024	1.882	1.654	+12,1 %	limitada por cómputo (prefill)
Llama-7B	4096	7.628	6.570	+13,9 %	limitada por cómputo (prefill)

Validación de plegado sin pérdida. El plegado de pesos (Prop. 1) es matemáticamente exacto; el paper verificó salidas bit-idénticas en tres checkpoints abiertos:

Modelo	Precisión	Resultado	
SmolLM2-135M	fp16	diff máxima = 0,0, similitud coseno = 1,0, texto idéntico	La preservación de
Llama-3.2-1B	fp32	generación voraz bit-idéntica	
Llama-3.1-8B	fp32	generación voraz bit-idéntica	

calidad en *lm-evaluation-harness* (wikitext word_ppl, MMLU 5-shot, HellaSwag 0-shot) se mantiene dentro del ruido del benchmark (peor $\Delta = +0,0017$ word_ppl).

9.1.7. Comparación

Método	Fórmula	Estadísticas Necesarias	Notas
LayerNorm	$\gamma_i(x_i - \mu) / \sqrt{\sigma^2 + \epsilon} + \beta_i$	media + varianza	Por defecto; centrado y reescalado completo [4].
RMSNorm	$\gamma_i x_i / \sqrt{\frac{1}{d} \sum_j x_j^2 + \epsilon}$	Solo RMS	Menor sobrecarga; línea base ampliamente usada [107].
pRMSNorm	$\gamma_i x_i / \sqrt{\frac{1}{k} \sum_{j \leq k} x_j^2 + \epsilon}$	RMS parcial	RMS del primer $p\%$ de dims; <code>prms_partial_ratio</code> por defecto 6,25 % [107].
Tanh Dinámico	$\tanh(\alpha x)$	ninguna	Transformación acotada libre de normalización; reemplazo directo [113].
Erf Dinámico	$\text{erf}(\alpha x + s)$	ninguna	Alternativa libre de normalización; mejora sobre DyT [13].

Método	Fórmula	Estadísticas Necesarias	Notas
FlashNorm	$x_i / \sqrt{\frac{1}{d} \sum_j x_j^2 + \epsilon}$ (sin pesos)	Solo RMS	Reescritura exacta de RMSNorm→Lineal: pliega g en W (Prop. 1), difiere el escalar RMS a la salida del matmul (Prop. 2); 12–35 % de reducción de latencia en GPU T4 [32].

9.2. Ruta de Cuantización Ternaria BitNet

Cuando `use_bitnet=true`, las capas BitLinear reemplazan a `nn.Linear` estándar con cuantización ternaria de pesos $(-1, 0, +1)$ siguiendo BitNet [94]. Dado el tensor de pesos W , un escalado práctico es:

$$s = \text{mean}(|W|), \quad \tilde{W} = \text{clip} \left(\text{round} \left(\frac{W}{s} \right), -1, 1 \right).$$

El mapeo empaquetado utiliza dos bits por símbolo de peso para eficiencia de almacenamiento. Esto permite una compresión significativa ($\sim 32\times$ frente a FP32) pero es experimental y puede afectar la calidad del modelo; es más adecuado para el despliegue de inferencia.

La cuantización de activaciones para la ruta INT8 es:

$$q = \text{round} \left(x \cdot \frac{127}{\text{máx}(|x|) + \epsilon} \right), \quad q \in [-128, 127]$$

con des-cuantización $x \approx q/\alpha$. Para N parámetros, las estimaciones de tamaño antes de meta-datos y sobrecarga de empaquetado son:

$$\text{Tamaño FP32} \approx 4N, \quad \text{Tamaño FP16} \approx 2N, \quad \text{Tamaño 1.58-bit} \approx \frac{1,58}{8}N$$

lo que se alinea con objetivos de despliegue ligero [80, 12].

9.3. Enrutamiento de Tokens Mixture-of-Depths (MoD)

Cuando `use_mixture_of_depths=true`, cada bloque del transformer puntúa los tokens con un enrutador ligero. Solo el subconjunto superior de `mixture_of_depths_capacity_ratio` se actualiza; los tokens omitidos pasan sin cambios [114]. Esto asigna más profundidad a los tokens destacados, reduciendo el cómputo por capa.

- 1: **Entrada:** estados ocultos $H \in \mathbb{R}^{n \times d}$, enrutador R , ratio de capacidad ρ
- 2: $\text{puntajes} \leftarrow R(H)$ ▷ puntaje del enrutador por token
- 3: $\mathcal{S} \leftarrow \text{top-k}(\text{puntajes}, k = \lceil \rho \cdot n \rceil)$ ▷ seleccionar subconjunto destacado
- 4: $H_{\text{actualizar}} \leftarrow \text{bloque}(H[\mathcal{S}])$ ▷ aplicar bloque transformer a tokens seleccionados
- 5: $H[\mathcal{S}] \leftarrow H_{\text{actualizar}}$ ▷ escribir de vuelta; los tokens no seleccionados bypassan el bloque
- 6: **Salida:** H ▷ pérdida auxiliar de balance de carga añadida desde `mixture_of_depths_router_aux_loss_weight`

9.3.1. Configuración

- `use_mixture_of_depths`: bool — habilitar enrutamiento MoD de tokens.
- `mixture_of_depths_capacity_ratio`: float en $(0, 1]$ — fracción de tokens actualizados por capa.
- `mixture_of_depths_router_aux_loss_weight`: float ≥ 0 — peso de pérdida auxiliar para regularización del enrutador.

9.4. Memoria Condicional Engram

Engram (`engram_attn`) implementa memoria condicional mediante búsqueda N-gram escalable [15]. Construye tablas de búsqueda basadas en hash para contextos N-gram desde tamaño 2 hasta `engram_max_ngram_size`, con cabezas hash independientes por orden N-gram. Una convolución causal depthwise (`engram_kernel_size`) proporciona contexto de corto alcance antes de la búsqueda N-gram.

- 1: **Entrada:** flujo de tokens $x_{1:n}$, órdenes N-gram $\{2, \dots, N\}$, cabezas hash por orden H
- 2: $h_{\text{conv}} \leftarrow \text{DepthwiseConv1d}(x_{1:n}, k = \text{engram_kernel_size})$ $\triangleright$ contexto de corto alcance
- 3: **for** cada orden N-gram $k \in \{2, \dots, N\}$ **do**
- 4: $\text{ctx}_t^{(k)} \leftarrow x_{t-k+1:t}$ $\triangleright$ ventana de contexto N-gram
- 5: $\text{lookup}_t^{(k)} \leftarrow \text{HashTable}^{(k)}[\text{hash}(\text{ctx}_t^{(k)})]$ $\triangleright$ recuperación por cabeza, H cabezas por orden
- 6: **end for**
- 7: $y_t \leftarrow \sum_k \text{lookup}_t^{(k)} + h_{\text{conv},t}$ $\triangleright$ combinar memorias condicionales
- 8: **Salida:** $y_{1:n}$

9.4.1. Configuración

- `engram_max_ngram_size`: $\text{int} \geq 2$ — orden N-gram más alto (por defecto 3).
- `engram_n_heads_per_ngram`: $\text{int} \geq 1$ — cabezas hash por orden N-gram (por defecto 4).
- `engram_embed_dim_per_head`: $\text{int} \geq 1$ — dimensión de embedding por cabeza hash (por defecto 32).
- `engram_kernel_size`: $\text{int} \geq 1$ — ancho del kernel de conv causal depthwise (por defecto 4).
- `engram_seed`: int — semilla hash para reproducibilidad (por defecto 42).

Tamaño oculto total de Engram = $(\text{max_ngram_size}-1) \times \text{n_heads_per_ngram} \times \text{embed_dim_per_head}$.

9.5. Embeddings Factorizados y Convolución de Embedding

9.5.1. Embeddings Factorizados

Cuando `use_factorized_embedding=true`, la matriz de embedding se factoriza en dos matrices más pequeñas, reduciendo parámetros de $O(V \times H)$ a $O(V \times R + R \times H)$ donde $R = \text{factorized_embedding_dim}$.

- `use_factorized_embedding`: bool — habilitar factorización.
- `factorized_embedding_dim`: $\text{int} \geq 1$ — dimensión intermedia (típico: 64–256).

9.5.2. Convolución de Embedding

Cuando `use_embedding_conv=true`, se aplica una `Conv1d` depthwise sobre el flujo de embeddings antes del primer bloque transformer, con tamaño de kernel `embedding_conv_kernel`. Esto proporciona un filtro ligero de contexto local sobre embeddings de tokens.

9.6. Controles de Estabilidad del Paso de Entrenamiento

El paso de entrenamiento guiado por esquema aplica acumulación de gradientes, recorte de norma global, guardas de explosión post-recorte y reintentos acotados de NaN/Inf. El gradiente acumulado es:

$$g_{\text{acc}} = \frac{1}{K} \sum_{i=1}^K g_i, \quad K = \text{gradient_accumulation_steps}$$

Algorithm 40 Paso de Entrenamiento Guiado por Esquema con Controles de Estabilidad

Require: Flujo de lotes, configuración C

```
1: Inicializar contador de reintentos  $r \leftarrow 0$ 
2: for cada paso del optimizador do
3:   Acumular gradientes para  $K = C.\text{gradient\_accumulation\_steps}$  micro-lotes
4:   Aplicar recorte de norma global con  $\tau = C.\text{grad\_clip\_max\_norm}$ 
5:   if el gradiente post-recorte excede  $C.\text{inf\_post\_clip\_threshold}$  o se detecta NaN/Inf
   then
6:     if  $r < C.\text{max\_nan\_retries}$  then
7:       restaurar estado seguro / saltar paso;  $r \leftarrow r + 1$ 
8:       continue
9:     else
10:      detener entrenamiento con estado de fallo
11:    end if
12:  end if
13:  ejecutar paso del optimizador seleccionado por  $\text{optimizer\_class}$ 
14:  actualizar scheduler (cosine, constant, o linear_warmup_then_constant)
15:  if  $\text{paso mod checkpoint\_every\_n\_steps} = 0$  then
16:    guardar checkpoint rodante y podar a  $\text{max\_rolling\_checkpoints}$ 
17:  end if
18:  actualizar mejores checkpoints hasta  $\text{num\_best\_checkpoints}$ 
19:  emitir CSV + telemetría según  $\text{gradient\_log\_interval}$  y  $\text{telemetry\_log\_interval}$ 
20: end for
```

Algorithm 41 Enrutador de Modo de Inferencia SBERT

Require: modo m , modelo E , entradas X

```
1: if  $m = \text{similarity}$  then
2:   retornar  $\cos(E(x_1), E(x_2))$ 
3: else if  $m = \text{search}$  then
4:   retornar top- $k$  por producto-punto/coseno contra embeddings del corpus
5: else if  $m = \text{cluster}$  then
6:   retornar etiquetas de clustering sobre  $E(X)$ 
7: else
8:   retornar embeddings serializados  $E(X)$ 
9: end if
```

$$g_{\text{clip}} = g_{\text{acc}} \cdot \min\left(1, \frac{\tau}{\|g_{\text{acc}}\|_2 + \epsilon}\right), \quad \tau = \text{grad_clip_max_norm}$$

luego los guardas de desbordamiento usan $\text{inf_post_clip_threshold}$ y lógica de reintentos limitada por max_nan_retries .

9.7. Enrutador de Modo de Inferencia SBERT

El despachador de inferencia SBERT selecciona entre puntuación de similitud, búsqueda sobre corpus, agrupamiento y codificación persistente sobre un único codificador compartido [78]. La similitud coseno y la pérdida de regresión son:

$$\cos(e_1, e_2) = \frac{e_1^\top e_2}{\|e_1\| \|e_2\|}, \quad \mathcal{L}_{\text{cos}} = (\cos(e_1, e_2) - y)^2$$

con $y \in [-1, 1]$ en este pipeline.

10. Funciones de Activación

Este anexo documenta la librería completa de funciones de activación disponibles en el modelo. La librería proporciona **43 funciones de activación feed-forward**: 40 activaciones elementales y 3 variantes de FFN con compuerta. Las activaciones se agrupan en cinco familias, siguiendo la taxonomía de Dubey et al. [23] y la visión analítica de Lederer [51], y se añade la *Rational Activation Function* (RAF) aprendible de Fang et al. [26].

La selección se controla mediante el campo de configuración `ffn_activation` (un enumerado de cadenas) y se despacha en tiempo de ejecución mediante una factoría que replica el patrón de las capas de normalización (Anexo 7).

$$\text{ffn_activation} \in \{\text{silu}, \text{gelu}, \dots, \text{raf}, \text{swiglu}, \text{geglu}, \text{reglu}\}$$

10.1. Familia Clásica / Sigmoid–Tanh (12 activaciones)

La familia clásica comprende activaciones suaves, sin estado, basadas en funciones logísticas y algebraicas [51, 23]. Todas comparten monotonía o casi-monotonía y son continuamente derivables.

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad \text{Rango: } (0, 1), \text{ monótona, suave } [51] \quad (81)$$

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} = 2 \sigma(2x) - 1 \quad \text{Rango: } (-1, 1), \text{ monótona, suave } [51] \quad (82)$$

$$\text{Arctan}(x) = \arctan(x) \quad \text{Rango: } \left(-\frac{\pi}{2}, \frac{\pi}{2}\right), \text{ monótona, suave } [51] \quad (83)$$

$$\text{Softsign}(x) = \frac{x}{1 + |x|} \quad \text{Rango: } (-1, 1), \text{ suave, deriv. una vez en 0 } [51] \quad (84)$$

$$\text{Elliott}(x) = \frac{x}{1 + |x|} \quad \text{Alias de Softsign (notación “elliottsig” del survey) } [51] \quad (85)$$

$$\text{Identity}(x) = x \quad \text{Rango: } (-\infty, \infty), \text{ lineal, } C^\infty \quad \text{(interna)} \quad (86)$$

$$\text{Softplus}(x) = \log(1 + e^x) \quad \text{Rango: } [0, \infty), \text{ suave, } C^\infty \quad (87)$$

$$\text{Mish}(x) = x \tanh(\text{softplus}(x)) = x \tanh(\log(1 + e^x)) \quad \text{Rango: } [\approx -0,31, \infty), \text{ no monótona, suave} \quad (88)$$

$$\text{GELU}(x) = x \Phi(x) = x \cdot \frac{1}{2} \left(1 + \text{erf}\left(\frac{x}{\sqrt{2}}\right) \right) \quad \text{Rango: } (\approx -0,17, \infty), \text{ suave, probabilística} \quad (89)$$

$$\text{GELU-tanh}(x) = \frac{x}{2} \left(1 + \tanh\left(\sqrt{\frac{2}{\pi}}(x + 0,044715 x^3)\right) \right) \quad \text{Aproximación con tanh de GELU (más rápida)} \quad (90)$$

$$\text{ReLU}(x) = \max(0, x) \quad \text{Rango: } [0, \infty), \text{ tramos lineales, no suave en 0} \quad (91)$$

$$\text{SiLU}(x) = x \sigma(x) = \frac{x}{1 + e^{-x}} \quad \text{Rango: } (\approx -0,278, \infty), \text{ no monótona, suave} \quad (92)$$

SiLU (Sigmoid Linear Unit) es la activación por defecto (`ffn_activation=silu`). Cuando $\beta = 1$, el Swish paramétrico se reduce a SiLU. GELU y su aproximación con tanh son el estándar en BERT y GPT-2/3 [40]. Mish [64] es una composición auto-regularizada, no monótona, de Softplus y Tanh, que supera a Swish en varios benchmarks.

10.2. Familia Rectificada (12 activaciones)

La familia de rectificadores extiende ReLU con pendientes aprendibles, variantes acotadas y formas hiperbólicas rectificadas [66, 23].

$$\text{LeakyReLU}(x) = \begin{cases} x & x \geq 0 \\ a x & x < 0 \end{cases}, \quad a = 0,01 \quad \text{Rango: } (-\infty, \infty), \text{ suave} \quad (93)$$

$$\text{ReLU6}(x) = \min(\max(0, x), 6) \quad \text{Rango: } [0, 6], \text{ acotada, amigable} \quad (94)$$

$$\text{HardSwish}(x) = x \cdot \frac{\text{ReLU6}(x + 3)}{6} \quad \text{Rango: } (\approx -1,67, \infty), \text{ aprox. b} \quad (95)$$

$$\text{PReLU}(x) = \max(0, x) + \mathbf{p} \odot \min(0, x) \quad \text{Pendiente por canal aprendible} \quad (96)$$

$$\text{AbsReLU}(x) = \max(0, x) - \max(0, -x) = x \text{ rectificado a rampa de signo} \quad \text{Rango: } (-\infty, \infty), \text{ suave} \quad (97)$$

$$\text{NLReLU}(x) = \beta \log(1 + \max(0, x)) \quad \text{Rango: } [0, \infty), \beta = 1,0, \text{ compresión} \quad (98)$$

$$\text{BReLU}(x) = \min(\max(0, x), t), \quad t = 1, 0$$

Rango: $[0, t]$, rectificador acotado
(99)

$$\text{VReLU}(x) = |x|$$

Rango: $[0, \infty)$, rectificador simétrico
(100)

$$\text{Hexpo}(x) = a \max(0, x) - c \max(0, -x), \quad a=c=1, 0$$

Rectificador asimétrico bilateral
(101)

$$\text{PenalizedTanh}(x) = \max(0, \tanh(x))$$

Rango: $[0, 1)$, tanh rectificado, suave cerca de 0
(102)

$$\text{DisReLU}(x) = \max(0, x - \delta), \quad \delta = 0, 0$$

ReLU desplazado a la derecha
(103)

$$\text{LiSHT}(x) = x \tanh(x)$$

Rango: $[0, \infty)$ (magnitud), no monótona, suave
(104)

PRELU [37] convierte la pendiente negativa en un parámetro aprendible por canal, permitiendo a la red aprender la fuga óptima por característica. **HardSwish** [41] es la aproximación barata de Swish usada en MobileNetV3. **ReLU6** [42] se introdujo en MobileNetV1 por su compatibilidad con cuantización de coma fija.

10.3. Familia Exponencial / ELU (12 activaciones)

La familia exponencial-lineal proporciona saturación negativa suave y variantes auto-normalizadoras [17, 48, 23]. Varios miembros introducen parámetros aprendibles por canal.

$$\text{ELU}(x) = \begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}, \quad \alpha = 1, 0$$

Rango: $(-\alpha, \infty)$ [17]

(105)

$$\text{SELU}(x) = \lambda \text{ELU}_{\alpha'}(x)$$

$\alpha' \approx 1,6733$, $\lambda \approx 1,0507$, [48]

(106)

auto-normalizadora (media 0, var 1)

$$\text{CELU}(x) = \begin{cases} x & x \geq 0 \\ \alpha(e^{x/\alpha} - 1) & x < 0 \end{cases}, \quad \alpha = 1, 0$$

Derivable una vez en 0 para cualquier α [5]

(107)

$$\text{PELU}(x) = \begin{cases} \frac{\alpha}{\beta} x & x \geq 0 \\ \alpha(e^{x/\beta} - 1) & x < 0 \end{cases}$$

α, β aprendibles por canal [91]

(108)

$$\text{MPELU}(x) = \text{ReLU}(x) + \beta \cdot \text{ELU}_{\alpha}(x) \cdot \mathbb{1}_{x < 0}$$

α, β aprendibles por canal [23]

(109)

$$\text{FELU}(x) = \begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases} \quad \alpha \text{ aprendible, acotado a } [0, 1] \quad [23]$$

(110)

$$\text{EELU}(x) = \beta \text{ReLU}(x) + \alpha(e^x - 1) \cdot \mathbb{1}_{x < 0} \quad \alpha, \beta \text{ aprendibles por canal} \quad [23]$$

(111)

$$\text{PDELU}(x) = \begin{cases} x & x \geq 0 \\ \alpha(e^{x/\alpha} - 1) + (1 - \alpha)x & x < 0 \end{cases} \quad \alpha \text{ aprendible, interpola CELU-identidad} \quad [23]$$

(112)

$$\text{PREU}(x) = \beta \text{ReLU}(x) + \alpha(e^x - 1) \cdot \mathbb{1}_{x < 0}^{\leq 0} \quad \alpha, \beta \text{ aprendibles por canal} \quad [23]$$

(113)

$$\text{SoftExp}(x) = \begin{cases} \frac{1}{\alpha}(e^{\alpha x} - 1) + \alpha & \alpha > 0 \\ x & \alpha = 0 \\ -\frac{1}{\alpha} \ln(1 - \alpha(x + \alpha)) & \alpha < 0 \end{cases} \quad \alpha \text{ aprendible; interp. exp/lineal/log} \quad [30]$$

(114)

$$\text{ELiSH}(x) = \begin{cases} x \sigma(x) & x \geq 0 \\ (e^x - 1) \sigma(x) & x < 0 \end{cases} \quad \text{Rama pos. Swish, rama neg. con compuerta ELU} \quad [6]$$

(115)

$$\text{HardELiSH}(x) = \begin{cases} x \cdot \text{hard_sigmoid}(x) & x \geq 0 \\ (e^x - 1) \cdot \text{hard_sigmoid}(x) & x < 0 \end{cases} \quad \text{Variante con sigmoide rígida de ELiSH} \quad [6]$$

(116)

donde $\text{hard_sigmoid}(x) = \text{ReLU6}(x + 3)/6$.

ELU [17] aporta saturación negativa suave. **SELU** [48] induce auto-normalización con $\alpha' \approx 1,6733$, $\lambda \approx 1,0507$ fijos. **CELU** [5] es derivable una vez en 0 para cualquier α (a diferencia de ELU). **PELU** [91] hace ambos α, β aprendibles por canal. Las variantes paramétricas (MPELU, FELU, EELU, PDELU, PREU) generalizan ELU y PReLU introduciendo parámetros aprendibles por canal para las ramas negativa y positiva. **SoftExp** [30] interpola continuamente entre los regímenes logarítmico ($\alpha < 0$), lineal ($\alpha = 0$) y exponencial ($\alpha > 0$). **ELiSH** y **HardELiSH** [6] combinan comportamientos de Swish y ELU mediante una definición a tramos.

10.4. Swish y Activaciones Paramétricas

Swish [76] es una familia parametrizada por una pendiente β :

$$\text{Swish}_\beta(x) = x \sigma(\beta x) = \frac{x}{1 + e^{-\beta x}}.$$

Cuando $\beta = 1$ se obtiene SiLU (el valor por defecto). Con β grande se recupera ReLU; con $\beta \rightarrow 0$ se aproxima a la función lineal $x/2$.

- **Swish** (`swish`): β fijo (por defecto 1.0, configurado mediante `ffn_activation_config.swish_beta`). Sin parámetros aprendibles.
- **SwishTrainable** (`swish_trainable`): β es un parámetro aprendible por canal, inicializado a 1.0. Equivalente a SiLU al inicio, se adapta durante el entrenamiento.

- **Maxout** (`maxout`): calcula k proyecciones lineales y toma el máximo elemento a elemento: $\max_{i=0}^{k-1}(W_i x + b_i)$. Aproximador universal de cualquier función continua con suficientes piezas. El número de parámetros aumenta por un factor k (por defecto $k = 2$, configurado mediante `ffn_activation_config.maxout_pieces`).

Referencias: Swish [76], Maxout [31].

10.5. Funciones de Activación Racionales (RAF)

Siguiendo a Fang et al. [26], una *Rational Activation Function* es una razón aprendible de dos polinomios de bajo grado (un aproximante de Padé):

$$F(x) = \frac{P(x)}{Q(x)} = \frac{\sum_{j=0}^m a_j x^j}{1 + R(x)}$$

donde $\mathbf{a} \in \mathbb{R}^{m+1}$ y $\mathbf{b} \in \mathbb{R}^n$ son *aprendibles*, y el término del denominador $R(x)$ depende de la versión. La configuración por defecto coincide con el artículo: grado $(m, n) = (5, 4)$, versión “A” (segura), inicializada mediante un ajuste por mínimos cuadrados a GELU en $[-3, 3]$.

La implementación admite cinco variantes de denominador:

- **Versión A** (por defecto, “segura”): $Q(x) = 1 + \sum_k |b_k x^{k+1}|$ (valor absoluto por término). Garantiza $Q(x) \geq 1$, sin división por cero.
- **Versión B**: $Q(x) = 1 + |\sum_k b_k x^{k+1}|$ (valor absoluto de la suma completa). También garantiza $Q(x) \geq 1$.
- **Versión C**: $Q(x) = 0,1 + |\sum_k b_k x^k|$ con un suelo de 0,1. Denominador mínimo 0,1.
- **Versión D**: como B, pero inyecta ruido multiplicativo uniforme $U(1 - \varepsilon, 1 + \varepsilon)$ sobre los pesos del denominador *sólo durante el entrenamiento* ($\varepsilon = 0,1$). Efecto de regularización.
- **Versión N** (“no segura”): $Q(x) = 1 + \sum_k b_k x^{k+1}$ sin valor absoluto. Puede tener polos (ceros del denominador); usar con cuidado.

Escalado de entrada RAFT. Dado que un aproximante de Padé es un aproximador universal fiable sólo en un intervalo acotado, el modelo RAFT preprocesa las pre-activaciones de cada token con un escalado min-max por token hacia $[-3, 3]$:

$$\tilde{x} = \frac{x - \min(x)}{\max(x) - \min(x)} \cdot 6 - 3.$$

Se activa con `ffn_activation_config.raf_input_scaling` (por defecto `false`).

Objetivos de inicialización. Los coeficientes racionales pueden inicializarse ajustándose a cualquiera de las siguientes funciones objetivo: `gelu` (por defecto), `relu`, `leaky_relu`, `leaky_relu_0.1`, `sigmoid`, `tanh`, `swish/silu`, o `identity`. El ajuste usa una resolución por mínimos cuadrados sobre 2001 muestras uniformemente espaciadas en $[-3, 3]$.

Congelado. Fijar `raf_trainable=false` congela los parámetros racionales, útil para ajuste eficiente en parámetros. Las RAF congeladas se emparejan típicamente con una tasa de aprendizaje separada (mayor) para el resto de parámetros de la red.

Nota sobre el nombre. El acrónimo RAF significa *Rational Activation Function*, no “Rectified”; corresponde a la razón polinómica aprendible descrita arriba.

10.6. Variantes de FFN con Compuerta: SwiGLU, GEGLU, ReGLU

SwiGLU, GEGLU y ReGLU [81] son unidades feed-forward con compuerta que reemplazan el bloque estándar $\text{Linear} \rightarrow \text{activación} \rightarrow \text{Linear}$. Poseen sus propias proyecciones lineales y, por tanto, se implementan como módulos FFN, *no* como activaciones elementales:

$$\text{GatedFFN}(x) = \text{dropout}\left(W_{\text{down}}\left(\text{act}(x W_{\text{gate}}) \odot (x W_{\text{up}})\right)\right),$$

donde $W_{\text{gate}}, W_{\text{up}} \in \mathbb{R}^{d \times d_{\text{ff}}}$ y $W_{\text{down}} \in \mathbb{R}^{d_{\text{ff}} \times d}$. La función de compuerta es:

- **SwiGLU** (`swiglu`): $\text{act} = \text{SiLU}$ (por defecto, usado en Llama, PaLM).
- **GEGLU** (`geglu`): $\text{act} = \text{GELU}$ (usado en algunas variantes de T5).
- **ReGLU** (`reglu`): $\text{act} = \text{ReLU}$ (la opción más barata).

Cuando `ffn_activation` es uno de `swiglu/geglu/reglu`, la capa feed-forward sustituye los bloques FFN densos y MoE por un FFN con compuerta construido con la misma clase de proyección (BitLinear bajo BitNet). El sesgo está desactivado por defecto.

10.7. Esquema de Configuración

El objeto `ffn_activation_config` agrupa todos los parámetros de las activaciones aprendibles. Es opcional y se ignora para activaciones sin estado.

- `raf_degrees`: $[m, n]$ grados numerador/denominador del Padé (enteros ≥ 1). Por defecto: $[5, 4]$.
- `raf_version`: forma del denominador, uno de A (por defecto), B, C, D, N.
- `raf_approx_func`: objetivo de inicialización. Uno de `gelu` (por defecto), `relu`, `leaky_relu`, `leaky_relu_0.1`, `sigmoid`, `tanh`, `swish`, `silu`, `identity`.
- `raf_trainable`: congela los parámetros racionales cuando es `false`. Por defecto: `true`.
- `raf_input_scaling`: escalado min-max por token a $[-3, 3]$ antes del racional (preprocesamiento RAFT). Por defecto: `false`.
- `prelu_init`: pendiente negativa inicial para PReLU. Por defecto: 0,25.
- `elu_alpha`: constante de saturación de ELU. Por defecto: 1,0.
- `celu_alpha`: constante de saturación de CELU. Por defecto: 1,0.
- `swish_beta`: β fijo para Swish / β inicial para SwishTrainable. Por defecto: 1,0.
- `leaky_relu_slope`: pendiente negativa para LeakyReLU. Por defecto: 0,01.
- `maxout_pieces`: número de piezas lineales k para Maxout (entero ≥ 1). Por defecto: 2.
- Claves adicionales de la familia ELU paramétrica: `pelu_alpha`, `mpelu_alpha`, `mpelu_beta`, `felu_alpha`, `eelu_alpha`, `eelu_beta`, `pdelu_alpha`, `preu_alpha`, `preu_beta`, `softexp_alpha`. Todas por defecto 1,0 (excepto `softexp_alpha` que por defecto es 0,0).

10.8. Guía de Selección

El siguiente árbol de decisión ayuda a elegir la activación:

- **Por defecto seguro** → `silu` (SiLU/Swish₁, usado en Llama, PaLM).
- **Estabilidad clásica** → `gelu` o `relu`.
- **No monótona suave** → `mish` o `swish`.
- **Amigable para móvil** → `hardswish` o `relu6`.
- **Forma por tarea aprendible** → `raf`, `prelu`, `swish_trainable`, o `maxout`.
- **Redes auto-normalizadoras** → `selu` (con AlphaDropout).
- **FFN con compuerta (proyecciones propias)** → `swiglu`, `geglu`, o `reglu`.

Con cuantización BitNet, `silu` puede ser más robusta que las activaciones suaves que dependen de un cálculo de gradiente preciso. Las activaciones aprendibles (`raf`, `prelu`, `swish_trainable`) añaden parámetros pero pueden adaptarse a la distribución de la tarea.

11. Hyper-Connexiones Restringidas por Variedad (mHC)

Este anexo documenta la integración de las *Hyper-Connexiones Restringidas por Variedad* (*Manifold-Constrained Hyper-Connections*, mHC) [98], un marco de conexiones residuales que reemplaza el residual de identidad estándar por un flujo residual de n streams cuya matriz de mezcla de flujo se restringe al politopo de Birkhoff. El cuerpo principal difiere a este anexo la formulación matemática, los detalles de implementación y los resultados reportados; las claves bibliográficas citadas aquí se resuelven contra `docs/bibliography/`.

11.1. Motivación: la Propiedad de Mapeo de Identidad

La conexión residual estándar [38] propaga señales a través de la profundidad sin modificación: con $x_l \in \mathbb{R}^C$ y una función de capa F ,

$$x_{l+1} = x_l + F(x_l, W_l),$$

de modo que, recursivamente, $x_L = x_l + \sum_{i=l}^{L-1} F(x_i, W_i)$. El término directo x_l (el *mapeo de identidad*) permite que la información fluya de capas superficiales a profundas sin cambios, lo que He et al. [38] identificaron como clave para el entrenamiento estable de redes muy profundas.

Las *Hyper-Connections* (HC) [98] ensanchan el flujo residual por un factor de expansión n : el flujo pasa a ser $x_l \in \mathbb{R}^{n \times C}$ mientras que la función interna F de cada capa sigue operando en dimensión C . Tres mapeos lineales aprendibles gobiernan el flujo en cada capa:

- $H_l^{\text{pre}} \in \mathbb{R}^{1 \times n}$ agrega el flujo de dimensión nC a la entrada de capa de dimensión C ;
- $H_l^{\text{post}} \in \mathbb{R}^{1 \times n}$ proyecta la salida de la capa de vuelta al flujo;
- $H_l^{\text{res}} \in \mathbb{R}^{n \times n}$ mezcla características *dentro* del flujo residual.

La propagación de una sola capa es

$$x_{l+1} = H_l^{\text{res}} x_l + (H_l^{\text{post}})^\top F(H_l^{\text{pre}} x_l, W_l),$$

y, recursivamente, la señal profunda-a-superficial está gobernada por el mapeo compuesto $\prod_{i=L-1}^l H_{i+1}^{\text{res}}$. Debido a que H_l^{res} no está restringida en HC, este compuesto se desvía de la identidad, la norma

del flujo no se conserva y la señal hacia adelante/hacia atrás puede amplificarse o atenuarse sin límite. En un modelo MoE de 27B parámetros los autores reportan magnitudes de ganancia compuesta con picos cercanos a 3000 (frente a 1 para la identidad), correlacionadas con picos de norma de gradiente y una subida inesperada de pérdida alrededor del paso 12k. HC además multiplica el costo de acceso a memoria por aproximadamente n (el “muro de memoria”).

11.2. Formulación

Sea $x_l \in \mathbb{R}^{n \times C}$ el flujo en la capa l . Los coeficientes se calculan a partir del flujo aplanado $\tilde{x}_l = \text{vec}(x_l) \in \mathbb{R}^{1 \times nC}$:

$$\tilde{H}_l = \frac{1}{r_l} \left(\alpha \odot (\tilde{x}_l \varphi_l) \right) + b_l, \quad r_l = \frac{\|\tilde{x}_l\|_2}{\sqrt{nC}},$$

donde $\varphi_l \in \mathbb{R}^{nC \times (n^2+2n)}$ es una proyección lineal aprendida, $b_l \in \mathbb{R}^{1 \times (n^2+2n)}$ un sesgo aprendido y $\alpha^{\text{pre}}, \alpha^{\text{post}}, \alpha^{\text{res}} \in \mathbb{R}$ son escalares de compuerta aprendibles inicializados a un valor pequeño (0,01 en el paper y en este código base). El escalado por $1/r_l$ es matemáticamente equivalente a RMSNorm sobre el flujo aplanado, con la escala por dimensión absorbida en φ_l . Los tres bloques de coeficientes son entonces:

$$H_l^{\text{pre}} = \sigma(\tilde{H}_l^{\text{pre}}), \quad H_l^{\text{post}} = 2 \sigma(\tilde{H}_l^{\text{post}}), \quad H_l^{\text{res}} = \text{SK}(\exp(\tilde{H}_l^{\text{res}})),$$

donde σ es la sigmoide logística (que impone no negatividad y evita la cancelación de señal por coeficientes de signo mixto) y $\text{SK}(\cdot)$ es la proyección Sinkhorn–Knopp sobre el conjunto de matrices doblemente estocásticas

$$\mathcal{M}^{\text{res}} = \{ H \in \mathbb{R}^{n \times n} : H \geq 0, \quad H \mathbf{1}_n = \mathbf{1}_n, \quad \mathbf{1}_n^\top H = \mathbf{1}_n^\top \},$$

es decir, el politopo de Birkhoff (la envolvente convexa de las matrices de permutación). Partiendo de $M^{(0)} = \exp(\tilde{H}_l^{\text{res}})$, la proyección alterna normalizaciones de filas y columnas,

$$M^{(t)} = T_c(T_r(M^{(t-1)})),$$

para $t = 1, \dots, t_{\text{máx}}$ rondas ($t_{\text{máx}} = 20$ por defecto tanto en el paper como en este código base). Finalmente, la entrada de capa y el flujo actualizado son

$$F_l^{\text{pre}} = H_l^{\text{pre}} x_l \in \mathbb{R}^{1 \times C}, \quad x_{l+1} = H_l^{\text{res}} x_l + (H_l^{\text{post}})^\top \otimes F(F_l^{\text{pre}}, W_l).$$

11.3. Propiedades de la Restricción de Variedad

Restringir H_l^{res} al politopo de Birkhoff restaura el comportamiento de conservación del residual de identidad y garantiza tres propiedades [98]:

1. **Preservación de norma:** la norma espectral satisface $\|H_l^{\text{res}}\|_2 \leq 1$ (mapeo no expansivo), mitigando la explosión de gradientes.
2. **Cerradura composicional:** las matrices doblemente estocásticas son cerradas bajo multiplicación, por lo que el compuesto $\prod_i H_i^{\text{res}}$ sigue siendo doblemente estocástico a profundidad arbitraria, preservando la propiedad de mapeo de identidad entre *cualesquiera* dos profundidades.
3. **Interpretación geométrica:** como el politopo de Birkhoff es la envolvente convexa de las matrices de permutación, $H_l^{\text{res}} x$ es una combinación convexa de permutaciones de características, es decir, un mecanismo monótono de mezcla de información entre streams.

Cuando $n = 1$ la condición doblemente estocástica degenera al escalar 1, recuperando el mapeo de identidad exacto. Con $t_{\text{máx}}$ finito la proyección es aproximada, y la ganancia compuesta hacia atrás se desvía de 1 pero permanece acotada (alrededor de 1,6 en las ejecuciones de 27B del paper, una reducción de 3 órdenes de magnitud frente a los ≈ 3000 de HC).

11.4. Implementación en Frankenstein Transformer

mHC es un reemplazo opcional de la conexión residual estándar, controlado por el sub-objeto `model.mhc` (esquema jerárquico) o por las claves planas `use_mhc`, con `additionalProperties: false` a nivel de sub-objeto:

- `enabled` (`use_mhc`, bool, por defecto `false`): reemplazar el residual estándar por el flujo residual de n streams.
- `expansion_rate` (`mhc_expansion_rate`, int ≥ 1 , por defecto 4): factor de expansión del flujo n ; el flujo pasa a ser $n \times \text{hidden_size}$ mientras los internos de la capa permanecen en `hidden_size`. 1 recupera el mapeo de identidad.
- `sinkhorn_iters` (`mhc_sinkhorn_iters`, int ≥ 1 , por defecto 20): rondas de normalización Sinkhorn–Knopp $t_{\text{máx}}$.
- `gating_init` (`mhc_gating_init`, float > 0 , por defecto 0,01): valor inicial de los escalares de compuerta α .
- `checkpoint` (`mhc_checkpoint`, bool, por defecto `false`): gradient checkpointing en capas mHC, intercambiando cómputo por memoria para mitigar el aumento de $\sim n \times$ en la memoria de activaciones del flujo residual de n streams.
- `full_prec_under_bitnet` (`mhc_full_prec_under_bitnet`, bool, por defecto `true`): mantener la proyección de coeficientes φ_l como `nn.Linear` de precisión completa incluso cuando `use_bitnet` es `true`, evitando el ruido de cuantización ternaria en los pequeños coeficientes mHC; cuando es `false` (y BitNet está activado), φ_l usa `BitLinear`.

El módulo vive en `src/model/mhc.py`:

- `SinkhornKnoppFunction` (`torch.autograd.Function`): el pase hacia adelante aplica las normalizaciones alternadas de filas y columnas de $\exp(\cdot)$; el pase hacia atrás recomputa la iteración completa bajo `torch.enable_grad` y diferencia a través de ella, obteniendo el producto Jacobiano-vector exacto (la estrategia de recomputación en chip descrita en el paper).
- `ManifoldHyperConnections` (`nn.Module`): contiene φ_l (`proj`), b_l (`bias`) y los tres escalares de compuerta `alpha_pre`, `alpha_post`, `alpha_res`; expone `fpre` (proyectar el flujo a la entrada de capa), `recombine` (actualizar el flujo con la salida de la capa) y `mappings` (calcular $H^{\text{pre}}, H^{\text{post}}, H^{\text{res}}$).

Cableado en `src/model/frankenstein_model.py`:

- `HybridLayer` gana módulos opcionales `mhc_attn` y `mhc_ffn` (un módulo mHC por función de capa); la ruta `_forward_dense_mhc` ejecuta atención y FFN como funciones de capa sobre el flujo compartido (B, S, n, C) .
- `FrankensteinTransformer` expande el embedding de dimensión C a (B, S, n, C) al entrar mediante `mhc_in_proj` y lo colapsa de vuelta a C mediante `mhc_out_proj` antes de la cabeza.
- Los parámetros mHC se enrutan al grupo de parámetros `other` del optimizador.
- mHC es **incompatible con `use_mixture_of_depths`**: el enrutamiento MoD de tokens opera sobre un flujo C -dimensional único, en conflicto con el flujo residual de n streams; se lanza un `ValueError` si ambos están habilitados.

Ejemplo de configuración: `configs/examples/es_arch_mhc_adamw.yaml`.

11.5. Resultados Reportados

El paper evalúa mHC (y HC) con $n = 4$, $t_{\text{máx}} = 20$ e inicialización de α en 0,01 sobre modelos MoE estilo DeepSeek-V3 (atención MLA, RoPE, RMSNorm, balance de carga sin pérdida auxiliar) de 3B a 27B parámetros [98]:

- **Estabilidad:** mHC elimina las subidas de pérdida de HC (p. ej., cerca del paso 12k en el modelo de 27B) y mantiene acotada la ganancia residual compuesta ($\approx 1,6$ frente a picos de HC de ≈ 3000).
- **Calidad:** en el modelo de 27B, mHC mejora la pérdida final de entrenamiento en 0,021 sobre la línea base, supera a la línea base en los 8 benchmarks de evaluación (BBH, DROP, GSM8K, HellaSwag, MATH, MMLU, PIQA, TriviaQA) y a HC en 7 de 8, con las mayores ganancias en tareas de razonamiento (+2,1 BBH, +2,3 DROP sobre HC).
- **Escalado:** la mejora relativa de pérdida sobre la línea base se mantiene a través de escalas de cómputo (3B $\rightarrow$ 9B $\rightarrow$ 27B) y a través de 1T tokens de escalado de datos.
- **Sobrecarga:** con kernels fusionados (TileLang), cálculo de coeficientes en precisión mixta, recomputación selectiva y solapamiento de comunicación DualPipe, mHC añade solo 6,7 % de tiempo adicional de entrenamiento con $n = 4$ en el modelo de 27B.

11.6. Hyperloop: Hiperconexiones a Nivel de Bucle en Transformers en Bucle

El *Hyperloop Transformer* [106] combina Transformers en bucle — que reutilizan los pesos de capa a través de la profundidad — con hiperconexiones *a nivel de bucle*, orientándose a la eficiencia de parámetros en lugar de a la profundidad bruta. La pila de capas se particiona en *ciclo medio*: un bloque inicial (se ejecuta una vez), un bloque intermedio en bucle y un bloque final (se ejecuta una vez); el bloque intermedio en bucle se envuelve en hiperconexiones aplicadas solo tras cada iteración de bucle. Con $Y_t^{(l)} \in \mathbb{R}^{n \times C}$ el flujo matricial en el bucle l , $z_t^{(l)} = \text{RMSNorm}(\text{flatten}(Y_t^{(l)}))$, y parámetros por bucle $\{W_l^\tau, b_l^\tau, \alpha_l^\tau\}$ para $\tau \in \{\text{pre}, \text{post}, \text{res}\}$ más un embedding de posición de bucle $e_l \in \mathbb{R}^C$, la recurrencia es

$$y_t^{(l+1)} = H_l^{\text{res}} y_t^{(l)} + H_l^{\text{post}} \otimes (F(H_l^{\text{pre}} y_t^{(l)} + e_l), \quad (117)$$

con los coeficientes dependientes de datos

$$\begin{aligned} H_l^{\text{pre}} &= \sigma(\alpha_l^{\text{pre}}(W_l^{\text{pre}} z_t^{(l)} + b_l^{\text{pre}})), & H_l^{\text{post}} &= 2\sigma(\alpha_l^{\text{post}}(W_l^{\text{post}} z_t^{(l)} + b_l^{\text{post}})), \\ H_l^{\text{res}} &= \text{diag}(\sigma(\alpha_l^{\text{res}}(W_l^{\text{res}} z_t^{(l)} + b_l^{\text{res}}))) & W_l^{\text{res}} &\in \mathbb{R}^{n \times nC} \end{aligned}$$

(el H^{res} diagonal sustituye el $\text{sinkhorn}(\cdot)$ de mHC sobre una proyección densa $n^2 \times nC$ por una sigmoide sobre una compuerta diagonal — la ablación de la Tabla 6 del paper muestra que esto es a la vez más barato y más preciso: 14.40 de perplejidad frente a 14.59 Sinkhorn y 14.61 identity).

Cuatro propiedades distinguen el cableado Hyperloop del mHC por subcapa (§11): (1) las hiperconexiones se disparan una vez por *bucle*, no tras cada subcapa — también la ubicación más eficaz en la ablación de la Tabla 5 del paper; (2) el flujo se crea *copiando* la salida del bloque inicial n veces y se colapsa *promediando* los streams antes del bloque final, reemplazando las proyecciones aprendidas de mHC; (3) los parámetros son *por bucle*, relajando la compartición estricta de pesos de los Transformers en bucle ordinarios — el análisis de similitud de representaciones del paper (Tabla 8) muestra que las representaciones de las capas en bucle se desvían más entre bucles, lo que identifica como la fuente de las ganancias de calidad; y (4) H^{res} usa por defecto la parametrización sigmoide diagonal.

La integración en Frankenstein se controla con el booleano `mhc.hyperloop` (plano `mhc.hyperloop`; requiere `mhc.enabled` y `dims.num_loops ≥ 2`), con tres claves adicionales:

- `hyperloop_begin_layers` / `hyperloop_end_layers` (int ≥ 0 , por defecto 0): tamaños de los bloques inicial/final, que se ejecutan exactamente una vez. El paper asigna $\sim 25\%$ de los parámetros a cada uno y 50% al bloque intermedio (profundidad desenrollada = inicial + intermedio $\times$ bucles + final; p. ej. $2L \rightarrow 4L(\times 3) \rightarrow 2L$ en 16 capas). 0/0 recorre la pila completa.
- `hyperloop_res_parameterization` (enum, por defecto `diagonal`): `diagonal`, `sinkhorn` (mezcla doblemente estocástica completa estilo mHC, reutilizando `SinkhornKnoppFunction`) o `identity`.

Implementación: `src/model/hyperloop.py` aloja `HyperloopConnections` con `projs` / `biases` / `alphas_` / `loop_pos_embs` (e_l , inicializados a cero para que al inicio la actualización se reduzca a la recurrencia del Transformer en bucle simple). `FrankensteinEncoder` (y `FrankensteinViT`) lo construyen *en lugar de* la pareja `mhc_in_proj/mhc_out_proj`; el pase hacia adelante ejecuta inicial $\rightarrow$ copia $\rightarrow$ lectura/capa/actualización por bucle $\rightarrow$ promedio $\rightarrow$ final. `HybridLayer` desactiva sus módulos por capa `mhc_attn/mhc_ffn` bajo Hyperloop, de modo que las capas del bloque intermedio ejecutan la ruta C -dimensional estándar — lo cual **restaura la compatibilidad con Mixture-of-Depths** (el mHC por capa prohíbe MoD). Hyperloop es incompatible con los residuales `AttnRes` (`residuals.type full_attn` / `block_attn`), que asumen un flujo de n streams por capa lógica. El presupuesto de parámetros por bucle es $3n^2C + 3n + 3 + C$ (diagonal): para el modelo de 136M del paper ($C = 1024$, $n = 4$, 3 bucles) solo $\approx 150K$ parámetros más allá del Transformer en bucle simple.

Ejemplo de configuración: `configs/examples/hyperloop_mhc_adamw.yaml`.

Resultados reportados (arXiv:2604.21254)

Entrenado en FineWeb-Edu con $n = 4$ streams y 3 bucles (reparto de parámetros $25\%/50\%/25\%$), contra líneas base Transformer y mHC con profundidad equiparada:

- **Eficiencia de parámetros:** a escala equiparada de 240M/1B/2B, Hyperloop usa $\approx 50\%$ menos parámetros (136M/580M/991M) e iguala o supera las líneas base en perplejidad (14.40 vs 14.65 a escala 240M; 9.65 vs 10.19 a 1B; 8.49 vs 8.60 a 2B).
- **Cuantización:** la perplejidad INT4 (GPTQ) se degrada menos que en el modelo en bucle simple (14.68 vs 15.18 a escala 240M), por lo que el ahorro de parámetros sobrevive a la compresión post-entrenamiento.
- **Sobrecarga:** la colocación a nivel de bucle más el H^{res} diagonal mantienen el throughput de entrenamiento dentro de $\approx 5\%$ del Transformer en bucle simple en PyTorch sin optimizar (el mHC por capa pierde $\approx 33\%$ sin kernels fusionados).
- **Ablaciones:** la colocación por bucle supera a la por capa (Tabla 5); el H^{res} diagonal supera a Sinkhorn e identity (Tabla 6); el número de streams n muestra rendimientos decrecientes más allá de 4 (Tabla 4); LoRA por bucle (Transformers recursivos relajados) ayuda mucho menos por parámetro que la relajación por hiperconexiones (Tabla 7).

12. Residuales de Atención (AttnRes)

Este anexo documenta la integración de los *Residuales de Atención* (AttnRes) [89], una generalización de la conexión residual que reemplaza la suma residual de coeficiente unitario fijo por *atención softmax aprendida sobre la profundidad*. El cuerpo principal delega a este

anexo la formulación matemática, las cuatro estrategias disponibles (estándar, sin residual, Full AttnRes, Block AttnRes), el cableado de implementación, la integración con mHC y Mixture-of-Depths, y los resultados reportados. Las claves de bibliografía citadas aquí se resuelven contra `docs/bibliography/`.

12.1. Motivación: De una Suma Fija a Atención sobre la Profundidad

La conexión residual estándar [38] propaga señales a través de la profundidad sin modificar: con $x_l \in \mathbb{R}^C$ y una función de capa F ,

$$x_{l+1} = x_l + F(x_l, W_l),$$

de modo que, recursivamente, $x_L = x_l + \sum_{i=l}^{L-1} F(x_i, W_i)$. El término identidad x_l (el *mapeo de identidad*) permite que la información fluya de capas superficiales a profundas sin cambios, lo que He et al. [38] identificaron como clave para el entrenamiento estable de redes muy profundas. Las redes Highway [85] generalizan esto con compuertas elemento-a-elemento aprendidas $\mathbf{g}_l \in [0, 1]^C$,

$$x_{l+1} = (1 - \mathbf{g}_l) \odot x_l + \mathbf{g}_l \odot F(x_l, W_l),$$

que interpolan entre la ruta de identidad y la ruta de transformación con pesos dependientes de la entrada.

Los *Residuales de Atención* [89] dan el siguiente paso: en lugar de ponderar un único estado comprimido x_l , la capa l atiende sobre todas las salidas de capas anteriores. Sea $v_0 = h_1$ (el embedding de tokens) y $v_i = F(x_i, W_i)$ para $i \geq 1$. AttnRes computa, para cada capa l ,

$$q_l = w_l, \quad k_i = \text{RMSNorm}(v_i), \quad \alpha_{i \rightarrow l} = \text{softmax}_i(q_l^\top k_i), \quad x_{l+1} = \sum_{i=0}^l \alpha_{i \rightarrow l} v_i,$$

donde $w_l \in \mathbb{R}^C$ es un pseudo-query aprendido por capa, *inicializado a cero* según el paper. Con la inicialización a cero, el softmax es uniforme, por lo que AttnRes degenera a un promedio equiponderado de todas las salidas previas — igualando el residual estándar en el paso cero y evitando volatilidad de entrenamiento. RMSNorm sobre las keys evita que las capas con magnitudes naturalmente grandes dominen el softmax (ablación en el paper: § 5.3).

12.2. Cuatro Estrategias

El campo de esquema `model.residuals.type` selecciona una de las cuatro estrategias, cada una implementada como un módulo separado bajo `src/model/residuals/`.

12.2.1. Residual Estándar ("standard")

La estrategia por defecto, retrocompatible:

$$x_{l+1} = x_l + F(x_l, W_l).$$

Sin estado, sin parámetros extra, sin cómputo extra. Implementada como un pass-through no-op en `StandardResidual` que delega el merge a `HybridLayer`.

12.2.2. Sin Residual ("none", experimental)

Elimina la conexión skip por completo:

$$x_{l+1} = F(x_l, W_l).$$

Sin estado, sin parámetros extra. Útil solo como sonda de ablación; el término identidad es crítico para arquitecturas profundas (paper § 2.1) y el entrenamiento suele ser inestable sin él. Implementado como `NoResidual`.

12.2.3. Residuales de Atención Completa ("full_attn", paper § 3.1)

Cada capa atiende sobre *todas* las salidas de capas anteriores:

$$x_{l+1} = \sum_{i=0}^l \alpha_{i \rightarrow l} v_i, \quad \alpha_{i \rightarrow l} = \text{softmax}_i(w_l^\top \text{RMSNorm}(v_i)).$$

Añade $L \cdot C$ parámetros (L = profundidad lógica = `num_layers` $\times$ `num_loops`, C = `hidden_size`), un vector de query por capa. La memoria y el cómputo crecen como $O(Ld)$ por token; a profundidad típica ($L < 1000$) esto es insignificante. Implementado como `FullAttentionResidual`; soporta `attnres_gradient_checkpoint` para envolver la atención en `torch.utils.checkpoint` en ejecuciones con restricciones de memoria.

12.2.4. Residuales de Atención por Bloques ("block_attn", paper § 3.2)

Particiona las L capas lógicas en N bloques de $S = \lceil L/N \rceil$ capas cada uno. Dentro de un bloque las salidas de capa se acumulan como suma parcial estándar b_n^i ; a través de los bloques la atención se aplica sobre las N representaciones de bloque completas y la suma parcial en curso. Para la capa l en el bloque n ,

$$x_{l+1} = \sum_{m=0}^n \alpha_{m \rightarrow l} v_m, \quad \alpha_{m \rightarrow l} = \text{softmax}_m(w_l^\top \text{RMSNorm}(v_m)),$$

con $v_m = b_m$ para $m < n$ y $v_n = b_n^i$ (la suma parcial intra-bloque actual). N interpola entre Full AttnRes ($N = L$, un bloque por capa) y residuales estándar ($N = 1$, el embedding aislado como b_0). El sweet spot empírico del paper es $N \approx 8$; este código base usa $N = 8$ por defecto y valida $N \leq L$. Implementado como `BlockAttentionResidual`, que sigue el Algoritmo 1 del paper (cómputo en dos fases con fusión online-softmax).

12.3. Implementación en Frankenstein Transformer

El paquete `src/model/residuals/` aloja una clase por estrategia (`StandardResidual`, `NoResidual`, `FullAttentionResidual`, `BlockAttentionResidual`) más un `ResidualBase` abstracto que define los hooks del ciclo de vida `set_streams`, `register_state`, `reset_state`, `forward` y `finalize`. La factoría `build_residual(config)` en `src/model/residuals/factory.py` selecciona la clase correcta desde `FrankensteinModelConfig`.

Cableado en `src/model/frankenstein_encoder.py`:

- `FrankensteinEncoder` posee el módulo `ResidualBase` como `self.residual`; la factoría se invoca una vez en `__init__`.
- Antes del bucle de profundidad en loop, el encoder llama a `reset_state` y, para variantes `AttnRes`, a `set_embedding(x)` para que la atención sobre la profundidad conozca la fuente $v_0 = h_1$.
- Tras cada llamada a `HybridLayer`, si `self.residual.is_attn_res` es true, el encoder aplica `x = self.residual(layer_idx, x)` para sobrescribir el flujo con la agregación atendida. Para estrategias sin estado (`standard`, `none`) este paso se omite y `HybridLayer` continúa aplicando su propio merge residual internamente.

Cableado en `src/model/hybrid_layer.py`:

- `HybridLayer` lee `residual_type` de la configuración y despacha el merge residual según corresponda. Para `standard` el merge es el original `x = residual + mixer(norm(x))`; para `none` el skip se elimina (`x = mixer(norm(x))`); para las variantes `AttnRes` la capa realiza el merge estándar internamente porque la atención sobre la profundidad se aplica externamente por el encoder.

- `_forward_dense_mhc` (la ruta mHC) no se ve afectada porque mHC tiene su propia residual de expansión de flujos; combinar AttnRes con mHC lo maneja el campo `mhc_stream_mode` del módulo residual.

Esquema (jerárquico, con los renombres a claves planas entre paréntesis) y valores por defecto:

- `model.residuals.type` (`residual_type`, enum [`standard`, `none`, `full_attn`, `block_attn`], default `standard`): selecciona la estrategia.
- `model.residuals.full_attn.init_query_zero` (`full_attn_init_query_zero`, bool, default `true`): inicializa a cero los vectores de query por capa w_l .
- `model.residuals.full_attn.use_rmsnorm_keys` (`full_attn_use_rmsnorm_keys`, bool, default `true`): aplica RMSNorm sobre las keys antes del producto punto.
- `model.residuals.block_attn.num_blocks` (`block_attn_num_blocks`, int ≥ 1 , default 8): número de representaciones de bloque N ; validado $N \leq L$.
- `model.residuals.block_attn.init_query_zero` (`block_attn_init_query_zero`, bool, default `true`): inicializa a cero los vectores de query por capa.
- `model.residuals.block_attn.use_rmsnorm_keys` (`block_attn_use_rmsnorm_keys`, bool, default `true`): RMSNorm sobre las keys.
- `model.residuals.mhc_stream_mode` (`attnres_mhc_stream_mode`, enum [`independent`, `joint`], default `independent`): cómo AttnRes interactúa con el residual de n streams de mHC.
- `model.residuals.gradient_checkpoint` (`attnres_gradient_checkpoint`, bool, default `false`): envuelve la atención AttnRes en gradient checkpointing.

12.4. Integración con mHC y Mixture-of-Depths

La estrategia residual es *ortogonal* a mHC y Mixture-of-Depths (MoD): todas las combinaciones están soportadas. Los modos de interacción son:

mHC $\times$ AttnRes (`mhc_stream_mode`). Cuando `use_mhc=true` y el residual es `full_attn` o `block_attn`, la atención sobre la profundidad se aplica *por stream* ("`independent`") o sobre la proyección *aplanada* nC -dimensional ("`joint`"). El modo `independent` ejecuta n atenciones en paralelo, una por stream — coincidiendo con el encuadre del paper donde cada stream es una "vista" paralela del residual. El modo `joint` trata los n streams como un único residual grueso, más expresivo pero más hambriento de parámetros. Las proyecciones de coeficientes de mHC (φ_l , b_l , compuertas α) no se ven afectadas; AttnRes añade sus propios parámetros encima.

Mixture-of-Depths $\times$ AttnRes. MoD opera *dentro* de una capa (selecciona qué tokens reciben la actualización completa de capa) y es ortogonal a la elección residual. Cuando `use_mixture_of_depths=true` junto con un residual AttnRes, solo los tokens seleccionados por MoD contribuyen al buffer de salidas de capa (Full AttnRes) o a la suma parcial intra-bloque (Block AttnRes); el resto pasa sin cambios y se re-ensambla mediante la lógica existente de MoD. MoD es mutuamente excluyente con mHC (se lanza un `ValueError` en `HybridLayer._init__` si ambos están habilitados); las combinaciones correspondientes son (`no_mHC`, `MoD`, `AttnRes`), (`mHC`, `no_MoD`, `AttnRes`), o (`mHC`, `no_MoD`, `no_AttnRes`).

12.5. Resultados Reportados

El paper [89] valida AttnRes mediante leyes de escalado, ablaciones y una extensión Kimi Linear de 48B parámetros:

- **Leyes de escalado:** tanto Full como Block AttnRes superan consistentemente al baseline PreNorm a través de cinco tamaños de modelo. A 5.6 PFLOP/s-días, Block AttnRes alcanza pérdida 1,692 versus 1,714 del baseline — equivalente a una ventaja de cómputo de $1,25\times$. La brecha entre Full y Block AttnRes se reduce con la escala (Full 1,737 vs. Block 1,746 en el modelo de 16 capas).
- **Ablaciones:** la atención softmax dependiente de la entrada (1,737) supera al mezclado escalar independiente de la entrada (1,749) y a la atención sigmoid (1,741). RMSNorm sobre las keys es esencial (Full 1,737 vs. 1,743 sin ella; Block 1,746 vs. 1,750). La agregación multi-cabeza sobre la profundidad ($H = 16$) perjudica a Block AttnRes (1,752 vs. 1,746), indicando que la mezcla óptima es en gran medida uniforme a través de los canales. La atención de ventana deslizante sobre las últimas $W = 8$ capas se queda corta frente a Block AttnRes (1,764 vs. 1,746).
- **Extensión Kimi Linear:** un modelo Kimi Linear de 48B parámetros (3B activados) con Block AttnRes ($N \approx 9$, $S = 6$) pre-entrenado sobre 1.4T tokens mejora al baseline en los 14 benchmarks downstream (MMLU-Pro, GPQA-Diamond, BBH, HellaSwag, TriviaQA, GSM8K, MGSM, Math, CMATH, HumanEval, MBPP, CMMLU, C-Eval, ARC-C). Las mayores ganancias son en razonamiento multi-paso (GPQA-Diamond +7,5, Minerva Math +3,6) y generación de código (HumanEval +3,1). El análisis de la dinámica de entrenamiento muestra que AttnRes mitiga la dilución PreNorm: las magnitudes del estado oculto permanecen acotadas a lo largo de la profundidad y las normas del gradiente se distribuyen más uniformemente entre capas.
- **Sobrecosto:** el sobrecosto de entrenamiento es marginal cuando no se habilita paralelismo de pipeline; con paralelismo de pipeline Block AttnRes añade $< 4\%$ de sobrecosto end-to-end (caching cross-stage elimina transferencias redundantes) y $< 2\%$ de sobrecosto de latencia de inferencia (cómputo en dos fases con fusión online-softmax).

Configuraciones de ejemplo: `configs/examples/full_attn_res_adamw.yaml`, `configs/examples/block_attn_res_adamw.yaml`, `configs/examples/mhc_full_attn_res_adamw.yaml`.

13. Vision Transformer: Predicción de Parches, Clasificación y Segmentación

Este anexo documenta la clase de modelo `frankenstein_vit`, una implementación del Vision Transformer (ViT) [22] que reutiliza la pila de `HybridLayer` agnóstica de modalidad del encoder. Soporta tres tareas: predicción autosupervisada de parches enmascarados, clasificación de imágenes y segmentación de imágenes (por-píxel o estilo EoMT [45]).

13.1. Embedding de Parches y Codificación Posicional

Embedding de Parches. La imagen de entrada $x \in \mathbb{R}^{H \times W \times C}$ se divide en $N = HW/P^2$ parches no solapados de $P \times P$, proyectados linealmente a D dimensiones mediante una `Conv2d` (Ec. 1 del paper ViT). La secuencia de entrada se construye como

$$z_0 = [x_{\text{class}}; x_p^1 E; \dots; x_p^N E] + E_{\text{pos}},$$

donde $E \in \mathbb{R}^{P^2 C \times D}$ es la matriz de proyección de parches y E_{pos} es la codificación posicional.

Codificación Posicional. Por defecto, se usa una `nn.Parameter` aprendible 1D de forma $(1, N + 1, D)$, fiel al paper ViT. La alternativa `none` confía en RoPE/HoPE dentro de los mezcladores de atención, delegando la codificación posicional a los componentes de atención reutilizables.

Token [CLS]. Un token aprendible opcional se antepone a la secuencia de parches para clasificación. La salida en la posición 0 alimenta la cabeza de clasificación.

13.2. Predicción de Parches Enmascarados (Autosupervisado)

El preentrenamiento autosupervisado sigue el esquema de enmascaramiento estilo BERT del Apéndice B.1.2 del paper ViT: se corrompe el 50 % de los parches, de los cuales el 80 % se reemplaza por un token de máscara, el 10 % por un parche aleatorio y el 10 % se mantiene sin cambios.

Se soportan tres objetivos de reconstrucción:

1. **Color medio de 3 bits:** cross-entropy sobre 512 clases (mejor desempeño reportado).
2. **Parche 4×4 submuestreado de 3 bits:** 16×512 cabeceras de cross-entropy.
3. **L2 de parche completo:** MSE sobre los píxeles crudos (estilo MAE [39]).

El modelo predice solo en las posiciones enmascaradas; la pérdida se calcula exclusivamente sobre los parches corrompidos, evitando que la reconstrucción trivial de parches no enmascarados domine la señal de aprendizaje.

13.3. Clasificación de Imágenes

Pooling. La representación de salida se obtiene del token [CLS] (posición 0) o mediante Global Average Pooling (GAP) sobre todos los parches.

Cabeza. Una capa lineal $\text{Linear}(D, K)$ inicializada en cero, siguiendo ViT Sec. 3.2, para fine-tuning estable sobre las clases K .

Pérdida. Cross-entropy estándar sobre las K clases.

13.4. Segmentación de Imágenes

Dos tipos de cabeza, seleccionados por el campo de esquema `seg_head_type`:

13.4.1. Cabeza Por-Pixel (pixel)

Cada token de parche se proyecta a `num_seg_classes` canales mediante una $\text{Linear}(D, \text{num_seg_classes})$, se redimensiona a $(H/P, W/P)$ y luego un upsampler de convoluciones transpuestas estilo ViT-Det lo escala a la resolución completa (H, W) . La pérdida combina cross-entropy + Dice. Se soporta segmentación 1D en escala de grises (2 clases) y multicolor no solapada ($N + 1$ clases).

13.4.2. Encoder-only Mask Transformer (eomt)

Basado en EoMT [45]:

- El backbone se divide en L_1 (solo parches) + L_2 (parches + K consultas aprendibles).
- La MHSA dentro de los bloques L_2 procesa los cuatro cuadrantes de atención (parche↔parche, consulta↔consulta, consulta↔parche, parche↔consulta) en una sola operación.

- **Módulo de máscara:** logits de clase lineales + MLP de 3 capas para el embedding de máscara, producto punto con $\tilde{F}_4$ escalado.
- **Pérdida:** BCE ($\times 5$) + Dice ($\times 5$) + CE ($\times 2$) con emparejamiento húngaro.
- **Recocido de máscara:** P_{mask} decae polinomialmente (factor 0,9) a 0 en inferencia, lo que revierte el modelo a un ViT plano, $4\times$ más rápido.

13.5. Reutilización de la Infraestructura Existente

Los 34 mezcladores de atención (excepto `engram_attn`, que requiere IDs de tokens), 6 normas, 4 residuales, 42 activaciones y 23 optimizadores se reutilizan sin cambios mediante `HybridLayer`, que es agnóstica de modalidad y opera sobre tensores de forma (B, S, D) .

Las tres tareas de visión leen `batch_size`, `num_epochs`, `optimizer`, `scheduler_type`, `grad_clip_max_norm` y el checkpointing del mismo bloque `training`: top-level que `mlm` y `causal_lm`. El sub-bloque opcional `training.<task>`: solo contiene parámetros específicos de tarea: `label_smoothing` para clasificación, y `seg_loss_bce_weight` / `seg_loss_dice_weight` / `seg_loss_ce_weight` / `mask_annealing_factor` para segmentación EoMT.

La clase `FrankensteinViT` refleja el patrón envoltorio de `FrankensteinDecoder`: posee un `PatchEmbed` + una pila de `HybridLayer` + una cabeza específica de tarea, y fuerza `mode='encoder'` en tiempo de ejecución.

13.6. Pseudocódigo en PyTorch

El siguiente pseudocódigo ilustra el paso forward para la tarea de clasificación:

```

1: Entrada: pixel_values  $\in \mathbb{R}^{B \times C \times H \times W}$ 
2:  $x \leftarrow \text{patch\_embed}(\text{pixel\_values})$  ▷  $(B, N, D)$ 
3:  $x \leftarrow [\text{cls\_token}]; x$  ▷ anteponer token [CLS]  $\rightarrow (B, N+1, D)$ 
4:  $x \leftarrow x + \text{pos\_embed}$  ▷ codificación posicional aprendible 1D
5:  $x \leftarrow \text{dropout}(x)$ 
6: for cada layer en layers do
7:    $x \leftarrow \text{layer}(x)$  ▷ HybridLayer agnóstica de modalidad
8: end for
9:  $x \leftarrow \text{final\_norm}(x)$ 
10: logits  $\leftarrow \text{head}(x[:, 0])$  ▷ token [CLS]
11: Salida: logits  $\in \mathbb{R}^{B \times K}$ 

```

14. Codificaciones Posicionales de Todo el Modelo

Este anexo documenta el subsistema unificado de codificación posicional (PE) que aplica una única elección de `model.positional_encoding` a todos los mezcladores de atención de la red. El contrato del esquema es:

`positional_encoding` $\in \{\text{rope, hope, nope, alibi, bam, pape, pape_efficient, pape_ri, sinusoidal_absorbed}\}$

La implementación reside en `src/model/embeddings/` y los ayudantes de inyección compartidos en `src/model/attention/common.py`. Las claves bibliográficas citadas aquí se resuelven contra `docs/bibliography/`.

14.1. Arquitectura: Un Módulo Compartido, Exclusión Por Mezclador

Un único módulo de PE se construye una vez en el codificador (`FrankensteinEncoder` o `FrankensteinViT`) mediante `build_pos_encoder(config)` y se inyecta en cada `HybridLayer`,

que lo reenvía a cada mezclador en `__init__(config, pos_encoder=None)` y `forward(..., pos_encoder=None)`.

Cada mezclador lleva una bandera `use_pe` por mezclador (`<mezclador>_attn_use_pe`, por defecto `True` para mezcladores de atención, `False` para mezcladores recurrentes/de decaimiento como `retnet`, `mamba`, `ode`, `gla_attn`, `deltanet_attn`, `mtla_attn` y los seis mezcladores Falcon `falcon{1,2,3,1a,2a,3a}_attn`). Cuando `use_pe` es `False`, el mezclador ignora completamente el módulo inyectado.

La PE se aplica en dos fases mediante los ayudantes compartidos `apply_pe_to_qk()` (llamado antes del cálculo de puntuaciones de atención) y `apply_pe_to_scores()` (llamado después). El ayudante despacha según el tipo de PE y se convierte en una operación nula cuando la bandera `use_pe` del mezclador es `False`.

14.2. Estilos de Inyección

Los 12 valores del enum se agrupan en cuatro estilos de inyección:

1. **Rotación** (`rope`, `hope`, `sinusoidal_rotary`): rota los tensores de consulta y clave antes del cálculo de puntuaciones. El producto interno $\mathbf{q}_i^\top \mathbf{k}_j$ se convierte en función del desplazamiento relativo $i - j$.
2. **Sesgo de puntuación** (`alibi`): añade un sesgo proporcional a la distancia a la matriz de puntuaciones de atención *después* de que se calcule.
3. **Aumentación de Q/K** (`pape`, `pape_efficient`, `pape_ri`): concatena dimensiones posicionales adicionales a los vectores de consulta y clave antes del producto punto, aumentando la dimensión efectiva de la cabeza.
4. **Aditivo a nivel de embedding** (`sinusoidal_absolute`, `learned_absolute`): se añade directamente a los embeddings de tokens antes de la primera capa; ninguna acción por mezclador se realiza en el bloque de atención.

`nope` y `none` son ambas operaciones nulas: `nope` desactiva explícitamente la codificación posicional (el modelo debe aprender la posición implícitamente), mientras que `none` es el módulo nulo devuelto por la fábrica cuando no se desea ninguna PE.

14.3. Formulaciones Matemáticas

14.3.1. RoPE — Codificación Posicional Rotatoria

RoPE [86] rota la consulta y clave de cada cabeza un ángulo proporcional al índice del token. Para dimensión de cabeza d_h y posición de token m , la matriz de rotación $\mathbf{R}_m \in \mathbb{R}^{d_h \times d_h}$ actúa sobre sub-espacios 2-D (x_{2i}, x_{2i+1}) :

$$\mathbf{R}_m = \text{diag} \left(\begin{bmatrix} \cos m\theta_0 & -\sin m\theta_0 \\ \sin m\theta_0 & \cos m\theta_0 \end{bmatrix}, \dots, \begin{bmatrix} \cos m\theta_{d_h/2-1} & -\sin m\theta_{d_h/2-1} \\ \sin m\theta_{d_h/2-1} & \cos m\theta_{d_h/2-1} \end{bmatrix} \right),$$

con frecuencias $\theta_i = \text{rope_base}^{-2i/d_h}$. La puntuación de atención se convierte en $\mathbf{q}_m^\top \mathbf{R}_{m-n} \mathbf{k}_n$, función del desplazamiento relativo $m-n$. Un factor `rope_scaling` s reescala la posición efectiva a m/s para modos de extrapolación de longitud.

14.3.2. HoPE — Codificación Posicional Rotatoria Hiperbólica

HoPE [18] generaliza RoPE a la geometría hiperbólica del modelo de Lorentz. En lugar de rotaciones euclidianas, HoPE aplica rotaciones de Lorentz construidas a partir de funciones hiperbólicas, imponiendo un *decaimiento monótono* de los pesos de atención con el aumento

de la distancia entre tokens — una propiedad que RoPE carece porque su patrón de atención oscilatorio puede re-surgir en rangos largos. RoPE se recupera como caso especial. Las perillas `hope_base` y `hope_damping` controlan la frecuencia hiperbólica y la tasa de decaimiento.

14.3.3. NoPE — Sin Codificación Posicional

NoPE [44] es la ausencia explícita de cualquier inyección posicional. El modelo debe descubrir la posición implícitamente a partir de la máscara causal (decodificador) o de los datos mismos. El trabajo citado muestra que NoPE supera a los métodos explícitos de PE (incluyendo RoPE y ALiBi) en benchmarks de generalización de longitud sin requerir cómputo adicional, porque un decodificador con atención causal puede codificar implícitamente la posición relativa a través de sus patrones de atención.

14.3.4. ALiBi — Atención con Sesgos Lineales

ALiBi [73] no modifica los embeddings ni los vectores de consulta/clave. En su lugar añade un sesgo lineal estático específico por cabeza a la matriz de puntuaciones de atención:

$$\text{puntuación}_{i,j}^{(h)} = \frac{\mathbf{q}_i^{(h)\top} \mathbf{k}_j^{(h)}}{\sqrt{d_h}} - m_h \cdot (i - j), \quad m_h = \frac{1}{2^{\lceil h/8 \rceil}},$$

donde m_h es una pendiente geométrica por cabeza h y el sesgo penaliza las claves distantes. La perilla `alibi_num_heads` controla el número de cabezas del calendario de pendientes. ALiBi habilita la extrapolación de longitud: un modelo entrenado en 1024 tokens generaliza a 2048 sin reentrenamiento.

14.3.5. BAM — Mecanismo de Atención Bayesiana

BAM [9] reformula la codificación posicional como un prior probabilístico sobre posiciones y unifica métodos existentes: NoPE corresponde a un prior Uniforme, ALiBi a un prior Uniforme×Laplace. La instanciación práctica, GGD-BAM, añade una matriz de sesgo de posición relativa con Gaussiana Generalizada $\mathbf{B}$ a los logits de atención, exactamente como ALiBi pero con una forma no lineal y aprendible:

$$B_{i,j}^{(h)} = -(|j - \alpha_h i - \mu_h| + \varepsilon)^{\beta_h}, \quad \alpha_h = e^{-\theta_\beta^{(h)} \theta_\alpha^{(h)}} \geq 0,$$

con parámetros aprendibles por cabeza $\theta_\alpha, \theta_\beta$ (init `bam_theta_init`=0, el prior Uniforme) y localización opcional θ_μ (fijado a 0 por defecto vía `bam_learn_mu=false`). El piso ε (`bam_eps`, por defecto 10^{-5}) estabiliza la exponenciación cuando $\beta < 0$, un régimen relajado que suprime el contexto local y actúa como “cabeza de recuperación” de largo alcance. Casos especiales: $\beta = 1, \mu = 0$ recupera ALiBi; $\beta = 2$ da un prior Normal; $0 < \beta < 1$ produce colas más pesadas que Laplace. El paper aparea BAM con Scalable Softmax (SSMax), un reescalado transversal de logits $s \cdot \ln(n)$ (con s aprendible por cabeza) que contrarresta el “attention fading” y es componible con cualquier PE vía la bandera `use_ssmax` de nivel superior. BAM SSMax logra recuperación precisa de información a $500\times$ la longitud de contexto de entrenamiento.

14.3.6. PaPE — Codificación Posicional Parabólica

PaPE [67] es una codificación centrada en visión que aumenta la consulta y clave con dimensiones posicionales extra construidas a partir de funciones base parabólicas. Dados P parábolas (`pape_num_parabolas`) y S posiciones (`pape_num_positions`), la característica posicional para la coordenada $\mathbf{p} \in \mathbb{R}^D$ es

$$\phi_k(\mathbf{p}) = \sum_{j=1}^S \alpha_{k,j} f_j(\mathbf{p}), \quad f_j(\mathbf{p}) = -\|\mathbf{p} - \mathbf{c}_j\|^2 + b_j,$$

una suma de S paraboloides centrados en $\mathbf{c}_j$ con desplazamiento b_j . Las $P \cdot S$ dimensiones extra se concatenan a la consulta y clave antes del producto punto, por lo que la dimensión efectiva de la cabeza crece de d_h a $d_h + P \cdot S$. Se proveen tres variantes:

- **pape** — la implementación de referencia.
- **pape_efficient** — una reformulación en PyTorch puro que evita kernels Triton personalizados preservando la misma matemática.
- **pape_r1** — la variante invariante a rotación (PaPE-RI en el paper), que satisface invariancia rotacional por construcción y se controla con **pape_rotation_invariant**.

PaPE está diseñado para tokens de visión n -D (imágenes, video, cámaras de eventos, nubes de puntos) y es la PE recomendada para la ruta ViT.

14.3.7. Sinusoidal Absoluta

La codificación absoluta original del Transformer [92] añade un vector sinusoidal fijo al embedding del token:

$$\text{PE}_{(m,2i)} = \sin\left(\frac{m}{\text{sinusoidal_base}^{2i/d}}\right), \quad \text{PE}_{(m,2i+1)} = \cos\left(\frac{m}{\text{sinusoidal_base}^{2i/d}}\right),$$

con **sinusoidal_max_len** limitando la tabla precomputada y **sinusoidal_scale** multiplicando el embedding. Esta es una PE aditiva: se aplica una vez a nivel de embedding y los mezcladores no aplican ninguna PE por capa.

14.3.8. Sinusoidal Rotatoria

Una variante rotatoria de la codificación sinusoidal: las mismas frecuencias sinusoidales se usan para construir una matriz de rotación aplicada a la consulta y clave (como en RoPE), pero con las perillas **sinusoidal_base** y **sinusoidal_scale**. Esta es una PE de estilo rotacional aplicada por capa mediante **apply_pe_to_qk**.

14.3.9. Absoluta Aprendida

Una codificación absoluta aprendible: una matriz de parámetros de **learned_max_len** $\times$ d se añade a los embeddings de tokens a nivel de embedding. La desviación estándar de inicialización se controla con **learned_init_std**. Al igual que la sinusoidal absoluta, los mezcladores no realizan ninguna acción por capa.

14.4. Banderas use_pe Por Mezclador

Cada mezclador expone un campo de configuración **<mezclador>_attn_use_pe** (p. ej. **standard_attn_use_pe**, **titan_attn_use_pe**). Los valores por defecto son:

- **True** (mezcladores de atención): **standard_attn**, **titan_attn**, **sigmoid_attn**, **gated_softmax_attn**, **gqa_attn**, todos los mezcladores latentes (**m1a_attn**, **gqla_attn**, **mlra_attn**, **tucker_attn**, **iha_attn**, **gta_attn**, **cca_attn**, **ccgqa_attn**, **gma_attn**), todos los mezcladores dispersos (**longformer_attn**, **bigbird_attn**, **sparse_transformer_attn**, **sparsek_attn**, **nsa_attn**, **msa_attn**, **sparda_attn**, **fasa_attn**, **sparge_attn**), y **engram_attn**.
- **False** (mezcladores recurrentes/de decaimiento): **retnet**, **retnet_attn**, **mamba**, **ode**, **gla_attn**, **deltanet_attn**, **gated_deltanet_attn**, **gated_deltanet2_attn**, **hgrn2_attn**, **fox_attn**, **kda_attn**, **mtla_attn**.

El valor por defecto `False` para mezcladores recurrentes/de decaimiento refleja que estas arquitecturas incorporan su propio sesgo inductivo temporal/posicional en su recurrencia (p. ej. la rotación compleja de RetNet, el barrido selectivo de Mamba). Sobrescribir `use_pe=True` está permitido pero es típicamente redundante.

14.5. Unificación del Transformer de Visión

La ruta ViT (FrankensteinViT) usaba previamente su propio campo `pos_embedding_type` con valores `learned_1d`, `none`. Esto se ha unificado con el enum de todo el modelo: `learned_1d` se migra a `learned_absolute`, y `none` se mapea a `none`. El ViT construye el mismo módulo `build_pos_encoder(config)` y lo inyecta en sus HybridLayers, por lo que un ViT ahora puede usar RoPE, HoPE, ALiBi, PaPE, o cualquier otra PE del enum.

14.6. Compatibilidad con Legado

La bandera booleana legada `use_hope` está deprecada y mapeada al nuevo enum: `use_hope=True` $\rightarrow$ `positional_encoding=hope`, `use_hope=False` $\rightarrow$ `positional_encoding=rope`. La sobrescritura `positional_encoding` por mezclador que previamente existía solo en `titan_attn` es ahora una operación nula: el enum de todo el modelo es la única fuente de verdad, y la lista de permitidos de TitanAttention que restringía PE a `{hope, rope, none, nope}` se ha eliminado — los 12 valores ahora funcionan con cada mezclador.

14.7. Perfil Arquitectónico: Codificaciones Posicionales

La Tabla 16 resume las 12 codificaciones posicionales soportadas.

Nombre	Estilo	Idea Clave	Parámetros	Referencia
rope	Rotación	Rotación basada en frecuencia de Q/K; posición relativa mediante geometría de producto interno	<code>rope_base</code> , <code>rope_scaling</code>	[86]
hope	Rotación	Rotación de Lorentz hiperbólica; decaimiento monótono de atención con distancia	<code>hope_base</code> , <code>hope_damping</code>	[18]
nope	Ninguno	Sin PE explícita; el modelo aprende posición implícitamente de la máscara causal	—	[44]
alibi	Sesgo de puntuación	Penalización lineal estática de distancia añadida a puntuaciones de atención; extrapolación de longitud	<code>alibi_num_heads</code>	[73]
bam	Sesgo de puntuación	Sesgo de posición relativa con Gaussiana Generalizada; forma (β) y escala (α) aprendibles por cabeza; recupera ALiBi en $\beta = 1$; reescalado SSMax vía <code>use_ssm</code>	<code>bam_theta_init</code> , [9] <code>bam_learn_mu</code> , <code>bam_eps</code> , <code>use_ssm</code> , <code>ssmax_s_init</code>	
pape	Aum. Q/K	Funciones base parabólicas concatenadas a Q/K; centrada en visión, n -D	<code>pape_num_parabolas</code> , <code>pape_num_posiciones</code>	[55]
pape_efficient	Aum. Q/K	PaPE en PyTorch puro; sin kernels Triton personalizados	igual que <code>pape</code>	[67]
pape_ri	Aum. Q/K	PaPE invariante a rotación (PaPE-RI)	<code>pape_rotation_invariant</code>	[67]
sinusoidal_absolute	Aditivo	Sinusoidal fijo añadido a embeddings (Transformer original)	<code>sinusoidal_base</code> [92] <code>sinusoidal_max_len</code> , <code>sinusoidal_scale</code>	

continúa en la siguiente página

Nombre	Estilo	Idea Clave	Parámetros	Referencia
sinusoidal_rotary	Rotación	Frecuencias sinusoidales como matriz de rotación en Q/K	igual que sinusoidal	[92]
learned_absolute	Aditivo	Matriz de parámetros aprendible añadida a embeddings	<code>learned_max_len</code> <code>learned_init_std</code>	[92]
none	Ninguno	Módulo nulo; ninguna información posicional inyectada	—	—

Cuadro 16: Catálogo de codificaciones posicionales. “Estilo” es el mecanismo de inyección (rotación, sesgo de puntuación, aumentación de Q/K, aditivo). “Parámetros” lista las perillas principales de configuración.

15. SSOG: Atención Separable Sum of Gaussians

Este anexo cubre SSOG (Separable Sum of Gaussians), un mixer de atención de campo geométrico. SSOG [71] reemplaza la interacción puntuada por contenido de la atención de producto escalado por una mezcla aprendida de Gaussianas sobre *posición relativa*: cada cabeza posee un puñado de átomos Gaussianos—cinco números por átomo, un desplazamiento de centro (μ_y, μ_x) , un ancho por eje (σ_y, σ_x) y un peso de mezcla λ —que forman un campo fijo sobre el desplazamiento entre tokens. No hay productos punto consulta-clave en ninguna parte: el contenido nunca puntúa al contenido, solo *dirige* el campo mediante residuos pequeños y acotados.

Dado que una Gaussiana 2D se factoriza en un producto de dos Gaussianas 1D, aplicar el campo son dos pasadas de filtro 1D por átomo (filas y luego columnas de un raster de tokens de $\sqrt{N} \times \sqrt{N}$) seguidas de una contracción de mezcla λ . La matriz de atención $N \times N$ inducida nunca existe, por lo que el costo específico de atención es $\mathcal{O}(R \cdot N\sqrt{N} \cdot d)$ para R átomos en lugar de $\mathcal{O}(N^2 \cdot d)$. SSOG también omite por completo las proyecciones de consulta y clave, pagando $2d^2$ de proyecciones por capa en lugar de los $4d^2$ de SDPA. En la receta de referencia, el mecanismo completo supera a su gemelo SDPA igualado en ImageNet-1k (65,28 % vs 64,34 % con $\sim 3M$ de parámetros; 72,02 % vs 71,84 % con $\sim 12M$) siendo $\sim 20\%$ más pequeño y $\sim 30\%$ más barato por pasada, y por +17 puntos en CIFAR-100 con receta igualada.

15.1. Formulación Matemática

Sea el raster row-major de una rejilla $G_h \times G_w$ los tokens. El peso de atención del token p al token q es el log-sum-exp con softmax y temperatura de los log-pesos de los átomos evaluados en su desplazamiento:

$$A(p, q) = \text{softmax}_q \left(\frac{1}{\tau} s(p, q) \right), \quad s(p, q) = \text{logsumexp}_r \left(\log \lambda_r + \log \mathcal{N}(p - q; \mu_r, \sigma_r) \right),$$

donde τ es una temperatura aprendible y $\mathcal{N}(\cdot; \mu_r, \sigma_r)$ es una Gaussiana 2D con covarianza diagonal. Como la Gaussiana 2D se factoriza, el campo con softmax se aplica de forma separable: por eje, $a_y[i, j] = \text{softmax}_j(\log \mathcal{N}(\Delta y_{ij}; \mu_y, \sigma_y)/\tau)$ y análogamente a_x , seguido de

$$Y = \sum_{r=1}^R \lambda_r \left(a_x^{(r)} (a_y^{(r)} V) \right), \quad V = x W_V,$$

es decir, tres contracciones einsum por capa. Con direccionamiento por contenido (`lookat`) habilitado, sondas lineales inicializadas en cero predicen residuos por token acotados sobre los parámetros del campo detrás de compuertas softplus de arranque en frío:

$$\mu \leftarrow \mu_0 + s_\mu \cdot m \cdot \tanh(W_\mu x), \quad \sigma \leftarrow \sigma_0 e^{s_\sigma \tanh(W_\sigma x)}, \quad \lambda \leftarrow \text{softmax} \left(\log \lambda_0 + s_\lambda \tanh(W_\lambda x) \right),$$

con m el desplazamiento máximo en celdas de rejilla y escalas de compuerta $s_\bullet = \text{softplus}(\cdot)$ inicializadas en -8 ($\approx 3 \times 10^{-4}$), de modo que el modelo comienza como un campo geométrico congelado y aprende cuánto abrir cada toma de contenido. Los anchos se reparametrizan como $\sigma = \text{softplus}(\omega) + \epsilon + \sigma_{\text{piso}}$ para mantenerse estrictamente positivos.

15.2. Pseudocódigo Algorítmico

- 1: **Entrada:** estado oculto $x \in \mathbb{R}^{B \times N \times d}$ como raster $G_h \times G_w$, átomos $\{\mu_r, \omega_r, \log \lambda_r\}_{r=1}^R$ por cabeza, temperatura τ
- 2: $V \leftarrow xW_V$ reorganizado a (B, G_h, G_w, H, d_h) ▷ sin proyecciones Q/K
- 3: $\sigma_r \leftarrow \text{softplus}(\omega_r) + \epsilon + \sigma_{\text{piso}}$ ▷ anchos positivos
- 4: **if** direccionamiento (lookat) **then**
- 5: $\mu, \sigma, \lambda \leftarrow$ residuos por token acotados vía sondas init-cero y compuertas ▷ el contenido dirige
- 6: **end if**
- 7: $a_y \leftarrow \text{softmax}(\log \mathcal{N}(\Delta y; \mu_y, \sigma_y)/\tau)$, $a_x \leftarrow$ análogamente ▷ kernels 1D, uno por átomo
- 8: $Y \leftarrow \sum_r \lambda_r a_x^{(r)} (a_y^{(r)} V)$ ▷ pasada filas, pasada columnas, mezcla λ : sin $N \times N$
- 9: **Salida:** YW_O reorganizado a (B, N, d)

15.3. Características Clave

- **Complejidad de entrenamiento:** $\mathcal{O}(R \cdot N \sqrt{N} \cdot d)$ para R átomos fijos—casi lineal solo por geometría, no por aproximación de kernels.
- **Complejidad de inferencia:** mismo costo por pasada; solo encoder (el campo separable no tiene formulación causal), por lo que no hay semánticas de caché KV.
- **Entrenable:** los átomos $\{\mu, \omega, \log \lambda\}$, la temperatura y las sondas de direccionamiento son completamente diferenciables; las compuertas de arranque en frío se abren durante la optimización.
- **Fortalezas:** prior geométrico fuerte (+17 pts sobre SDPA en datos pequeños con receta igualada; supera a SDPA en ImageNet-1k con 3M y 12M parámetros con $\sim 20\%$ menos parámetros y $\sim 30\%$ menos FLOPs); interpretable por diseño (cada cabeza son unos pocos blobs graficables—las capas tempranas se vuelven convoluciones encubiertas, las intermedias detectores de franjas, las tardes se vuelven globales); el campo vive en coordenadas, lo que otorga transferencia de resolución zero-shot.
- **Limitaciones:** solo encoder; requiere un raster row-major fijo $G_h \times G_w$ (ViT necesita `cls_token=false`; las secuencias necesitan una rejilla $1 \times L$ explícita); los kernels de direccionamiento por query añaden un término de memoria; los resultados en lenguaje no están probados—allí el puntaje por contenido probablemente es estructural.

16. Atención de Peso Rápido para Aprendizaje Continuo

Este anexo cubre la familia Falcon [110], un marco de atención de peso rápido que trata la transición recurrente del estado de peso rápido como una **regla de aprendizaje continuo en línea** bajo semántica autoregresiva de *lectura tras escritura* (read-after-write, RAW). La observación central del marco es de alineación temporal: para el objetivo de predicción de prefijo, el ejemplo local de memoria rápida revelado en el paso t es el **par prefix-alineado** $(x_t, y_t) = (\phi(k_{t-1}), v_t)$ — desplazado un paso respecto a la asociación de mismo paso $(\phi(k_t), v_t)$ usada por DeltaNet y la atención lineal estándar. La asociación de mismo paso sigue siendo causal, pero optimiza un objetivo interno diferente. El marco deriva **actualizaciones de primer orden normalizadas** para dos objetivos (regresión de error cuadrático y producto interno negativo) y tres estructuras de tamaño de paso (escalar, por columna, ventana deslizante), dando seis variantes: Falcon-1/2/3 (familia de regresión) y Falcon-1A/2A/3A (familia de producto interno). Las seis variantes están implementadas en el código bajo `model.attention.falcon` con un bloque de configuración compartido, cada una proporcionando tanto un escaneo recurrente de referencia como un kernel chunk-parallel estilo SSD.

16.1. Preliminares: Alineación, Normalización, Renormalización

Semántica de lectura tras escritura. Con mapas de características $\phi(k_t)$ (QK-RMSNorm por defecto), el flujo prefix-alineado fija $x_t = \phi(k_{t-1})$ para $t \geq 2$ con centinela de frontera $x_1 = 0$; la lectura es $o_t = S_t^\top \phi(q_t)$. La escritura en el paso t por tanto actualiza la memoria *antes* de que la consulta del paso $t+1$ la lea, de modo que ninguna clave se asocia jamás con su propio token.

Tamaños de paso normalizados. Un paso de gradiente sobre el objetivo local $\ell_t(S)$ con el denominador acoplado al objetivo da

$$\eta_t = \frac{\beta_t}{\text{estadístico}_t + \lambda_t + \varepsilon}, \quad \beta_t \in (0, 2),$$

donde el estadístico es la energía cuadrática de la clave $\|x_t\|^2$ (Falcon-1/1A/2/2A), el estadístico espectral de ventana $\mu_t^{(B)} = \lambda_{\max}(X^\top X)/B_t$ (Falcon-3), o la energía media de ventana $\bar{E}_t^{(B)}$ (Falcon-3A). La normalización acoplada al objetivo garantiza descenso por paso y elimina la sensibilidad a la escala de las tasas de aprendizaje fijas. La ganancia de **plasticidad** β_t , el ridge de **olvido** λ_t , la **alineación** temporal y la ventana de repetición B quedan así separados como cuatro perillas previamente entrelazadas.

Renormalización de decaimiento positivo. Cuando $\lambda_t > 0$, la contracción por paso $\alpha_t = \min(\eta_t \lambda_t, 1 - \varepsilon_\gamma)$ debe aplicarse de forma estable. La implementación fija α_t estrictamente por debajo de 1, calcula prefijos logarítmicos chunk-locales en fp32 vía $\log(1 - \alpha_t)$ y sumas acumuladas, reescala los generadores al dominio sin decaimiento ($\tilde{\eta}_t = \eta_t/\gamma_t$, $\tilde{v}_t = v_t/c_{t-1}$ con $c_{t-1} = \prod_{r \leq t-1} \gamma_r$) y reescala salidas y el estado emitido por el δ acumulado. Los centinelas de frontera son $(\alpha_1, \gamma_1) = (0, 1)$ y $\eta_1 = 0$, de modo que el primer paso es una lectura pura.

16.2. La Familia de Regresión (Falcon-1/2/3)

El objetivo de error cuadrático sobre el par desplazado es

$$\ell_t(S) = \frac{1}{2} \|v_t - S^\top x_t\|^2 + \frac{\lambda_t}{2} \|S\|_F^2, \quad \nabla_S \ell_t = x_t(S^\top x_t - v_t)^\top + \lambda_t S,$$

que es L_t -suave con $L_t = \|x_t\|^2 + \lambda_t$.

16.2.1. Falcon-1: Regresión NLMS Escalar

La variante escalar de la regla delta — la recursión NLMS clásica del filtrado adaptativo, mejorada con el flujo desplazado y un ridge explícito:

$$S_t = (1 - \eta_t \lambda_t) S_{t-1} + \eta_t x_t (v_t - S_{t-1}^\top x_t)^\top, \quad o_t = S_t^\top \phi(q_t).$$

Con $\varepsilon = 0$, $\lambda_t = 0$ y la asignación sin desplazar $x_t = \phi(k_t)$ esto recupera DeltaNet exactamente. La eigenestructura de la transición $A_t = \gamma_t I - \eta_t x_t x_t^\top$ (con $\gamma_t = 1 - \eta_t \lambda_t$) muestra que la dirección de escritura se contrae por $1 - \beta_t$ mientras el subespacio ortogonal lleva γ_t : $\beta_t > 1$ produce un cambio de signo estable a lo largo de la dirección de escritura, útil para seguimiento de estado. La forma chunk-parallel usa la representación WY $\prod_s (I - \eta_s x_s x_s^\top) = I - U T U^\top$ con una única solución triangular unitaria inferior de residuo simple $L = \text{tril}(G, -1) + I$ donde $G = X^\top X$ (Algoritmo 8 del artículo), tras la renormalización de decaimiento positivo.

16.2.2. Falcon-2: Regresión NLMS por Columnas

La pérdida ridge se descompone a lo largo de las coordenadas de valor, de modo que cada canal de valor j recibe su propio tamaño de paso compartiendo el normalizador NLMS:

$$\eta_{j,t} = \frac{\beta_{j,t}}{\|x_t\|^2 + \lambda_t + \varepsilon}, \quad S_t = S_{t-1}(I - \lambda_t \text{Diag}(\boldsymbol{\eta}_t)) + x_t(\boldsymbol{\eta}_t \odot \mathbf{r}_t)^\top.$$

El kernel chunk-parallel forma el Gram de claves compartido $G = X^\top X$ y resuelve el lote de sistemas triangulares unitarios inferiores por canal $L_j = I + \text{tril}(G \odot (\Sigma_j \Sigma_j^\top), -1)$ con $\Sigma = \sqrt{\tilde{\boldsymbol{\eta}}}$ (Algoritmo 1). Definida pero no evaluada por separado en el artículo.

16.2.3. Falcon-3: Regresión de Minilote con Ventana Deslizante

Repetición acotada (bounded rehearsal): cada paso regresa la memoria rápida sobre los últimos $B_t \leq B$ pares prefix-alineados, con *todos los residuos de ventana evaluados en el estado pre-actualización* S_{t-1} :

$$\mu_t = \frac{\lambda_{\max}(X_{\mathcal{I}_t}^\top X_{\mathcal{I}_t})}{B_t}, \quad \eta_t = \frac{\beta_t}{\mu_t + \lambda_t + \varepsilon}, \quad S_t = (1 - \eta_t \lambda_t) S_{t-1} + \frac{\eta_t}{B_t} \sum_{j \in \mathcal{I}_t} x_j (v_j - S_{t-1}^\top x_j)^\top,$$

con $\mathcal{I}_t = \{\text{máx}(2, t - B + 1), \dots, t\}$. El promediado por ventana mantiene la magnitud de la actualización invariante a B : cada par se repite en exactamente B actualizaciones consecutivas con peso $1/B$, por lo que su inyección acumulada es independiente de B . El estado por sí solo *no* es Markov: la continuación exacta requiere una cola FIFO de los últimos $B - 1$ pares, y los kernels chunk recogen una porción extendida con $|\mathcal{J}| \leq C + B - 1$. La forma chunk-parallel es una recurrencia afín de rango B resuelta por sustitución hacia adelante por bloques sobre el espacio de índices extendido (tiempo $\times$ rango), con componentes de rango del mismo tiempo desacoplados (Algoritmo 3).

16.3. La Familia de Producto Interno (Falcon-1A/2A/3A)

El objetivo de producto interno negativo

$$\ell_t^{\text{ip}}(S) = -\langle S^\top x_t, v_t \rangle + \frac{\lambda_t}{2} \|S\|_F^2 \quad \Rightarrow \quad \nabla_S \ell_t^{\text{ip}} = -x_t v_t^\top + \lambda_t S$$

produce escrituras puramente aditivas (hebbianas) con ganancias normalizadas por energía.

16.3.1. Falcon-1A y Falcon-2A

$$\text{Falcon-1A: } S_t = \gamma_t S_{t-1} + \eta_t x_t v_t^\top, \quad \gamma_t = 1 - \min(\eta_t \lambda_t, 1 - \varepsilon_\gamma); \quad \text{Falcon-2A: } S_t = S_{t-1} \text{Diag}(\boldsymbol{\gamma}_t) + x_t(\boldsymbol{\eta}_t \odot v_t)^\top$$

Con $\lambda_t = 0$ y la asignación sin desplazar esto es exactamente la atención lineal estándar / acumulación Mamba-2; el flujo desplazado lo convierte en la variante next-latent desplazada un paso. El denominador de la familia A no lo exige la curvatura (el objetivo es lineal) — conserva la escritura normalizada por energía como estabilizador de magnitud. La forma chunk-parallel es atención lineal con máscara de decaimiento $M_{t,i} = \eta_i \prod_{r=i+1}^t \gamma_r$ (máscaras por canal para Falcon-2A).

16.3.2. Falcon-3A: Producto Interno con Ventana Deslizante

La variante aditiva con ventana — la mejor configuración de extrapolación de longitud de la familia:

$$\bar{N}_t^{(B)} = \frac{1}{B_t} \sum_{j \in \mathcal{I}_t} x_j v_j^\top, \quad \bar{E}_t^{(B)} = \frac{1}{B_t} \sum_{j \in \mathcal{I}_t} \|x_j\|^2, \quad \eta_t = \frac{\beta_t}{\bar{E}_t^{(B)} + \lambda_t + \varepsilon}, \quad S_t = \gamma_t S_{t-1} + \eta_t \bar{N}_t^{(B)}.$$

La máscara de decaimiento con banda de ventana factoriza como $M = D \cdot \text{Diag}(\boldsymbol{\eta}) \cdot A$, donde A es el operador de ventana de banda B y D el kernel de decaimiento causal, evaluada sobre la porción extendida (Algoritmo 4).

16.4. Interfaz de Configuración

Las seis variantes comparten un bloque anidado, `model.attention.falcon`, seleccionado mediante las entradas de `layer_pattern` `falcon1_attn`, `falcon2_attn`, `falcon3_attn`, `falcon1a_attn`, `falcon2a_attn`, `falcon3a_attn`:

Clave	Por defecto	Descripción
<code>chunk_size</code>	64	Tamaño de chunk de los kernels <code>chunk-parallel</code> ; <code>null</code> selecciona el escaneo recurrente de referencia
<code>qk_norm</code>	<code>rms_norm</code>	Normalización QK (<code>rms_norm</code> o <code>l2_norm</code>); RMS-Norm calculado en fp32
<code>beta_mode</code>	<code>ctx_eta</code>	Parametrización de la compuerta de plasticidad: <code>static</code> , <code>ctx_beta</code> (ganancia condicionada al contenido) o <code>ctx_eta</code> (paso normalizado condicionado al contenido)
<code>lambda_mode</code>	<code>ctx</code>	Compuerta de olvido: <code>static</code> o <code>ctx</code> (acoplada en escala con el estadístico de curvatura desacoplado)
<code>beta / lambda</code>	1,0 / 0,0	Ganancia y ridge estáticas (usadas cuando el modo correspondiente es <code>static</code>)
<code>window</code>	4	Ventana deslizante B (solo Falcon-3 / Falcon-3A)
<code>short_conv / conv_kernel</code>	<code>true / 4</code>	Convoluciones cortas causales en profundidad sobre las proyecciones q/k/v
<code>eps / eps_gamma</code>	10^{-6} / 10^{-4}	Estabilizador del tamaño de paso y piso de fijación del decaimiento positivo

Cuadro 17: Perillas de configuración compartidas de Falcon (`model.attention.falcon`). Cada variante expone además un opt-out de codificación posicional por mezclador `falcon{1,2,3,1a,2a,3a}_attn_use_pe`, por defecto `False` como los demás mezcladores recurrentes/de decaimiento.

Notas de implementación: los kernels recurrente y `chunk-parallel` están verificados numéricamente equivalentes (`chunk` $\equiv$ recurrente a $\leq 3,6 \times 10^{-7}$ en las seis variantes, incluidas las rutas con decaimiento, multi-chunk y ventana); los gradientes fluyen a través de las islas de solución triangular en fp32 (los generadores de características toman solo $\sqrt{\eta}$ mientras los objetivos de valor toman $\sqrt{\eta} e^{-u_{t-1}}$, con la raíz cuadrada fijada en 10^{-12} para retropropagación sin NaN en la frontera $\eta = 0$); los exponentes positivos se fijan en 80.

16.5. Resultados Publicados

Modelo (124M, 49.2B tokens FineWeb-Edu)	WikiText ppl	LMB. ppl	FineEdu ppl	Prom. 0-shot
Transformer (RoPE)	33.25	47.43	17.38	48.16
Mamba-2	34.53	48.74	17.70	48.80
DeltaNet	34.19	52.84	17.84	48.88
Gated DeltaNet	30.99	46.70	17.32	48.78
Falcon-1A.3	34.02	49.84	17.40	48.95
Falcon-1.3	33.00	48.70	17.10	49.18

Cuadro 18: Resultados de modelado de lenguaje reportados por Zhang et al. [110] a 124M de parámetros. En extrapolación de longitud para sumas de dígitos variables (33–48 dígitos), Falcon-3A.3 alcanza **87.2 %** de precisión media frente a 65.8 % de un Transformer con RoPE y 85.9 % de Falcon-1A.3: la familia de producto interno lleva la aritmética, mientras que la familia de regresión lleva la perplejidad.

16.6. Relación con Trabajos Previos

- **DeltaNet**: la regla delta es el paso de descenso de gradiente del objetivo de error cuadrático con el emparejamiento de mismo paso; Falcon lo recupera con el cambio crítico de índice más normalización acoplada al objetivo y contracción λ_t explícita.
- **Gated DeltaNet**: añade una compuerta de arrastre aprendida libre; Falcon *deriva* el arrastre $\gamma_t = 1 - \eta_t \lambda_t$ del objetivo local y la parametrización de paso normalizada en lugar de añadir una compuerta independiente, y usa por defecto QK-RMSNorm en lugar de normalización ℓ_2 .
- **Atención lineal / Mamba-2**: el numerador aditivo es un paso de gradiente del objetivo de producto interno con la asignación sin desplazar; los kernels chunkwise reutilizan el esquema SSD.
- **TTT / Titans / ATLAS**: actualizaciones de peso rápido como entrenamiento en tiempo de prueba; Falcon-3 es una especialización de ventana deslizante de la vista de objetivo interno con alineación estricta next-latent.
- **Filtrado adaptativo (LMS/NLMS/RLS)**: Falcon importa los principios de estabilidad y normalización de NLMS a la atención de peso rápido bajo causalidad estricta.

16.6.1. Cuándo Usar Cada Variante

1. **Falcon-1**: la mejor perplejidad de modelado de lenguaje de la familia (FineEdu 17.10, superando a Gated DeltaNet 17.32); olvido principista ligado al objetivo local.
2. **Falcon-2**: plasticidad más fina que Falcon-1 al costo de kernels chunk por canal más pesados; sin evaluación en el artículo.
3. **Falcon-3**: horizonte de repetición controlado con estadísticos de ventana exactos; el kernel más complejo.
4. **Falcon-1A**: variante aditiva simple y estable; segunda mejor extrapolación de longitud (85.9 %).
5. **Falcon-2A**: granularidad de olvido por canal; sin evaluación.
6. **Falcon-3A**: la mejor extrapolación de longitud del artículo (87.2 % en sumas de 33–48 dígitos); carry de tareas aritméticas.