Atención densa: interacciones por pares completas, coste $O(n^2)$

Estándar
$\text{softmax}(QK^T/\sqrt{d})V$

Sigmoide
$\sigma(QK^T)V$

GQA
cabezas K, V compartidas

Continuum
$\int \exp(\gamma \cdot q^T k(t)/\sqrt{d}) \cdot v(t)\, dt / Z$

XSA
$Y - (Y \cdot \hat{v})\hat{v}$

MTA
convolución sobre (q,k,cabezas)
→ softmax → convolución →
group norm con compuerta