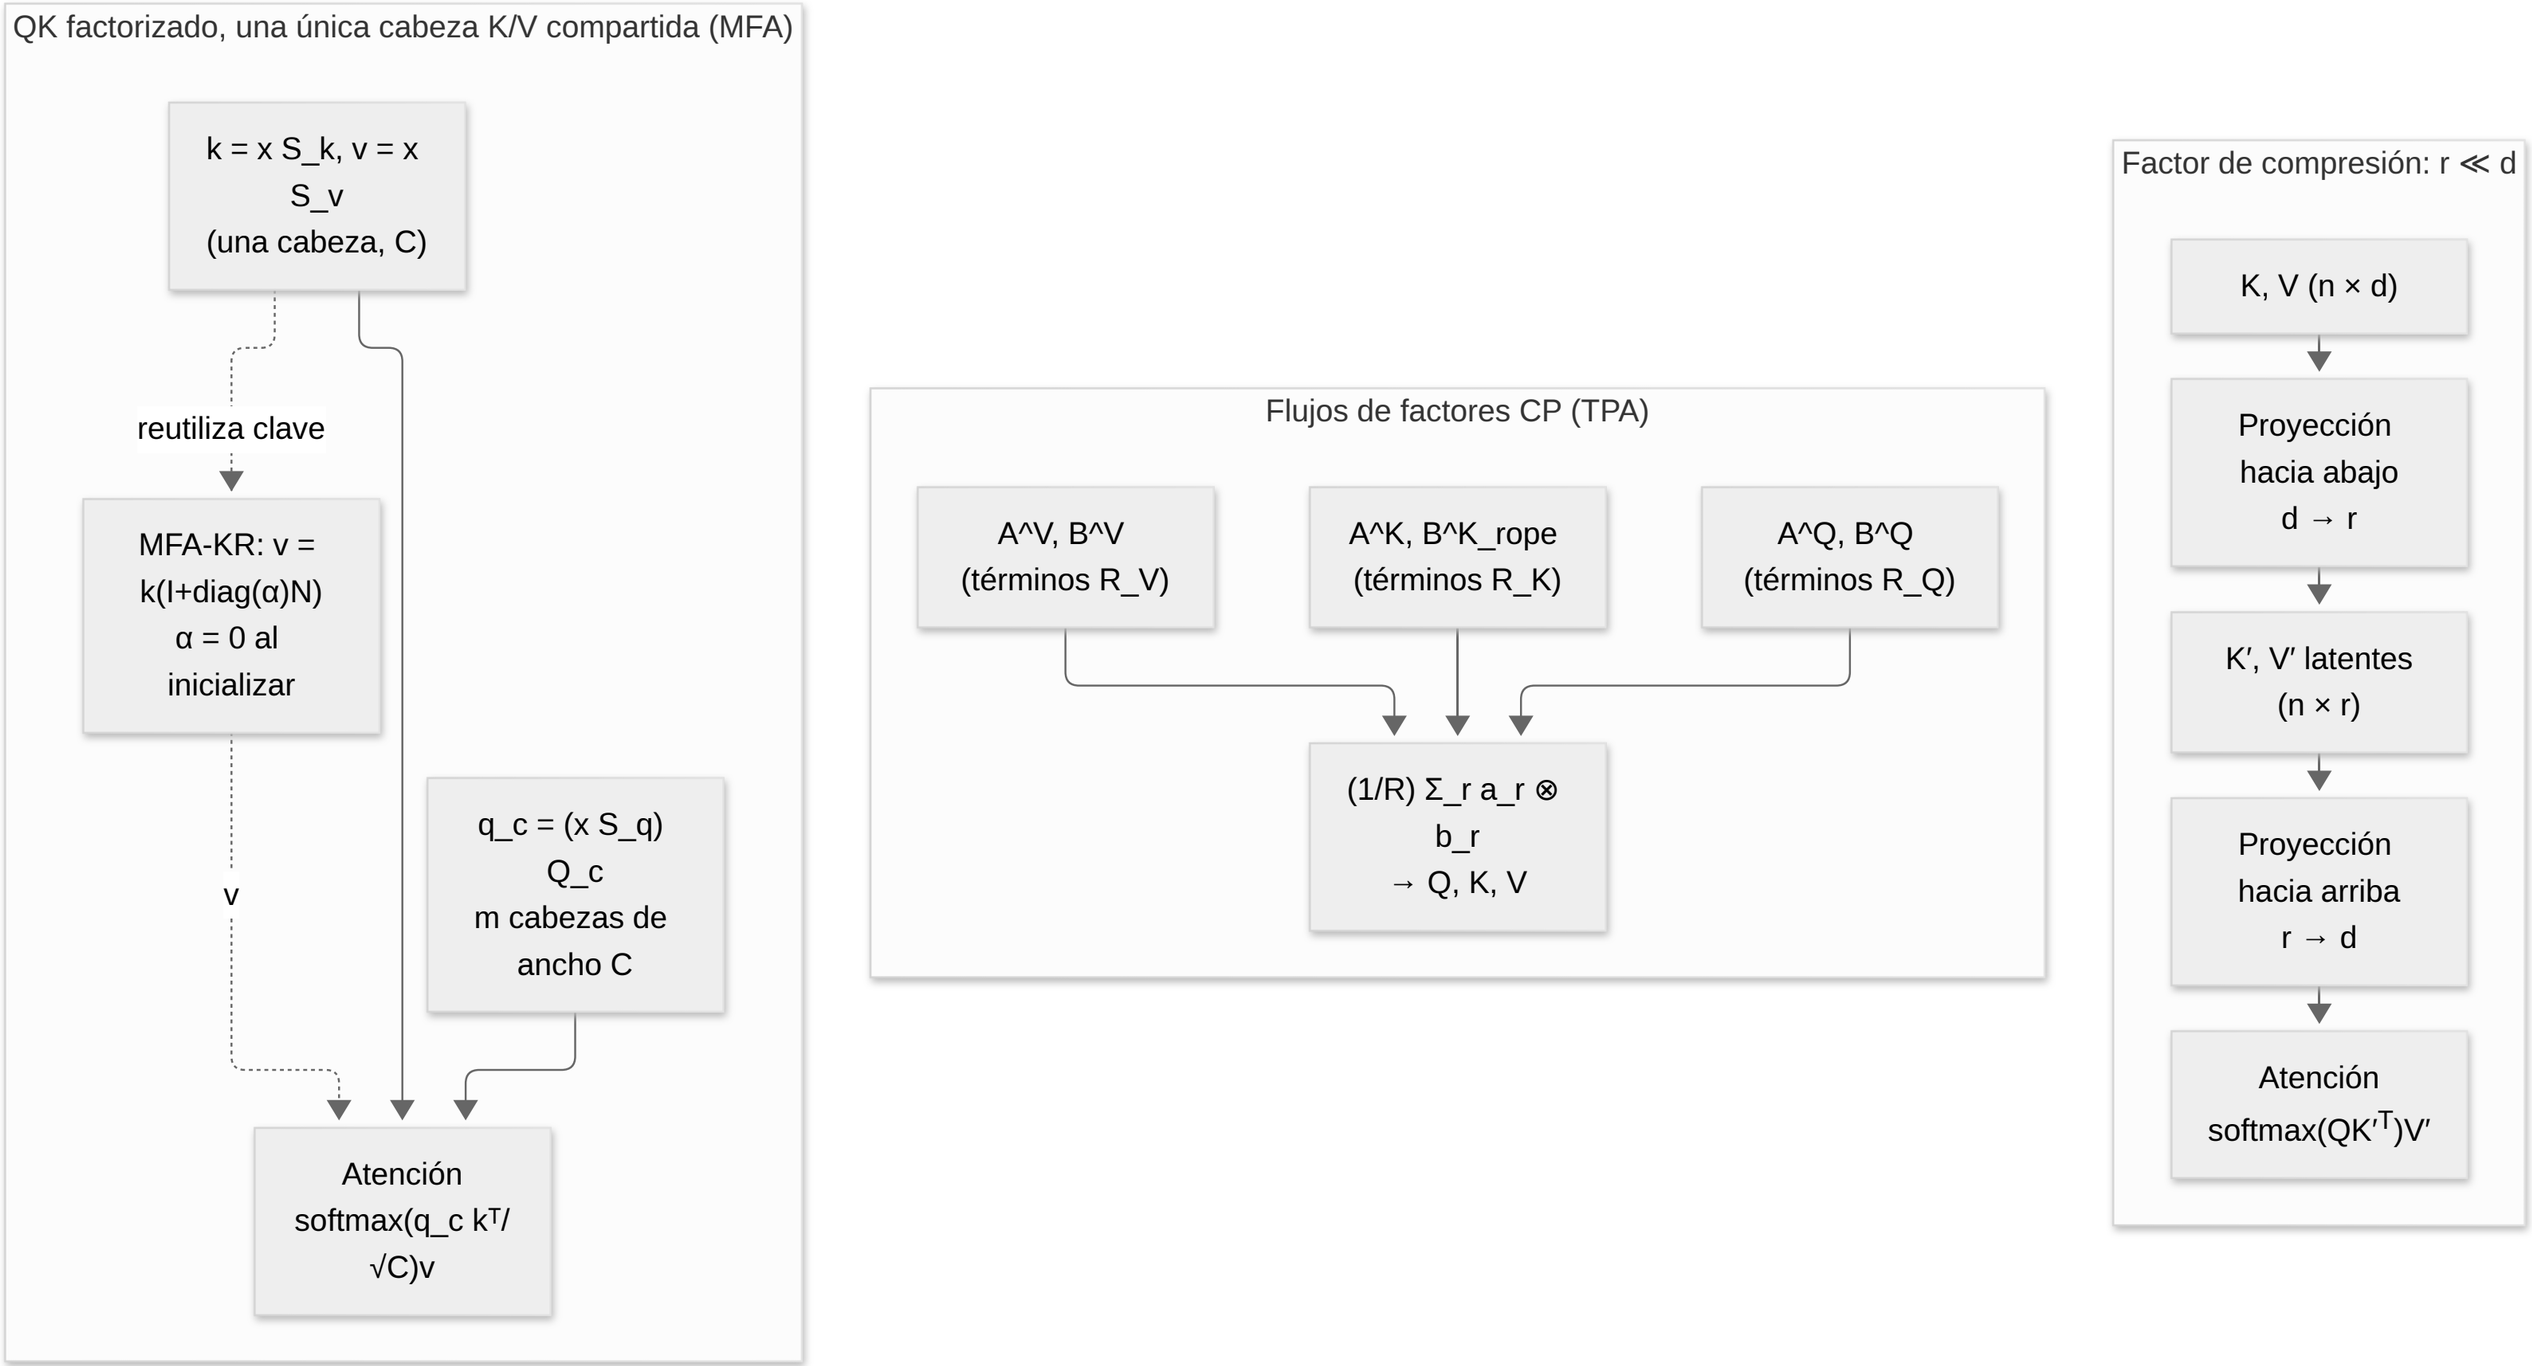

QK factorizado, una única cabeza K/V compartida (MFA)
k = x S_k, v = x S_v (una cabeza, C)
reutiliza clave
MFA-KR: v = k(I+diag(α)N) α = 0 al inicializar
v
q_c = (x S_q) Q_c m cabezas de ancho C
Atención softmax(q_c k^T/√C)v
Flujos de factores CP (TPA)
A^V, B^V (términos R_V)
A^K, B^K_rope (términos R_K)
A^Q, B^Q (términos R_Q)
(1/R) Σ_r a_r ⊗ b_r → Q, K, V
Factor de compresión: r ≪ d
K, V (n × d)
Proyección hacia abajo d → r
K′, V′ latentes (n × r)
Proyección hacia arriba r → d
Atención softmax(QK′^T)V′