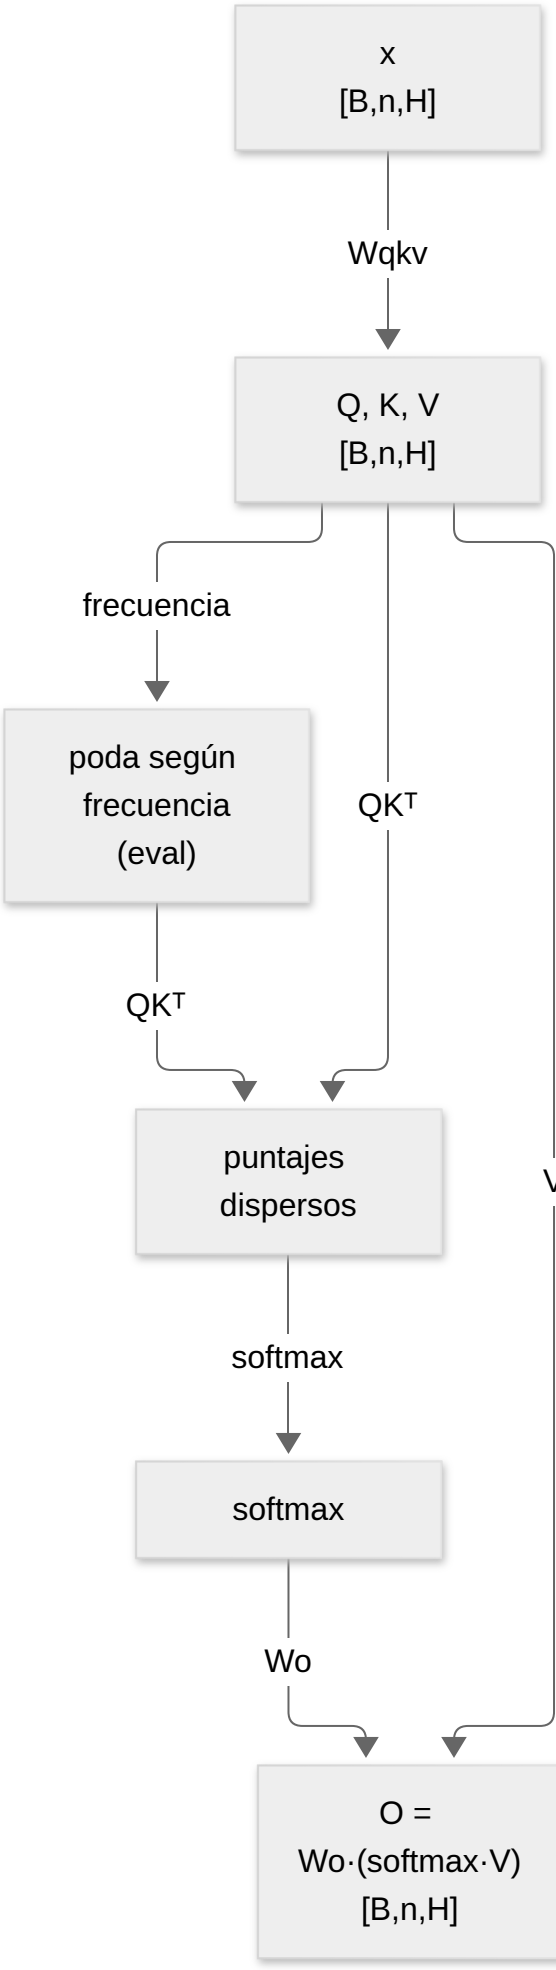

x
[B,n,H]
Wqkv
Q, K, V
[B,n,H]
frecuencia
poda según
frecuencia
(eval)
QKᵀ
QKᵀ
V
puntajes
dispersos
softmax
softmax
Wo
O =
Wo·(softmax·V)
[B,n,H]