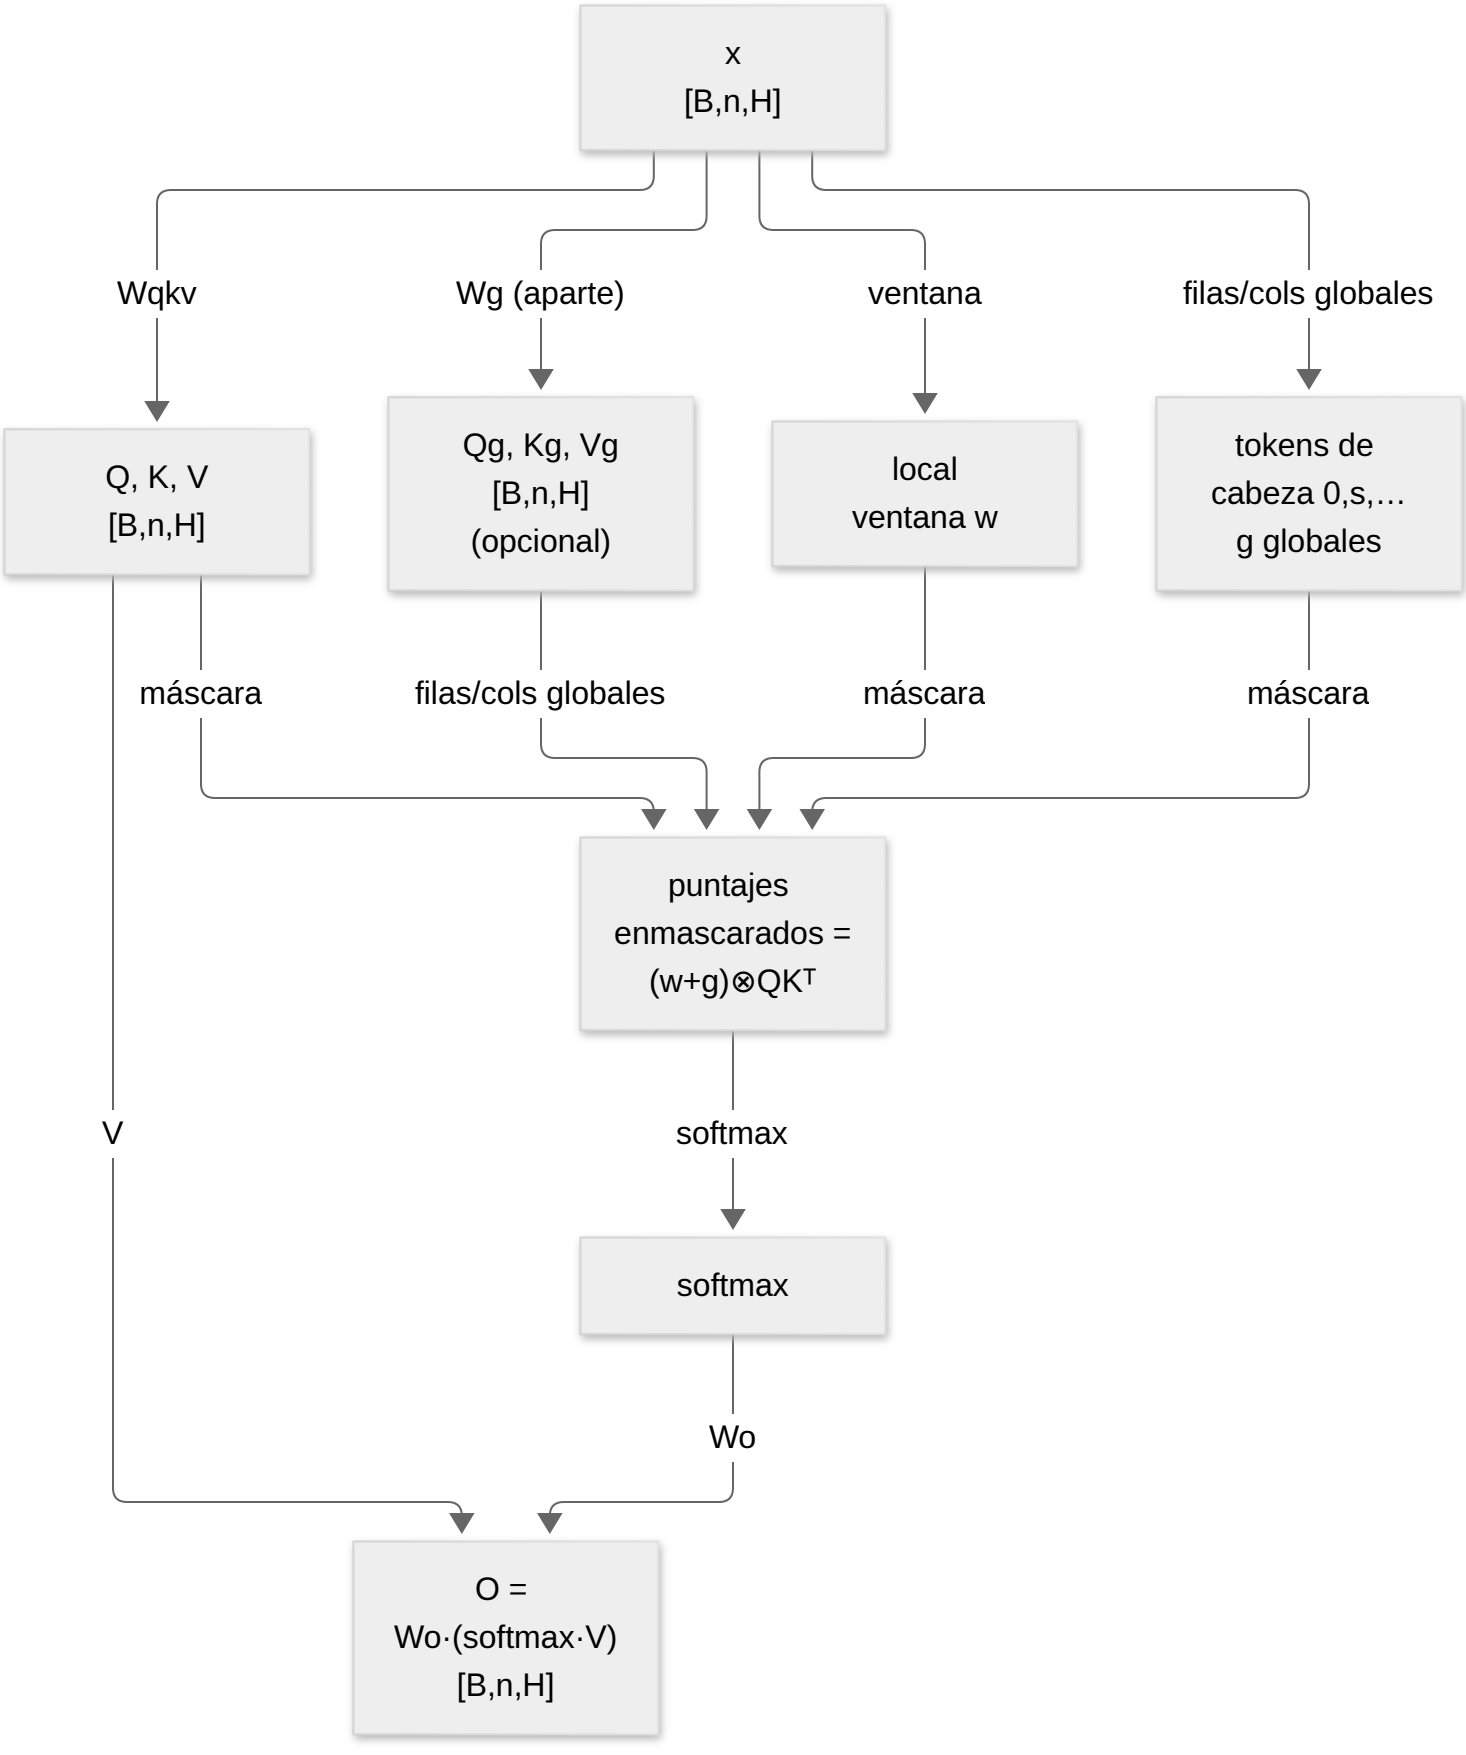

x
[B,n,H]
Wqkv
Wg (aparte)
ventana
filas/cols globales
Q, K, V
[B,n,H]
Qg, Kg, Vg
[B,n,H]
(opcional)
local
ventana w
tokens de
cabeza 0,s,…
g globales
máscara
filas/cols globales
máscara
máscara
puntajes
enmascarados =
(w+g)⊗QKᵀ
V
softmax
softmax
Wo
O =
Wo·(softmax·V)
[B,n,H]