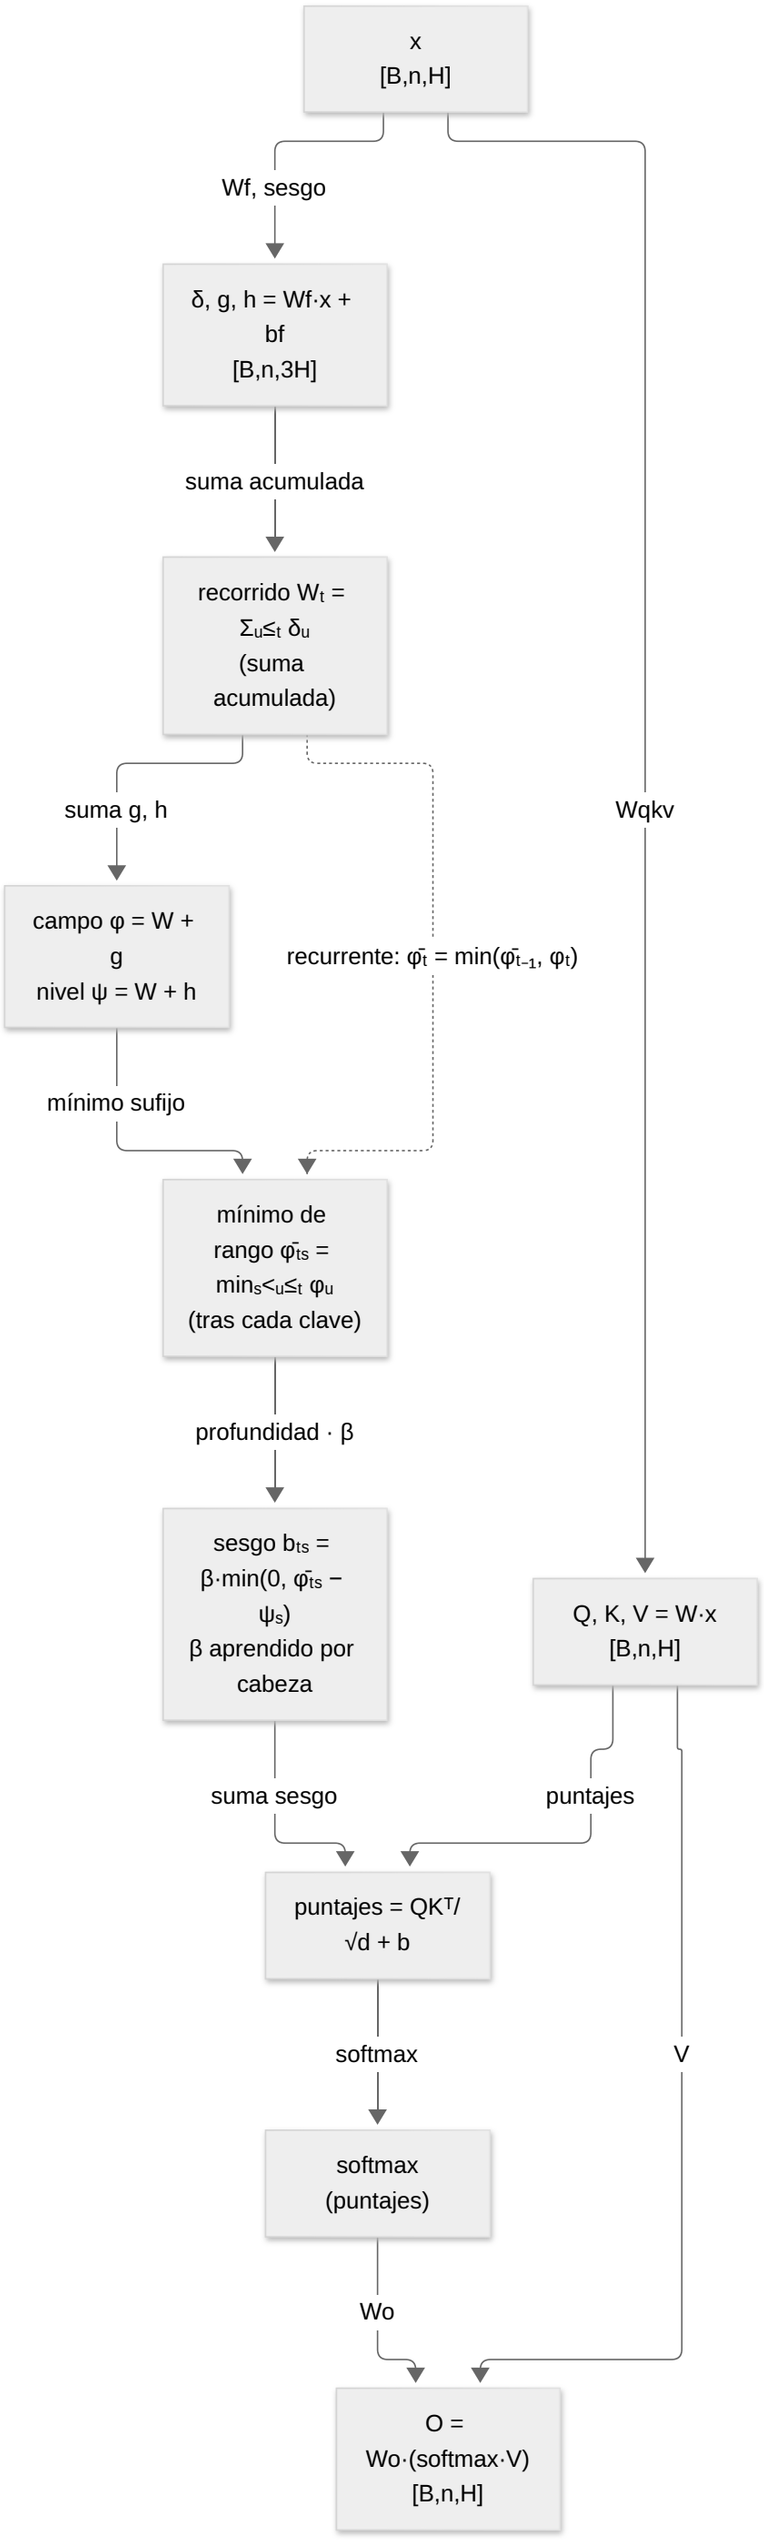

x
[B,n,H]
Wf, sesgo
δ, g, h = Wf·x + bf
[B,n,3H]
suma acumulada
recorrido W_t = $\Sigma_{u \le t}\ \delta_u$ (suma acumulada)
suma g, h
Wqkv
campo φ = W + g
nivel ψ = W + h
recurrente: $\bar{\varphi}_t = \min(\bar{\varphi}_{t-1}, \varphi_t)$
mínimo sufijo
mínimo de rango $\bar{\varphi}_{ts}$ = $\min_{s<u\le t}\ \varphi_u$ (tras cada clave)
profundidad · β
sesgo b_{ts} = β·min(0, $\bar{\varphi}_{ts}$ − ψ_s)
β aprendido por cabeza
Q, K, V = W·x
[B,n,H]
suma sesgo
puntajes
puntajes = $QK^T/\sqrt{d}$ + b
softmax
V
softmax (puntajes)
Wo
O = Wo·(softmax·V)
[B,n,H]