
x
[B,n,H]
Wqkv
Q, K, V
[B,n,H]
K̂, L2
agrupa claves
k_pool (4:1)
agrupa
cubetas de
Ward
c_b (Alg. 1)
K,V
max_h q̂·c_b
QKᵀ
top-p cubetas →
k claves de
largo alcance
expande
J = sumideros
∪ k
∪ ventana
QKᵀ
puntajes
dispersos
= QKᵀ sobre J
softmax
softmax
Wo
O =
Wo·(softmax·V)
[B,n,H]