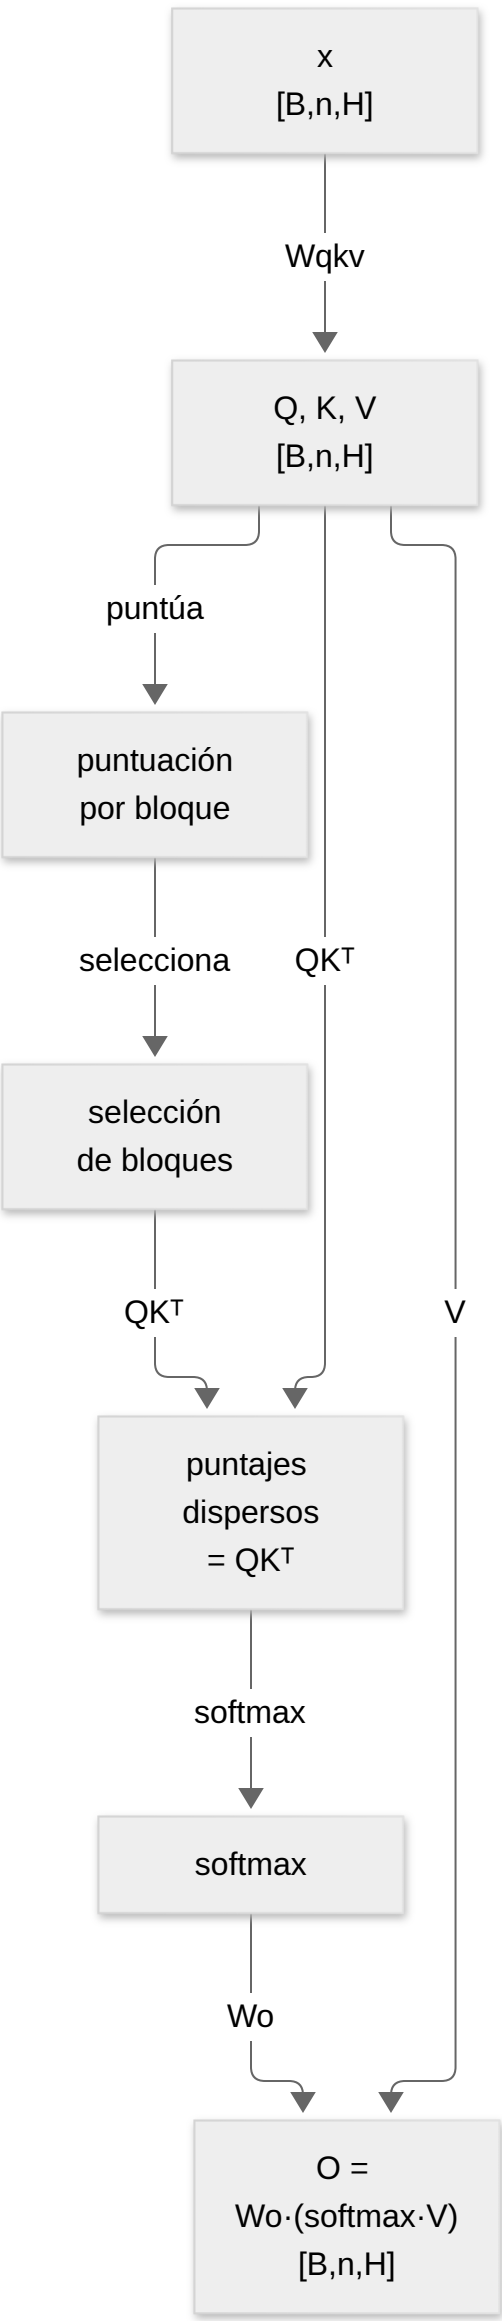

x
[B,n,H]
Wqkv
Q, K, V
[B,n,H]
puntúa
puntuación
por bloque
selecciona
QKᵀ
selección
de bloques
QKᵀ
V
puntajes
dispersos
= QKᵀ
softmax
softmax
Wo
O =
Wo·(softmax·V)
[B,n,H]