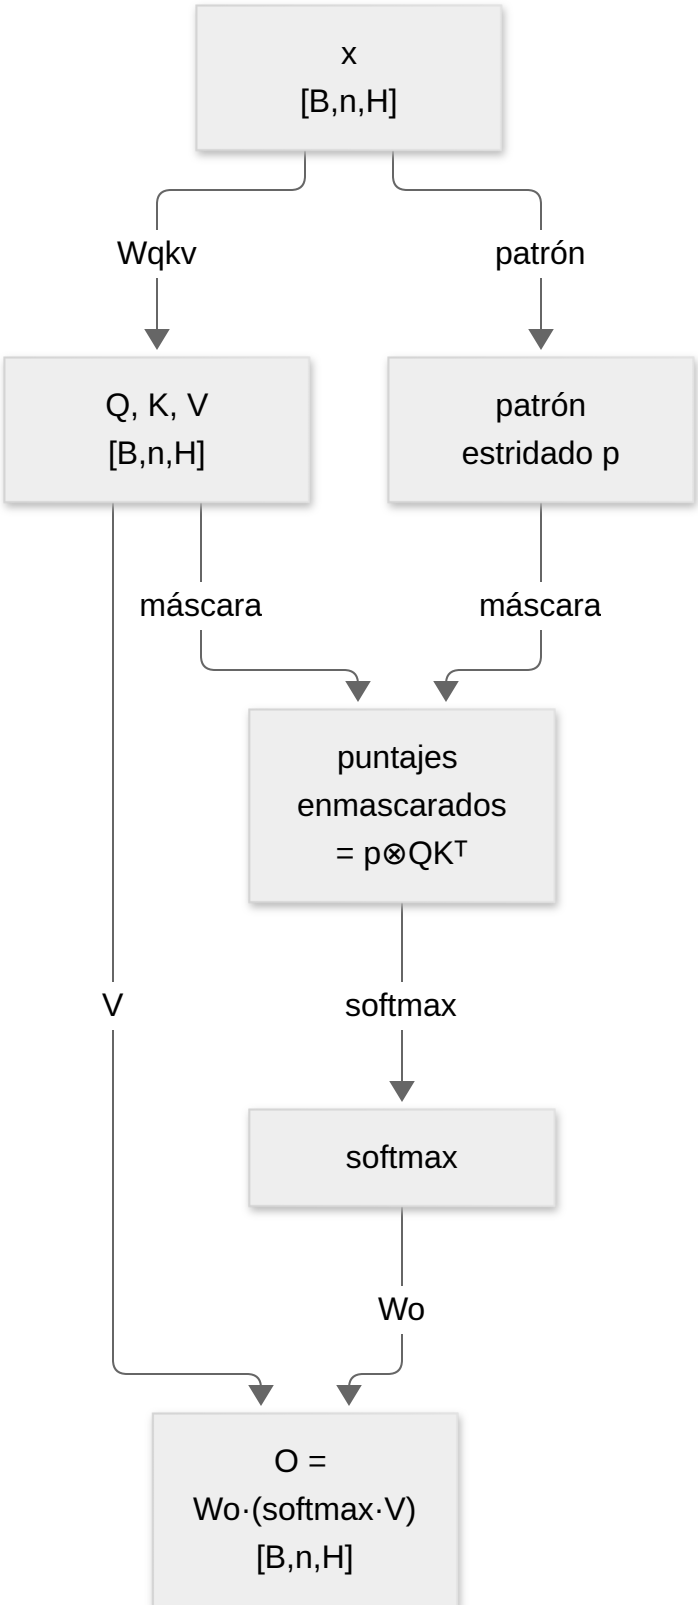

x
[B,n,H]
Wqkv
patrón
Q, K, V
[B,n,H]
patrón
estridado p
máscara
máscara
puntajes
enmascarados
= p⊗QK^T
V
softmax
softmax
Wo
O =
Wo·(softmax·V)
[B,n,H]