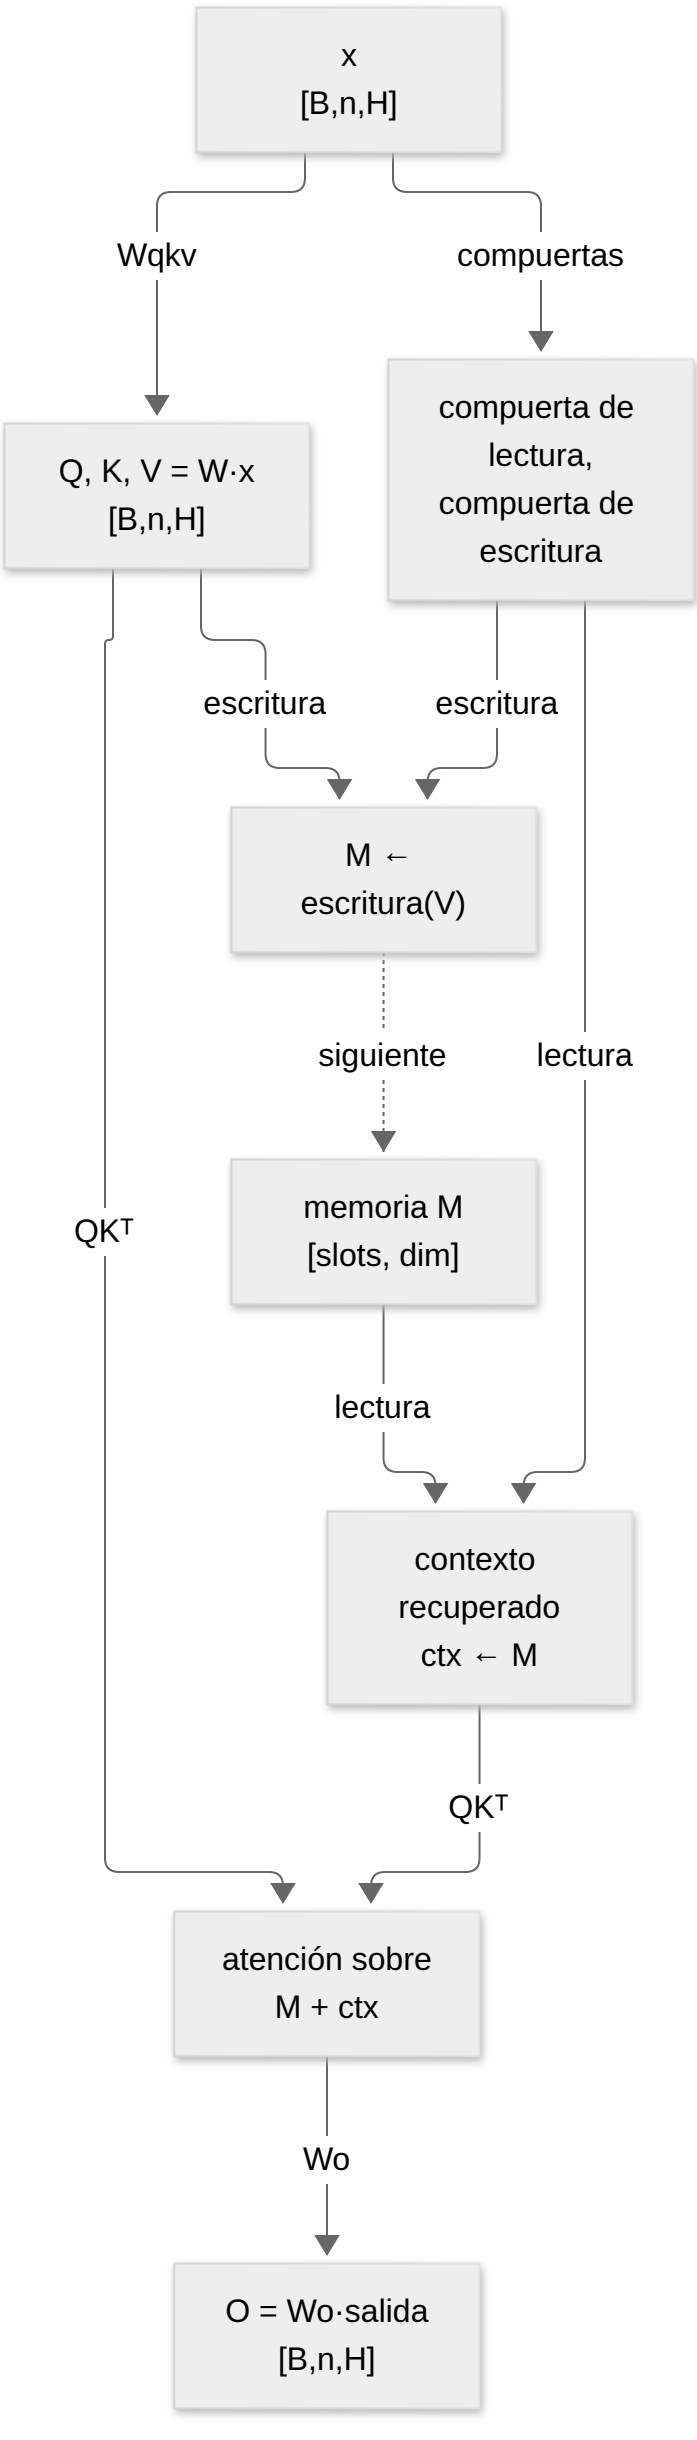

x
[B,n,H]
Wqkv
compuertas
Q, K, V = W·x
[B,n,H]
compuerta de lectura, compuerta de escritura
escritura
escritura
M ← escritura(V)
siguiente
lectura
memoria M
[slots, dim]
QKᵀ
lectura
contexto recuperado
ctx ← M
QKᵀ
atención sobre M + ctx
Wo
O = Wo·salida
[B,n,H]