lote de datos → pérdida L(θ)

retropropagación
gradiente g

todo optimizador
θ ← θ − η · u(g, estado)

¿recordar el pasado?
momentum · reducción de varianza

¿reescalar cada coordenada?
adaptativo · pasos por parámetro

¿usar curvatura o estructura matricial?
segundo orden · geométrico

¿estado demasiado grande?
eficiente en memoria · bajo rango

¿ajustar el schedule es penoso?
schedule-free · sin parámetros

¿paisaje demasiado irregular?
evolutivo · población